

基于支持向量机（SVM）的图像分类研究

copycat666
东北电力大学 计算机学院

摘要：本文研究了基于支持向量机（SVM）的图像分类方法。SVM 以其强大的分类性能和良好的泛化能力，在图像分类任务中展现出优势。文章介绍了 SVM 的基本原理，并阐述了具体的实验过程。实验部分采用公开数据集，利用灰度共生矩阵（GLDM）进行特征提取，最终在 Matlab R2024a 中进行训练与测试。结果显示 SVM 在分类准确率等方面表现较好。总之，基于 SVM 的图像分类方法是已经被验证的一种有效的解决方案。

关键词：支持向量机（SVM）；图像分类；特征提取；灰度共生矩阵（GLDM）；数据挖掘算法

1. 引言

随着信息技术的不断进步，图像分类作为计算机视觉领域的一项基础任务，日益受到学术界和工业界的广泛关注。支持向量机（SVM）作为一种经典的机器学习算法，以其出色的分类性能和良好的泛化能力，在图像分类领域展现出巨大潜力。本研究旨在探讨基于 SVM 的图像分类方法，通过优化特征提取和分类器设计，提高图像分类的准确性和效率，为图像分类技术的发展提供新的思路和方法。

2. 支持向量机的基本原理

支持向量机（Support Vector Machine, SVM）的基本思想是寻找一个最优的超平面（Hyperplane），使得训练集中的样本点尽可能地被正确地分类，并且分类间隔最大化。这里的“间隔”是指样本点到超平面的几何距离，而支持向量则是距离超平面最近的那些样本点。

2.1 线性可分问题

SVM 寻找超平面的过程就是找到合适的 (w, b) 使得在满足约束条件 $y_i[w^T x_i + b] \geq 1$ 的情况下使得支持向量 x 到超平面的距离 $r = \frac{|w^T x + b|}{\|w\|}$ 最大，即 $\|w\|$ 最小。即在所有支持向量都比非支持向量离超平面更近的条件下，找到合适的 (w, b) 使得各支持向量尽可能远离超平面。SVM 对于线性可分问题的主要思想是凸优化，通过拉格朗日乘数法寻找

目标函数 $f(w) = \frac{\|w\|^2}{2}$ 的最小值，即 $L(w, b, \lambda) = \frac{\|w\|^2}{2} + \sum_{i=1}^N \lambda_i (y_i [w^T x_i + b] - 1)$ ，其中

$\lambda = (\lambda_1, \lambda_2, \dots, \lambda_n)$ 是拉格朗日乘子[1]。SVM 对于线性可分问题具有很强的泛化性。

2.2 非线性可分问题

在处理非线性问题时，SVM 的主要思想是利用核函数对低维的样本点进行升维，从而提高将线性不可分问题转化为线性可分问题的概率。常用的核函数包括：线性核 $K(x_i, x_j) = x_i^\top x_j$ ；多项式核 $K(x_i, x_j) = (\gamma x_i^\top x_j + b)^d$ ；高斯核 $K(x_i, x_j) = e^{-\gamma \|x_i - x_j\|^2}$ 和 sigmoid 核 $K(x_i, x_j) = \tanh(\gamma x_i^\top x_j + b)$ [1]。

3. SVM 实现图像分类

3.1 基本原理

图像分类问题是计算机视觉领域中的一个重要任务，它需要将图像分为不同的类别，以便进行进一步的分析和处理。为了使用 SVM 对图像进行分类，首先需要从图像中提取特征。这些特征可以是像素的颜色值、边缘检测，或者图像中存在的纹理。一旦提取了特征，就可以将它们用作 SVM 算法的输入，再选择合适的参数、核函数进行分类[2]。

3.2 实验环境

操作系统	Windows 11
CPU	13th Gen Intel Core i7-13620H 2.40 GHz
GPU	NVIDIA GeForce RTX 4050
计算平台	Matlab R2024a

3.3 数据集

本文所采用的数据集来自网络图片，可分为车辆、猫、花朵、鱼四个类别，每个类别各 100 张图片，其中 60 张作为训练样本，40 张作为测试样本。共 240 张训练样本，160 张测试样本。

3.4 实验步骤

3.4.1 灰度共生矩阵提取

灰度共生矩阵 (GLDM) 的统计方法是 20 世纪 70 年代初由 R.Haralick 等人提出的, 它是在假定图像中各像素间的空间分布关系包含了图像纹理信息的前提下, 提出的具有广泛性的纹理分析方法。灰度共生矩阵被定义为从灰度为特定值的像素点出发, 离开某个固定位置的点上灰度值相同的概率, 所有估计的值可以表示成一个矩阵的形式[3]。这里为了取不同方向 (0、45、90、135 度) 的灰度共生矩阵, 通过循环计算各个方向的灰度共生矩阵并进行归一化处理 (计算对比度、逆差距、熵、自相关), 然后取平均值和方差作为最终提取的特征。

3.4.2 合并特征

编写一个特征提取函数, 这个函数输入为整理过的训练集和测试集, 输出为训练集的特征、标签和测试集的特征、标签。这个函数的功能是将方向梯度直方图 (HOG) 特征和提取的 GLCM 特征合并。首先取第一张图片进行灰度化以及阈值分割, 将图片大小调整在 256*256 的范围 (统一大小) 分别进行 HOG 和 GLCM 的特征提取, 分别得到两种特征向量, 取两个向量的长度之和, 即为一张图片特征提取后的总长度。遍历训练集每一张图片, 对其进行灰度化、阈值化、调整大小, 然后进行特征提取, 将 HOG 特征和 GLCM 特征合并成一个向量作为特征矩阵的一行, 即一张图片的特征向量。样本的标签构建则将每张图片所处的文件夹的名字作为该图片的标签, 并与特征向量顺序相对应。

3.4.3 SVM 训练与测试

调用前面的特征提取函数得到训练和测试用的特征向量与对应的标签, 便可以进行 SVM 的训练和测试。此处使用 Matlab 自带的训练 SVM 函数 `fitcecoc`, 且测试可以用 `predict` 函数预测结果。本文还使用降维算法主成分分析 (PCA) 作为对照组[4]。

3.5 实验结果




图 1 SVM 针对 car 类图片的分类结果




图 2 SVM 针对 cat 类图片的分类结果

```
reading img...
training...
done.
160 samples are tested, with 14 errors.
accuracy rate = 91.27%
>>
```

图 3 SVM 对四类图片的识别准确率

```
testing samples from C:\Users\devpr\Desktop
160 samples are tested, with 8 errors.
accuracy rate = 95%
>>
```

图 4 PCA 对四类图片的识别准确率

4. 结论

实验结果表明，SVM 在图像分类任务中表现优良，具有较好的泛化能力。但是在本次实验中，相对主成分分析（PCA）算法而言，识别精度略有不足，可能是由于样本量过少导致的。总而言之，SVM 适用于图像识别领域。

参考文献

- [1] 张松兰.支持向量机的算法及应用综述[J].江苏理工学院学报,2016,22(2):14-1721
- [2] 郭勇. 基于支持向量机的图像处理研究方法研究[D]. 陕西:西安理工大学,2006. DOI:10.7666/d.D293669.
- [3] 郭德军,宋蛰存.基于灰度共生矩阵的纹理图像分类研究[J].林业机械与木工设备,2005,33(7):21-23
- [4] 赵蕾.主成分分析方法综述[J].软件工程,2016,19(6):1-3