

AQUA-PINN：面向实时游戏三维水流仿真的物理信息神经网络

AQUA-PINN: An Adaptive Quasi-Uniform Approximation Physics-Informed Neural Network for Real-Time Three-Dimensional Water Flow Simulation in Games

copycat666^{1,2,†}, jabberloop_is_killin^{3,4}, mysteriousK^{1,2}, doro^{1,2},

1. EigenLife 机器学习实验室，东北电力大学，吉林
2. 《电子游戏科学与技术》编辑委员会
3. 中国五子棋协会，香港特别行政区
4. GeepSeek Team

†: Corresponding Author

摘要：水体是三维游戏中视觉沉浸与交互真实感的核心来源，而实时水流仿真长期被网格法、粒子法与半解析简化所主导。这些经典方法的计算开销随分辨率幂次增长，精度与帧率之间始终存在尖锐矛盾。本文提出并实现了一种面向游戏场景的物理信息神经网络——AQUA-PINN (Adaptive Quasi-Uniform Approximation Physics-Informed Neural Network)，以三维不可压缩 Navier-Stokes 方程的强形式残差作为训练约束，配合拟均匀配点采样与自适应损失加权，在无需任何网格离散的前提下重建定常水流的速度场与压力场。本文以具有解析解的三维 Arnold-Beltrami-Childress 定常流作为制造解基准，系统开展了七个维度的实验：训练动力学与网络架构对比、配点采样策略对比、粘度参数扫描、物理约束与纯数据回归的对比、损失权重消融、三维流场渲染可视化，以及部署成本分析。结果表明，AQUA-PINN 在约三千次迭代内将速度场的相对 L^2 误差降至 10^{-2} 量级；在同等训练预算下，物理约束在标注稀缺时能够取得与纯监督回归相当的精度，从而以零标注成本获得流场重建能力；低差异序列采样在配点充分时较随机均匀采样略有优势；训练完成后，网络对全场单帧推理耗时随查询点数近线性增长，在游戏常见的稀疏查询场景下处于毫秒量级，展现出作为离线训练、在线推理的游戏流体代理模型的潜力。本文给出了完整的数学建模、工程实现、定量误差分析与可复现实验流程，为严肃游戏与交互式仿真中的物理保真提供了一套可复用且可验证的方法学。

关键词：物理信息神经网络；不可压缩 Navier-Stokes 方程；三维水流仿真；实时游戏物理；制造解；拟均匀采样；神经代理模型

Abstract. Water bodies are central to the visual immersion and interaction realism of three-dimensional games, yet real-time water-flow simulation has long been dominated by grid-based methods, particle-based methods, and semi-analytic simplifications. The computational cost of these classical approaches grows polynomially with resolution, and a sharp tension between accuracy and frame rate persists. In this paper we propose and implement AQUA-PINN (Adaptive Quasi-Uniform Approximation Physics-Informed Neural Network), a physics-informed neural network tailored to game scenarios that imposes the strong-form residuals of the three-dimensional incompressible Navier-Stokes equations as training constraints. By combining quasi-uniform collocation sampling with adaptive loss weighting, it reconstructs the velocity and pressure fields of steady water flow without any grid discretisation. Using the analytically solvable three-dimensional Arnold-Beltrami-Childress steady flow as a manufactured-solution benchmark, we conduct seven systematic experiments: training-dynamics and network-architecture comparison, collocation-sampling comparison, a viscosity sweep, a comparison between physics-constrained and purely data-driven regression, loss-weight ablation, three-dimensional rendering and visualisation, and deployment-cost analysis. The results show that AQUA-PINN reduces the relative L^2 velocity error to the order of 10^{-2} within roughly three thousand iterations. Under an equal training budget, the physics-constrained formulation attains accuracy comparable to purely supervised regression when labels are scarce, thereby reconstructing the flow field at zero labelling cost. Low-discrepancy sampling shows a modest advantage over random uniform sampling when collocation points are sufficiently abundant. After training, the per-frame inference cost of a full-field evaluation grows nearly linearly with the number of query points and stays at the millisecond level for the sparse query patterns typical of games, demonstrating the potential of AQUA-PINN as an offline-trained, online-queried surrogate model for game fluids. Full mathematical modelling, engineering implementation, quantitative error analysis, and a reproducible experimental procedure are provided.

Keywords: Physics-Informed Neural Network; Incompressible Navier-Stokes Equations; Three-Dimensional Water Flow; Real-Time Game Physics; Manufactured Solution; Quasi-Uniform Sampling; Neural Surrogate Model

一、引言

1.1. 研究背景与问题

水是三维游戏世界中最富表现力也最难模拟的物理对象。无论是海洋表面的波浪、瀑布的飞溅、河流绕过礁石时的湍流，还是角色涉水时激起的水花，水流的行为都同时牵动渲染、碰撞与交互三条技术链路，而这三者共同指向同一个底层问题：如何在每一帧的严格时间预算之内，求得一组在物理上可信的流场。现代游戏引擎普遍采用的计算流体方法可以大致划分为网格法、粒子法与混合法三类，它们各自在精度、稳定性与计算成本之间作出取舍，却都难以摆脱一个根本性的张力——分辨率越高，逼近真实流动的能力越强，单帧的计算与存储开销也随之幂次增长。这一张力在三维不可压缩流中尤为突出：不可压缩性约束要求速度场逐点满足散度为零的条件，经典求解器为此必须在每个时间步求解一次全局泊松压力方程，其代价在分辨率提高时迅速成为性能瓶颈。

近年来，物理信息神经网络（Physics-Informed Neural Network, PINN）为偏微分方程的求解提供了一条全新的路径。这类方法将偏微分方程以强形式残差嵌入神经网络的损失函数，通过自动微分精确计算微分算子，从而在连续坐标系中直接逼近方程的解。与经典离散方法相比，PINN 具有若干结构性优势：它不依赖网格，因而天然摆脱了网格生成与网格质量对精度的制约；它以参数化函数的连续表示替代离散节点上的数值，因而能够以亚网格的解析形式输出任意坐标处的场值；它在训练完成后可以极低的成本进行推理，恰好契合游戏场景中“离线训练、在线推理”的部署范式。这些优势使 PINN 成为游戏流体模拟中极具吸引力的候选方案，然而，将其从理论上的可能落实为工程上可用的组件，仍然面临训练收敛困难、误差控制缺乏定量基准、以及对高雷诺数流动表示能力不足等一系列开放问题。

本文的工作正是在这一背景下展开的。本文并不宣称物理信息神经网络能够全面取代成熟的游戏流体引擎，而是试图回答一个更聚焦也更可检验的问题：对于游戏中最常见的一类水流场景——定常或准定常的不可压缩三维流动——一个结构简单、可在个人计算机上训练的 PINN 能够在多大程度上重建真实的流场，其精度如何随采样、网络结构与损失配置而变化，其部署成本又是否落在实时应用的可行范围之内。为了严格回答这一问题，本文选择具有精确解析解的三维 Arnold-Beltrami-Childress (ABC) 定常流作为制造解基准，使每一项精度结论都可以与真值逐点比对，从而将经验性的观察转化为可复现的定量结论。

1.2. 相关工作

物理信息神经网络的概念可以追溯到 Lagaris 等人将人工神经网络用于求解常微分方程与偏微分方程的早期工作 [1]，其基本思想是用可微的神经网络近似方程解，并将方程残差与边界条件残差并入训练目标。Raissi 等人将这一思想系统化，建立了以自动微分为核心、统一处理前向与逆向问题的现代 PINN 框架 [2]，随后又将其推广到从流动可视化数据中重建速度场与压力场的“隐藏流体力学”任务 [3]。Karniadakis 等人对物理信息机器学习进行了全面的综述，明确了物理约束与数据驱动相融合的一般原则 [4]，Cai 等人则专门梳理了 PINN 在流体力学中的进展 [5]。在不可压缩 Navier-Stokes 方程这一具体对象上，Jin 等人提出了 NSFnets，将速度与压力作为联合输出并以散度约束与动量残差共同监督 [6]，Sun 等人探索了无仿真数据的物理约束代理建模 [7]，Mojgani 等人则研究了拉格朗日视角下的 PINN 表示 [8]。这些工作共同确立了 PINN 求解不可压缩流动的技术路线，但其验证多集中于二维基准或特定的工程算例，针对三维流动的系统验证仍相对匮乏。

与此同时，研究者逐渐认识到 PINN 的训练并不像表面那样一帆风顺。Wang 等人分析了训练过程中的梯度病态现象，指出不同损失项之间的梯度不平衡会导致收敛缓慢甚至停滞 [9]，并据此提出了改进的网络架构与损失构造策略 [10]。Krishnapriyan 等人系统刻画了 PINN 在刚性方程上的失效模式 [11]，Nabian 等人研究了重要性采样对训练效率的提升 [12]，Sitzmann 等人提出的周期激活函数网络则为表示高频场提供了更强的表达能力 [13]。这些关于训练动力学与误差机理的深入理解，是本文在方法层面进行采样策略设计与损失权重消融的理论依据。

在游戏图形学的另一侧，流体模拟同样经历了数十年的发展。Stam 提出的稳定流体方法以半拉格朗日平流与隐式扩散保证了无条件稳定，成为游戏流体模拟的里程碑 [14]；Bridson 等人对网格类流体模拟给出了系统性的工程总结 [15][16]；Fedkiw 等人将水平集方法引入烟雾模拟 [17]；粒子类方法方面，平滑粒子流体动力学与基于位置的流体凭借其直观性与实时性在游戏中广泛使用 [18][19][20]。这些经典方法的共同特征是逐帧离散求解，每一帧的计算成本与分辨率强相关，且其精度验证通常依赖视觉观感而非定量误差。本文的工作在两个传统之间建立了一座桥梁：以经典流体动力学的方程体系为物理依据，以 PINN 的连续表示为求解手段，最终面向游戏实时性的部署需求进行定量评估。这一交叉视角使本文区别于单纯的方法复现，也区别于脱离应用场景的理论研究。值得注意的是，本文作者团队的前序工作已对计算流体力学在游戏水体渲染中的理论与工程实践进行了系统综述 [21]，从 Stable Fluids 与浅水方程等游戏专用简化模型，到 Unreal Engine 5.3 Chaos 异构计算架构与移动端格子 Boltzmann 方法等工业实现，再到神经物理混合模型（NeuroFLIP）等未来方向，勾勒了这一领域的完整技术图谱。本文正是在该综述所展望的物理信息神经网络路线上的一次具体落地，以制造解基准为三维不可压缩流提供了可复现的定量验证。

1.3. 研究问题与评估框架

基于上述背景与相关工作，本文提出四个可以严格检验的研究问题，并以制造解基准逐一作答。第一个问题是表示能力：一个中等规模的全连接网络，是否足以表示三维不可压缩流场的速度与压力结构，其精度与网络宽度、激活函数之间存在怎样的定量关系。第二个问题是采样效率：在训练点数受限的条件下，配点的空间分布策略能够在多大程度上影响最终精度，拟均匀采样相对随机采样是否具有可度量的优势。第三个问题是物理约束的价值：方程残差作为全局先验，在标注数据稀缺时能够带来多大的精度增益，这一增益如何随数据量变化。第四个问题是部署可行性：训练完成的网络在实时推理中的单帧成本是否落在游戏帧预算之内，其内存占用相比经典离散表示缩减了多少。

为回答上述问题，本文建立了统一的评估框架。评估的核心是制造解基准所提供的解析真值，它使每一个精度结论都可以归结为可复现的数值。评估的维度则覆盖精度、效率与视觉三个层面：精度维度以相对 L^2 误差与方程残差度量，效率维度以训练耗时与推理耗时度量，视觉维度以流线、粒子平流与切片渲染度量。这三个维度共同构成了对方法能力的完整刻画，避免了单一指标可能带来的片面结论。后续各实验均在这一框架下设计与报告，实验之间共享同一套物理参数与网络配置，从而保证结果的可比性与可复现性。

1.4. 创新点与组织

综合而言，本文的贡献体现在以下相互关联的几个方面。其一，本文提出 AQUA-PINN，一个面向游戏三维水流的物理信息神经网络方法，其命名即点明了方法的两项关键设计——拟均匀（Quasi-Uniform）配点采样与自适应（Adaptive）损失加权，二者分别回应了采样效率与训练稳定性这两个公认的 PINN 瓶颈。其二，本文以三维 ABC 定常流作为制造解基准，为三维不可压缩流的 PINN 求解提供了一个具有解析真值的严格验证平台，使每一项误差结论都具备逐点可比的基础。其三，本文开展了覆盖训练动力学、采样策略、粘度参数、物理约束价值、损失权重、渲染效果与部署成本共七个维度的实验，形成了对方法能力与边界的完整刻画。其四，本文将 PINN 的推理成本明确置于游戏帧预算的语境中加以度量，论证了“离线训练、在线推理”的流体代理模型在实时游戏中的可行性。

本文的其余部分组织如下。第 2 节建立三维不可压缩水流问题的数学模型，并阐述 PINN 求解该问题的通用形式。第 3 节详细介绍 AQUA-PINN 的方法设计，包括网络结构、强形式残差构造、拟均匀采样与自适应加权。第 4 节构造三维 ABC 定常流制造解，并给出其满足 Navier-Stokes 方程的解析证明。第 5 节系统呈现七个实验的设计、结果与分析，配以图表与对比。第 6 节讨论方法面向实时游戏部署的工程含义、与经典方法的对比及局限性。第 7 节总结全文并展望未来工作。

二、问题建模：三维不可压缩水流

2.1. 控制方程

水在常温常压下可视为不可压缩牛顿流体，其运动由连续性方程与 Navier-Stokes 方程共同支配。设流体密度为 ρ 、动力粘度为 μ 、运动粘度为 $\nu = \mu/\rho$ ，速度场为 $\mathbf{u}(\mathbf{x}, t) = (u, v, w)$ ，压力场为 $p(\mathbf{x}, t)$ ，则质量守恒与动量守恒分别写作

$$\nabla \cdot \mathbf{u} = 0 \quad (1)$$

与

$$\rho \left(\frac{\partial \mathbf{u}}{\partial t} + (\mathbf{u} \cdot \nabla) \mathbf{u} \right) = -\nabla p + \mu \nabla^2 \mathbf{u} + \mathbf{f} \quad (2)$$

其中 $\mathbf{f}$ 为体积力（例如重力）， $(\mathbf{u} \cdot \nabla) \mathbf{u}$ 为对流项， $\nabla^2 \mathbf{u}$ 为粘性扩散项。式 (1) 的散度为零条件刻画了不可压缩性的本质：流体微元在运动过程中体积保持不变。值得注意的是，压力 p 在式 (2) 中并不具有独立的演化方程，它在数学上扮演拉格朗日乘子的角色，其作用是使速度场在每一时刻满足不可压缩约束。这一数学结构直接导致了经典求解方法的困难——压力与速度耦合，必须通过求解泊松方程加以解耦——也为基于神经网络的直接场重建方法提供了发挥空间。

本文关注游戏场景中最常见的一类情形，即定常流动。在定常假设下， $\partial \mathbf{u} / \partial t = 0$ ，式 (2) 简化为

$$\rho (\mathbf{u} \cdot \nabla) \mathbf{u} = -\nabla p + \mu \nabla^2 \mathbf{u} + \mathbf{f} \quad (3)$$

定常流动广泛存在于水体的准静态特征分析中：河床底部稳定绕过障碍物的流动、旋涡在长时间平均下的结构、以及水面波浪在周期性驱动下达到的稳态解，都可以在定常框架下加以近似。从游戏开发的角度看，定常流场可作为“环境流场”的基底，在其上叠加时间相关的扰动，从而以极低的运行时成本获得丰富的流动表现。

这一认识构成了本文选择定常问题作为切入点的工程动机。

2.2. 水的物理性质与模拟精度需求

在进入数值方法的讨论之前，有必要明确水作为模拟对象的物理特性，以及游戏场景对这些特性的精度需求。水的运动粘度在室温下约为 $10^{-6} \text{ m}^2/\text{s}$ ，这一数值意味着在游戏常见的米级尺度与米每秒级流速下，雷诺数通常高达 10^6 以上，流动在物理上处于充分发展的湍流状态。然而，游戏中的水流模拟几乎从不追求对湍流的直接数值求解——那在计算上远超实时性的可行范围。游戏实践的通行做法是求解经过平均化或滤波处理的有效方程，或在视觉层面模拟湍流的外观特征，以可接受的计算代价换取观感上的真实。这一现实为神经网络方法提供了契机：既然游戏的目标是视觉可信而非逐涡解析，那么一个能够以连续表示捕捉流场宏观结构的代理模型，就可能在精度与效率之间取得比经典离散方法更有利的平衡。

与此同时，游戏对水流模拟的精度需求呈现出鲜明的层次结构。交互物理层需要精确的流体力以驱动漂浮物、角色与粒子的运动，这一层对速度场的局部精度要求最高；视觉表现层需要连贯的流线与合理的涡结构以支撑渲染，这一层对场的宏观拓扑要求最高；而环境氛围层仅需要大体合理的水体运动以营造沉浸感，精度要求相对宽松。本文所提出的 AQUA-PINN 恰恰通过其连续表示的特性，能够以单一的参数化模型同时服务于上述多个精度层级——高精度查询用于交互物理，中精度采样用于视觉表现，低精度概览用于环境氛围——各层级之间的精度差异由查询密度而非模型本身来调节。这一“一次训练、分层使用”的特性，是经典逐分辨率离散方法难以提供的。

2.3. 不可压缩 Navier-Stokes 方程的数学性质

不可压缩 Navier-Stokes 方程的适定性是偏微分方程理论中的核心难题。在三维情形下，光滑解的整体存在性与唯一性至今仍是悬而未决的公开问题，其严格讨论可参见 Temam 的专著 [22]。从数值求解的角度，这一方程呈现出一系列需要小心处理的特性。首先是对流项的非线性： $(\mathbf{u} \cdot \nabla) \mathbf{u}$ 对 $\mathbf{u}$ 是二次的，这使得任何以线性算子为基础的经典谱方法或有限元方法都需要借助迭代或固定点技巧加以处理。其次是刚性问题：当粘度 ν 趋于零时，粘性项的作用集中于极薄的边界层与内层中，方程的解在局部呈现剧烈变化，对任何数值方法的网格分辨率或参数表达能力都构成严峻挑战。再次是约束的耦合性：不可压缩约束要求速度场在函数空间中位于一个散度为零的子流形上，经典方法通过投影步骤将速度场投影回该子流形，而这一投影步骤正是计算开销的主要来源。

从几何数值积分的视角审视，不可压缩 Navier-Stokes 方程还具有能量耗散结构：在无外力且边界条件齐次的情形下，动能满足耗散不等式，粘性项单调地消耗动能，而这一耗散速率与涡量场的强度直接相关。这一结构对于评估数值方法的长时行为具有重要意义，也为神经网络方法的设计提供了线索——一个能够尊重能量耗散趋势的表示，比一个仅仅逐点拟合残差的表示更可能捕捉到流动的宏观特征。本文的方法在损失构造中直接使用强形式残差，因而在训练收敛的意义上间接约束了动量平衡与质量守恒，但对能量耗散结构的显式刻画则留待未来工作。

2.4. 经典求解方法及其在游戏中的局限

游戏图形学中的流体求解方法大体沿两条路线演进。网格法以有限差分或有限体积为基础，其中最具代表性的是 Stam 提出的稳定流体框架 [14] 及其后继发展 [16]。这类方法将流场离散到规则网格上，以半拉格朗日方法处理平流项以规避显式格式的 CFL 稳定性限制，并以隐式或投影方法施加不可压缩约束。投影步骤通常要求求解一个覆盖全部网格节点的压力泊松方程，其计算代价在高分辨率下迅速攀升；此外，网格方法的精度受限于网格分辨率，无法解析小于网格尺度的流动结构。粒子法以平滑粒子流体动力学 [18][19] 与基于位置的流体 [20] 为代表，将流体离散为一组相互作用的粒子，其直观性与对自由表面的自然处理使其在游戏中广受欢迎，但粒子数目与邻域搜索的开销同样随分辨率增长，且压力场的求解在粒子框架下精度有限，容易引入可觉察的伪压缩与抖动。

无论网格法还是粒子法，其共同的计算模式是逐帧求解、按分辨率付费。这一模式在固定分辨率与固定帧率的游戏语境下意味着：开发者必须在精度与性能之间作出取舍，而取舍得出的结果往往是一个经过大量工程调校的折中产物。本文所探索的物理信息神经网络代表了一种不同的计算模式——先以较高的离线成本一次性训练一个流场的连续表示，再以极低的在线成本在任意坐标处查询场值。这种模式的价值不在于取代上述经典方法，而在于为那些“流场结构相对稳定、但需要高分辨率查询”的场景提供一种互补的选择，例如静态水体的环境流场、漩涡与回流区的预计算、以及水体交互的查询式评估。接下来的章节将把这一思路具体化为可实现的 AQUA-PINN 方法。

从数值细节上审视，经典方法的性能瓶颈还可以更精确地定位。网格法的显式时间推进受到 CFL 条件的约束，时间步长必须正比于网格尺度，分辨率提高一倍，时间步数随之翻倍，总计算量以三次方以上的速度增长；而投影步骤中的压力泊松方程求解，其每一次迭代都需要在全部网格节点上进行通信密集的松弛运算，在多核并行下也难以获得理想的加速比。粒子法的瓶颈则集中在邻域搜索与不可压缩性维持上，粒子数增加时，邻域

搜索的代价超线性增长，而维持不可压缩所需的迭代松弛同样消耗可观的帧预算。这些具体的数值瓶颈共同构成了经典方法在三维高分辨率下的性能天花板，也为本文所探索的替代计算模式提供了清晰的动机——若流场的查询需求远高于其动态演化需求，那么以离线训练换取在线查询效率的策略就具有显著的优势。

2.5. 无量纲化与雷诺数

为了在统一的框架下讨论不同尺度与不同介质的水流问题，对式 (2) 进行无量纲化是必要的。设特征长度为 L 、特征速度为 U ，引入无量纲变量 $\mathbf{x}' = \mathbf{x}/L$ 、 $\mathbf{u}' = \mathbf{u}/U$ 、 $t' = tU/L$ 、 $p' = p/(\rho U^2)$ ，则动量方程化为

$$\frac{\partial \mathbf{u}'}{\partial t'} + (\mathbf{u}' \cdot \nabla') \mathbf{u}' = -\nabla' p' + \frac{1}{Re} \nabla'^2 \mathbf{u}' + \mathbf{f}' \quad (4)$$

其中雷诺数定义为

$$Re = \frac{UL}{\nu} \quad (5)$$

雷诺数的物理意义是惯性力与粘性力之比，它单值地刻画了流动的动力学相似性：几何相似的两个流动只要雷诺数相同，其无量纲流场便相同。这一事实对本文具有双重含义。一方面，它意味着本文在无量纲化坐标系下得到的结论可以按相似性原理迁移到不同尺度的真实水体，本文实验中的粘度扫描本质上就是雷诺数扫描。另一方面，它揭示了数值方法面临的核心困难随雷诺数的演化：雷诺数越高，对流项的非线性作用越强，流场中的小尺度结构越丰富，对表示能力与分辨率的要求也越高。本文实验三所观察到的误差随粘度降低而上升，正是这一困难在神经网络表示中的直接体现。

2.6. 涡量方程与压力泊松方程

不可压缩流场的两个关键物理量——涡量与压力——各自满足具有独立物理意义的方程，理解这些方程对于评估任何求解方法都至关重要。对式 (2) 两边取旋度，并利用不可压缩条件，可得涡量 $\boldsymbol{\omega} = \nabla \times \mathbf{u}$ 的演化方程

$$\frac{\partial \boldsymbol{\omega}}{\partial t} + (\mathbf{u} \cdot \nabla) \boldsymbol{\omega} = (\boldsymbol{\omega} \cdot \nabla) \mathbf{u} + \nu \nabla^2 \boldsymbol{\omega} \quad (6)$$

其中 $(\boldsymbol{\omega} \cdot \nabla) \mathbf{u}$ 为涡线拉伸项，它是三维流动区别于二维流动的本质特征，也是三维湍流能量级串的机理来源。对式 (2) 两边取散度，并结合式 (1)，可导出压力所满足的泊松方程

$$\nabla^2 p = -\rho \nabla \cdot ((\mathbf{u} \cdot \nabla) \mathbf{u}) \quad (7)$$

式 (7) 揭示了压力场的椭圆性本质：压力在每一时刻由速度场的瞬时结构通过一个全局椭圆方程确定，压力信息以无限速度在流场中传播。这正是经典投影方法每步求解压力泊松方程的数学根源，也是压力在神经网络训练中较速度更难收敛的结构原因——压力的确定依赖速度场的全局散度结构，这一全局依赖削弱了局部监督信号的效力，使压力场的幅值难以被方程约束唯一锁定。

2.7. 能量耗散结构

不可压缩 Navier-Stokes 方程具有严格的能量耗散结构，这一结构为评估数值方法的物理保真度提供了重要判据。在无外力、齐次边界条件下，对式 (2) 点乘速度场并在计算域上积分，利用不可压缩条件与分部积分，可得动能

$$K(t) = \frac{\rho}{2} \int_{\Omega} |\mathbf{u}|^2 d\mathbf{x} \quad (8)$$

的演化满足

$$\frac{dK}{dt} = -\mu \int_{\Omega} |\nabla \times \mathbf{u}|^2 d\mathbf{x} \leq 0 \quad (9)$$

式 (9) 表明动能单调不增，其耗散速率正比于涡量的全局平方积分。这一耗散不等式对本文的启示在于：一个物理上忠实的方法，其重建的流场应当尊重这一能量趋势。AQUA-PINN 虽然不显式地将能量耗散作为损失项，但强形式动量残差在收敛时隐含地保证了能量平衡关系在配点意义上的成立。未来工作中将能量耗散作为显式的物理约束加入损失，有望进一步提升方法在长时与低粘度情形下的物理保真度。

三、AQUA-PINN 方法

3.1. 方法总览与命名

AQUA-PINN 的全称为 Adaptive Quasi-Uniform Approximation Physics-Informed Neural Network，即自适应拟均匀近似物理信息神经网络。其名称凝练了方法的两项核心设计：拟均匀（Quasi-Uniform）指向配点采样环节，即以低差异序列替代纯随机采样，在同等点数下获得对计算域更均匀的覆盖；自适应（Adaptive）指向损失构造环节，即通过权重调节在方程残差与边界条件残差之间取得动态平衡。这两项设计分别针对 PINN 公认的两类瓶颈——采样效率与训练稳定性——而提出，因此命名本身即是对方法机理的凝练表述。

方法以全连接神经网络参数化流场的连续表示。网络以空间坐标 (x, y, z) 为输入，以速度三分量与压力 (u, v, w, p) 为输出。与经典方法在离散网格节点上存储场值不同，AQUA-PINN 将流场表示为一个可微的映射 $F_\theta: \mathbb{R}^3 \rightarrow \mathbb{R}^4$ ，其中 θ 为网络参数。这一连续表示带来的直接收益是：场值可以在任意坐标处查询，查询分辨率与训练分辨率解耦；微分算子可以通过自动微分精确计算，无需离散近似；训练完成后，整个流场的存储开销仅为网络参数本身，与查询分辨率无关。图 1 以端到端数据流的形式总结了 AQUA-PINN 的完整架构：坐标经全连接网络映射为流场，流场一方面经自动微分组装方程残差并形成方程损失，另一方面在边界处与真值对比形成边界损失，二者加权求和后交由优化器更新网络参数，如此迭代直至收敛。




图 1: AQUA-PINN 端到端架构。坐标经全连接网络映射为流场 (u, v, w, p) ；流场经自动微分组装动量与连续性方程残差，形成方程损失 $\mathcal{L}_{pde}$ ；流场在边界处与真值对比形成边界损失 $\mathcal{L}_{bc}$ ；二者加权求和后交由 Adam 优化器更新网络参数（虚线反馈），迭代直至收敛。

3.2. 网络结构与强形式残差

AQUA-PINN 采用标准的全连接前馈网络。设网络层数为 L ，第 ℓ 层的宽度为 n_ℓ ，激活函数为 σ ，则网络的前向传播可写作

$$\mathbf{h}^{(0)} = \mathbf{x}, \quad \mathbf{h}^{(\ell)} = \sigma(\mathbf{W}^{(\ell)} \mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)}), \quad F_\theta(\mathbf{x}) = \mathbf{W}^{(L)} \mathbf{h}^{(L-1)} + \mathbf{b}^{(L)} \quad (10)$$

其中 $\mathbf{W}^{(\ell)}$ 与 $\mathbf{b}^{(\ell)}$ 为第 ℓ 层的权重与偏置。输出层不使用激活函数，以便压力与速度取任意实值。在本文的基准实验中，网络采用四个隐藏层、每层 48 个神经元的配置，激活函数默认使用双曲正切函数，其对符号与幅度的对称处理与流场中速度分量正负交替的特性相契合。本文第 5 节的实验一将系统比较不同激活函数与不同网络宽度对精度的影响。

网络输出与物理量之间的对应关系为 $F_\theta(\mathbf{x}) = (\hat{u}, \hat{v}, \hat{w}, \hat{p})$ 。为了衡量该输出在多大程度上满足控制方程，本文在计算域内选取一组配点 $\{\mathbf{x}_i\}_{i=1}^{N_f}$ ，并在每一点处利用自动微分计算各阶导数，构造动量方程残差。具体而言，将式 (3) 移项后，三个动量分量残差定义为

$$\mathcal{R}_u = \rho \left(\hat{u} \frac{\partial \hat{u}}{\partial x} + \hat{v} \frac{\partial \hat{u}}{\partial y} + \hat{w} \frac{\partial \hat{u}}{\partial z} \right) + \frac{\partial \hat{p}}{\partial x} - \mu \nabla^2 \hat{u} - f_x \quad (11)$$

$$\mathcal{R}_v = \rho \left(\hat{u} \frac{\partial \hat{v}}{\partial x} + \hat{v} \frac{\partial \hat{v}}{\partial y} + \hat{w} \frac{\partial \hat{v}}{\partial z} \right) + \frac{\partial \hat{p}}{\partial y} - \mu \nabla^2 \hat{v} - f_y \quad (12)$$

$$\mathcal{R}_w = \rho \left(\hat{u} \frac{\partial \hat{w}}{\partial x} + \hat{v} \frac{\partial \hat{w}}{\partial y} + \hat{w} \frac{\partial \hat{w}}{\partial z} \right) + \frac{\partial \hat{p}}{\partial z} - \mu \nabla^2 \hat{w} - f_z \quad (13)$$

连续性方程残差定义为

$$\mathcal{R}_c = \frac{\partial \hat{u}}{\partial x} + \frac{\partial \hat{v}}{\partial y} + \frac{\partial \hat{w}}{\partial z} \quad (14)$$

其中所有一阶导数由自动微分在计算图上精确求得，拉普拉斯算子通过对一阶导数再次求导得到。值得强调的是，这些导数计算不涉及任何离散化误差——自动微分在机器精度意义下逐层传播梯度，因而残差 $\mathcal{R}$ 的精度仅受限于浮点运算的舍入误差。这一点是 PINN 相对于有限差分等离散方法的根本优势之一。

3.3. 损失函数与边界条件

AQUA-PINN 的训练目标由方程残差项与边界条件项两部分构成。设计算域为 Ω ，其边界为 $\partial\Omega$ ，边界上采 N_b 个点 $\{\mathbf{x}_j^b\}_{j=1}^{N_b}$ 。边界条件损失度量网络输出与边界真值之间的偏差：

$$\mathcal{L}_{bc} = \frac{1}{N_b} \sum_{j=1}^{N_b} \left(\|\hat{\mathbf{u}}(\mathbf{x}_j^b) - \mathbf{u}_{bc}(\mathbf{x}_j^b)\|^2 + (\hat{p}(\mathbf{x}_j^b) - p_{bc}(\mathbf{x}_j^b))^2 \right) \quad (15)$$

方程残差损失为各配点处残差平方的均值：

$$\mathcal{L}_{pde} = \frac{1}{N_f} \sum_{i=1}^{N_f} (\mathcal{R}_u^2 + \mathcal{R}_v^2 + \mathcal{R}_w^2 + \lambda_{cont} \mathcal{R}_c^2) \quad (16)$$

总损失为二者的加权和：

$$\mathcal{L} = \mathcal{L}_{pde} + \lambda_{bc} \mathcal{L}_{bc} \quad (17)$$

其中 λ_{cont} 为连续性约束的权重， λ_{bc} 为边界条件的权重。这两个超参数共同决定了方程约束与边界约束在训练中的相对强弱，本文第 5 节的实验五将对其影响进行系统的消融分析。在基准配置中，本文取 $\lambda_{cont} = 10$ 、 $\lambda_{bc} = 100$ ，使边界条件在训练初期占据主导，从而先锁定流场的大尺度结构，再逐步细化内部区域对方程残差的满足程度。

3.4. 拟均匀配点采样

配点的空间分布对 PINN 的训练效率与最终精度具有决定性影响。纯随机均匀采样在点数较少时容易出现局部聚集与空洞，导致某些区域的方程约束几乎未被采样，训练信号的空间覆盖不均。针对这一问题，AQUA-PINN 引入了拟均匀采样策略，即采用低差异序列在计算域内生成配点。低差异序列的构造思想在于：使任意子区域内的点数与该子区域的体积成正比，且比例偏差随点数增加以对数阶而非平方根阶衰减，从而在点数有限时获得比随机采样更均匀的覆盖。

本文具体考察了两类低差异序列。其一是拉丁超立方采样，其将每一维均匀划分为 N 个区间，并在每个区间内恰好放置一个采样点，再通过随机置换消除各维之间的相关性。其二是 Hammersley 序列，其基于逆根函数 (radical inverse function) 构造，以素数基底的逆根作为各维坐标，具有严格确定性与极低偏差。本文第 5 节的实验二将对这两类拟均匀采样与随机均匀采样进行定量对比，验证其在减少配点需求方面的实际收益。

3.5. 训练算法

AQUA-PINN 采用 Adam 优化器 [23] 配合阶梯式学习率衰减进行训练。网络参数以 Xavier 初始化 [24] 赋初值，保证各层激活的方差在初始化时保持一致，避免梯度在深层传播中的过早消失或爆炸。训练过程的每一次迭代包含以下步骤：从前向传播计算网络输出；通过自动微分计算一阶与二阶导数；按式 (11) 至 (14) 计算方程残差；按式 (15) 与 (16) 组装损失；反向传播更新参数。学习率按训练进程分段衰减，使优化在后期能够进入更精细的收敛阶段。

需要说明的是，AQUA-PINN 的训练是一劳永逸的离线过程，其成本与运行时完全解耦。这一特性与游戏的部署范式高度契合：开发阶段以离线算力训练流场表示，运行时仅执行前向推理。本文第 5 节的实验七将对这一“离线训练、在线推理”模式的成本进行定量刻画。

Listing 1: AQUA-PINN 的训练主循环（核心逻辑）

```

1  def train(n_f=3000, n_bc=1200, epochs=3000, ...):
2      model = AQUA_PINN() # MLP: 3 -> 48x4 -> 4
3      x_f, x_bc = sample_points(n_f, n_bc, strategy="hammersley")
4      opt = torch.optim.Adam(model.parameters(), lr=1e-3)
5      for ep in range(epochs):
6          opt.zero_grad()
7          ru, rv, rw, cont = physics_residual(model, x_f, nu=nu)
8          loss_pde = (ru**2).mean() + (rv**2).mean() \
9                  + (rw**2).mean() + 10.0 * (cont**2).mean()
10         out_bc = model(x_bc)
11         loss_bc = (out_bc[:, :3] - u_bc).pow(2).mean() \
12                 + (out_bc[:, 3:] - p_bc).pow(2).mean()
13         loss = loss_pde + 100.0 * loss_bc
14         loss.backward(); opt.step()
15     return model

```

3.6. 软约束与硬约束

PINN 施加物理约束的方式可以区分为软约束与硬约束两大类，这一区分对于理解方法的误差行为具有重要意义。软约束方式将方程残差作为损失函数的一项，通过优化使残差趋于零，本文的 AQUA-PINN 即属此类。软约束的优点是实现简洁、适用面广，能够以统一的方式处理任意形式的方程与边界条件；其缺点是约束仅在最优解处被近似满足，训练过程中的解并不严格满足方程，且在损失项之间不平衡时可能出现某一约束被系统性牺牲的情形。硬约束方式则通过构造特殊的网络输出结构，使约束被构造性地精确满足，例如以散度为零的向量势表示速度场，或以满足边界条件的距离函数构造输出 [25]。硬约束的优点是约束恒成立，缺点是构造往往与具体问题绑定，通用性受限。

本文选择软约束作为基准配置，是基于可扩展性的考量——软约束能够直接推广到时变方程、复杂边界与多物理场耦合，而无需为每一类问题重新设计网络结构。同时，本文通过实验五的权重消融，系统考察了软约束下损失项不平衡对精度的影响，并据此给出了权重配置的合理区间。这一选择与大部分 PINN 文献的实践一致 [2][6]，而硬约束作为精度提升的潜在手段，留待未来工作探索。

3.7. 训练梯度病理与自适应加权策略

PINN 训练中的梯度病理是近年来被深入研究的难题。Wang 等人指出，PINN 的损失函数中方程残差项与边界条件项在反向传播时产生的梯度在幅值上可能相差数个数量级，导致优化过程被某一主导项牵着走，其余约束无法得到有效满足 [9]。这一问题在本文的方程中同样存在：动量残差项涉及二阶导数，其梯度幅值天然大于仅涉及零阶项的边界条件损失；连续性项仅涉及一阶导数，其梯度幅值介于二者之间。若不对这些梯度差异加以处理，训练容易陷入某一约束被优先满足、其余约束被忽视的失衡状态。

AQUA-PINN 的自适应加权设计正是针对这一病理的回应。本文采用显式的权重系数 λ_{bc} 与 λ_{cont} 来平衡三项损失，并在基准配置中取 $\lambda_{bc} = 100$ 、 $\lambda_{cont} = 10$ ，使边界条件在训练初期占据主导。这一经验配置背后的机理是：边界条件约束的是解在低维流形上的取值，其满足为大尺度结构的确立提供了骨架；而方程残差约束的是解在高维内部区域的行为，其精细化需要在骨架确立之后逐步完成。本文实验五的消融结果验证了这一机理的合理性。除显式加权外，文献中还提出了基于梯度范数动态平衡的自适应加权方案 [10]，其与本文显式方案的结合是未来值得探索的方向。

3.8. 收敛性讨论

严格地讨论 AQUA-PINN 的收敛性需要同时诉诸逼近论与优化论两个层面的结果。在逼近论层面，通用逼近定理保证了具有足够宽度的单隐层网络能够在紧集上以任意精度逼近连续函数 [26][27]，这为网络表示光滑流场提供了理论下限。然而，通用逼近定理并不保证优化过程能够找到该最优逼近——网络的非凸损失景观中可能存在大量局部极小与鞍点，Adam 等一阶方法能够收敛到何种质量取决于初始化、学习率调度与损失结构的综合作用。在优化论层面，本文的实验观察表明，在本文的问题规模与配置下，训练过程呈现稳定单调收敛，未观察到停滞或发散；这一经验性结论虽非严格的收敛定理，却为方法在同类问题上的可复现性提供了实践依据。

从误差构成的角度，PINN 的总体误差可以粗略分解为三部分：网络表示能力所决定的逼近误差、优化过程未达最优所导致的优化误差、以及配点离散所引入的积分逼近误差。本文实验一通过宽度消融考察了第一项，实验二通过采样策略考察了第三项，而第二项则体现在损失曲线的收敛行为中。这一分解为后续的定向改进提供了清晰的靶向。

四、制造解基准：三维 ABC 定常流

4.1. 制造解方法的意义

对任何数值方法进行严格验证，首要前提是拥有一个已知精确解的问题。在计算流体力学中，制造解方法（Method of Manufactured Solutions）通过人为构造一个满足方程的解，并反推出使该解成立的源项或边界条件，从而获得一个解析真值已知的验证基准。制造解方法的优势在于：解的每一阶导数都解析可求，误差可以逐点、逐阶地精确度量；解的光滑性与结构可以被自由设计，从而有针对性地考察方法在特定特征下的表现。对于本文而言，制造解提供了对 PINN 误差进行定量评估的黄金标准，使“精度如何”这一问题有了不容辩驳的答案。

4.2. ABC 流的定义与 Beltrami 性质

本文选用三维 Arnold-Beltrami-Childress 流作为制造解。ABC 流由 Arnold 在研究理想流体定常流拓扑时提出 [28]，由 Childress 在运动发电机问题中引入 [29]，其混沌性质由 Dombre 等人系统研究 [30]。ABC 流的速度场定义为

$$\mathbf{u}^*(\mathbf{x}) = \begin{pmatrix} A \sin y + C \cos z \\ B \sin z + A \cos x \\ C \sin x + B \cos y \end{pmatrix} \quad (18)$$

其中 A, B, C 为常系数，本文取 $A = B = C = 1$ 。该流场具有两项对本文至关重要的数学性质。第一项性质是散度为零：注意到 $\partial u^*/\partial x = 0$ (u^* 不含 x)， $\partial v^*/\partial y = 0$ ， $\partial w^*/\partial z = 0$ ，故 $\nabla \cdot \mathbf{u}^* = 0$ 逐点成立，不可压缩约束被精确满足。第二项性质是 Beltrami 性质，即涡量场与速度场共线。直接计算可得

$$\nabla \times \mathbf{u}^* = \mathbf{u}^* \quad (19)$$

即涡量恰好等于速度本身。Beltrami 性质使得对流项大幅简化。利用向量恒等式

$$(\mathbf{u} \cdot \nabla) \mathbf{u} = \frac{1}{2} \nabla |\mathbf{u}|^2 - \mathbf{u} \times (\nabla \times \mathbf{u}) \quad (20)$$

并代入式 (19)，由于 $\mathbf{u}^* \times (\nabla \times \mathbf{u}^*) = \mathbf{u}^* \times \mathbf{u}^* = 0$ ，对流项简化为纯梯度：

$$(\mathbf{u}^* \cdot \nabla) \mathbf{u}^* = \frac{1}{2} \nabla |\mathbf{u}^*|^2 \quad (21)$$

4.3. 定常 Navier-Stokes 的精确满足

将式 (21) 代入定常 Navier-Stokes 方程 (3)，并注意到对单位频率的正弦余弦场，拉普拉斯算子作用等价于乘以 -1 ，即 $\nabla^2 \mathbf{u}^* = -\mathbf{u}^*$ ，可得

$$\frac{\rho}{2} \nabla |\mathbf{u}^*|^2 = -\nabla p^* - \mu \mathbf{u}^* + \mathbf{f}^* \quad (22)$$

为使上述方程精确成立，只需选取制造压力场 p^* 与制造体积力 $\mathbf{f}^*$ 使得各项相互平衡。本文取制造压力场为

$$p^*(\mathbf{x}) = \cos x \cos y \cos z \quad (23)$$

其梯度为 $\nabla p^* = (-\sin x \cos y \cos z, -\cos x \sin y \cos z, -\cos x \cos y \sin z)$ 。制造体积力则定义为

$$\mathbf{f}^* = \frac{\rho}{2} \nabla |\mathbf{u}^*|^2 + \nabla p^* + \mu \mathbf{u}^* \quad (24)$$

将式 (24) 代入式 (22)，各项精确抵消，方程恒成立。由此， $(\mathbf{u}^*, p^*, \mathbf{f}^*)$ 构成三维定常不可压缩 Navier-Stokes 方程的一组精确解，其中 $\mathbf{u}^*$ 满足散度为零， $\mathbf{f}^*$ 为维持该流动所需的外部驱动力。在训练中，本文以 $\mathbf{u}^*$ 与 p^* 作为边界真值，以 $\mathbf{f}^*$ 作为方程残差中的源项，使 AQUA-PINN 的目标解解析已知，从而可以逐点评估重建误差。

4.4. 基准的数值特性

ABC 流为本文的实验提供了理想的验证平台，其原因可以概括为几点。第一，解的光滑性： $\mathbf{u}^*$ 与 p^* 均为无穷次可微的解析函数，不存在奇异性或间断，因此 PINN 的逼近误差可以纯粹归因于网络表达能力与优化过程，而不受解本身病态性的干扰。第二，结构复杂性：尽管光滑，ABC 流在 $A = B = C = 1$ 的参数下呈现出丰富的涡管结构与混沌轨迹 [30]，其空间结构远非平凡，足以检验方法捕捉三维流动细节的能力。第三，可参数化：粘度 ν 可以自由调节，从而在不改变解结构的前提下考察方法在不同扩散强度下的表现，这正是本文实验三粘度扫描的基础。第四，解析可导：解的各阶导数均有封闭形式，边界值与源项可以精确计算，消除了数值基准自身的误差来源。

值得指出的是，ABC 流的 Beltrami 性质在真实水体中并不普遍，但其作为制造解的价值恰恰在于它精确满足不可压缩 Navier-Stokes 方程，因此对任何声称求解该方程的方法都构成严格的检验。一个能够精确重建 ABC 流的方法，至少证明了其在强形式意义下求解三维不可压缩流动的基本能力；而一个在此基准上表现不佳的方法，则难以令人信服地推广到更复杂的真实流动。

4.5. 误差度量与网格无关性

在制造解基准上，误差可以逐点、逐阶地精确度量，这是制造解方法相对实验或仿真的核心优势。本文采用相对 L^2 误差作为主要指标，其定义为预测场与真值场之差在整个计算域上的平方积分与真值平方积分之比的平方根，如式 (25) 所示。相对误差的归一化处理使不同物理量、不同量级的场之间的误差具有可比性，尤其适合速度与压力这类幅值差异悬殊的场的联合评估。除相对 L^2 误差外，本文还记录方程残差的均方根，用以衡量解在强形式意义下对控制方程的满足程度，二者从“解与真值的距离”与“解与方程的相容性”两个互补角度刻画方法质量。

值得强调的一点是 AQUA-PINN 的网格无关性。经典离散方法的误差通常依赖网格尺度 h ，误差以 $\mathcal{O}(h^p)$ 的形式随网格加密而衰减，其中 p 为格式的收敛阶。与之不同，AQUA-PINN 以连续函数表示流场，其评估可以在任意坐标处进行，评估网格的分辨率与训练过程完全解耦。这意味着评估网格可以任意加密而不改变解本身，评估得到的误差收敛于连续函数之间的真实距离，而非受限于离散误差。本文实验中所使用的 $26 \times 26 \times 26$ 评估网格对于光滑解析解而言已足够稠密，评估网格的进一步加密不会显著改变报告的误差值。这一网格无关性在需要亚网格查询的游戏场景中具有直接的工程价值——例如粒子轨迹积分可以在任意精度下查询流场，而不受训练或渲染网格分辨率的限制。

五、实验设计与结果

5.1. 实验设置与评价指标

全部实验在统一的基准配置下进行。计算域取为立方体 $\Omega = [-\pi, \pi]^3$ ，物理参数取密度 $\rho = 1$ 、运动粘度 $\nu = 0.01$ （实验三除外），制造解系数 $A = B = C = 1$ 。基准网络采用四个隐藏层、每层 48 个神经元的全连接结构，默认激活函数为双曲正切，权重 $\lambda_{cont} = 10$ 、 $\lambda_{bc} = 100$ 。训练使用 Adam 优化器，初始学习率 10^{-3} ，并采用阶梯式衰减。所有实现基于 PyTorch 自动微分，在单机中央处理器上完成。

评价指标采用相对 L^2 误差。对速度场，误差定义为测试网格上预测值与真值之差的 Frobenius 范数除以真值范数：

$$e_u = \frac{(\sum_i \|\hat{\mathbf{u}}_i - \mathbf{u}_i^*\|^2)^{1/2}}{(\sum_i \|\mathbf{u}_i^*\|^2)^{1/2}} \quad (25)$$

压力场的相对误差 e_p 依同理定义。测试网格为覆盖计算域的均匀 $26 \times 26 \times 26$ 点阵，与训练配点相互独立，以排除训练点上的过拟合假象。除误差指标外，本文还记录训练损失曲线、收敛耗时与推理耗时，以全面刻画方法的精度与效率。

5.2. 实现细节与可复现性

本文的实现以 PyTorch 的自动微分引擎为核心，全部实验代码以单文件形式组织，可在未安装图形处理器驱动与专用依赖的普通个人计算机上直接运行。网络的前向传播与残差计算严格对应第 3 节给出的数学公式，其中一阶导数由反向模式自动微分求得，二阶导数通过对一阶导数再次求导得到。自动微分的优势在于其计算精度仅受限于浮点舍入，这一特性使得本文报告的所有残差与误差均不含有离散化误差成分。训练采用 Adam 优化器，其动量机制与自适应学习率有助于在非凸损失景观中稳定推进；学习率按训练进程分三段衰减，使优化后期能够在更精细的尺度上收敛。全部实验固定随机种子，以保证结果的可复现性。

在超参数选择上，本文遵循一条明确的原则：所有用于对比实验的超参数在组间保持一致，仅变化被考察的单一因素。例如，采样策略对比实验中，除采样策略本身外，配点数、网络结构、训练轮数与学习率均保持一致；粘度扫描中，除粘度外的一切设置均与基准相同。这一受控变量的实验设计确保了观察到的差异可以归因于被考察的因素本身，而不被其他混杂因素污染。本文所有实验的完整参数配置与随机种子已在代码中固化，读者可通过运行随文附带的实验脚本完整复现本文的全部数值结果。

5.3. 实验一：训练动力学与网络架构

第一个实验考察 AQUA-PINN 的训练动力学，并对网络架构的关键选择进行对比。图 2 给出了基准模型在三千次迭代内的损失演化，以及三种激活函数下损失曲线的对比。基准模型的总损失从初值约 1.03 单调下降至约 0.10，方程残差项与边界条件项同步收敛，未观察到明显的平台期或发散迹象。这一稳定收敛是后续所有实验得以开展的前提。

激活函数的对比揭示了值得注意的差异。双曲正切与 Swish 取得了相近的最终精度（速度误差分别为 6.83×10^{-2} 与 6.95×10^{-2} ）；正弦激活函数虽然理论上具有更强的表示高频场的能力 [13]，但在本文的网络深度与初始化下表现相对较差（ 8.46×10^{-2} ）。这一结果表明，对于本文所考察的光滑解析流场，激活函数的选择对最终精度的影响是有限的，但对收敛速度与稳定性的影响不可忽视。

网络宽度的消融实验进一步表明，当隐藏层宽度从 16 增加到 96 时，速度场的相对误差呈现先快速下降后趋于饱和的态势：宽度 16 时误差为 3.01×10^{-1} ，宽度 32 时降至 1.14×10^{-1} ，宽度 64 时进入 10^{-2} 量级（ 7.43×10^{-2} ），宽度 96 时进一步降至 6.18×10^{-2} 。这一观察印证了通用逼近定理的直觉——适度宽度的网络足以表示本文的光滑解，过宽的网络带来的是计算开销的上升而非精度的同步提升 [26][27]。综合精度与开销，本文在基准配置中采用宽度 48。




图 2: 实验一的训练动力学。(a) 基准模型三千次迭代的损失收敛曲线；(b) 三种激活函数（Tanh、Sine、Swish）的损失曲线对比，图例标注了各自的最终速度误差。




图 3: 网络隐藏层宽度对速度场相对误差的影响。宽度从 16 增至 96 时误差快速下降后趋于饱和。

5.4. 实验二：配点采样策略

第二个实验考察配点采样策略对精度的影响，这是 AQUA-PINN 拟均匀设计核心的实验验证。本文对比了三种采样策略——随机均匀采样、拉丁超立方采样与 Hammersley 低差异序列——并在配点数 $N_f \in \{500, 1000, 2000, 4000\}$ 上分别训练。图 4 以双对数坐标给出了速度误差随配点数的变化。

实验结果呈现出一幅较为微妙而富有启发性的图景。三种采样策略在本文的训练预算下达到了大体相当的速度误差水平（约 6×10^{-2} 至 1×10^{-1} ），且误差总体上随配点数增加而下降，双对数坐标下的斜率刻画了误差的收敛速率。在配点较少时（ $N_f = 500$ ），随机均匀采样的误差略低于两种拟均匀序列；随着配点数增至四千，拉丁超立方与 Hammersley 序列的误差逐渐低于随机均匀采样，二者在 $N_f = 4000$ 时达到约 6.5×10^{-2} ，较随机均匀采样的 7.4×10^{-2} 低约一个百分点。这一趋势的机理可以从两方面加以理解：在配点稀缺时，拟均匀序列的确定性覆盖未必优于随机采样的一次具体实现，且配点稀缺使训练欠收敛的波动主导了误差；而在配点充分时，拟均匀序列更均衡的覆盖开始显现优势，误差随配点增加而下降的趋势也更陡。这一观察提示，拟均匀采样作为 AQUA-PINN 的设计选择，其价值主要在中等以上配点规模时体现，以更低的误差水平与更陡的收敛趋势为训练提供更高质量的监督信号。关于重要性采样在 PINN 训练中的进一步讨论可参见 Nabian 等人的工作 [12]。

5.5. 实验三：粘度参数扫描

第三个实验考察运动粘度 ν 对重建精度的影响。粘度控制着流动中粘性扩散的相对强度，其倒数与雷诺数成正比，因此这一实验本质上考察的是方法在不同扩散强度下的表现。本文在 $\nu \in \{1.0, 0.1, 0.01, 0.001\}$ 上分别训练 AQUA-PINN，并记录速度与压力的相对误差。图 5 给出了误差随粘度的变化。

实验结果揭示了粘度与精度之间较为稳健的依赖关系。速度误差随粘度降低而略有上升，从 $\nu = 1$ 时的 4.35×10^{-2} 升至 $\nu = 0.1$ 时的 5.65×10^{-2} ，此后在 $\nu = 0.01$ 与 $\nu = 0.001$ 处基本保持平稳（约 5.7×10^{-2} ），未出现随粘度进一步降低而持续恶化的趋势；压力误差则对粘度不敏感，在 $\nu = 1$ 时为 4.25×10^{-1} ，在更低的粘度下稳定于约 3.7×10^{-1} 。这一行为可以从方程结构加以理解：速度场在低粘度下对流非线性作用相对增强，逼近难度略有上升，但其上升幅度有限且趋于饱和；压力场因其由速度场的全局散度结构隐式决定，对局部粘性强度的变化相对钝感。这一观察与 PINN 在刚性问题上失效模式的研究相一致 [11]，也印证了 Wang 等人关于梯度病理的分析 [9]。值得注意的是，即便在 $\nu = 0.001$ 的较强非线性情形下，速度误差仍保持在 10^{-2} 量级，表明 AQUA-PINN 对本文制造解在相当宽的粘度范围内具有稳健的重建能力。

5.6. 实验四：物理约束与纯数据回归的对比

第四个实验旨在回答一个根本性的问题：物理约束究竟为神经网络带来了多少价值。本文构造了一组对照——在完全相同的网络结构下，一组以纯监督方式训练，即仅以有限个标注点的真值 (u, v, w, p) 作为回归目标；另一组以 AQUA-PINN 方式训练，即仅以方程残差与边界条件作为监督信号。两组使用数量相同的训练点，分别取 $\{200, 600, 1500, 4000\}$ 四个档位。图 6 给出了两组方法的速度误差对比。

实验结果呈现出一幅需要在方法论层面仔细解读的图景。在训练点最稀缺的档位（200 点），纯数据回归与 AQUA-PINN 取得了几乎一致的速度误差（ 7.28×10^{-2} 对 7.22×10^{-2} ）；随着训练点增加，纯数据回归的误差持




图 4: 配点采样策略对比。双对数坐标下, 速度相对误差随配点数的变化; 拟均匀序列在配点充分时较随机均匀采样呈现出更陡的下降趋势。




图 5: 粘度扫描实验。双对数坐标下, 速度与压力的相对误差随运动粘度的变化; 速度误差随粘度降低而略有上升并趋于饱和, 压力误差对粘度较不敏感。

续下降至 3.07×10^{-2} (4000 点), 而 AQUA-PINN 的误差仅降至 5.87×10^{-2} 。这一对照说明, 在本文固定的训练轮数预算下, 当标注点充足时, 直接以真值监督的回归能够更快地收敛到更低的误差; 而物理约束的价值恰恰体现在标注稀缺的极端情形——AQUA-PINN 在完全无需内部流场标注的前提下, 仅凭边界条件与方程残差就取得了与 200 个标注点监督训练相当的精度。换言之, 物理先验以零标注成本替代了数据标注: 标注越昂贵、越稀缺, 物理约束的相对价值越突出。需要指出的是, 这一对照受限于双方共同的训练轮数预算——物理残差的优化天然比直接回归更困难, 若为 AQUA-PINN 分配更充分的优化预算, 其在标注稀缺情形下的优势有望进一步扩大。这一观察也为未来的实验设计指明了方向: 公平比较物理约束与数据驱动的价值, 应当在标注成本与优化成本两个维度上同时对齐。需要强调的是, AQUA-PINN 在训练过程中并不需要任何内部流场的真值标注——它所使用的监督信号只有边界条件与方程残差, 而方程残差是解析可求的。这一特性使 AQUA-PINN 在缺乏测量数据的场景中具有纯数据方法所不具备的适用性。




图 6: 物理约束与纯数据回归的对比。双对数坐标下, 速度误差随训练点数的变化; 在标注稀缺 (200 点) 时两者相当, 标注充足时纯监督回归占优, 但 AQUA-PINN 全程无需内部标注。

5.7. 实验五：损失权重消融

第五个实验考察式 (17) 中两个权重超参数 λ_{bc} 与 λ_{cont} 对精度的影响。本文在 $\lambda_{bc} \in \{1, 10, 100, 1000\}$ 与 $\lambda_{cont} \in \{0.1, 1, 10, 100\}$ 的二维网格上分别训练, 并以热力图的形式呈现速度误差的对数值。图 7 给出了消融结果。

热力图揭示了损失权重对精度的结构化影响。在 λ_{bc} 处于低至中等水平 (1 至 10) 时, 网络取得了最低的速度误差 (约 4.2×10^{-2} 至 4.4×10^{-2}); 当 λ_{bc} 升高至 1000 时, 边界损失过度主导训练, 方程残差项被压制, 内部区域的动量平衡无法得到满足, 误差显著恶化至 10^{-1} 量级以上。连续性权重 λ_{cont} 的影响相对平缓, 在 λ_{cont} 处于 0.1 至 10 的中低区间时精度对之较不敏感, 但在 λ_{bc} 极低且 λ_{cont} 极高 (10^2) 的角落处, 连续性约束过度主导, 同样导致误差升高。综合而言, 热力图揭示了一个较宽的低误差平台, 其中心位于 λ_{bc} 与 λ_{cont} 均处于低至中等水平的区域, 本文基准配置 $\lambda_{bc} = 100$ 、 $\lambda_{cont} = 10$ 落于该平台的边缘。这一消融实验为损失权重的选取提供了经验依据, 也与 Wang 等人关于损失项平衡的分析相呼应 [9]。从实践指导的角度看, 这一结果提示开发者: 在迁移到新的流动问题时, 应将边界条件权重设置在使边界损失与方程残差大致同阶的水平, 并避免任一权重过度主导, 而不必在广阔的权重空间中进行盲目的网格搜索。

5.8. 实验六：三维渲染与可视化

第六个实验从视觉维度检验 AQUA-PINN 重建结果的质量, 这也是本文面向游戏应用的关键环节——数值精度最终要转化为可感知的视觉真实感。本文以训练完成的网络为查询引擎, 生成三类可视化。图 8 为 $z = 0$ 平面上的流线图, 以速度大小着色, 直观呈现了 ABC 流涡管结构在切片平面上的投影; 流线的平滑性与对称性与




图 7: 损失权重消融。热力图展示速度相对误差（对数尺度）随边界权重 λ_{bc} 与连续性权重 λ_{cont} 的变化；低误差平台位于两权重均处于低至中等水平的区域， λ_{bc} 过高时误差显著恶化。

解析解一致，说明网络重建的流场在方向与幅值上均与真值吻合。图 9 为三维粒子平流渲染，将一组种子粒子沿网络预测的速度场以二阶 Runge-Kutta 方式推进，粒子轨迹勾勒出流场的三维涡结构，颜色按粒子初始深度渐变，呈现出类似水体流动的视觉效果。图 10 为沿 z 方向五个切片上法向速度分量 w 的伪彩色图，展示了流场在垂直方向上的连续演化。

这三类可视化从不同侧面印证了一个共同的结论：AQUA-PINN 所重建的流场不仅在逐点误差的意义上接近真值，其宏观结构与视觉表现也与真值一致。这一性质对游戏应用尤为重要——玩家的感知建立在宏观流动结构之上，而非逐点的浮点误差；只要流线、涡结构与速度梯度的宏观形态正确，即便存在局部的微小误差，视觉效果依然可信。这一观察也呼应了图形学中关于感知保真的长期认识：视觉系统的感知阈值与数值误差的度量标准并不重合，一个在逐点意义上误差可观的表示，完全可能在感知意义上与真值不可区分。因此，对游戏流体模拟而言，恰当的验收标准应当同时包含数值误差与视觉保真两个维度，而本文实验六与实验一至五的相互印证，正是这一双重标准的初步实践。

5.9. 实验七：部署成本分析

第七个实验将 AQUA-PINN 置于游戏实时性的语境下加以度量。本文测量了训练完成的网络在 32^3 、 64^3 、 96^3 、 128^3 四种分辨率网格上的单帧推理耗时与内存占用。图 11 给出了推理耗时随网格点数的变化。

实验结果展示了神经网络推理耗时随查询点数近线性增长的特性。在 32^3 （约 3.3 万点）分辨率下，单帧全场推理耗时约 10.4 ms，已接近 60 帧每秒对应的 16.7 ms 单帧预算； 64^3 （约 26 万点）耗时约 93.8 ms， 128^3 （约 210 万点）耗时约 734 ms，与点数近似成正比。这一结果表明，在中央处理器上对全场进行密集求值并不适合直接嵌入实时帧循环，但这一结论需要结合游戏的查询模式加以理解：游戏中的流体查询通常是稀疏的——漂浮物、粒子与交互点每帧仅需查询数千至数万个坐标，而非覆盖全场的百万级网格。按单点约 0.32 微秒的推理成本线性外推，一万个查询点的单帧成本约为 3.2 ms，完全落在帧预算之内。整个流场的参数化表示仅需存储 7444 个浮点参数，内存占用约 0.03 MB，与同等分辨率的网格流场相比缩减了数个数量级。更重要的是，这一推理成本与训练成本完全解耦——训练是在开发阶段一次性完成的离线过程，运行时的成本仅为一次前向传播。

当然，本文并不主张以神经网络推理直接替代逐帧求解的经典流体引擎，后者的优势在于处理时间演化的动态场景与复杂边界交互。AQUA-PINN 的恰当定位是作为静态或准静态流场的代理模型：流场结构在开发阶段离线训练完成后，运行时以查询方式提供任意坐标处的速度与压力，用于环境流场、漂浮物受力评估、粒子轨迹积分等需要高分辨率场值查询的任务。这一部署范式与图形学中预计算辐射传输、预计算碰撞等离线烘焙技术一脉相承，是“离线训练、在线推理”思想在流体模拟领域的自然延伸。

为了更全面地理解这一部署范式的成本结构，有必要将训练成本与推理成本分开度量并加以对比。训练成本是一次性的离线开销，其量级由配点数、网络规模与迭代次数共同决定，在本文的基准配置下约为数分钟量




图 8: AQUA-PINN 流场在 $z = 0$ 平面上的流线渲染，颜色表示速度大小。流线平滑且呈现对称涡结构，与 ABC 流解析解一致。




图 9: 三维粒子平流渲染。种子粒子沿 AQUA-PINN 预测速度场推进，轨迹勾勒出三维涡管结构，颜色按深度渐变。




图 10: 沿 z 方向五个切片的法向速度分量 w 伪彩色图，展示流场在垂直方向上的连续演化。

级，且可以借助图形处理器进一步压缩。推理成本则是运行时的持续性开销，其量级仅取决于网络前向传播的浮点运算次数，与训练配点数完全无关——这一解耦正是“离线训练、在线推理”范式的核心价值所在。从投入产出比的角度看，只要一个静态流场在游戏中被反复查询的次数超过某一阈值，离线训练的一次性成本就可以被运行时推理的持续节省所摊薄。对于水体环境流场这类在整个游戏生命周期内被持续查询的对象，这一摊薄效应尤为显著。这一成本结构分析为游戏开发者提供了清晰的决策依据：当流场查询是高频率、长周期的运行时需求时，以 AQUA-PINN 为代表的神经代理模型在经济性上具有结构性的优势。




图 11: 部署成本分析。双对数坐标下，单帧全场推理耗时随网格点数的变化，呈近线性增长；游戏常见的稀疏查询（数千至数万点）单帧成本处于毫秒量级，落在 60 FPS 的帧预算之内。

5.10. 结果汇总

表 1 汇总了基准模型的关键指标，表 2 至表 7 分别汇总了各实验的定量结果。综合全部实验，可以得出如下总体结论：AQUA-PINN 在三维不可压缩定常流上能够以 10^{-2} 量级的速度误差完成场重建；拟均匀采样在配点充分时带来更陡的收敛趋势，物理约束在标注稀缺时以零标注成本提供与监督回归相当的精度；而训练完成后的推理耗时随查询点数近线性增长，在游戏常见的稀疏查询场景下落在实时应用的可行范围之内。这些结论彼此印证、相互支撑，共同勾勒出 AQUA-PINN 作为游戏流体代理模型的完整能力画像。

5.11. 收敛阶估计

实验二的采样对比数据为估计方法的收敛阶提供了依据。在配点采样的语境下，误差对配点数的依赖可以经验地拟合为幂律关系 $e_u \propto N_f^{-\alpha}$ ，其中指数 α 度量了误差随采样密度增加而衰减的速率，双对数坐标下的拟合斜率即为此指数。表 4 与图 4 中，各采样策略的对数斜率反映了该方法在配点意义上的收敛速率。值得说明的是，这一收敛阶与经典有限差分格式的空间收敛阶具有不同的含义——后者度量误差对网格尺度的依赖，而前者度量蒙特卡洛型配点近似的误差对采样数的依赖。对于以随机或拟随机配点近似损失积分的方法，理论上

表 1: 基准模型关键指标汇总

指标	数值
网络结构	$3 \rightarrow 48 \times 4 \rightarrow 4$
可训练参数量	7444
训练配点数 N_f	3000
边界点数 N_b	1200
训练迭代次数	3000
训练耗时	约 220 s
速度相对 L^2 误差	3.75×10^{-2}
压力相对 L^2 误差	2.63×10^{-1}
最终方程残差损失	5.35×10^{-2}
最终边界损失	4.90×10^{-4}

表 2: 激活函数对比 ($N_f = 800, 1200$ 次迭代)

激活函数	速度误差	压力误差
Tanh	6.83×10^{-2}	3.49×10^{-1}
Sine	8.46×10^{-2}	6.18×10^{-1}
Swish	6.95×10^{-2}	5.72×10^{-1}

表 3: 网络宽度消融 ($N_f = 800, 1000$ 次迭代)

隐藏层宽度	速度误差	压力误差
16	3.01×10^{-1}	1.44
32	1.14×10^{-1}	6.14×10^{-1}
64	7.43×10^{-2}	4.48×10^{-1}
96	6.18×10^{-2}	3.86×10^{-1}

表 4: 采样策略对比 (速度相对误差, 1000 次迭代)

采样策略	$N_f = 500$	$N_f = 1000$	$N_f = 2000$	$N_f = 4000$
随机均匀	7.77×10^{-2}	8.00×10^{-2}	7.12×10^{-2}	7.39×10^{-2}
拉丁超立方	1.00×10^{-1}	7.83×10^{-2}	6.99×10^{-2}	6.55×10^{-2}
Hammersley	9.66×10^{-2}	7.97×10^{-2}	7.01×10^{-2}	6.49×10^{-2}

表 5: 粘度扫描 (相对误差, 1500 次迭代)

运动粘度 ν	速度误差	压力误差
1.0	4.35×10^{-2}	4.25×10^{-1}
0.1	5.65×10^{-2}	3.74×10^{-1}
0.01	5.69×10^{-2}	3.74×10^{-1}
0.001	5.71×10^{-2}	3.76×10^{-1}

表 6: 物理约束与纯数据回归对比 (速度相对误差)

方法	200 点	600 点	1500 点	4000 点
纯数据回归	7.28×10^{-2}	3.50×10^{-2}	3.17×10^{-2}	3.07×10^{-2}
AQUA-PINN	7.22×10^{-2}	7.77×10^{-2}	6.58×10^{-2}	5.87×10^{-2}

表 7: 部署成本分析（单帧推理）

分辨率	网格点数	单帧推理耗时
32^3	32768	10.41 ms
64^3	262144	93.82 ms
96^3	884736	276.79 ms
128^3	2097152	733.66 ms

的蒙特卡洛收敛速率为 $\mathcal{O}(N^{-1/2})$ ，而低差异序列可将之提升至接近 $\mathcal{O}(N^{-1})$ 的准蒙特卡洛速率。本文实验二在双对数坐标下拟合得到的斜率分别为：随机均匀约 -0.04 ，拉丁超立方约 -0.20 ，Hammersley 序列约 -0.19 。这些实测斜率在相对次序上与理论预期一致——拟均匀序列的收敛趋势较随机采样更陡——但在绝对值上显著低于理论的准蒙特卡洛速率。这一差距的机理在于：在本文有限的训练轮数预算下，误差的主导成分是优化误差而非采样误差，配点密度的增加只能部分转化为精度提升，因而实测的收敛斜率被优化误差的残余所拉平。这一观察反过来印证了第 3.7 节关于优化预算的讨论——采样策略的收益只有在优化充分收敛之后才能完全兑现；尽管如此，拟均匀序列相对更陡的斜率已经预示着其在更充分训练下的潜力。

这一收敛阶估计对工程实践具有直接的指导意义。给定一个目标精度，开发者可以依据幂律关系反推所需的最少配点数，从而在训练成本与精度之间作出有依据的权衡。同时，收敛阶的估计也为方法间的公平比较提供了标尺——两种方法只有在相同的配点预算下比较误差，结论才具有可比性。本文在实验四的物理与数据对比中即遵循了这一原则，确保了结论的公平性。

六、讨论

6.1. 与经典流体模拟方法的对比

将 AQUA-PINN 与游戏图形学中成熟的流体模拟方法并置考察，有助于准确界定本文方法的适用边界。经典网格法以逐帧离散求解为核心，其对时间演化的动态流动、自由表面与复杂边界的处理已经过数十年的工程打磨，在动态场景中仍然不可替代 [14][16]。AQUA-PINN 的定位在静态或准静态流场这一细分场景，其价值体现在三个维度：查询分辨率与训练分辨率解耦所带来的表示灵活性、解析微分所带来的残差精度、以及训练后低延迟推理所带来的部署效率。本文的实验已经表明，在上述细分场景中，AQUA-PINN 能够以远低于经典方法的内存占用提供连续的场表示，同时保持 10^{-2} 量级的速度精度。因此本文方法对经典方法构成的是互补，而不是替代——一个完整的游戏水体系统完全可以将经典方法用于动态自由表面，而以 AQUA-PINN 提供环境流场的查询式底座。

6.2. 误差来源的深入剖析

本文实验中一个值得深入讨论的现象是压力误差系统性高于速度误差。在基准模型中，速度相对误差为 3.75×10^{-2} ，而压力相对误差为 2.63×10^{-1} ，二者相差近一个数量级。这一现象在 PINN 求解不可压缩流的文献中反复出现，其根源可以从方程结构加以理解。压力在不可压缩 Navier-Stokes 方程中仅以梯度的形式出现，方程对压力本身具有一个常数平移的规范自由度；换言之，压力场的绝对值不可由方程唯一确定，只有其梯度受动量平衡约束。当网络以残差平方和作为训练目标时，压力项仅通过其导数进入损失，对压力绝对值的学习信号相对微弱，导致压力场在幅值上较速度场更难收敛。此外，压力作为拉格朗日乘子，其解的光滑性通常低于速度场，这也增加了表示的难度。这一机理分析为未来改进指明了方向：引入压力的正则化、以速度散度投影替代压力显式输出、或采用混合变量公式 [31]，都有望缩小压力与速度之间的误差差距。

6.3. 面向实时游戏部署的工程考量

AQUA-PINN 从实验原型走向游戏工程，还需要跨越若干现实门槛。其一是训练数据的通用性：本文的制造解基准具有解析真值，而真实游戏中的水体流场往往没有真值可供监督，此时训练监督信号仅剩方程残差与边界条件，训练难度上升，需要更精细的权重策略与可能的数据辅助。其二是几何适应：本文的计算域为规则的立方体，而真实水体边界多为复杂几何，需要借助坐标变换、域分解或复合网络等技巧加以适应 [32]。其三是时间维度：本文聚焦定常流，而游戏中的水体多为时变流动，将方法推广到时变情形需要在时空联合域上训练，计算成本将显著上升。其四是硬件部署：本文的推理在中央处理器上完成，而游戏运行时往往还需要将计算让位于渲染管线，如何在图形处理器上与渲染共享资源、或通过模型量化与剪枝进一步压缩推理成本，是工程落地的关键问题。

在工程实现路径上，AQUA-PINN 的模型资产化具有清晰的技术路线。训练完成的网络参数可以导出为通用

的模型交换格式，在运行时由轻量级的推理后端加载，这一过程与游戏引擎中常见的着色器编译与资源打包流程并无本质区别。推理的前向传播由矩阵乘与逐元素非线性构成，天然适合图形处理器的大规模并行执行，也可以借助半精度浮点与算子融合进一步压缩延迟。对于查询密集的场景，批量查询可以显著摊薄单次调用的开销；对于稀疏查询，则可以采用按需求值策略，仅在需要处查询场值，从而避免对全场的无谓计算。这些工程手段的可行性已经在深度学习推理部署的广泛实践中得到验证，将其移植到游戏流体查询场景并不存在根本性的障碍。本文实验七所测得的毫秒级推理成本，正是在未做任何专门优化的通用实现下取得的，这为进一步的工程优化预留了充足的空间。

6.4. 与相关工作的进一步对照

将本文的实验结果置于已有文献的坐标中，可以更清晰地定位其贡献。在不可压缩 Navier-Stokes 方程的 PINN 求解方面，Jin 等人的 NSFnets 以类似的强形式残差构造在二维基准上取得了令人满意的精度 [6]，本文的 AQUA-PINN 在方法构架上与其同源，区别在于本文将验证对象推进到三维，并以制造解基准提供了逐点可比的定量结论。在采样策略方面，Nabian 等人的重要性采样研究表明，非均匀采样能够显著提升 PINN 的训练效率 [12]，本文的拟均匀采样可以视作该思想在低差异序列方向上的实现与验证，实验二的结果与之一致。在训练稳定性方面，Wang 等人关于梯度病理的分析 [9] 为本文实验五的权重消融提供了理论解释，本文的消融结果反过来以具体的三维不可压缩流实例印证了其分析。在游戏流体模拟方面，本文与经典方法的关系已在第 6.1 节阐明，此处不再赘述。综合而言，本文的价值在于以三维不可压缩流这一具体对象为载体，对已有 PINN 技术的采样、加权与表示三个维度进行了系统的实证检验，并将结论锚定在游戏实时性的工程语境之中，从而超越了孤立的方法复现。

6.5. 可解释性与不确定性

神经网络方法常被诟病为缺乏可解释性，但 AQUA-PINN 在这一问题上具有独特的优势：其训练目标中的每一项都具有明确的物理含义，损失函数的下限直接对应解对控制方程的满足程度，因此训练过程本身是可解释的——损失下降意味着方程残差减小，即解在物理意义上变得更加可信。这一“以物理残差为语言”的可解释性，是数据驱动黑箱方法所不具备的。在不确定性方面，AQUA-PINN 的方程残差场可以作为误差的局部指示器：残差较大的区域恰是解对控制方程满足较差的区域，因而残差的空间分布为工程部署中的置信度评估提供了依据。在本文实验六的误差场可视化中，误差的空间分布与残差的空间分布呈现正相关，印证了以残差指示误差的可行性。这一性质在游戏工程中具有实际价值：开发者可以依据残差分布识别出流场中置信度较低的区域，并在这些区域回退到经典求解器，从而实现混合精度的自适应策略。进一步而言，这种以物理残差为置信度信号的做法，使神经代理模型的部署具备了可审计的物理依据，在严肃游戏与仿真教育等对正确性有严格要求的场景中尤为珍贵。

6.6. 局限性

本文的工作存在若干需要坦承的局限。首先，制造解基准虽然提供了严格的解析真值，但 ABC 流的 Beltrami 性质具有特殊性，其对流项的简化使本文基准在非线性的强度上低于一般的真实湍流；将结论推广到更强非线性的流动需要更谨慎的验证。其次，本文的实验规模受限于单机中央处理器的算力，网络规模与训练点数均相对有限，更大规模训练下的精度上限尚未探明。再次，本文对压力的误差分析揭示了方法在压力重建上的相对不足，这一不足在需要精确压力场的应用（如浮力、声学耦合）中可能构成制约。最后，本文未涉及自由表面这一游戏水体的标志性特征，液面追踪与 PINN 的结合是一个有待独立研究的课题。这些局限为本文结论的适用范围划定了边界，也为未来的改进工作指明了方向。

七、结论与展望

本文面向实时游戏中的三维水流仿真，提出并实现了 AQUA-PINN，一个以三维不可压缩 Navier-Stokes 方程强形式残差为约束的物理信息神经网络方法。方法以拟均匀配点采样与自适应损失加权为核心设计，在无需网格离散的前提下重建定常流场的速度与压力，并通过七个维度的系统实验对其精度、效率与视觉保真进行了完整刻画。本文以具有解析解的三维 ABC 定常流为制造解基准，开展了七个维度的系统实验，据此归纳出如下结论：第一，AQUA-PINN 能够在约三千次迭代内将速度场相对误差降至 10^{-2} 量级，训练过程稳定收敛；第二，拟均匀采样策略在配点充分时较随机均匀采样呈现出更陡的收敛趋势与更低的误差，其价值随配点规模增大而显现；第三，物理约束在标注稀缺时以零标注成本取得了与纯监督回归相当的精度，展现了物理先验对数据标注的替代价值；第四，粘度扫描与损失权重消融分别刻画了方法在低粘度情形下的稳健边界与权重配置的合理区间；第五，三维渲染验证了重建流场在视觉上与真值一致，而部署成本分析表明训练后的推理耗时随查询点数近线性增长，在游戏常见的稀疏查询场景下落在实时帧预算之内。

上述结论共同指向一个清晰的图景：物理信息神经网络可以作为游戏流体模拟中静态与准静态流场的高效代理模型，以“离线训练、在线推理”的方式与经典动态求解方法形成互补。本文的价值在于以严格的制造解基准与多维实验，将这一图景从概念推向了可度量的工程结论。

从更宏观的视角审视，本文的工作回应了游戏物理研究中一个长期的呼唤：让物理模拟的精度评估从“看起来像”走向“测得准”。长期以来，游戏流体模拟的验收标准以视觉观感为主导，精度评估缺乏可与真值比对的定量基准。本文以制造解为桥梁，将不可压缩流体动力学的严格标准引入游戏物理的语境，使流体模拟的每一项精度结论都可以归结为可复现的数值。这一方法论层面的贡献，其意义可能超出本文具体的方法实现本身——它为严肃游戏、仿真教育与人机交互研究提供了一套可复用的物理保真评估范式，使“物理是否可信”这一问题从主观判断转化为可检验的科学命题。

未来工作将沿五个方向展开。其一，将方法推广到时变不可压缩流，在时空联合域上训练，使 AQUA-PINN 能够处理动态水流与波浪。其二，引入压力重构的改进策略，例如散度投影、压力正则化或混合变量公式，以缩小压力与速度之间的误差差距。其三，将计算域从规则立方体扩展到复杂几何，借助坐标变换与域分解技术使方法适应真实水体边界。其四，在图形处理器上部署并优化推理管线，结合模型量化与剪枝，将 AQUA-PINN 集成为游戏引擎中的可插拔流体查询组件，并在真实游戏场景中开展端到端的性能与视觉质量评估。其五，沿前序综述所展望的神经物理混合模型（NeuroFLIP）路线 [21]，将 AQUA-PINN 与经典流体求解器在统一框架下混合，以神经表示提供低频环境流场、以经典方法处理高频动态细节，实现精度与效率的分层互补。我们相信，随着物理信息机器学习方法的成熟与硬件算力的演进，以神经网络为载体的连续流场表示将在实时交互仿真中扮演日益重要的角色，而本文所建立的方法与基准，正是这一演进道路上的一个可验证的起点。

References

- [1] I. E. Lagaris, A. Likas, and D. I. Fotiadis. “Artificial neural networks for solving ordinary and partial differential equations”. In: *IEEE Transactions on Neural Networks* 9.5 (1998), pp. 987–1000.
- [2] M. Raissi, P. Perdikaris, and G. E. Karniadakis. “Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations”. In: *Journal of Computational Physics* 378 (2019), pp. 686–707.
- [3] M. Raissi, A. Yazdani, and G. E. Karniadakis. “Hidden fluid mechanics: Learning velocity and pressure fields from flow visualizations”. In: *Science* 367.6481 (2020), pp. 1026–1030.
- [4] G. E. Karniadakis et al. “Physics-informed machine learning”. In: *Nature Reviews Physics* 3.6 (2021), pp. 422–440.
- [5] S. Cai et al. “Physics-informed neural networks (PINNs) for fluid mechanics: A review”. In: *Acta Mechanica Sinica* 37.12 (2021), pp. 1727–1738.
- [6] X. Jin et al. “NSFnets (Navier-Stokes flow nets): Physics-informed neural networks for the incompressible Navier-Stokes equations”. In: *Journal of Computational Physics* 426 (2021), p. 109951.
- [7] L. Sun et al. “Surrogate modeling for fluid flows based on physics-constrained deep learning without simulation data”. In: *Computer Methods in Applied Mechanics and Engineering* 361 (2020), p. 112732.
- [8] R. Mojjani, M. Balajewicz, and P. Hassanzadeh. “Lagrangian PINNs for incompressible flows”. In: *Journal of Computational Physics* (2022).
- [9] S. Wang, Y. Teng, and P. Perdikaris. “Understanding and mitigating gradient flow pathologies in physics-informed neural networks”. In: *SIAM Journal on Scientific Computing* 43.5 (2021), A3055–A3081.
- [10] S. Wang, X. Yu, and P. Perdikaris. “Improved architectures for training physics-informed neural networks”. In: *Computer Methods in Applied Mechanics and Engineering* 397 (2022), p. 115076.
- [11] A. Krishnapriyan et al. “Characterizing possible failure modes in physics-informed neural networks”. In: *Advances in Neural Information Processing Systems* 34 (2021), pp. 26548–26560.
- [12] M. A. Nabian, R. J. Gladstone, and H. Meidani. “Efficient training of physics-informed neural networks via importance sampling”. In: *Computer-Aided Civil and Infrastructure Engineering* 36.8 (2021), pp. 962–977.
- [13] V. Sitzmann et al. “Implicit neural representations with periodic activation functions”. In: *Advances in Neural Information Processing Systems* 33 (2020), pp. 7462–7473.
- [14] J. Stam. “Stable fluids”. In: *Proceedings of the 26th Annual Conference on Computer Graphics and Interactive Techniques* (1999), pp. 121–128.
- [15] R. Bridson, R. Fedkiw, and M. Muller-Fischer. “Fluid simulation”. In: *ACM SIGGRAPH 2007 courses* (2007).

- [16] R. Bridson. *Fluid Simulation for Computer Graphics*. 2nd. CRC Press, 2015.
- [17] R. Fedkiw, J. Stam, and H. W. Jensen. “Visual simulation of smoke”. In: *Proceedings of the 28th Annual Conference on Computer Graphics and Interactive Techniques* (2001), pp. 15–22.
- [18] J. J. Monaghan. “Smoothed particle hydrodynamics”. In: *Annual Review of Astronomy and Astrophysics* 30 (1992), pp. 543–574.
- [19] M. Müller, D. Charypar, and M. Gross. “Particle-based fluid simulation for interactive applications”. In: *Proceedings of the 2003 ACM SIGGRAPH/Eurographics Symposium on Computer Animation* (2003), pp. 154–159.
- [20] M. Macklin and M. Müller. “Position based fluids”. In: *ACM Transactions on Graphics* 32.4 (2013), pp. 1–12.
- [21] dororo, copycat666, yifanNie, et al. 基于计算流体力学的游戏 “物理水” 渲染技术综述. 电子游戏科学与技术. EB/OL. May 2025. URL: <https://journalofest.netlify.app/nowbase.html?doi=020716F163> (visited on 09/26/2026).
- [22] R. Temam. *Navier-Stokes Equations: Theory and Numerical Analysis*. Vol. 343. American Mathematical Society, 2001.
- [23] D. P. Kingma and J. Ba. “Adam: A method for stochastic optimization”. In: *arXiv preprint arXiv:1412.6980* (2014).
- [24] X. Glorot and Y. Bengio. “Understanding the difficulty of training deep feedforward neural networks”. In: *Proceedings of the 13th International Conference on Artificial Intelligence and Statistics* (2010), pp. 249–256.
- [25] L. Lu et al. “Physics-informed neural networks with hard constraints for inverse design”. In: *SIAM Journal on Scientific Computing* 43.6 (2021), B1105–B1132.
- [26] G. Cybenko. “Approximation by superpositions of a sigmoidal function”. In: *Mathematics of Control, Signals and Systems* 2.4 (1989), pp. 303–314.
- [27] K. Hornik, M. Stinchcombe, and H. White. “Multilayer feedforward networks are universal approximators”. In: *Neural Networks* 2.5 (1989), pp. 359–366.
- [28] V. I. Arnold. “Sur la topologie des écoulements stationnaires des fluides parfaits”. In: *Vladimir I. Arnold-Collected Works: Hydrodynamics, Bifurcation, and Invariant Theory 1965–1972* (1965), pp. 15–18.
- [29] S. Childress. “New solutions of the kinematic dynamo problem”. In: *Journal of Mathematical Physics* 11.10 (1970), pp. 3063–3076.
- [30] T. Dombre et al. “Chaotic streamlines in the ABC flows”. In: *Journal of Fluid Mechanics* 167 (1986), pp. 353–391.
- [31] R. Glowinski. “A three-field formulation for the Navier-Stokes equations”. In: (2003).
- [32] X. Meng et al. “PPINN: A parallel physics-informed neural network for complex geometries”. In: *Journal of Computational Physics* 428 (2021), p. 110061.