

SKIN_ERA：CS:GO/CS2 饰品市场交易数据集（2013-2023）

SKIN_ERA: A 10-Year Trading Dataset of the CS:GO/CS2 Skin Market (2013–2023)

copycat666^{1,2*}, Charles¹, doro^{1,2}, mysteriousK^{1,2}

1. 《电子游戏科学与技术》编辑委员会；2. EigenLife 机器学习实验室，东北电力大学，吉林

*: Corresponding Author

摘要：本文构建并公开了一个面向 CS:GO/CS2 饰品市场研究的多源时序数据集——SKIN_ERA。该数据集融合了 Kaggle 平台的 Steam 市场价格历史记录与 CSGO-API 项目的静态属性信息，包含 20,575 个独立饰品、34,615,938 条价格记录，时间跨度从 2013 年 4 月至 2023 年 5 月，共计约 10 年。通过名称标准化算法，成功将 11,924 个饰品与稀有度、武器类型、磨损档位等静态属性关联，整体匹配率为 58.0%。统计分析表明，饰品价格呈高度右偏分布（偏度 7.54），0 至 20 美元区间占总记录的 85.4%；价格与成交量呈显著正相关（ $r=0.7026$ ）；四象限分析揭示约 34% 的交易记录处于“高价低量”状态，反映了虚拟资产市场中存在的流动性风险。基于该数据集，本文开展了市场次日成交额预测的基准实验，对比了 XGBoost、LightGBM、Random Forest、MLP 和 LSTM 五种模型的性能。实验结果表明，LSTM 取得了最优预测效果（MAE=453,841 美元， $R^2=0.6268$ ），验证了序列建模方法在虚拟资产预测任务中的优势；而 MLP 由于缺乏序列建模能力导致严重欠拟合（ $R^2=-0.8935$ ）。SKIN_ERA 数据集可服务于政策冲击评估、市场有效性检验、虚拟资产定价因子分析、流动性风险管理以及机器学习算法验证等多个研究方向，为理解虚拟经济、评估政策冲击、检验市场理论提供了不可替代的数据支撑。

数据集已公开发布，[点击下载](#)

关键词：CS:GO；CS2；饰品市场；虚拟资产；时间序列预测；LSTM；XGBoost；LightGBM

一、简介

电子竞技虚拟物品市场已成为数字经济中不可忽视的组成部分。以 Valve 公司开发的《反恐精英：全球攻势》（CS:GO）及其续作《反恐精英 2》（CS2）中的饰品交易市场为例，自 2013 年饰品系统上线以来，该市场已发展成为一个估值约 60 亿美元、日交易量逾 500 万美元的庞大虚拟经济体系。饰品不仅具有游戏内的视觉呈现功能，更承载了稀缺性、收藏价值和社交属性，形成了独特的经济生态。

2025 年 10 月，Valve 对饰品合成机制进行了重大调整，将顶级饰品的获取方式从传统的概率性开箱转变为确定性合成——玩家可用 5 件红色品质皮肤 100% 合成一件金色品质的刀具或手套。这一变更从根本上改变了饰品的稀缺性定价逻辑，导致市场总估值在短期内蒸发约 30%，引发了关于虚拟资产定价机制、市场效率以及平台治理的广泛讨论。

在此背景下，构建一个高质量、长周期、多属性的饰品交易数据集，对于理解虚拟资产市场的运行规律、检验市场有效性、评估政策冲击的影响具有重要的学术价值。然而，现有研究面临两个关键挑战：一是缺乏覆盖足够长时间跨度的交易数据；二是缺少将价格序列与饰品静态属性（稀有度、磨损、武器类型等）相关联的结构化数据。

1.1. 现有数据集简述及其局限性

目前学术界和工业界公开的 CS:GO/CS2 相关数据集主要包含以下两类：

（1）Steam 市场历史价格数据集（Kaggle / leawind）

该数据集是目前规模最大的公开价格时序数据集，包含 20,575 个饰品、3,461 万条价格记录，时间跨度从 2013 年 4 月至 2023 年 5 月。每个饰品的历史价格以独立的 CSV 文件存储，包含时间戳、美元价格和销量三个字段。该数据集的优势在于覆盖面广、时间跨度长，但存在两个主要局限：一是缺乏饰品的静态属性信息（如稀有度、武器类型、磨损范围等），使得研究人员无法从品类特征维度分析价格行为；二是饰品名称以 Base64 编码存储，且命名格式包含 StatTrak™ 标记和磨损档位后缀，增加了数据使用的门槛。

（2）CSGO-API 静态属性数据集（GitHub / ByMykel）

该数据集系统性地整理了 CS:GO/CS2 所有物品的静态属性，涵盖武器皮肤、贴纸、探员、箱子、音乐盒等 11 个品类，共计 15,915 个物品。以皮肤数据为例，每条记录包含 19 个字段：物品唯一标识、名称、武器类型、稀有度、最小/最大磨损值、是否 StatTrak™、是否纪念品、所属收藏品、来源箱子等。该数据集的优势在于属性维度丰富、数据结构规范，但其本质是静态元数据，不包含任何时间序列信息，无法单独用于价格趋势分析。

1.2. 数据集构建思路简述

针对上述数据集的互补性特征，本研究将 Steam 市场价格时序数据与 CSGO-API 静态属性数据进行多源融合，构建一个属性完备、时间连续、易于使用的标准化数据集——SKIN_ERA。

1. 融合策略：以 Kaggle 价格数据集中的 20,575 个物品为索引，通过饰品名称的标准化处理（去除 StatTrak™ 标记、磨损档位后缀等），与 CSGO-API 中 15,915 个物品的静态属性进行匹配。匹配后的数据集每条记录同时包含价格时序信息（日期、价格、销量）和物品属性信息（类型、稀有度、武器、磨损范围等），形成便于后续分析的宽表结构。

2. 数据规模：融合后的数据集包含 34,615,938 条价格记录，覆盖 2013 年 4 月至 2023 年 5 月共计约 10 年、3,660 天的交易历史，匹配成功率为 58.0%。未匹配的 8,651 个物品主要为社区贴纸、选手签名等非标准物品，受限於 CSGO-API 的覆盖范围。

3. 独特价值：与现有数据集相比，SKIN_ERA 的核心创新体现在三个方面。其一，时间跨度的完整性——覆盖 CS:GO 饰品系统上线至 CS2 发布前的完整十年，为研究虚拟资产市场的长期演化提供了罕见的数据基础。其二，属性维度的丰富性——将价格序列与静态属性字段关联，支持多维度、细粒度的实证分析。其三，数据格式的规范性——统一了名称编码、清洗了异常值、补全了缺失属性，降低了研究者的数据预处理成本。

1.3. 本数据集的核心应用场景和局限性

需要特别说明的是，SKIN_ERA 的数据时间范围截至 2023 年 5 月，即 CS2 正式发布前。2025 年 10 月 Valve 对饰品合成机制的重大调整，从根本上改变了饰品的稀缺性定价逻辑——从“概率获取”变为“成本计算”，这导致基于历史数据训练的价格预测模型、交易策略等，不再适用于现实中的交易决策指导。市场结构发生了不可逆的变化，历史规律在新机制下可能失效。然而，这恰恰凸显了 SKIN_ERA 作为历史标本的特殊学术价值：

第一，准自然实验的基准参照。2025 年的合成机制调整是一次外生的政策冲击，SKIN_ERA 提供了调整前的完整市场状态记录，可作为 DID 等因果推断方法的处理前基准期，帮助研究者量化政策冲击的真实效应。

第二，市场有效性检验的完整样本。在长达十年的样本期内，CS:GO 饰品市场经历了多次重大事件（新箱子发布、大行动更新、游戏免费化、中国区解锁、CS2 官宣等）。SKIN_ERA 为检验虚拟资产市场的半强式

有效假说提供了丰富的自然实验场景。

第三，虚拟资产定价理论的实证基础。尽管新合成机制改变了供给侧的约束条件，但饰品价格的基本决定因素——稀有度、审美价值、实用价值、社交价值——并未消失。SKIN_ERA 记录了这些因素在“旧机制”下的定价效应，为理解虚拟资产定价的底层逻辑提供了基准参照。

第四，方法论的验证平台。对于时间序列预测、异常检测等机器学习方法，SKIN_ERA 提供了一个规模适中、属性丰富、有明确真实值的验证场景。即使历史模式不再延续，新方法在历史数据上的表现仍可作为算法性能的相对比较基准。

综上所述，SKIN_ERA 并非一个旨在指导当前交易的“实用工具”，而是一个服务于虚拟资产市场实证研究的“历史数据集”。它的价值不在于预测未来，而在于记录过去——记录一个特定历史时期（开箱抽奖时代）CS:GO 饰品市场的完整图景，为理解虚拟经济、评估政策冲击、检验市场理论提供不可替代的数据支撑。

二、数据采集与融合

2.1. 数据来源

本研究使用的原始数据来自两个公开数据源，分别提供饰品的价格时间序列与静态属性信息。

2.1.1. Steam 市场价格时序数据集

价格时序数据取自 Kaggle 平台发布的“Steam Market Price Dataset - CS:GO”[1]。该数据集包含 20,575 个独立饰品条目，每个条目对应一个 CSV 文件，存储该饰品自首次上架至 2023 年 5 月的历史价格序列。每个价格记录包含 Unix 毫秒级时间戳、美元计价价格以及当日销量三个字段。数据集中饰品名称采用 Base64 编码存储，且命名格式包含 StatTrak™ 标记、纪念品标识以及磨损档位后缀。

该数据集的优势在于覆盖范围广、时间跨度长。其局限在于仅包含价格与销量信息，缺乏饰品的静态属性字段，研究人员无法从该数据集直接获知饰品的稀有度、武器类型、磨损范围或所属收藏品等定价因子。

2.1.2. CSGO-API 静态属性数据集

静态属性数据取自 GitHub 平台的开源项目“CSGO-API”[2]。该项目系统性地整理了 CS:GO 及 CS2 中所有可交易物品的元数据，涵盖武器皮肤、贴纸、探员、箱子、音乐盒、涂鸦、钥匙、徽章、钥匙链、收藏品和工具共计 11 个品类，总计 15,915 个物品。以武器皮肤数据为例，每条记录包含 19 个字段：物品唯一标识符、名称、武器类型、稀有度、最小磨损值、最大磨损值、是否 StatTrak™、是否纪念品、所属收藏品、来源箱子等。

该数据集的优势在于属性维度丰富、数据结构规范。其局限在于不包含任何时间序列信息，无法单独用于价格趋势分析。

2.2. 数据预处理与融合

2.2.1. 名称标准化算法

两个数据集的核心关联键均为饰品名称，但命名格式存在显著差异。Kaggle 数据集中的名称为 Base64 编码，且包含 StatTrak™ 标记和磨损档位后缀；CSGO-API 数据集中的名称为明文，且不包含上述后缀。因此，需要对 Kaggle 数据集中的名称进行解码与标准化处理。

名称标准化算法的处理流程如下。首先，对 Base64 编码的字符串进行解码，得到原始名称字符串。其次，移除名称中的“StatTrak™”标记。再次，移除名称末尾括号内的磨损档位标识，包括“Factory New”、“Minimal Wear”、“Field-Tested”、“Well-Worn”、“Battle-Scarred”五种。最后，移除名称首尾的空白字符，得到标准化后的基础名称。该标准化名称用于与 CSGO-API 数据集中的名称字段进行匹配。

2.2.2. 匹配与融合流程

融合流程以 Kaggle 价格数据集为主表，以 CSGO-API 静态属性数据集为辅助表，通过标准化名称进行左连接。具体步骤如下。

第一步，遍历 Kaggle 数据集的索引文件 item_index.csv，对每条记录执行名称解码与标准化，得到基础名称。第二步，在 CSGO-API 的 11 个 JSON 文件中查找与该基础名称匹配的物品记录。第三步，若匹配成功，将对应的静态属性字段（物品类型、稀有度、武器类型、磨损范围等）附加到该物品的所有价格记录中；若匹配失败，则保留价格记录，静态属性字段置为空值。第四步，将所有物品的价格序列纵向拼接，形成完整的数据集。

最终融合得到的数据集包含 34,615,938 条价格记录，覆盖 20,575 个物品，时间跨度为 2013 年 4 月 26 日至 2023 年 5 月 27 日，共计 3,683 天。静态属性匹配成功的物品为 11,924 个，整体匹配率为 58.0%。

2.2.3. 未匹配物品分析

未匹配的 8,651 个物品主要分为三类。第一类是社区贴纸与选手签名贴纸，CSGO-API 的 stickers.json 主要收录官方贴纸，对社区创作贴纸的覆盖不足。第二类是特殊活动胶囊与通行证，这些物品的命名格式与标准皮肤差异较大。第三类是部分 StatTrak™与纪念品变体，其名称后缀在标准化过程中被移除后，与 CSGO-API 中的基础名称无法精确对应。

2.3. 数据集字段说明

融合后的数据集包含以下字段类别。

时间信息：date（日期），格式为 YYYY-MM-DD。

价格与交易信息：pricedollar（美元价格）、sells（当日销量）、dailyvalue（成交额，由 price_dollar 与 sells 相乘计算）。

物品标识信息：itemfilename（原始文件名）、itemfullname（完整名称）、itembasename（标准化基础名称）。

物品属性信息：itemtype（物品类型，包括 skin、sticker、crate、agent 等）、wear（磨损档位）、isstattrak（是否 StatTrak™）、issouvenir（是否纪念品）、isknifeorglove（是否刀具或手套）。

CSGO-API 静态属性：itemid（物品唯一标识）、rarity（稀有度）、weapon（武器类型）、minfloat（最小磨损值）、maxfloat（最大磨损值）、hasstatic_attrs（是否匹配到静态属性）。

数据以 Parquet 格式存储，压缩率高且读写性能良好，单个文件大小约为 500MB，便于后续分析处理。


三、数据集统计分析

3.1. 整体规模与覆盖

SKIN_ERA 数据集的基本规模信息如下：数据集包含 34,615,938 条价格记录，覆盖 20,575 个独立饰品物品，时间跨度为 2013 年 4 月 26 日至 2023 年 5 月 27 日，共计 3,683 天（约 10.1 年）。静态属性匹配成功的物品为 11,924 个，整体匹配率为 58.0%。

3.2. 价格与成交量分布特征

饰品价格呈现显著的高度右偏分布特征。价格最小值为 0.03 美元，最大值为 2,081.24 美元，平均值约为 20.99 美元，而中位数仅为 1.06 美元。价格标准差为 71.08 美元，偏度为 7.54，峰度为 89.74，变异系数为 3.39。这些统计量共同表明：大部分饰品价格集中在较低区间，少数高价饰品构成分布的右侧长尾。



从价格区间来看，0 至 1 美元区间的记录数占比为 48.87%，1 至 5 美元区间占比为 23.94%，两者合计超过总记录数的 70%。0 至 20 美元区间的记录数占比高达 85.4%。成交量分布同样呈现右偏特征，单日成交量中位数为 11 件，而平均值达到 141 件。成交量区间方面，0 至 50 区间内的记录数约占总记录的 75%。

表 1. 价格与成交量分布统计


统计指标	数值	区间分布	记录数占比
最小值	\$0.03	\$0-1	48.87%
最大值	\$2,081.24	\$1-5	23.94%
平均值	\$20.99	\$5-20	12.55%

中位数	\$1.06	\$20-100	8.28%
标准差	\$71.08	\$100 以上	6.37%
偏度	7.54	成交量 0-50	74.91%
峰度	89.74	成交量 50-500	21.37%
变异系数	3.39	成交量 500 以上	3.72%

历史最高价前 20 名的物品中，贴纸类与刀具/手套类占据主导地位。排名第一的是“Sticker | OG (Glitter) | Rio 2022”，最高价达到 2,081.24 美元。前 20 名中有 7 款刀具、4 款手套和 4 款贴纸，反映出高价值饰品主要集中在稀有外观类物品。

3.3. 市场整体统计

在整个时间窗口内，CS:GO/CS2 饰品市场的总成交额为 57.05 亿美元，总成交量为 48.88 亿件。日均成交额为 154.87 万美元，日均成交量 132.67 万件。月度统计显示，月均成交额为 4,676.54 万美元，成交额最高的月份为 2023 年 4 月（2.24 亿美元），成交量最高的月份为 2023 年 3 月（1.17 亿件）。



年度统计如表 2 所示。市场成交额在 2013 年至 2015 年快速攀升，2015 年达到 7.27 亿美元后有所回落。2019 年起市场进入新一轮增长周期，2021 年成交额达到峰值 8.79 亿美元。年度均价在 2021 年达到最高点 28.10 美元，此后下降至 2023 年的 16.36 美元。

表 2. 年度市场统计

年份	年成交额（亿美元）	年成交量（亿件）	年均价（美元）
2013	0.15	0.12	18.10
2014	2.33	1.96	20.94
2015	7.27	5.97	22.59

2016	5.50	4.18	17.55
2017	3.96	3.23	16.54
2018	3.11	2.62	15.82
2019	4.49	4.71	20.29
2020	6.68	6.23	24.28
2021	8.79	8.30	28.10
2022	8.12	7.13	25.89
2023	6.65	4.42	16.36

3.4. 按物品类型与属性的分类统计

数据集共包含 10 种物品类型，其统计结果如表 3 所示。贴纸（sticker）的物品数量最多（5,866 个），皮肤（skin）次之（5,182 个）。从价格角度来看，箱子的均价最高（18.72 美元），皮肤的均价为 6.58 美元。从成交量来看，皮肤的累计成交量最大（23.41 亿件），占总成交量的 47.9%。




表 3. 按物品类型统计


类型	物品数	均价（美元）	中位数（美元）	最高价（美元）	总销量（亿件）
sticker	5,866	4.37	0.82	2,081.24	5.19
skin	5,182	6.58	0.72	1,943.81	23.41
crate	349	18.72	3.71	1,971.87	7.84
graffiti	139	2.58	0.07	1,273.45	0.13
music_kit	117	6.04	4.65	1,239.21	0.09
patch	112	1.18	0.29	450.77	0.40
collectible	67	8.46	3.70	388.13	2.28

agent	63	4.98	1.98	925.11	0.68
key	27	7.22	1.11	654.35	1.11
tool	2	10.39	1.54	85.48	0.001

在皮肤类物品中，稀有度等级从低到高依次为 Consumer Grade、Industrial Grade、Mil-Spec Grade、Restricted、Classified、Covert。如表 4 所示，随着稀有度等级的提升，物品均价单调递增。Covert 级皮肤的平均价格（25.45 美元）约为 Consumer Grade（2.68 美元）的 9.5 倍。

表 4. 按稀有度与磨损档位统计（皮肤类）


类别	等级	物品数	均价（美元）	中位数（美元）
稀有度	Consumer Grade	731	2.68	0.36
	Industrial Grade	611	4.22	0.62
	Mil-Spec Grade	1,659	4.62	0.50
	Restricted	1,157	5.67	0.85
	Classified	661	9.23	1.84
	Covert	363	25.45	5.62
磨损档位	Factory New	1,078	6.17	0.78
	Minimal Wear	1,110	5.68	0.67
	Field-Tested	1,073	7.91	0.72
	Well-Worn	991	5.53	0.48
	Battle-Scarred	930	7.67	1.06



从武器类型来看，AK-47 以 37.03 美元的均价高居首位，显著高于其他武器。M4A1-S（21.97 美元）、

M4A4（19.42 美元）、Desert Eagle（16.15 美元）分列其后。皮肤数量最多的武器为 P250（217 个）、MAC-10（213 个）和 AK-47（206 个）。

3.5. 相关性分析与四象限分析



为探究价格与成交量之间的动态关系，本研究计算了日度数据层面的皮尔逊相关系数。价格与成交量的相关系数为 0.7026 ($p < 0.001$)，呈现显著正相关，说明高价格饰品通常伴随更高的成交量。价格与成交额的相关系数为 0.6498 ($p < 0.001$)。价格变化率与成交量变化率的相关系数为 -0.0650 ($p < 0.001$)，呈现微弱负相关，表明饰品市场存在一定的“价涨量缩”特征。

以价格中位数（1.06 美元）和成交量中位数（11 件）为分界线，将交易记录划分为四个象限，结果如表 5 所示。高价高量象限（Q1）占总记录的 15.90%，代表市场中兼具高价值与高流动性的优质资产。低价高量象限（Q2）占 32.97%，主要为涂鸦类消耗品。高价低量象限（Q4）占 34.09%，代表高价但流动性差的稀有收藏品。


表 5. 四象限分析结果

象限	记录数占比	均价（美元）	均成交量	典型物品示例
Q1（高价高量）	15.90%	10.28	116	AK-47
Q2（低价高量）	32.97%	0.27	366	Sealed Graffiti
Q3（低价低量）	17.04%	0.40	4	各类冷门贴纸
Q4（高价低量）	34.09%	56.32	3	StatTrak™ 高端刀具


3.6. 时间序列特征与数据质量

从年度均价来看，2013 年至 2015 年呈上升趋势，2016 年至 2018 年有所回落，2019 年至 2021 年再次攀升，2021 年达到峰值 28.10 美元后下降至 2023 年的 16.36 美元。月度季节性方面，3 月的均价最高（25.21 美元），5 月最低（15.31 美元）。周度季节性方面，周五和周六的价格最高（约 21.45 美元），周二最低（20.58 美元），周度差异约为 4%。

数据质量方面，时间戳、价格和销量字段不存在缺失值。静态属性字段（item_type 和 rarity）的缺失率为 41.63%，属于预期内的数据覆盖问题。采用 3 倍标准差准则进行异常值检测，价格异常值占比 2.02%，成交量异常值占比 0.17%，这些异常值主要源于新品上市初期的价格波动和特定事件引发的交易高峰，蕴含重要的市场信息，本数据集予以保留。



CS2 饰品市场数据汇总仪表盘



四、基准实验

4.1. 实验任务定义

本研究的基准实验任务为 CS2 饰品市场次日成交额预测。设第 t 日的市场总成交额为 V_t （单位：美元），则预测任务可形式化地表示为：基于截至第 t 日及之前的历史观测数据，构建预测函数 $\hat{f}$ ，使得 $\hat{V}_{t+1} =$

$\hat{f}(\mathcal{H}_t)$ 尽可能接近真实值 V_{t+1} ，其中 $\mathcal{H}_t = \{V_{t-k}, S_{t-k}, P_{t-k}, \dots \mid k = 0, 1, \dots, K\}$ 包含历史成交额、成交量、均价等多维特征。该任务属于典型的单步时间序列预测问题。与预测单一饰品价格相比，预测市场整体成交额具有两个优势：其一，聚合后的序列噪声更小，信噪比更高；其二，成交额反映了市场整体活跃度，对于理解虚拟资产市场的宏观动态具有更直接的意义。

4.2. 特征工程

时间序列预测的核心挑战在于如何从历史数据中提取有效的预测信号。本研究构建的特征体系涵盖三个维度：时间特征、滞后特征和滚动统计特征。

时间特征用于捕捉市场中存在的日历效应。具体包括： $d_{\text{week}} \in \{0, \dots, 6\}$ 表示星期几（周一为 0）， $m \in \{1, \dots, 12\}$ 表示月份， y 表示年份， $d_{\text{year}} \in \{1, \dots, 366\}$ 表示年内第几天， $q \in \{1, 2, 3, 4\}$ 表示季度，以及 t_{since} 表示距数据集起始日的天数。这些特征能够帮助模型捕捉周末效应、月度季节性和年度趋势。

滞后特征是时间序列预测的核心输入。对于成交额序列 V_t 、成交量序列 S_t 和均价序列 P_t ，分别构造滞后 L 期的特征：

$$\text{lag}_L(V) = V_{t-L}, \quad L \in \{1, 2, 3, 7, 14, 21, 30\}$$

对于成交量和均价同理。其中 1-3 期用于捕捉近期趋势，7 期和 14 期用于捕捉周度及双周模式，21 期和 30 期用于捕捉月度周期。

滚动统计特征用于刻画序列的局部波动特征。对于窗口长度 $W \in \{3, 5, 7, 14, 30\}$ ，分别计算移动平均和移动标准差：

$$\text{MA}_W(V) = \frac{1}{W} \sum_{i=0}^{W-1} V_{t-i}, \quad \text{Std}_W(V) = \sqrt{\frac{1}{W-1} \sum_{i=0}^{W-1} (V_{t-i} - \text{MA}_W)^2}$$

这些特征能够为模型提供关于序列局部趋势和波动性的信息。

经过特征工程后，共得到 45 个特征变量。数据集按时间顺序划分为训练集（70%）、验证集（15%）和测试集（15%），确保不存在未来信息泄露。

4.3. 基准模型

本研究选取五个具有代表性的机器学习模型作为基准，涵盖树模型、集成学习和深度学习方法。

4.3.1. XGBoost

XGBoost（eXtreme Gradient Boosting）是由 Chen 和 Guestrin 提出的梯度提升树系统。其核心思想是迭代地添加决策树，每棵新树拟合前一棵树的残差。对于包含 K 棵树的模型，预测值为：

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i), \quad f_k \in \mathcal{F}$$

其中 $\mathcal{F}$ 为回归树函数空间。目标函数由损失项和正则化项构成：

$$\mathcal{L} = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$

正则化项 $\Omega(f_k) = \gamma T + \frac{1}{2} \lambda \|\omega\|^2$ ， T 为叶节点数， ω 为叶权重。XGBoost 采用二阶泰勒展开近似损失函数，并在分裂时计算增益：

$$\mathcal{L}_{\text{split}} = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma$$

其中 $G = \sum g_i$ ， $H = \sum h_i$ 分别为一阶和二阶梯度之和。

4.3.2. LightGBM

LightGBM 由 Ke 等人提出，在 GBDT 框架下引入两项创新以提升训练效率。其一为基于梯度的单边采样（GOSS），保留大梯度样本而随机采样小梯度样本，并对小梯度样本进行加权补偿：

$$w = \frac{1-a}{b}$$

其中 a 为大梯度样本保留比例， b 为小梯度样本采样比例。其二为互斥特征绑定（EFB），将稀疏特征空间中互斥的特征进行捆绑，降低特征维度。这两项改进使 LightGBM 在保持精度的同时显著降低计算开销。

4.3.3. 随机森林

随机森林由 Breiman 提出，通过集成大量决策树提升预测稳定性。每棵树基于 Bootstrap 采样得到的训练集构建，在节点分裂时仅随机选择 $\sqrt{p}$ 个特征（回归任务）进行最优分割搜索。对于回归任务，最终预测为所有树预测值的平均：

$$\hat{y} = \frac{1}{M} \sum_{j=1}^M T_j(x)$$

研究表明，当树的数目足够多时，随机森林的泛化误差有上界保证。

4.3.4. 多层感知机

多层感知机（MLP）是一种前馈人工神经网络。对于单隐藏层 MLP，其数学形式可表示为：

$$\hat{y} = \phi_{\text{out}} \left(\sum_{j=1}^H w_j^{\text{out}} \cdot \phi_{\text{hidden}} \left(\sum_{i=1}^p w_{ij}^{\text{in}} x_i + b_j^{\text{in}} \right) + b^{\text{out}} \right)$$

其中 $\phi(\cdot)$ 为激活函数（本研究使用 ReLU）， H 为隐藏层神经元数。本研究采用三层结构：输入层（45 个神经元）、两个隐藏层（分别为 128 和 64 个神经元）和输出层（1 个神经元），使用 Adam 优化器进行训练。

4.3.5. 长短期记忆网络

长短期记忆网络（LSTM）由 Hochreiter 和 Schmidhuber 提出，是循环神经网络的一种变体，专门设计用于解决长序列依赖中的梯度消失问题。LSTM 单元通过三个门控结构控制信息流动：遗忘门 f_t 、输入门 i_t 和输出门 o_t ：

$$\begin{aligned} f_t &= \sigma(W_f x_t + U_f h_{t-1} + b_f) \\ i_t &= \sigma(W_i x_t + U_i h_{t-1} + b_i) \\ \tilde{c}_t &= \tanh(W_c x_t + U_c h_{t-1} + b_c) \\ c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \\ o_t &= \sigma(W_o x_t + U_o h_{t-1} + b_o) \\ h_t &= o_t \odot \tanh(c_t) \end{aligned}$$

其中 $\odot$ 表示逐元素乘法， σ 为 sigmoid 激活函数。遗忘门决定上一时刻记忆的保留程度，输入门控制新信息的写入，输出门决定当前隐藏状态的输出。LSTM 能够有效捕捉时间序列中的长期依赖关系，适用于成交额预测任务。已有研究表明，LSTM 在 CS2 饰品市场中可取得优于传统策略的收益表现。本研究使用 30 步的输入序列长度，每个时间步的特征维度为 45。

4.4. 实验设置与评估指标

所有模型以次日成交额为预测目标，采用均方误差（MSE）作为损失函数。评估指标包括：

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2},$$

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\%$$

超参数配置如下：XGBoost 和 LightGBM 采用 200 棵树，最大深度为 6；随机森林采用 150 棵树，最大深度为 12；MLP 采用 Adam 优化器，最大迭代 500 次，早停轮数 20；LSTM 采用 Adam 优化器，训练 100 轮，早停轮数 20，序列长度为 30。所有模型的随机种子统一设为 42 以保证可复现性。

4.5. 实验结果与分析

在测试集上对各模型进行对比评估，评估指标包括 MAE（平均绝对误差，单位：美元）、RMSE（均方根误差，单位：美元）、 R^2 （决定系数）和 MAPE（平均绝对百分比误差，%）。所有模型均采用 4.4 节所述的超参数配置，在相同的数据划分下进行训练与测试。实验结果如表 6 所示。

表 6. 各模型市场成交额预测性能对比

模型	MAE（美元）	RMSE（美元）	R^2	MAPE（%）
XGBoost	577,651.82	1,407,122.04	0.1672	136.80
LightGBM	526,034.11	1,288,887.69	0.3013	173.82
Random Forest	540,249.32	1,312,797.46	0.2751	111.02
MLP	1,849,151.65	2,121,751.03	-0.8935	97.46
LSTM	453,841.15	960,570.06	0.6268	301.99

从表 6 可以得出以下观察结果。

第一，LSTM 在整体预测精度上表现最优。LSTM 的 MAE 为 453,841 美元，RMSE 为 960,570 美元，均为所有模型中的最低值。其 R^2 达到 0.6268，意味着模型能够解释测试集约 62.7% 的方差。这一结果验证了 LSTM 在捕捉时间序列长期依赖关系方面的优势，与文献[7]的结论一致。成交额序列具有较强的时序自相关性，LSTM 的门控机制使其能够有效记忆历史模式并据此预测未来值。

第二，树模型（XGBoost、LightGBM、Random Forest）表现中等，但显著优于 MLP。LightGBM 取得第二好的 R^2 （0.3013），其 MAE（526,034 美元）和 RMSE（1,288,888 美元）均优于 XGBoost 和 Random Forest。LightGBM 的相对优势可能归因于其基于梯度的单边采样策略，该策略在具有噪声的时间序列数据中表现出更强的鲁棒性[4]。三个树模型的 R^2 均在 0.17 至 0.30 之间，说明它们能够捕捉部分但非全部的市场变化模式。


第三，MLP 在该预测任务中表现严重失效。MLP 的 R^2 为负数（-0.8935），意味着其预测效果劣于简单使用训练集均值的基准模型。这一结果并不意外：MLP 作为前馈神经网络，不具备处理序列结构的内置机制。对于时间序列预测，MLP 需要依赖特征工程（如滞后特征）提供足够的信息，但其全连接结构仍难以有效捕捉时间维度上的依赖关系。即使采用了多层结构（128-64-32）和 ReLU 激活函数，MLP 在测试集上仍出现严重的欠拟合现象。这进一步印证了对于时序数据，具有序列建模能力的网络结构（如 LSTM）是更合适的选择。


第四，各模型的 MAPE 指标普遍偏高，反映了预测任务的固有难度。LSTM 的 MAPE 高达 301.99%，LightGBM 为 173.82%，即使是 R^2 最高的 LSTM 也无法实现较低百分比的相对误差。这一现象的根本原


因在于成交额序列的波动性： V_t 的均值为 154.87 万美元，但标准差达到约 85 万美元，且存在显著的极端值（2023 年 3 月单月成交额高达 1.17 亿件）。在这种高波动环境下，即使是较小的绝对误差也会导致较大的百分比误差。MAPE 对真实值较小的预测点极其敏感，而数据集中存在大量低成交额交易日，进一步放大了 MAPE 指标的解释难度。因此，在评估模型性能时，应优先关注 MAE 和 RMSE 等绝对误差指标，而非 MAPE。从绝对误差来看，LSTM 的平均预测偏差控制在 45 万美元左右，占日均成交额（155 万美元）的比例约为 29%，这在实际应用中具有一定参考价值。

第五， R^2 与 MAPE 之间呈现一定的矛盾关系。LSTM 拥有最高的 R^2 （0.6268），但其 MAPE（301.99%）也是所有模型中最高的。这看似矛盾的现象实际上是由 MAPE 指标的特性导致的：LSTM 在预测高价日时可能产生相对较大的相对误差，而树模型由于预测值偏向均值，在某些交易日虽然绝对误差更大，但相对误差反而较小。综合考虑各项指标，LSTM 在捕捉市场趋势方面具有显著优势，而 LightGBM 则在控制极端相对误差方面表现更好。

总体而言，五个模型在该预测任务中的性能排序为：LSTM > LightGBM > Random Forest $\approx$ XGBoost > MLP。LSTM 凭借其序列建模能力成为本任务的最优模型，但其 MAPE 偏高仍表明市场成交额预测是一个具有挑战性的问题，未来工作可考虑引入外部特征（如赛事信息、更新公告、社交媒体情绪等）以进一步提升预测精度。







五、数据集使用方向与未来工作

5.1. 政策冲击评估

2025 年 10 月 Valve 对饰品合成机制的重大调整，为研究虚拟资产市场的政策冲击效应提供了理想的准自然实验场景。SKIN_ERA 数据集记录了调整前长达十年的完整市场状态，可作为双重差分（DID）、断点回归（RDD）等因果推断方法的处理前基准期。研究者可以基于本数据集构建反事实预测模型，量化合成机制变更对饰品价格、市场流动性、价格发现效率等方面的真实影响。具体而言，可探讨以下问题：不同稀有度饰品对供给冲击的敏感度是否存在差异；市场需要多长时间完成对新定价机制的价格重估；合成机制的确定性转变是否降低了市场的投机程度。

5.2. 市场有效性检验

SKIN_ERA 长达十年的时间跨度，覆盖了 CS:GO 饰品市场从萌芽到成熟的全过程，期间经历了多次重大事件，包括新箱子发布、大行动更新、游戏免费化、中国区解锁、CS2 官宣等。这些事件为检验虚拟资产市场的有效市场假说提供了丰富的自然实验场景。研究者可运用事件研究法，检验价格是否能够快速、无偏地反映新信息。例如，当 Valve 宣布某款箱子将停止掉落时，该箱子的价格应在消息公布后迅速调整至新的均衡水平，而非呈现可预测的漂移趋势。通过检验价格调整的速度和准确性，可以评估 CS2 饰品市场属于弱式有效、半强式有效还是强式有效。

5.3. 虚拟资产定价因子分析

SKIN_ERA 的独特价值在于将价格时间序列与静态属性字段进行了关联。研究者可以基于本数据集系统性地检验虚拟资产的定价因子体系。具体而言，可构建多因子定价模型：

$$P_i = \alpha + \beta_1 \cdot \text{Rarity}_i + \beta_2 \cdot \text{Weapon}_i + \beta_3 \cdot \text{Wear}_i + \beta_4 \cdot \text{Collection}_i + \beta_5 \cdot \text{StatTrak}_i + \epsilon_i$$

其中 P_i 为饰品 i 的价格，稀有度、武器类型、磨损档位、所属收藏品、是否 StatTrak™ 等作为解释变量。通过该模型可以量化不同属性对饰品价格的边际贡献，检验稀有度溢价是否稳定存在，不同武器类型之间的定价差异是否显著，以及 StatTrak™ 标记带来的额外价值。这些发现对于理解虚拟资产与传统金融资产在定价机制上的异同具有理论意义。

5.4. 流动性风险与市场微观结构

四象限分析结果显示，约 34% 的交易记录属于“高价低量”象限，这些饰品虽有较高的标价但流动性极差。这种现象构成了典型的流动性风险——持有者可能无法在不显著影响价格的情况下完成交易。SKIN_ERA 数据集中高粒度的日度成交数据，使研究者能够构建流动性度量指标（如买卖价差、Amihud 非流动性指标、换手率等），并检验流动性风险是否被市场定价。此外，还可研究成交量的分布特征、大小单的交易行为差异、以及极端事件期间流动性的共同崩溃现象。

5.4. 机器学习算法验证平台

对于时间序列预测、异常检测、图神经网络等机器学习方法，SKINERA 提供了一个规模适中、属性丰富、有明确真实值的验证场景。数据集的规模（3,461 万条记录）足以支持深度学习模型的训练，又不会因过大而增加实验成本。研究者可在此平台上对比不同算法在虚拟资产预测任务中的表现，或开发新的方法以应对该任务中的挑战（如高波动性、非平稳性、结构性断点等）。即使 2025 年合成机制调整后历史模式不再延续，SKINERA 仍可作为算法性能的相对比较基准，服务于方法论层面的研究。

5.5. 局限性与未来扩展

本数据集存在以下局限性，有待未来工作改进。其一，数据时间范围截至 2023 年 5 月，未能覆盖 2025 年的合成机制调整及其后续影响。未来可采集 2023 年至今的数据，将时间窗口扩展至包含政策冲击后的完整时期，以支持断点分析和政策评估研究。其二，静态属性匹配率仅为 58.0%，未匹配的 8,651 个物品（主要为社区贴纸和选手签名）的静态属性信息缺失。未来可通过补充采集 CSGO-API 未覆盖的物品元数据来提升匹配率。其三，数据集目前仅包含 Steam 官方市场的交易数据，未纳入第三方交易平台（如 Buff、CSFloat、Skinport 等）的价格信息。这些平台的市场份额已不容忽视，将其数据纳入将有助于构建更全面的市场图景。其四，当前版本未包含新闻、赛事、社交媒体情绪等外部变量，这些因素对饰品价格具有显著影响。未来可将 HLTV 赛事数据、Reddit 讨论数据、Valve 官方更新公告等纳入，构建多模态数据集，以支持更丰富的分析任务。

参考文献

- [1] ByMykel. CSGO-API: Community-driven API for CS:GO item data. GitHub. <https://github.com/ByMykel/CSGO-API>
- [2] leawind. Steam Market Price Dataset - CS:GO. Kaggle. <https://www.kaggle.com/datasets/leawind/steam-market-price-dataset-csgo>
- [3] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016: 785-794.
- [4] Ke G, Meng Q, Finley T, et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. Advances in Neural Information Processing Systems, 2017, 30: 3146-3154.
- [5] Breiman L. Random Forests. Machine Learning, 2001, 45(1): 5-32.
- [6] Rumelhart D E, Hinton G E, Williams R J. Learning Representations by Back-propagating Errors. Nature, 1986, 323(6088): 533-536.
- [7] Hochreiter S, Schmidhuber J. Long Short-Term Memory. Neural Computation, 1997, 9(8): 1735-1780.

开放源代码

您可前往 https://gitee.com/copycat666/articles/raw/master/opensource/skinera_build.zip 下载数据集构建程序，并按照 readme 的教程构建数据集并运行基准算例