

《王者荣耀》多段位对局经济时序数据集与基础算例： 基于 XGBoost-KDE 的王者荣耀对局经济多尺度区间预测模型

*Honor of Kings Multi-Rank Match Economic Time-Series Dataset and Baseline Case Study:
Multi-Scale Interval Economic Forecasting Based on XGBoost-KDE*

copycat666^{1,2*}, doro^{1,2}, mysteriousK^{1,2}, Gina 老师¹, lubyanka_lover,

1. 《电子游戏科学与技术》编辑委员会
2. EigenLife 机器学习实验室，东北电力大学

*: Corresponding Author. <mailto:dev.projectamadeus@outlook.com>

摘要：本文构建并公开了《王者荣耀》多段位对局经济时序数据集。数据集包含 2000（代表性样本）到 429085（完整数据）局真实对局回放数据，覆盖青铜至王者段位，以分钟粒度记录团队经济、个体经济、经济来源构成及时序变化。统计分析与基线实验验证了数据集的有效性，并构建了基于极端梯度提升机（XGBoost）与核密度估计（KDE）的经济短/中/长期区间预测模型作为算例。该数据集可用于经济预测、发育策略学习、游戏平衡性分析等任务。

关键词：王者荣耀；经济时序数据；多段位；MOBA 游戏

Abstract. This paper constructs and publicly releases the *Honor of Kings* multi-rank match economic time-series dataset. The dataset contains real match replay data ranging from 2,000 (representative sample) to 429,085 (full dataset) matches, covering ranks from *Bronze* to *King*. It records team economy, individual economy, economic source composition, and their temporal changes at a minute-level granularity. Statistical analyses and baseline experiments validate the effectiveness of the dataset. Additionally, a short-term economic interval forecasting model based on Extreme Gradient Boosting (XGBoost) and Kernel Density Estimation (KDE) is constructed as a case study. This dataset can be used for tasks such as economic prediction, farming strategy learning, and game balance analysis.

Keywords: *Honor of Kings* (mobile game developed by Tencent), economic time-series data, multi-rank, MOBA games

数据集（代表性样本）下载地址

https://gitee.com/copycat666/articles/blob/master/opensource/wzry_economy_dataset.json

完整数据集尺寸非常大。如需要，请通过[邮件](#)申请获取。

一、引言

王者荣耀作为当前全球用户规模最大的多人在线战术竞技（Multiplayer Online Battle Arena, MOBA）类移动游戏之一，其核心玩法围绕两支五人队伍展开对抗，以摧毁敌方水晶为最终胜利条件。在 MOBA 游戏中，经济系统是连接玩家行为与对局胜负的核心纽带——英雄通过击杀小兵、野怪、敌方英雄及摧毁防御塔获取金币，购买装备提升战斗力，进而形成“经济优势→装备领先→团战胜利→推进终结”的胜负传导链条。经济数据的时序演化蕴含着丰富的决策信息。一支队伍何时选择抱团推进、何时争夺远古生物、何时进行分带牵制，本质上都建立在对当前经济态势的判断之上。领先方需要思考如何将经济优势转化为实

际推进,落后方则需要寻找翻盘窗口。因此,对经济时序数据的系统建模与分析,对于理解 MOBA 游戏的胜负机制、优化玩家决策、开发智能游戏助手等任务具有重要的研究价值与实践意义。

然而,当前面向王者荣耀的经济时序数据集仍面临以下问题:

第一,缺乏公开可用的标准化数据集。现有研究多依赖研究者自行爬取或人工记录,数据格式不统一,难以复现与对比。官方 API 虽能提供部分对局数据,但经济指标的细粒度(如经济来源构成、个体经济时序)往往难以直接获取。

第二,多段位覆盖不足。不同段位玩家的经济获取效率、资源分配策略、团战决策模式存在显著差异。低段位对局中,玩家常出现“只打架不发育”的现象,经济积累曲线波动剧烈;高段位对局则表现出更合理的经济分配与更紧凑的节奏控制。现有数据集多集中于高段位或职业比赛,缺乏对全段位经济模式的系统对比。

第三,经济时序数据的标注粒度较粗。多数研究仅记录对局结束时的经济总量或分均经济,缺少对经济积累过程、经济来源构成、经济差距演化轨迹的细粒度标注,难以支撑经济预测、发育策略学习等时序建模任务。

基于上述问题,本文构建并公开了《王者荣耀》多段位对局经济时序数据集(以下简称“本数据集”),旨在为 MOBA 游戏经济分析提供基础数据支撑。

二、数据集介绍

本数据集聚焦于 MOBA 游戏中最核心的动态变量——经济系统,通过结构化方式记录对局过程中的经济时序数据,旨在为经济预测、发育策略优化、胜负分析等任务提供标准化的数据基础。

2.1. 数据集特性

本数据集具备以下核心特性:

1. 完整的经济数据,包含团队总经济、个人经济、分均经济、经济来源构成等多层次指标;
2. 游戏状态记录,同步记录击杀数、防御塔数量、暴君/主宰控制数等关键状态;
3. 宏观动作标签,自动标注推塔、打龙、团战、发育等策略行为标签;
4. 多阶段覆盖,覆盖前期、中期、后期全阶段的经济曲线演化;
5. 胜负均衡采样,胜局与负局按 1:1 比例采集,避免类别不平衡;
6. 多段位覆盖,涵盖青铜至王者全部七个段位层级。

2.2. 数据结构

本数据集采用分层嵌套的 JSON 存储,以对局为基本组织单元,每个对局包含按分钟采样的时序帧序列。

2.2.1. 顶层结构

数据集的顶层结构如下:

代码 1. 数据集顶层结构 JSON 示例

```
{
  "metadata": {
    "version": "1.0",
    "created_at": "2026-04-03T...",
    "num_games": 500,
    "rank_distribution": {...},
    "description": "王者荣耀多段位对局经济时序数据集"
  },
  "data": [
    [/* 第 1 局游戏的帧序列 */],
    [/* 第 2 局游戏的帧序列 */],
    ...
  ]
}
```

元数据各 JSON 属性的说明如下：

字段	类型	说明
version	string	数据集版本号
created_at	string	数据集创建时间（ISO 格式）
num_games	int	包含的对局总数
rank_distribution	object	各段位对局数量分布
description	string	数据集描述信息

2.2.2. 单帧数据结构

每个 dataframe 包含以下字段：

字段	类型	说明
frame_id	int	帧编号，从 0 开始递增
game_time_sec	int	游戏进行时间（秒）
player_perspective	string	玩家视角，"blue" 或 "red"
economy	object	经济数据（详见 2.2.3）
game_state	object	游戏状态（详见 2.2.4）
timing_phase	string	游戏阶段："early_game"/"mid_game"/"late_game"
macro_action_label	string	宏观动作标签（详见 2.2.5）

2.2.3. 经济数据结构

economy 字段是数据集的核心，其结构如下：

代码 2. economy 字段 JSON 结构示例

```
"economy": {
```

```
"total_gold": {
  "blue_team": 45200,
  "red_team": 39800,
  "difference": 5400,
  "difference_per_minute": 450
},
"individual": {
  "blue_mid": {"hero": "不知火舞", "gold": 11200, "gold_rank": 1},
  "blue_jungle": {"hero": "镜", "gold": 9800, "gold_rank": 2},
  "blue_adc": {"hero": "马可波罗", "gold": 8700, "gold_rank": 3},
  "blue_sup": {"hero": "张飞", "gold": 7200, "gold_rank": 4},
  "blue_top": {"hero": "吕布", "gold": 8300, "gold_rank": 5}
},
"gold_per_minute": {
  "blue_team_gpm": 3767,
  "red_team_gpm": 3317,
  "blue_mid_gpm": 933,
  "blue_jungle_gpm": 817
},
"economy_breakdown": {
  "minion_kill_gold": 15600,
  "hero_kill_gold": 8400,
  "tower_destroy_gold": 2000,
  "monster_kill_gold": 5200,
  "natural_income": 14000
}
}
```

子字段	说明
total_gold	团队总经济及双方经济差
individual	各位置英雄的个体经济与队内排名
gold_per_minute	分均经济（团队级和个体级）
economy_breakdown	经济来源构成分解

2.2.4. 游戏状态数据结构

game_state 字段记录对局的关键态势信息。

代码 3. game_state 字段 JSON 结构示例

```
"game_state": {
  "blue_kills": 12,
  "red_kills": 8,
  "blue_towers_alive": 5,
  "red_towers_alive": 3,
  "dragon_kills": {"blue": 2, "red": 1},
```

```
"dominator_kills": {"blue": 1, "red": 0}
}
```

字段	说明
blue_kills / red_kills	双方累计击杀数
blue_towers_alive / red_towers_alive	双方剩余防御塔数量
dragon_kills	暴君击杀数（暴君/黑暗暴君）
dominator_kills	主宰击杀数

2.2.5. 宏观动作标签

macro_action_label 字段采用自动标注方法生成，标签类型如下：

标签	含义	触发条件
farm_safe	安全发育	无大规模冲突，经济平稳增长
push_top_tower	推上路塔	上路防御塔血量下降
push_mid_tower	推中路塔	中路防御塔血量下降
push_bot_tower	推下路塔	下路防御塔血量下降
take_dragon	打暴君	至少 2 名英雄在龙坑半径 500 内
take_dominator	打主宰	至少 2 名英雄在龙坑半径 500 内
teamfight	团战	双方多名英雄在狭小区域内交战
split_push	单带	单人深入推塔，其余队友在远端
defend_base	守家	己方高地塔被攻击
invade_jungle	入侵野区	进入敌方野区且击杀野怪
group_for_vision	抱团做视野	多名英雄在关键河道区域聚集

2.3. 数据集采集流程

2.3.1. 数据来源

本数据集来源于以下几个渠道：1. 高段位玩家真实对局回放；2. 腾讯官方 API 战斗回放解析接口返回的 BattleReport 数据包；3. 职业联赛及平台赛事直播数据。

2.3.2. 采样策略

为保证数据集的代表性与均衡性，采用以下采样策略：

策略维度	具体设置
时间采样	每分钟抽取一帧，避免连续帧冗余
胜负均衡	胜局:负局 = 1:1
局势均衡	顺风局:逆风局:僵持局 = 1:1:1
段位覆盖	青铜、白银、黄金、铂金、钻石、星耀、王者各段位均采集
对局时长	覆盖 15-25 分钟完整对局

2.3.3. 数据生成流程

原始数据来源于游戏回放文件或官方 API 接口。随后进行数据清洗，剔除异常对局（如挂机、提前投降、数据不完整）。接着进行特征提取，从原始日志中提取经济相关字段并聚合，将数据转化为结构化格式。然后执行事件检测，自动识别击杀、推塔、打龙等关键事件。之后通过规则填充，将事件标签向前填充 30 秒，以覆盖准备阶段。再进行标签标注，按优先级规则生成宏观动作标签（团战 > 打龙 > 推塔 > 发育）。随后进行数据增强，对经济数据添加可控高斯噪声，以提升模型泛化能力。最终生成可供使用的最终数据集。

2.3.4. 数据增强方法

为增强数据集的泛化能力，对经济数据施加高斯噪声扰动。具体地，对团队总经济进行如下增强操作：

设原始蓝方团队总经济为 G_{blue} ，噪声水平参数为 σ （默认取 $\sigma = 0.05$ ），则增强后的蓝方团队总经济 G'_{blue} 通过(1)计算：

$$G'_{\text{blue}} = G_{\text{blue}} \times (1 + \varepsilon), \quad \varepsilon \sim \mathcal{N}(0, \sigma^2) \quad (1)$$

其中 ε 为服从均值为 0、标准差为 σ 的高斯分布随机变量。红方团队总经济保持不变，为保证经济差的一致性，增强后的经济差 D' 如(2)所示：

$$D' = G'_{\text{blue}} - G_{\text{red}} \quad (2)$$

数据增强的关键参数说明如下：噪声水平（noise_level）默认值为 0.05，表示高斯噪声的相对标准差；增强倍率（augmentation_ratio）默认值为 2.0，即每条原始数据生成 2 条增强样本。通过引入可控的随机扰动，该方法能够提升模型对微小经济波动的鲁棒性与泛化能力。

代码 4. 基于 Gaussian 随机噪声的数据增强算法（python3）

```
def economic_augmentation(data, noise_level=0.05):
    augmented = data.copy()
    augmented["economy"]["total_gold"]["blue_team"] = int(
        augmented["economy"]["total_gold"]["blue_team"] *
        (1 + np.random.normal(0, noise_level))
    )
    augmented["economy"]["total_gold"]["difference"] = (
        augmented["economy"]["total_gold"]["blue_team"] -
        augmented["economy"]["total_gold"]["red_team"]
    )
    return augmented
```


2.4. 数据集统计指标

2.4.1. 总体规模


统计项	数值	统计项	数值
对局总数	2000 局（代表性样本）	对局总数	429085 局（完整数据）

总帧数	76776 帧	总帧数	7704361 帧
单局平均帧数	16-50 帧（对应 8-25 分钟对局）	单局平均帧数	30-50 帧（对应 8-25 分钟对局）
数据总量	约 200MB（JSON 格式）	数据总量	约 41.79GB（JSON 格式）

2.4.2. 玩家段位分布（代表性样本）





2.4.3. 经济指标分布（代表性样本）



团队经济统计：

GPM 指标	蓝色方	红色方	阶段	均值	标准差	
平均 GPM	3,579	3,438	前期	346	6,549	
最高 GPM	11,059	10,478	中期	1,717	21,691	
最低 GPM	0	2	后期	4,145	46,210	
GPM 标准差	954	954	宏观动作 TOP-5:			
经济差指标	数值		动作标签	频次	占比	排名
平均值	1,726		farm_safe	29,034	37.82%	1
标准差	26,313		push_mid_tower	11,221	14.62%	2
最大值	+272,012		take_dominator	8,582	11.18%	3
最小值	-287,473		push_top_tower	8,514	11.09%	4
中位数	385		split_push	7,825	10.19%	5




不同阶段的经济差统计：




2.4.4. 对局宏观动作分布（代表性样本）






排名	动作名称	出现次数	总占比	累计占比	前期占比 (32,000 帧)	中期占比 (26,427 帧)	后期占比 (18,349 帧)	经济领先占比 (30,232 帧)	均势占比 (20,854 帧)	经济落后占比 (25,690 帧)
1	安全发育	29,034	37.82%	37.82%	73.56%	-	-	10.03%	76.73%	38.93%
2	推中路塔	11,221	14.62%	52.43%	5.62%	21.69%	20.12%	29.76%	8.07%	2.11%
3	打主宰	8,582	11.18%	63.61%	5.81%	14.27%	16.09%	28.39%	-	-
4	推上路塔	8,514	11.09%	74.70%	5.72%	14.21%	15.96%	28.16%	-	-
5	单带	7,825	10.19%	84.89%	4.70%	11.88%	17.34%	-	2.23%	28.01%
6	守家	7,005	9.12%	94.02%	-	11.74%	13.25%	-	-	27.27%
7	团战	2,685	3.50%	97.51%	-	-	-	1.87%	7.59%	2.09%
8	打暴君	1,910	2.49%	100.00%	-	-	-	-	5.38%	-
-	其他 / 未	-	-	-	4.59%	26.21%	17.24%	1.79%	-	1.70%

	列出									
总计		76,776	100.00%	-	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%





2.4.5. 各项统计检验结果 (代表性样本)






图 8: 综合统计摘要

统计指标	数值	P 值/备注
样本量	2,000	-
经济增速均值	135086.3105	$\sigma=45331.3648$
胜率 (蓝方)	55.35%	二项分布
平均时长	18.7min	$\pm 6.4\text{min}$
GPM 差均值	135.3	t 检验 $p < 0.001$
经济波动均值	12,329	$\sigma=10,854$
K-S 检验	0.0475	$p=2.36\text{e-}04$
卡方检验 (龙)	0.00	无显著相关

2.6. 本章小结

本章对数据集进行了全面介绍。首先阐述了数据集的定位与核心特性；随后详细说明了数据的分层结构，包括元数据、帧序列、经济数据、游戏状态及宏观动作标签等字段的定义与格式；接着介绍了数据采集来源、采样策略、生成流程及数据增强方法；最后给出了数据统计概览和使用说明。本数据集具备多段位覆盖、细粒度经济指标、宏观动作标注等特点，可为 MOBA 游戏经济分析提供标准化的数据基础。

三、数据集算例——基于极端梯度提升机（XGBoost）与核密度估计（KDE）的王者荣耀对局经济多尺度区间预测模型

本章旨在利用该数据集，构建经济预测模型，实现对未来经济差的点预测与区间预测。经济差是衡量对局优劣势的核心指标，准确预测其未来变化对于战术决策具有重要参考价值。然而，由于 MOBA 游戏的高度动态性与不确定性，点预测难以全面刻画预测风险，因此引入区间预测方法量化不确定性，提供更加可靠的决策依据。本算例中，我们采用**极端梯度提升机（XGBoost）**进行经济的数值预测，利用 XGBoost 处理非线性关系能力强、训练效率高、内置正则化防过拟合、在表格数据上表现优异的优点；并采用**核密度估计法（Kernel Density Estimation, KDE）**进行概率预测。

本算例的经济预测任务可形式化定义如下：给定截至当前时刻 t 的历史经济与状态信息序列

$\mathcal{H}_t = \{(E_{t-k}, S_{t-k}), \dots, (E_t, S_t)\}$ ，设定预测目标：未来 Δt 分钟后的经济差 $\Delta G_{t+\Delta t}$ 。其中： E_t 表示 t 时刻的经济指标（团队总经济、分均经济、经济来源构成等）； S_t 表示 t 时刻的游戏状态（击杀数、防御塔数、龙控制数等）； $\Delta G_t = G_t^{\text{blue}} - G_t^{\text{red}}$ 表示 t 时刻的经济差。

3.1. 点预测与区间预测

我们构建 XGBoost-KDE 模型。该模型同时提供两种预测输出：1. 未来时刻的经济预测值 y ，快速判断经济走势，提供决策支持；2. 未来时刻的经济预测值在置信水平 a 下的置信区间 $[L, U]$ ，用于告诉我们未来的经济大致会在哪个范围，支持风险评估和更鲁棒的战术选型。总而言之，区间预测的优势在于：不仅告知“经济差会变成多少”，还告知“这个预测有多大的不确定性”，从而支持更稳健的决策。

3.2. 特征工程

基于数据集提供的信息，构建以下特征集：

3.2.1. 经济特征

经济特征包含：当前经济差 ΔG_t ；经济差变化率 $\frac{\Delta G_t - \Delta G_{t-1}}{\Delta t}$ ；分均经济比 $\frac{GPM_{blue}}{GPM_{red}}$ ；

3.2.2. 游戏状态特征

游戏状态特征包含：双方击杀差；防御塔差；龙控制比；游戏阶段编码（early/mid/late_game 独热编码）。

3.2.3. 滑动窗口时序特征

滑动窗口为 3 个 dataframe。窗口内的时序特征包括：经济差均值，经济差一阶差分；近期经济差线性拟合斜率；近期经济差标准差。

3.2.4. 段位特征

段位特征包含：段位编码（青铜-王者 1-7）和低段位/中段位/高段位分类。

3.3. 基于 XGBoost-KDE 的预测模型构建

3.3.1. 预测步长设定


预测步长指模型将预测未来多长时间内的数值。本算例设置以下预测步长进行对比实验：

1 分钟	短期预测	即时决策（如是否开团）
2 分钟	中期预测	资源争夺预判
5 分钟	中长期预测	推进节奏规划
10 分钟	长期预测	胜负趋势预判

3.3.2 极端梯度提升机（XGBoost）

XGBoost (eXtreme Gradient Boosting) 是由 Chen 和 Guestrin 于 2016 年提出的集成学习算法，属于梯度提升决策树 (Gradient Boosting Decision Tree, GBDT) 框架的优化实现[1]。其核心思想是：通过迭代地训练多棵决策树，每棵新树用于拟合前一棵树的预测残差，最终将所有树的预测结果相加得到最终输出[2]。

与传统的 GBDT 相比，XGBoost 在以下方面进行了改进：1. 引入二阶泰勒展开，利用损失函数的一阶和二阶导数信息，加速收敛；2. 加入正则化项控制模型复杂度，防止过拟合；3. 采用列采样和并行化技术提升训练效率[3]。



XGBoost 属于集成学习方法中的 Boosting 流派。Boosting 的核心思想是将多个弱学习器（此处为决策树）

组合成一个强学习器。其工作流程如下:

第一棵树对训练数据进行初步拟合,但不可避免地会存在预测误差;第二棵树专门学习第一棵树的残差,尝试弥补其不足;第三棵树继续学习第二棵树的残差,依此类推。每棵树都像一个“补丁”,不断修正前序模型的错误。最终,模型将所有树的输出相加,得到一个综合性的预测结果[3]。

这种逐步修正的机制使得 XGBoost 具有强大的拟合能力。在本算例的经济预测任务中,经济差与多种特征之间存在复杂的非线性关系,单棵决策树难以捕捉这些模式,而多棵树的叠加则能够逐步逼近真实的经济演化规律[1-3]。

XGBoost 的一大创新是在目标函数中引入了正则化项。正则化的本质是对模型复杂度施加惩罚,类似于在优化目标中增加一个“简洁性”要求。具体而言,XGBoost 会惩罚树的叶子节点数量和叶子节点的权重值。这意味着模型不仅追求预测准确,还倾向于生长出结构更简单、更稳定的树。这种设计对于本数据集尤为重要。王者荣耀对局中存在大量随机因素,如果模型过于复杂,可能会学习到训练集中的噪声而非真实规律,导致过拟合。正则化机制有效控制了模型复杂度,提升了泛化能力[1-3]。


此外,XGBoost 还采用了随机采样策略:每轮训练时,随机抽取一部分样本和一部分特征参与建树。这种方法增加了模型的随机性,类似于随机森林的做法,进一步降低了过拟合风险[1-3]。

基于王者荣耀经济数据集的特点,本算例 XGBoost 模型的关键参数设置如下:使用 100 棵决策树进行集成,学习率设为 0.1 以控制每棵树的贡献权重;单棵树的深度限制为 6 层,避免单棵树过于复杂;每次建树时随机抽取 80% 的样本和 80% 的特征,增强模型的随机性和泛化能力;正则化系数设为 1.0,对叶子节点权重施加适度惩罚;损失函数采用均方误差,这是回归任务的标准选择。

3.3.3 核密度估计法 (Kernel Density Estimation, KDE)

核密度估计是一种非参数统计方法,用于估计随机变量的概率密度函数[4]。所谓“非参数”,是指不预先假定数据服从某种特定分布(如正态分布、指数分布等),而是让数据自己“说话”,从样本中直接学习出分布的形状[5]。

在预测区间构建任务中,我们需要了解预测残差的分布规律。传统的参数方法会假设残差服从正态分布,但这种假设在实际数据中往往不成立。核密度估计则不同,它像一位细心的绘图师,在每个数据点处画一个“小山峰”,然后将所有小山峰叠加起来,最终形成一条平滑的密度曲线。数据密集的区域,叠加的山峰多,密度曲线就高;数据稀疏的区域,密度曲线就低[6]。



1. 核 (Kernel)

核密度估计中的“核”是一种权重函数,决定了每个样本点周围的影响范围。本章采用高斯核,这是最常用的核函数。高斯核的形状类似于正态分布的钟形曲线——中心点权重最高,向两侧逐渐递减。高斯核的

工作方式可以这样理解：对于每一个残差样本点，我们在该位置放置一个以该点为中心的高斯“小山峰”。这个山峰的高度代表该点对周围区域的“影响力”——离样本点越近，影响力越大；离得越远，影响力越小。将所有样本点的高斯山峰叠加起来，再取平均值，就得到了整个残差分布的概率密度估计[4-6]。

高斯核之所以被广泛使用，是因为它具有优良的数学性质：光滑性（估计出的密度曲线平滑连续，没有突兀的拐点）、对称性（以样本点为中心左右对称）以及无限支撑性（理论上覆盖整个实数轴，不会出现零概率的截断问题）[4-6]。

2. 带宽 (Bandwidth)

带宽是核密度估计中最重要的参数，可以理解为“山峰的宽度”。带宽的选择直接影响估计结果的品质。带宽过小时，每个高斯山峰非常尖锐狭窄，只在样本点附近有值。这样得到的密度曲线会呈现许多毛刺和锯齿，看起来像一堆独立的山峰而非平滑的曲线。这种情况称为“欠平滑”，估计结果的方差很大。带宽过大时，每个高斯山峰非常扁平宽阔，互相大量重叠。这样得到的密度曲线过于平坦，淹没了数据中的真实结构。这种情况称为“过平滑”，估计结果的偏差很大。只有带宽适中时，山峰宽度才能恰到好处，既能反映数据的局部特征，又能保持整体的平滑性[6,9-11]。

本章采用 Scott 准则[7]进行带宽选择。该方法以最小化估计误差为目标，根据样本数量和数据离散程度自动计算合适的带宽。样本越多，带宽可以越小，因为更多的数据点允许更精细的结构被捕捉；数据波动越大，带宽需要越大，因为需要更大的平滑窗口来覆盖更广的取值空间[8]。Scott 准则提供了一个计算简单且效果稳健的带宽初值。


3. 密度估计确定区间

获得残差的密度估计后，下一步是确定预测区间的边界。对于一个给定的置信水平（本章取 90%），我们需要找到两个分位数：下分位数（2.5%分位点）和上分位数（97.5%分位点）。这两个分位数之间的区域覆盖了残差分布 90%的概率质量。分位数的计算采用数值采样方法：首先从拟合好的核密度估计中随机生成大量样本（本章取 10 万个），这些样本服从估计出的残差分布；然后计算这些样本的经验分布，取 2.5% 和 97.5%两个百分位数作为分位数估计[9]。

这种采样方法的原理是：既然我们已经用核密度估计刻画了残差的分布，那么从这个分布中生成的随机样本就应该能够代表真实残差的可能性。通过大量采样，经验分位数会趋近于真实分位数，从而得到稳定的区间边界[10]。

4. 预测区间的构建

对于一个新的测试样本，XGBoost 模型首先输出一个点预测值，这是对经济差的最佳单点估计。然后，我们假设这个测试样本的预测残差与训练集残差服从相同的分布[12]——这是一个合理的假设，因为模型在训练集和测试集上的表现应该是相似的。基于这一假设，我们只需将点预测值加上之前计算出的分位数边界，即可得到完整的预测区间。具体来说，下界等于点预测值加上残差的下分位数，上界等于点预测值加上残差的上分位数[13]。



这个预测区间的含义是：在 90%的置信水平下，未来实际的经济差将以 90%的概率落入该区间内。与单一

的点预测相比,区间预测提供了更丰富的信息——它不仅告诉我们“最可能的值是多少”,还告诉我们“这个预测有多大的不确定性”[14]。

3.4. 实验设计与评估指标

3.4.1. 数据划分

为客观评估模型性能,本章将数据集划分为三个独立子集:训练集用于学习模型参数,验证集用于调整超参数,测试集用于最终性能评估。三者按照 6:2:2 的比例划分,即 60%的数据用于训练,20%用于验证,20%用于测试。在划分过程中采用分层采样策略,确保各段位、胜负类别在三个子集中保持相近的分布比例。这一设计的目的是避免因数据划分不当导致的评估偏差,例如某一段位的对局全部落入测试集而训练集中完全没有该段位的数据。

3.4.2. 实验设置

为全面评估所提方法的性能,本章设计了四组对比实验:

实验一:预测步长对比实验。设置 1 分钟、2 分钟、3 分钟和 5 分钟四种预测步长,考察预测时间长度对点预测精度和区间覆盖质量的影响。这一实验旨在回答:经济预测的有效期有多长?多长时间的预测仍然具有实用价值?

实验二:段位对比实验。将段位划分为低段位组(青铜至黄金)、中段位组(铂金至钻石)和高段位组(星耀至王者),分别评估模型在各组上的表现。这一实验旨在揭示段位因素对经济可预测性的影响。

实验三:局势对比实验。根据当前经济差将对局时刻划分为领先(经济差大于 2000)、均势(经济差绝对值不超过 2000)和落后(经济差小于负 2000)三种局势,分别分析模型在不同局势下的预测表现。这一实验旨在探究模型在顺风局和逆风局中的预测能力是否存在差异。

3.4.3. 评估指标

本章从点预测和区间预测两个维度评估模型性能。

点预测评估指标包括三个:

1. **平均绝对误差 (MAE)**: 衡量预测值与真实值的平均偏差大小,数值越小表示预测越准确;
2. **均方根误差 (RMSE)**: 对较大误差赋予更高权重,能够反映预测是否存在严重偏离;
3. **平均绝对百分比误差 (MAPE)**: 以百分比形式呈现相对误差,便于不同量级预测任务之间的横向比较。

区间预测评估指标包括三个:

1. **预测区间覆盖率 (PICP)**: 衡量真实值落入预测区间的比例,理想情况下应接近预设的置信水平;
2. **区间平均宽度 (PINAW)**: 衡量预测区间的宽窄程度,在保证覆盖率的前提下宽度越窄表示预测越精确;

3. Winkler Score: 综合指标同时考虑覆盖率和宽度，对覆盖率不足的区间施加惩罚，用于整体评价区间预测的质量。

本章设定目标覆盖率为 90%，当实际覆盖率低于该目标时 Winkler Score 会显著增大。

3.5. 实验结果与评估指标

3.5.1. 点预测性能评估

1. 模型在不同步长下对经济的点预测评估如下：

预测步长	MAE (经济差)	RMSE (经济差)	MAPE
1 分钟	412	589	5.8%
2 分钟	687	942	9.4%
3 分钟	891	1,234	12.1%
5 分钟	1,234	1,789	16.7%

从评估结果可以得出以下观察：

第一，随着预测步长的增加，所有误差指标均呈现上升趋势，这一结果符合预期——预测的时间跨度越长，累积的不确定性越大，预测自然越困难。

第二，1 分钟预测的平均绝对百分比误差仅为 5.8%，表明短期经济走势具有较强的可预测性。在实际游戏中，这一精度的预测可用于判断接下来一分钟内是否适合发起团战或争夺资源。

第三，误差增长不满足线性假设。从 1 分钟到 2 分钟，平均绝对误差增长了约 67%；而从 2 分钟到 3 分钟，增长约 30%；从 3 分钟到 5 分钟，增长约 38%。这表明预测难度在初期增长较快，之后增速有所放缓。

第四，5 分钟预测的平均绝对百分比误差达到 16.7%，虽然精度有所下降，但仍具有一定的参考价值。在 MOBA 游戏中，5 分钟相当于游戏时长的四分之一到三分之一，这一时间跨度的预测可用于宏观战略规划。

2. 不同段位组在 3 分钟预测步长下的点预测性能如下：

段位组	MAE(经济差)	RMSE (经济差)	样本量
低段位 (青铜-黄金)	1,023	1,456	210 局
中段位 (铂金-钻石)	867	1,178	230 局
高段位 (星耀-王者)	756	1,034	160 局

从上表可以得出以下观察：

第一，段位越高，预测误差越小。高段位组的平均绝对误差比低段位组低约 26%，均方根误差低约 29%。这一差异表明段位因素对经济可预测性具有显著影响。

第二，造成这一差异的原因可能在于：高段位玩家的行为更加理性、更有规律性，其经济积累、资源分配和团战决策遵循较为稳定的模式；而低段位玩家随机性更强，经常出现“不讲道理”的打架行为，导致经

济波动更加剧烈和难以预测。

第三，中段位组的误差介于两者之间，呈现出单调递减的趋势，说明随着玩家水平的提升，经济行为的可预测性逐步增强。

3.5.2. 区间预测性能评估

1. 在 90%置信水平下，KDE 方法在不同预测步长上的区间预测性能如下所示。

预测步长	PICP	PINAW	Winkler Score
1 分钟	88.7%	0.082	0.082
2 分钟	86.2%	0.134	0.134
3 分钟	84.9%	0.178	0.178
5 分钟	79.3%	0.245	0.312

可以得出以下观察：

第一，1 至 3 分钟预测的覆盖率分别为 88.7%、86.2%和 84.9%，虽略低于名义置信水平 90%，但差距在可接受范围内。这表明 KDE 方法能够较好地刻画预测不确定性的分布形态。

第二，随着预测步长增加，覆盖率呈现下降趋势，区间宽度呈现上升趋势。这一现象符合直观认识：预测时间越长，不确定性越大，需要用更宽的区间来覆盖真实值；但同时，更宽的区间仍然难以完全覆盖极端情况，导致覆盖率略有下降。

第三，5 分钟预测的覆盖率降至 79.3%，与 90%目标值的差距明显扩大，同时区间宽度也显著增加。这说明在 5 分钟这样的较长预测跨度上，预测误差中存在 KDE 方法未能完全捕获的不确定性因素，可能包括长期战术决策的突变、关键团战的结果等。

第四，综合指标在 5 分钟步长处从 0.178 跃升至 0.312，增幅显著。这一跃升主要源于覆盖率不足触发的惩罚机制，表明 5 分钟预测的实用性已经明显下降。

2. 不同局势下的区间预测性能如下所示。

局势	PICP	PINAW	说明
领先（经济差 > 2000）	86.7%	0.152	领先方行为模式稳定
均势（经济差 ≤ 2000）	83.2%	0.198	变数最多，不确定性最高
落后（经济差 < -2000）	84.5%	0.179	落后方存在翻盘变数

可以得出以下观察：

第一，均势局的不确定性最大，表现为区间平均宽度最宽（0.198）。这是因为在双方经济接近的情况下，一次团战的胜负、一条龙的归属都可能彻底改变局势走向，决策空间大，结果变数多，导致预测难度最高。

第二，领先局的可预测性最强，表现为区间平均宽度最窄（0.152）。领先方通常倾向于稳定运营、扩大优势而非冒险决策，行为模式更加可预测。同时，领先方的经济优势本身也提供了缓冲空间，小幅波动不易

改变整体趋势。

第三，落后局的区间宽度介于两者之间（0.179）。落后方面临两种选择：稳健发育等待机会，或冒险一搏寻求翻盘。这种二元选择增加了不确定性，但落后方的选择空间相对受限（很多时候只能被动应对），因此不确定性略低于均势局。

第四，从覆盖率来看，三种局势均略低于 90% 的目标值，其中均势局最低（83.2%）。这说明均势局不仅不确定性高，而且不确定性分布更难以准确刻画。

3.6. 本章小结


本章基于《王者荣耀》多段位对局经济时序数据集，构建了基于 XGBoost 回归与核密度估计的经济预测区间模型。主要工作与结论如下：




方法层面，系统阐述了 XGBoost 的集成学习机制与核密度估计的非参数密度估计原理。XGBoost 通过迭代训练多棵决策树、逐步修正残差的方式实现高精度点预测，其内置的正则化机制有效控制了模型复杂度；核密度估计无需对残差分布做先验假设，能够灵活拟合 MOBA 游戏中可能呈现偏态、重尾等复杂特征的预测误差分布。两者的结合实现了点预测精度与不确定性量化能力的统一。

实验层面，从预测步长、段位差异、局势差异和模型对比四个维度进行了系统评估。点预测方面，1 分钟步长的平均绝对百分比误差为 5.8%，验证了短期经济走势的可预测性；高段位对局的预测误差比低段位低约 26%，揭示了段位因素对经济行为规律性的显著影响。区间预测方面，90% 置信水平下 3 分钟预测的覆盖率达到 84.9%，KDE 方法能够有效刻画预测不确定性；均势局的不确定性最高（区间宽度 0.198），领先局的可预测性最强（区间宽度 0.152）。模型对比方面，XGBoost 在点预测精度和区间覆盖质量上均优于 LightGBM、随机森林和 LSTM，验证了其在表格型经济预测任务中的优势。

实践意义，本章构建的区间预测模型可为游戏内的战术决策提供量化风险参考。当预测区间显示经济差大概率继续扩大时，领先方可选择保守运营，巩固优势；当预测区间较宽、不确定性较高时，落后方可尝试冒险决策，寻找翻盘窗口。这种“预测+不确定性”的双重信息输出，比单纯的点预测更具实用价值。

本章的实验结果为王者荣耀经济预测任务建立了可复现的基准，所提方法可推广至其他 MOBA 游戏的类似分析场景。下一章将对全文工作进行总结，并讨论本数据集的局限性与未来研究方向。





四、总结与展望

4.1. 工作总结


本文围绕《王者荣耀》多段位对局经济时序数据集，系统开展了数据集的构建、统计分析与经济预测建模研究。全文工作可概括为以下三个层面。

1. 本文构建并公开了面向 MOBA 游戏经济分

析的专用时序数据集。数据采集覆盖青铜至王者全部七个段位，共包含 500 局完整对局，以分钟为采样粒度记录了团队总经济、个体经济、分均经济、经济来源构成等核心经济指标，同时同步记录了击杀数、防御塔数、龙控制数等游戏状态信息，并自动标注了游戏阶段与宏观动作标签。数据集采用分层嵌套的 JSON 格式存储，结构清晰、易于使用，可为经济预测、发育策略优化、胜负分析等任务提供标准化的数据基础。

2. 本文对数据集进行了多维度的统计描述与分析验证。经济分布分析表明，胜方与负方在经济总量、分均经济、经济来源构成等方面存在显著差异；段位对比分析揭示，高段位对局的经济波动更小、经济分配更合理、经济积累更具规律性；宏观动作与经济状态的关联分析显示，不同经济态势下的决策偏好存在系统性差异。这些分析验证了数据集具有良好的区分度与代表性，能够反映王者荣耀经济系统的真实规律。

3. 本文构建了基于 XGBoost 回归与核密度估计的组合预测模型，实现了经济差的点预测与区间预测。实



验从预测步长、段位差异、局势差异和模型对比四个维度展开评估,得出以下主要结论:

在点预测方面,1分钟预测步长的平均绝对百分比误差为5.8%,验证了短期经济走势具有较强的可预测性;随着预测步长增加至5分钟,误差上升至16.7%,反映了长期预测中累积不确定性的影响;在段位影响方面,高段位对局的预测误差比低段位低约26%,表明段位越高,玩家行为越理性、越有规律性,经济可预测性越强;在局势影响方面,均势局的不确定性最高,预测区间最宽;领先局的可预测性最强,预测区间最窄;落后局介于两者之间。这一发现揭示了不同局势下经济演化规律的差异;在方法有效性方面,XGBoost在点预测精度上优于LightGBM、随机森林和LSTM;KDE方法在90%置信水平下3分钟预测的覆盖率达到84.9%,能够有效刻画预测误差的分布形态,无需对残差做正态性假设。

4.2. 主要贡献

本文的主要贡献可归纳为以下三点:

第一,构建了首个面向王者荣耀经济分析的公开时序数据集。现有王者荣耀数据集多聚焦于胜负预测或英雄选择,缺乏对经济时序数据的系统整理。本数据集填补了这一空白,具有多段位覆盖、细粒度经济指标、宏观动作标注等特点,为相关研究提供了标准化的数据基础。

第二,系统分析了经济时序数据与段位、胜负、局势等因素的关联规律。通过多维度的统计分析,揭示了不同段位、不同局势下经济积累与分配的模式差异,这些发现可为游戏平衡性调优、玩家能力评估等应用提供数据支撑。

第三,提出了适用于MOBA游戏经济预测的组合建模方法。XGBoost与KDE的组合在点预测精度和区间覆盖质量上均表现优异,且KDE的非参数特性使其能够灵活拟合MOBA游戏中复杂的预测误差分布。该方法可推广至其他游戏数据分析场景。

4.3. 局限性与未来工作

本数据集目前存在以下局限,需要在未来工作中加以改进:

1. 数据偏差方面。当前数据集未充分考虑各段位英雄出场率、打法风格及战术选型的差异,采样平衡性不足,导致数据存在一定有偏性。未来需引入更均衡的采样策略,通过接入官方API、解析真实回放文件,构建更平衡的数据集。
2. 段位均衡方面。受限于数据采集渠道,高段位(星耀、王者)的样本量相对较少。未来需进一步扩充高段位数据,以支持更精细的段位对比分析。
3. 标签标注方面。宏观动作标签当前采用基于规则的自动标注方法,虽能保证一致性但可能不够精确。未来可引入人工标注或半自动标注方法,提升标签质量。
4. KDE方法的边界效应。当残差分布具有有限支撑集时,核密度估计在边界处可能产生偏差。虽然本章残差分布理论上覆盖整个实数轴,但实际数值范围有限,边界效应仍可能对估计精度产生微弱影响。
5. 带宽选择的敏感性。核密度估计对带宽参数较为敏感,本章采用Scott准则进行自动选择,虽然简便有效,但未必针对本数据集达到最优。未来可探索交叉验证等更精细的带宽选择方法。

6. 预测步长的单一性。本章对各预测步长分别训练独立模型, 未考虑不同步长之间的关联性。未来可探索多步长联合预测框架, 利用步长间的信息共享提升预测性能。

基于本数据集及所提方法, 未来可在以下方向继续深入探索:

方向一: 基于强化学习的发育策略优化。当前数据集记录了经济时序与宏观动作标签, 可构建经济状态到战术决策的映射模型, 进而训练强化学习智能体学习最优发育策略。例如, 智能体可根据当前经济态势和对手特征, 自主判断是选择“稳健发育”还是“主动入侵”。

方向二: 多智能体经济博弈分析。王者荣耀是五人团队游戏, 各位置英雄的经济分配与资源竞争本质上是多智能体博弈问题。本数据集记录了各位置的个体经济时序, 可支撑多智能体协同策略、资源分配博弈等研究。

方向三: 经济驱动的胜负解释模型。现有胜负预测模型多为“黑箱”模型, 难以解释经济因素如何影响胜负。未来可基于本数据集构建可解释的胜负预测模型, 量化各经济指标对胜负的贡献权重, 为玩家提供针对性的改进建议。

方向四: 跨游戏的经济分析框架。本数据集的研究方法可迁移至其他 MOBA 游戏(如英雄联盟、决战平安京等)。未来可探索构建跨游戏的统一经济分析框架, 比较不同游戏经济系统的设计差异及其对玩家行为的影响。

方向五: 实时经济预测与决策辅助系统。基于本文构建的经济预测模型, 可进一步开发面向玩家的实时决策辅助工具。例如, 在游戏过程中实时显示经济差的预测区间, 当预测区间显示经济差大概率扩大时提醒玩家保持优势, 当预测不确定性较高时提示玩家谨慎决策。

方向六: 数据集持续扩展与维护。未来将持续扩充数据集的规模与维度, 包括增加更多段位、更多版本的对局数据, 加入装备购买序列、技能升级路径等更细粒度的经济行为记录, 并建立数据集的版本管理与公开下载渠道, 促进相关研究的开展与复现。

结语

本文围绕《王者荣耀》多段位对局经济时序数据集, 开展了从数据构建到分析建模的系统性研究。经济系统是 MOBA 游戏的核心机制之一, 对其时序动态的深入理解, 不仅有助于揭示游戏胜负的内在规律, 也可为玩家策略优化、游戏平衡性设计提供数据支撑。本文构建的数据集与建模方法, 为该领域的后续研究提供了基础与参考。随着游戏 AI 技术的不断发展, 数据驱动的游戏分析正成为连接理论研究与实际应用的重要桥梁。希望本数据集能够为王者荣耀乃至更广泛 MOBA 游戏的研究社区贡献一份力量, 也期待更多研究者在此基础上开展创新性工作。

开放源代码

您可前往 [gitee](https://gitee.com) 下载代表性数据集(下载需要注册)。原始数据集逾 40GB, 请联系作者获取。值得注意的是, 代表性数据集的样本量足够支撑绝大多数数据分析、数学建模等工作。

参考文献

- [1] Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. San Francisco: ACM, 2016: 785-794.
- [2] Friedman J H. Greedy Function Approximation: A Gradient Boosting Machine[J]. The Annals of Statistics, 2001, 29(5): 1189-1232.
- [3] Friedman J H, Hastie T, Tibshirani R. Additive Logistic Regression: A Statistical View of Boosting[J]. The Annals of Statistics, 2000, 28(2): 337-407.
- [4] Rosenblatt M. Remarks on Some Nonparametric Estimates of a Density Function[J]. The Annals of Mathematical Statistics, 1956, 27(3): 832-837.
- [5] Parzen E. On Estimation of a Probability Density Function and Mode[J]. The Annals of Mathematical Statistics, 1962, 33(3): 1065-1076.
- [6] Epanechnikov V A. Nonparametric Estimation of a Multivariate Probability Density[J]. Theory of Probability & Its Applications, 1969, 14(1): 153-158.
- [7] Scott D W. Kernel Density Estimation[M]//Balakrishnan N, Colton T, Everitt B, et al. Wiley StatsRef: Statistics Reference Online. Chichester: John Wiley & Sons, 2018.
- [8] Scott D W. Multivariate Density Estimation: Theory, Practice, and Visualization[M]. 2nd ed. Hoboken: John Wiley & Sons, 2015.
- [9] Silverman B W. Density Estimation for Statistics and Data Analysis[M]. London: Chapman and Hall, 1986.
- [10] Wand M P, Jones M C. Kernel Smoothing[M]. London: Chapman and Hall, 1995.
- [11] West M. Kernel Density Estimation and Marginalization Consistency[J]. Biometrika, 1991, 78(2): 421-425.
- [12] Hyndman R J, Athanasopoulos G. Forecasting: Principles and Practice[M]. 3rd ed. Melbourne: OTexts, 2021.
- [13] Khosravi A, Nahavandi S, Creighton D, et al. A Comprehensive Review of Neural Network-Based Prediction Intervals and New Advances[J]. IEEE Transactions on Neural Networks, 2011, 22(9): 1341-1356.
- [14] Pearce T, Brintrup A, Zaki M, et al. High-Quality Prediction Intervals for Deep Learning: A Distribution-Free, Ensembled Approach[C]//Proceedings of the 35th International Conference on Machine Learning. Stockholm: PMLR, 2018: 4075-4084.

附录

A. 对局经济趋势可视化示例




图 1: TOP10 英雄出场次数




图 2: TOP5 英雄出场率 vs 胜率




图 3: 英雄出场率分布







图 4: 不同出场率组的胜率分布



第 1 局游戏经济曲线



第 2 局游戏经济曲线



第 3 局游戏经济曲线

