

一种用于光伏储能游戏数据中心的光伏功率概率预测方法及系统

A PV Power Probabilistic Forecasting Method and System for PV-ESS-Powered Game Data Centers

copycat666^{1,2*}

1. 《电子游戏科学与技术》编辑委员会, dev.projectamadeus@outlook.com

2. EigenLife 机器学习实验室, 东北电力大学, 吉林

*: Corresponding Author

摘要：本发明公开了一种用于光伏储能游戏数据中心的光伏功率概率预测方法及系统，属于光伏发电功率预测技术领域。本发明包括：首先，获取历史气象数据与光伏功率数据，进行数据预处理与划分；其次，通过密度峰值聚类将历史气象数据划分为若干典型聚类，生成软分配向量；然后，构建聚类条件引导的变分自编码器，学习气象-功率数据的低维流形结构，输出解耦的初始隐变量；接着，构建混合专家 SDE-Net，包括 DriftNet 漂移网络和 DiffNet 扩散网络，其中 DiffNet 采用切向各向异性噪声注入机制，包含流形切向约束和特征重要性加权；采用 Euler-Maruyama 算法求解离散型随机微分方程，生成预测样本集合；最后，通过联合损失函数对模型进行训练，输出预测均值和预测区间。本发明通过流形学习和切向各向异性噪声注入机制，实现了物理一致性约束下的不确定性量化，显著提升了光伏功率概率预测的可靠性和锐度。

关键词：光伏功率预测，光伏储能，概率预测，区间预测，游戏数据中心

技术领域

本发明涉及光伏发电功率预测技术领域，具体涉及一种基于变分自编码器与混合专家 SDE-Net 的光伏功率概率预测方法及系统。

背景技术

随着全球能源转型加速，在游戏数据中心等高性能计算场景中，集成光伏（PV）系统和电池储能系统（ESS）以构建绿色微电网已成为重要趋势。然而，此类 PV-ESS 供电系统的稳定运行依赖于对“净负荷”（即数据中心负载与光伏出力的差值）的精准预测。净负荷预测直接决定了 ESS 的充放电策略及电网交互功率，对系统的经济性与可靠性至关重要。现有的概率预测方法（如贝叶斯神经网络、蒙特卡洛 Dropout、分位数回归等）虽能提供预测区间，但在 PV-ESS 净负荷预测场景中存在以下关键问题：

第一，缺乏对多源物理耦合关系的建模能力。净负荷由动态变化的数据中心负载（受用户行为、游戏发布等影响）和间歇性光伏出力（受气象条件支配）共同决定，二者在原始观测空间中存在复杂的非线性耦合。现有方法通常将各特征视为独立通道，忽略了数据的本征流形结构，导致在快速变化场景下预测误差急剧增大。

第二，各向同性噪声假设不符合物理实际。现有方法（如原始 SDE-Net）普遍采用各向同性的随机噪声注入机制，无法区分不同物理特征（如用户活跃数与云层类型）对净负荷不确定性的差异化贡献。这种机制会在确定性强的特征上引入冗余噪声，而在随机性强的特征上噪声注入不足，导致预测区间在物理上不一致、锐度过窄或覆盖率过低。

第三，缺乏对流形几何约束的利用。真实世界的 PV-ESS 净负荷数据分布在高维观测空间中，但其本质自由度远低于表观维度。现有方法在高维空间中直接建模不确定性，使得随机演化过程容易偏离物理可行的状态区域，尤其在遇到“恶劣天气叠加游戏发布”等复合分布外事件时，预测区间严重失效。

因此，亟需一种能够挖掘气象-负载耦合流形结构、在数据本征几何上施加物理一致性噪声注入，并提供可靠且锐利的预测区间的 PV-ESS 净负荷概率预测方法。

附图说明

图 1 为本发明方法的整体流程图；

图 2 为变分自编码器的整体架构图；

图 3 为混合专家 SDE-Net 的整体架构图。

具体实施方式

下面结合附图和具体实施例对本发明作进一步详细说明。

在一个具体实施例中，对系统初始值进行定义，定义 N_{meteo} 为气象要素种类数， D_y 为每日光伏功率采样点数量， L 为序列窗口长度， q 为截断距离百分位数， τ 为软分配温度参数， θ_ρ 是局部密度阈值， θ_δ 为相对距离阈值， β 为 KL 散度权衡系数， N_{layer} 为 MoE-Informer 层数， N_{exp} 为专家网络数量， N_{top} 为 Top-K 激活保留专家数， $D_{forward}$ 为专家网络的前馈隐藏层维度， γ_0 为基础噪声强度常数， α'_{init} 为可学习缩放参数向量初始值， N_{bin} 为互信息分箱数， T 为离散型随机微分方程总演化时间， N_t 为时间步数， M 为前向传播次数， λ_1 为 $\mathcal{L}_{pred}$ 的权重系数， λ_2 为 $\mathcal{L}_{Wass}$ 的权重系数， λ_3 为 $\mathcal{L}_{MoE}$ 的权重系数， η 为初始学习率， N_{pat} 为早停耐心值， B 为批次大小。

S1：数据预处理与划分

S1.1：获取历史气象数据与光伏功率数据。本实施例的数据集来源于某地两年的历史气象数据与光伏功率数据，时间分辨率为 15 分钟。历史气象数据包括水平面总辐照度、散射辐照度、直射辐照度、云量、温度、相对湿度、气压、风速、风向，共 N_{meteo} 种气象要素；光伏功率数据为对应历史气象数据时间分辨率下的光伏有功功率序列，每日 D_y 个采样点。其中 N_{meteo} 为气象要素种类数， D_y 为每日光伏功率采样点数量。

S1.2：数据清洗与归一化。首先，对步骤 S1.1 所述的历史气象数据与光伏功率数据进行数据清洗：数据中的缺失值采用线性插值填充，对超出最大装机容量的光伏功率异常数据使用物理模型估算理论功率并替换。然后，对各气象要素的数据进行 Z-score 标准化，消除量纲差异。最后，对光伏功率数据按装机容量进行归一化，将光伏功率值映射至 $[0,1]$ 区间。

S1.3：数据划分：按时间顺序将数据集划分为训练集（前 70%）和验证集（后 30%），训练集用于模型训练，验证集用于模型选择。以气象数据的对应时刻的光伏功率向量作为预测目标，记为 $y_j \in \mathbb{R}^{D_y}$ 。

S2：密度峰值聚类

对每日气象特征向量执行密度峰值聚类，将历史气象数据划分为若干典型聚类，生成每日气象特征向量的软分配向量。具体如下：

S2.1：构建每日气象特征向量。针对清洗后的气象数据的每个气象要素计算以下四种统计特征：日均值、日最大值、日最小值、日标准差，构成每日气象特征矩阵 $U_{meteo} \in \mathbb{R}^{N_{day} \times D_u}$ ，其中 $D_u = 4 \times N_{meteo}$ 为各

个气象要素的统计特征数, N_{day} 为总天数, 则 $\mathbf{U}_{meteo}$ 的第 i 行为第 i 日的每日气象特征向量, 记做 $\mathbf{u}_i \in \mathbb{R}^{D_u}$, 其中 $i = 1, 2, \dots, N_{day}$ 。

S2.2: 计算距离矩阵 $[d_{i'j'}]$ 。对于任意 $i', j' \in [1, N_{day}]$, 计算任意两日的每日气象特征向量 $\mathbf{u}_{i'}$, $\mathbf{u}_{j'}$ 的欧氏距离 $d_{i'j'} = \|\mathbf{u}_{i'} - \mathbf{u}_{j'}\|_2$ 。

S2.3: 确定截断距离 d_c 。将距离矩阵 $[d_{i'j'}]$ 中所有非零距离值按升序排列, 取第 q 百分位数作为截断距离, 其中 q 为截断距离百分位数。

S2.4: 计算局部密度。记第 i 日的每日气象特征向量 $\mathbf{u}_i$ 的局部密度为 ρ_i , 采用高斯核密度估计:

$$\rho_i = \sum_{j'=1}^{N_{day}} \exp\left(-\left(\frac{d_{ij'}}{d_c}\right)^2\right)$$

S2.5: 计算相对距离。记第 i 日的每日气象特征向量 $\mathbf{u}_i$ 的相对距离为 δ_i 。将样本按 ρ_i 降序排列, 设排序后的索引序列为 $\{i_1, i_2, \dots, i_{N_{day}}\}$, 满足 $\rho_{i_1} \geq \rho_{i_2} \geq \dots \geq \rho_{i_{N_{day}}}$, 则局部密度最高样本的相对距离为

$$\delta_{i_1} = \max_{j' \neq i_1} d_{i_1 j'}, \text{ 对于 } k' = 2, 3, \dots, N_{day}, \delta_{i_{k'}} = \min_{m'=1}^{k'-1} d_{i_{k'} i_{m'}}。$$

S2.6: 选取聚类中心。绘制以局部密度为横轴、相对距离为纵轴的决策图, 选取同时满足 $\rho_i > \theta_\rho \cdot \bar{\rho}$ 且 $\delta_i > \theta_\delta \cdot \bar{\delta}$ 的点作为聚类中心, 其中, θ_ρ 是局部密度阈值, θ_δ 为相对距离阈值, $\bar{\rho}$ 和 $\bar{\delta}$ 分别为局部密度和相对距离的均值。记聚类簇数为 K , $\mathbf{c}_k \in \mathbb{R}^{D_u}$ 为第 k 簇的中心向量, 其中 $k = 1, 2, \dots, K$ 。

S2.7: 计算软分配向量。记第 i 日的每日气象特征向量 $\mathbf{u}_i$ 的软分配向量为 $\mathbf{s}_i = [s_i^{(1)}, s_i^{(2)}, \dots, s_i^{(K)}]^\top \in \mathbb{R}^K$, 则:

$$s_i^{(k)} = \frac{\exp(-\|\mathbf{u}_i - \mathbf{c}_k\|_2^2 / \tau)}{\sum_{k''=1}^K \exp(-\|\mathbf{u}_i - \mathbf{c}_{k''}\|_2^2 / \tau)}$$

其中 τ 为软分配温度参数, $k'' = 1, 2, \dots, K$ 。

S3: 变分自编码器构建

构建聚类条件引导的变分自编码器, 包括编码器、解码器两个网络。通过编码器-解码器结构学习气象-功率数据的低维流形结构, 输出解耦的初始隐变量。变分自编码器的整体架构如图 2 所示, 具体如下:

S3.1: 构建序列样本。采用滑动窗口方式, 以连续 L 个时刻的历史气象数据作为输入特征矩阵, 记为 $\mathbf{X}_j \in \mathbb{R}^{L \times N_{meteo}}$, $j = 1, 2, \dots, N_{seq}$, 其中 N_{seq} 为序列样本总数, L 为序列窗口长度。

S3.2: 构建编码器。编码器接收输入特征矩阵 $\mathbf{X}_j$ 和对应第 i'' 日的每日气象特征向量的软分配向量 $\mathbf{s}_{i''}$ 。首先将 $\mathbf{X}_j$ 展平为向量 $\mathbf{x}_j^{flat} \in \mathbb{R}^{L \cdot N_{meteo}}$, 与 $\mathbf{s}_{i''}$ 拼接后经 4 层全连接层处理, 各全连接层的神经元数量分别为 512、256、128、64。编码器输出随机隐变量分布的均值向量 $\boldsymbol{\mu}_j \in \mathbb{R}^{D_z}$ 和对数方差向量 $\log \boldsymbol{\sigma}_j^2 \in \mathbb{R}^{D_z}$, 其中 D_z 为隐空间维度。

S3.3: 生成随机隐变量。从标准正态分布采样随机向量 $\boldsymbol{\epsilon}_j \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_{D_z})$, 其中 $\mathbf{I}_{D_z}$ 是维数为 D_z 的单位方阵。

采用重参数化技巧生成随机隐变量 $\mathbf{r}_j^{(0)} \in \mathbb{R}^{D_z}$:

$$\sigma_j = \exp\left(\frac{1}{2} \cdot \ln \sigma_j^2\right)$$

$$\mathbf{r}_j^{(0)} = \boldsymbol{\mu}_j + \sigma_j \odot \boldsymbol{\epsilon}_j$$

其中 $\odot$ 为 Hadamard 积。

S3.4: 构建解码器网络。解码器网络将随机隐变量 $\mathbf{r}_j^{(0)}$ 映射回原始数据空间，经 4 层全连接层处理，各全连接层的神经元数量分别为 64、128、256、512，最终输出重构序列 $\hat{\mathbf{X}}_j \in \mathbb{R}^{L \times N_{meteo}}$ 。

S3.5: 变分自编码器损失函数。通过优化证据下界训练变分自编码器，损失函数 $\mathcal{L}_{VAE}$ 包含重构损失和 KL 散度正则项。重构损失采用均方误差，确保流形能够保留原始数据的主要信息。KL 散度正则项促使隐空间分布接近标准正态先验，有利于特征的解耦，KL 散度权衡系数取 β 。

S3.6: 反向传播：变分自编码器根据步骤 S3.5 所述的损失函数执行反向传播，调整步骤 S3.2 所述的编码器和步骤 S3.4 所述的解码器中各神经元的参数。训练过程中采用早停策略，最终，变分自编码器输出解耦的初始隐变量 $\mathbf{z}_j^{(0)}$ 。

S4: 混合专家 SDE-Net 构建

构建混合专家 SDE-Net，包括 DriftNet 漂移网络、DiffNet 扩散网络。混合专家 SDE-Net 的整体架构如图 3 所示，具体如下：

S4.1: 构建 DriftNet 漂移网络。DriftNet 漂移网络由 N_{layer} 层 MoE-Informer 层、平均池化层、输出投影层组成，其中 N_{layer} 为 MoE-Informer 层数。每层 MoE-Informer 层在标准 Informer 层的前馈网络中引入混合专家架构，包含多头概率稀疏自注意力子层和混合专家前馈子层。多头概率稀疏自注意力子层通过概率稀疏机制筛选出对预测起主导作用的查询向量，降低计算复杂度。混合专家前馈子层包含 N_{exp} 个并行的专家网络和一个门控路由网络，其中 N_{exp} 为专家网络数量。每个专家网络为独立的两层全连接层，各全连接层的神经元数量分别为 256、64，采用 GELU 激活函数，专家网络的前馈隐藏层维度为 $D_{forward}$ ，其中 $D_{forward}$ 为专家网络的前馈隐藏层维度。门控路由网络接收当前混合专家前馈子层的输入，输出各专家的路由权重，采用 Top-K 稀疏激活机制，仅保留路由权重最大的 N_{top} 个专家参与计算，其余专家的路由权重重置零并重新归一化，其中 N_{top} 为 Top-K 激活保留专家数。门控路由网络采用负载均衡损失作为损失函数，用于防止专家退化，通过 KL 散度损失鼓励各专家平均使用频率接近均匀分布，同时通过路由权重的信息熵正则鼓励路由决策的多样性，避免门控网络退化至仅激活单一专家。

S4.2: 构建 DiffNet 扩散网络。DiffNet 采用多层感知机结构，接收初始隐变量 $\mathbf{z}_j^{(0)}$ 作为输入，经 3 层全连接层处理，各全连接层的神经元数量分别为 128、64、32，最终输出扩散系数向量 $\mathbf{G}_j \in \mathbb{R}^{D_z}$ 。同时，采用切向各向异性噪声注入机制对扩散系数向量 $\mathbf{G}_j$ 进行约束，包含流形切向约束和特征重要性加权两个部分：

S4.2.1: 流形切向约束

将噪声约束在初始隐变量 $\mathbf{z}_j^{(0)}$ 组成的数据流形的切空间内，确保随机扰动仅沿数据分布的主要变化方向施加，不会将系统状态驱离物理合理的区域。具体实现步骤如下：

首先，计算步骤 S3.2 所述编码器输出均值向量 μ_j 对输入展平向量 $\mathbf{x}_j^{flat}$ 的雅可比矩阵 $\mathbf{J}_j \in \mathbb{R}^{D_z \times (L \cdot N_{meteo})}$ ，并对雅可比矩阵 $\mathbf{J}_j$ 进行奇异值分解：

$$\mathbf{J}_j = \frac{\partial \mu_j}{\partial \mathbf{x}_j^{flat}} = \mathbf{U}_j \mathbf{\Lambda}_j \mathbf{V}_j^T$$

其中 $\mathbf{U}_j \in \mathbb{R}^{D_z \times D_z}$ 为左奇异向量矩阵， $\mathbf{\Lambda}_j \in \mathbb{R}^{D_z \times (L \cdot N_{meteo})}$ 为奇异值对角矩阵， $\mathbf{V}_j \in \mathbb{R}^{(L \cdot N_{meteo}) \times (L \cdot N_{meteo})}$ 为右奇异向量矩阵。

然后，取前 r 个最大奇异值对应的右奇异向量构成切空间基矩阵 $\mathbf{V}_{tang,j} \in \mathbb{R}^{(L \cdot N_{meteo}) \times r}$ 。

最后，计算切空间投影矩阵 $\mathbf{P}_{tang,j} \in \mathbb{R}^{(L \cdot N_{meteo}) \times (L \cdot N_{meteo})}$ ：

$$\mathbf{P}_{tang,j} = \mathbf{V}_{tang,j} \mathbf{V}_{tang,j}^T$$

该投影矩阵满足幂等性 $\mathbf{P}_{tang,j}^2 = \mathbf{P}_{tang,j}$ 和对称性 $\mathbf{P}_{tang,j}^T = \mathbf{P}_{tang,j}$ 。切空间投影矩阵 $\mathbf{P}_{tang,j}$ 对随机噪声施加流形切向约束，确保随机噪声仅沿流形的主要变化方向施加，不会将系统状态驱离物理合理的区域。

S4.2.2：特征重要性加权

通过计算初始隐变量 $\mathbf{z}_j^{(0)}$ 各维度与光伏功率向量 $\mathbf{y}_j$ 的互信息获得特征重要性向量 $\mathbf{w}_{imp} \in \mathbb{R}^{D_z}$ 。对于初始隐变量 $\mathbf{z}_j^{(0)}$ 第 d 维分量 ($d = 1, 2, \dots, D_z$) 和光伏功率向量 $\mathbf{y}_j$ 的每个维度 y_m ($m = 1, 2, \dots, D_y$)，首先进行等宽分箱离散化，互信息分箱数为 N_{bin} 。记分箱后得到的初始隐变量 $\mathbf{z}_j^{(0)}$ 第 d 维分量为 $\tilde{z}_{bin}^{(d)}$ ，记分箱后得到的离散化光伏功率变量为 $\tilde{y}_{bin}^{(m)}$ ，计算 $\tilde{z}_{bin}^{(d)}$ 与 $\tilde{y}_{bin}^{(m)}$ 的互信息：

$$I(\tilde{z}_{bin}^{(d)}; \tilde{y}_{bin}^{(m)}) = \sum_{a=1}^{N_{bin}} \sum_{b=1}^{N_{bin}} p(a, b) \ln \left(\frac{p(a, b)}{p(a)p(b)} \right)$$

其中 $p(a, b)$ 为 $\tilde{z}_{bin}^{(d)}$ 取第 a 个分箱且 $\tilde{y}_{bin}^{(m)}$ 取第 b 个分箱的联合概率， $p(a)$ 和 $p(b)$ 为边缘概率，

$I(\tilde{z}_{bin}^{(d)}; \tilde{y}_{bin}^{(m)})$ 是初始隐变量 $\mathbf{z}_j^{(0)}$ 第 d 维分量 $\tilde{z}_{bin}^{(d)}$ 与光伏功率变量 $\tilde{y}_{bin}^{(m)}$ 的互信息。然后，对所有功率维度取平均，通过计算 $\tilde{z}_{bin}^{(d)}$ 与 $\tilde{y}_{bin}^{(m)}$ 的互信息得到初始隐变量 $\mathbf{z}_j^{(0)}$ 第 d 维特征 $\mathbf{z}_{j,d}^{(0)}$ 的重要性度量 $w_{imp,d}$ ，进而构造特征重要性向量 $\mathbf{w}_{imp}$ ：

$$w_{imp,d} = \frac{1}{D_y} \sum_{m=1}^{D_y} I(\tilde{z}_{bin}^{(d)}; \tilde{y}_{bin}^{(m)})$$

$$\mathbf{w}_{imp} = [w_{imp,1}, w_{imp,2}, \dots, w_{imp,D_z}]$$

将 $\mathbf{w}_{imp}$ 进行最大最小归一化，使 $w_{imp,d} \in [0,1]$ 。记各向异性噪声强度向量为 $\boldsymbol{\sigma}_{Ani} = [\sigma'_1, \sigma'_2, \dots, \sigma'_{D_z}] \in \mathbb{R}^{D_z}$ ：

$$\boldsymbol{\sigma}_{Ani} = \gamma_0 \cdot \text{Softplus}(-\boldsymbol{\alpha}' \odot \mathbf{w}_{imp} \odot \mathbf{z}_j^{(0)})$$

其中 γ_0 为基础噪声强度常数； $\boldsymbol{\alpha}' = [\alpha'_1, \alpha'_2, \dots, \alpha'_{D_z}] \in \mathbb{R}^{D_z}$ 为可学习的缩放参数向量，初始值为 $\boldsymbol{\alpha}'_{init}$ ， $\boldsymbol{\alpha}'_{init}$ 为可学习缩放参数向量初始值； $\odot$ 表示逐元素乘积；Softplus函数是一种平滑地将实数映射为非负值的激活函数，确保噪声强度始终大于零。该公式使噪声强度与特征重要性呈负相关：对于初始隐变量 $\mathbf{z}_j^{(0)}$ 的第 d 维特征 $z_{j,d}^{(0)}$ ，对应的各向异性噪声强度 σ'_d 为：

$$\sigma'_d = \gamma_0 \cdot \text{Softplus}(-\alpha'_d \cdot w_{imp,d} \cdot z_{j,d}^{(0)})$$

其中， $w_{imp,d}$ 是第 d 维特征的特征重要性度量， $z_{j,d}^{(0)}$ 是初始隐变量 $\mathbf{z}_j^{(0)}$ 的第 d 维特征， α'_d 是对应的可学习的缩放参数。对于 $w_{imp,d}$ 较大的重要特征维度，该公式输出较小值，施加较弱扰动以保持预测稳定性；对于 $w_{imp,d}$ 较小的次要特征维度，噪声强度较大，允许探索不确定性。

S5：离散型随机微分方程求解

混合专家 SDE-Net 的前向传播过程可以被视为一个离散型随机微分方程的求解过程。对于离散型随机微分方程，本专利采用 Euler-Maruyama 算法进行求解。

在离散型随机微分方程求解过程中，首先将各向异性噪声强度向量 $\boldsymbol{\sigma}_{Ani}$ 通过步骤 S4.2.1 所述的编码器的雅可比矩阵的摩尔-彭若斯广义逆映射回输入空间，经步骤 S4.2.1 所述的切空间投影矩阵约束后再映射回隐空间，得到流形切向约束修正后的各向异性噪声强度向量 $\boldsymbol{\sigma}_{tang,j}$ ：

$$\boldsymbol{\sigma}_{tang,j} = \mathbf{J}_j \left(\mathbf{P}_{tang,j} (\mathbf{J}_j^\dagger \boldsymbol{\sigma}_{Ani}) \right)$$

其中 $\mathbf{J}_j^\dagger$ 为 $\mathbf{J}_j$ 的摩尔-彭若斯广义逆。

然后，采用 Euler-Maruyama 算法求解离散型随机微分方程。从初始时刻 $t_0 = 0$ 的初始隐变量 $\mathbf{z}_j^{(0)}$ 开始，迭代更新 N_t 步得到终端隐变量 $\mathbf{z}_j^{(N_t)}$ 。对于第 n 步 ($n = 0, 1, \dots, N_t - 1$)，当前时刻 $t_n = n \cdot \Delta t$ ，其中时间步长 $\Delta t = T/N_t$ ，其中 T 为离散型随机微分方程总演化时间， N_t 为时间步数，则更新公式为：

$$\mathbf{z}_j^{(n+1)} = \mathbf{z}_j^{(n)} + F_\theta(\mathbf{z}_j^{(n)}, t_n, \mathbf{s}_j) \cdot \Delta t + (\mathbf{G}_j \odot \boldsymbol{\sigma}_{tang,j}) \cdot \sqrt{\Delta t} \cdot \boldsymbol{\epsilon}_j^{(n)}$$

其中： $F_\theta(\mathbf{z}_j^{(n)}, t_n, \mathbf{s}_j)$ 为步骤 S4.1 所述的 DriftNet 漂移网络在时刻 t_n 的输出，通过描述系统在初始隐变量 $\mathbf{z}_j^{(0)}$ 组成的数据流形上的确定性漂移趋势，引导初始隐变量 $\mathbf{z}_j^{(0)}$ 向预测目标方向演化； $\mathbf{G}_j \in \mathbb{R}^{D_z}$ 为步骤 S4.2 所述的 DiffNet 扩散网络输出的扩散系数向量，描述预测空间中各功率维度的基准不确定性强度；

$\sigma_{tang,j}$ 为经流形切向约束修正后的各向异性噪声强度向量，用于将扩散系数向量 $\mathbf{G}_j$ 各功率维度的基准不确定性强度约束在物理合理范围内， $\epsilon_j^{(n)}$ 为标准高斯噪声。

终端隐变量 $\mathbf{z}_j^{(N_t)}$ 经 DriftNet 漂移网络的平均池化层和输出投影层得到最终预测均值 $\hat{\mathbf{y}}_j \in \mathbb{R}^{D_y}$ 。

S6: 生成预测样本集合

对于每个初始隐变量 $\mathbf{z}_j^{(0)}$ ，重复执行 M 次步骤 S5 所述的离散型随机微分方程求解过程，即 M 次随机前向传播，经 Euler-Maruyama 算法求解离散型随机微分方程得到终端隐变量序列 $\{\mathbf{z}_{j,1}^{(N_t)}, \mathbf{z}_{j,2}^{(N_t)}, \dots, \mathbf{z}_{j,M}^{(N_t)}\}$ ，最终获得预测样本集合 $\{\hat{\mathbf{y}}_j^{(1)}, \hat{\mathbf{y}}_j^{(2)}, \dots, \hat{\mathbf{y}}_j^{(M)}\}$ 。该预测样本集合构成预测分布。

S7: 模型训练

模型训练过程中会执行步骤 S3 到步骤 S6 所述的过程，构建联合损失函数 $\mathcal{L}_{total}$ 对步骤 S3、步骤 S4 所述模型进行训练。联合损失函数 $\mathcal{L}_{total}$ 由以下 4 部分组成：

$$\mathcal{L}_{total} = \mathcal{L}_{VAE} + \lambda_1 \mathcal{L}_{pred} + \lambda_2 \mathcal{L}_{Wass} + \lambda_3 \mathcal{L}_{MoE}$$

其中： $\mathcal{L}_{VAE}$ 为步骤 S3 所述变分自编码器的损失函数，包含重构损失和 KL 散度正则项； $\mathcal{L}_{pred}$ 为步骤 S4.1 所述 DriftNet 漂移网络的预测精度损失，采用均方误差计算预测值与真实值的差异； $\mathcal{L}_{Wass}$ 为 Wasserstein 距离损失的 Sinkhorn 近似，用于计算步骤 S6 所述预测分布和真实分布的整体差异，使预测分布的形状逼近真实分布，从而间接保障基于该分布构建的预测区间兼具良好的覆盖率与合理的宽度； $\mathcal{L}_{MoE}$ 为步骤 S4.1 所述门控路由网络的负载均衡损失。 λ_1 为 $\mathcal{L}_{pred}$ 的权重系数， λ_2 为 $\mathcal{L}_{Wass}$ 的权重系数， λ_3 为 $\mathcal{L}_{MoE}$ 的权重系数。

采用 Adam 优化器以最小化总损失函数为目标联合优化所有可学习参数，初始学习率为 η ，采用 ReduceLROnPlateau 衰减策略。训练过程中采用早停策略，当验证集损失连续 N_{pat} 轮未下降时停止训练，并保存模型参数。批次大小取 B 。其中 N_{pat} 为早停耐心值， B 为批次大小。

S8: 概率预测

S8.1: 对于待预测样本，首先计算其每日气象特征向量，通过密度峰值聚类得到软分配向量。

S8.2: 通过变分自编码器输出解耦的初始隐变量，经混合专家 SDE-Net 模型执行 M 次随机前向传播。对于第 r 次传播 ($r = 1, 2, \dots, M$)，输出预测值 $\hat{\mathbf{y}}_{pred}^{(r)}$ 。

S8.3: 计算预测均值为 M 次预测结果的平均值： $\hat{\mathbf{y}}_{pred}^{(r)} = \frac{1}{M} \sum_{r=1}^M \hat{\mathbf{y}}_{pred}^{(r)}$ 。

S8.4: 构建预测区间。对于预设置信水平 $100(1 - \alpha)\%$ ，其中 α 是置信度，通常取 $\alpha = 0.1$ 构建 90% 置信区间。基于 M 次前向传播的经验分布计算分位数，将 M 次预测值排序后取其 $\frac{\alpha}{2}$ 分位数作为区间下界， $(1 - \frac{\alpha}{2})$ 分位数作为区间上界。模型的输出包括未来 24 小时共 96 个时间点的光伏功率预测数据，每一个时间点的预测数据包括：

1. 预测均值 $\bar{y}_{pred}$; 2. 预测区间 $PI = [Q_{\frac{\alpha}{2}}(\{\hat{y}_{pred}^{(r)}\}_{r=1}^M), Q_{1-\frac{\alpha}{2}}(\{\hat{y}_{pred}^{(r)}\}_{r=1}^M)]$ 。

其中 $Q_{\frac{\alpha}{2}}(\{\hat{y}_{pred}^{(r)}\}_{r=1}^M)$ 为 M 次随机前向传播的经验分布的 $\frac{\alpha}{2}$ 分位数, $Q_{1-\frac{\alpha}{2}}(\{\hat{y}_{pred}^{(r)}\}_{r=1}^M)$ 为 M 次随机前向传播的经验分布的 $(1 - \frac{\alpha}{2})$ 分位数。

以上所述仅为本发明的优选实施例而已,并不用于限制本发明,对于本领域的技术人员来说,本发明可以有各种更改和变化。凡在本发明的精神和原则之内,所作的任何修改、等同替换、改进等,均应包含在本发明的保护范围之内。

