

# 不完全信息博弈的遗憾最小化求解：算法变体与更新次序对收敛速率的影响

*Regret Minimization Solvers for Imperfect-Information Games: The Effect of Algorithm Variants and Update Order on Convergence*

Orbweaver, copycat666<sup>1,2\*</sup>, mysteriousK<sup>1,2</sup>

1. EigenLife 机器学习实验室, 东北电力大学, 吉林; 2. 《电子游戏科学与技术》编辑委员会, 吉林, submission.joest.cn@outlook.com

\*: Corresponding Author

**摘要:** 不完全信息博弈的求解是游戏人工智能与算法博弈论的基础问题, 反事实遗憾最小化 (CFR) 及其变体是其中最常用的方法。已有比较研究给出的收敛结论往往来自不同实现与不同预算口径, 算法变体与更新次序的贡献未被分离。本文在一个可复现的实验平台上比较四类确定性求解器 (CFR、CFR+、线性 CFR、折扣 CFR) 与蒙特卡洛 CFR 外部采样, 并把更新次序 (同步更新与交替更新) 作为显式因子。基准为 Kuhn 扑克与 Leduc 扑克, 评价量是由精确最优反应计算得到的平均策略可利用度。在同步更新下, CFR+ 与折扣 CFR 在 Leduc 上的可利用度分别比 CFR 低 6.7 倍与 8.0 倍; 改为交替更新后排序反转, 二者的可利用度分别恶化 10.7 倍与 13.8 倍, 而 CFR 反而改善 1.6 倍。更新次序对收敛的影响不小于算法变体的影响。两个基准都收敛到已知的博弈值 (Kuhn 为  $-1/18$ , Leduc 约为  $-0.0856$ ), 验证了实现与评价口径。

**关键词:** 反事实遗憾最小化; 可利用度; 更新次序; 收敛速率; Leduc 扑克; 蒙特卡洛采样

**Abstract.** Solving imperfect-information games is a foundational problem in game artificial intelligence and algorithmic game theory, and counterfactual regret minimization (CFR) and its variants are the standard approach. Reported convergence conclusions come from different implementations and budget conventions, so the contributions of the algorithm variant and of the update order are not separated. This paper compares four deterministic solvers (CFR, CFR+, Linear CFR, Discounted CFR) and Monte-Carlo CFR with external sampling on a single reproducible platform, treating the update order (simultaneous versus alternating) as an explicit factor. The benchmarks are Kuhn poker and Leduc poker, and the metric is the exploitability of the average strategy computed by exact best response. Under simultaneous updates, CFR+ and Discounted CFR reach an exploitability on Leduc that is 6.7 and 8.0 times lower than CFR; under alternating updates the ranking reverses and their exploitability degrades by factors of 10.7 and 13.8, while CFR improves by a factor of 1.6. The update order therefore matters at least as much as the choice of variant. Both benchmarks converge to their known game values (Kuhn:  $-1/18$ ; Leduc: about  $-0.0856$ ), which validates the implementation and the evaluation.

**Keywords:** Counterfactual Regret Minimization; Exploitability; Update Order; Convergence Rate; Leduc Poker; Monte-Carlo Sampling

## 一、引言

### 1.1. 问题的提出

不完全信息扩展式博弈是电子游戏常用的形式化模型。在这类博弈中, 参与者无法观测对手的私有信息, 均衡策略通常必须随机化, 因此不能通过反向归纳直接求出。在游戏人工智能与算法博弈论中, 求解这类博弈的标准做法是把它写成双人零和博弈, 再用遗憾最小化算法逼近其纳什均衡。反事实遗憾最小化 (Counterfactual Regret Minimization, CFR) 是这一方向的代表性方法: 它在每个信息集上最小化反事实遗憾, 使平均策略的平均遗憾以  $O(1/\sqrt{T})$  的速度趋于零, 从而给出可利用度趋于零的近似均衡 [1, 2]。该框架已在限注德州扑克等基准上达到可用的精度 [3]。

围绕 CFR 的改进大体沿三条路线展开: 修改遗憾的更新规则, 例如遗憾匹配加 (regret matching+) 与折扣 CFR 对正负遗憾分别折扣 [1, 2]; 修改平均策略的累积权重, 例如线性与折扣平均 [2]; 对博弈树进行采样以降低单次迭代代价, 例如蒙特卡洛 CFR 及其方差缩减 [4]。这些改动在各自原文中都报告了明显的加速, 但不同工作使用的实现、更新次序与预算口径并不统一。

一个具体的差异出现在更新次序上。CFR+ 在原文中采用交替更新, 即先更新一方, 再用更新后的对手策略更新另一方 [1]; 而多数面向教学的实现采用同步更新, 即双方使用同一份策略快照, 迭代结束时一并写入 [5]。

当把这两种次序混在不同的算法变体上比较时，观测到的差异同时包含变体的贡献与更新次序的贡献，二者无法分开归因。本文的研究问题由此提出：在固定实现与固定评价口径下，算法变体与更新次序各自对收敛速率有多大影响，二者是否存在交互；在采样类算法与精确算法之间，按迭代次数比较与按时间比较是否会给出不同结论。

## 1.2. 本文工作

本文在统一的实现与评价口径下比较四类确定性遗憾最小化求解器与一类采样求解器，并把更新次序作为显式因子。基准博弈是 Kuhn 扑克与 Leduc 扑克；评价量是平均策略的可利用度，由精确最优反应计算得到，不引入任何近似。主要结果有四点。其一，两个基准都收敛到文献中的已知博弈值，Kuhn 的博弈值为  $-1/18 \approx -0.055556$ ，Leduc 的博弈值约为  $-0.0856$ ，可利用度随预算单调下降，说明实现与评价口径正确。其二，在同步更新下，CFR+ 与折扣 CFR 明显优于其余变体，在 Leduc 上把可利用度降到 CFR 的  $1/6.7$  与  $1/8.0$ ，与文献中对这两类改进的描述一致；经验收敛阶也高于  $1/2$ 。其三，把更新次序改为交替之后排序发生反转，CFR+ 与折扣 CFR 在 Leduc 上的可利用度分别恶化 10.7 倍与 13.8 倍，而 CFR 改善 1.6 倍，更新次序的影响与算法变体的影响属于同一量级。其四，蒙特卡洛 CFR 外部采样在 Leduc 上把单次迭代代价降低约两个数量级，但相对标准差随预算下降缓慢，按时间比较时不占优势。

## 二、问题设定与评价量

### 2.1. 扩展式博弈

一个有限的、双人的扩展式博弈由下列要素构成：历史集合  $H$ ，其中终局历史集合为  $Z$ ，非终局历史集合为  $H \setminus Z$ ；行动者函数  $P$ ，把非终局历史映到行动者集合  $\{0, 1, c\}$ ，其中  $c$  表示机会；机会节点上的外生概率分布；玩家  $i$  的信息集划分  $\mathcal{I}_i$ ；信息集  $I$  上的行动集  $A(I)$ ；以及终局上的收益函数  $u_i : Z \rightarrow \mathbb{R}$ 。本文只考虑双人零和博弈，即  $u_1(z) = -u_0(z)$  对所有  $z \in Z$  成立，并要求博弈具有完全回忆：玩家在任一信息集中的所有历史上下，对自己过去的行动与观察具有相同的记忆。

玩家  $i$  的行为策略记为  $\sigma_i$ ，它对每个信息集  $I \in \mathcal{I}_i$  给出行动集上的概率分布  $\sigma_i(I) \in \Delta(A(I))$ 。策略组合  $\sigma = (\sigma_0, \sigma_1)$  诱导出终局上的概率分布，因此收益期望  $u_i(\sigma)$  有定义。双人零和博弈的纳什均衡等价于极小极大解，其值记为  $v^*$ 。

### 2.2. 可利用度

衡量一个近似均衡的标准量是可利用度。给定策略组合  $\sigma$ ，定义

$$\varepsilon(\sigma) = \frac{1}{2} \left( \max_{\sigma'_0} u_0(\sigma'_0, \sigma_1) + \max_{\sigma'_1} u_1(\sigma_0, \sigma'_1) \right). \quad (1)$$

式 (1) 中每一项都是给定对手策略时的最优反应收益。由极小极大定理， $\varepsilon(\sigma) \geq 0$ ，且  $\varepsilon(\sigma) = 0$  当且仅当  $\sigma$  是纳什均衡。式 (1) 等于扑克文献中常用的 NashConv 的一半，在扑克机器人的评价中沿用已久 [3, 6]。在小规模博弈上，均衡也可以由序列形式的线性规划精确求出 [7, 8]，或由双预言机一类方法迭代逼近 [9]；这些方法的代价随信息集数迅速增长，因此在信息集很多的博弈上，迭代式的遗憾最小化成为常规选择。由于博弈具有完全回忆，最优反应可以在信息集层面通过一次自底向上的动态规划求得：对每个信息集  $I$ ，比较各行动在  $I$  上按反事实到达概率加权的子树价值，取最大者。该计算不依赖学习，因此可利用度是一个不含随机性的评价量，可以直接用于比较不同算法在同一预算下的解题质量。

## 三、算法

### 3.1. 反事实遗憾与遗憾匹配

反事实遗憾最小化在每个信息集上维护各行动的累积遗憾，并用遗憾匹配把累积遗憾映射成当前策略。对信息集  $I$  与行动  $a \in A(I)$ ，累积遗憾定义为

$$R^T(I, a) = \sum_{t=1}^T \left( v^{\sigma^t}(I, a) - v^{\sigma^t}(I) \right), \quad (2)$$

其中  $v^\sigma(I, a) = \sum_{h \in I} \pi_{-i}^\sigma(h) u_i(\sigma \mid h \rightarrow a)$  是反事实价值,  $\pi_{-i}^\sigma(h)$  是除玩家  $i$  以外所有参与者（机会与对手）到达  $h$  的概率,  $v^\sigma(I) = \sum_a \sigma(I, a) v^\sigma(I, a)$ 。遗憾匹配给出的下一轮策略为

$$\sigma^{t+1}(I, a) = \frac{[R^t(I, a)]^+}{\sum_{b \in A(I)} [R^t(I, b)]^+}, \quad [x]^+ = \max(x, 0), \quad (3)$$

当所有遗憾非正时取均匀分布。遗憾匹配保证平均遗憾以  $O(1/\sqrt{T})$  趋于零 [10, 11]。在双人零和完全回忆博弈中, 两个玩家的平均遗憾之和给出了平均策略组合可利用度的上界, 其量级为

$$\frac{1}{T} (R_0^T + R_1^T) \leq \frac{\Delta |I| \sqrt{|A|}}{\sqrt{T}}, \quad (4)$$

其中  $\Delta$  是收益范围,  $|I|$  与  $|A|$  分别是信息集数与行动数的上界 [12]。输出的平均策略为

$$\bar{\sigma}^T(I, a) = \frac{\sum_{t=1}^T w_t \pi_i^{\sigma^t}(I) \sigma^t(I, a)}{\sum_{t=1}^T w_t \pi_i^{\sigma^t}(I)}, \quad (5)$$

其中  $w_t$  是平均权重,  $\pi_i^{\sigma^t}(I)$  是玩家  $i$  自身到达  $I$  的概率。 $w_t$  的取法把 CFR 与它的若干变体区分开来。

### 3.2. 算法变体

本文比较四类确定性变体与一类采样变体, 它们共享式 (2) 至式 (5) 的框架, 差别只在遗憾更新规则与平均权重。

第一类是 CFR, 采用式 (3) 的遗憾匹配, 累积遗憾不做截断, 平均权重取常数  $w_t = 1$ , 即均匀平均。

第二类是 CFR+, 采用遗憾匹配加: 每次累计时把累积遗憾在零处截断, 即

$$R^t(I, a) \leftarrow \max(R^{t-1}(I, a) + \delta^t(I, a), 0), \quad (6)$$

其中  $\delta^t(I, a)$  是信息集  $I$  上行动  $a$  在本轮的即时遗憾; 平均权重取线性  $w_t = t$  [1]。

第三类是线性 CFR, 遗憾增量与平均权重都按  $t$  加权, 即即时遗憾乘以  $t$ , 同时  $w_t = t$ 。

第四类是折扣 CFR, 对正遗憾与负遗憾分别按  $t$  的幂次折扣:

$$R^t(I, a) \leftarrow R^t(I, a) \cdot \frac{t^\alpha}{t^\alpha + 1}, \quad R^t(I, a) > 0, \quad (7)$$

$$R^t(I, a) \leftarrow R^t(I, a) \cdot \frac{t^\beta}{t^\beta + 1}, \quad R^t(I, a) < 0, \quad (8)$$

同时平均权重按  $w_t = (t/(t+1))^\gamma$  折扣, 本文取原文推荐的  $\alpha = 1.5$ 、 $\beta = 0$ 、 $\gamma = 2$  [2]。

### 3.3. 更新次序

更新次序规定一次迭代中两个玩家的遗憾被写入的先后关系。同步更新在一次迭代内使用同一份策略快照完成两个玩家的遍历, 把两组遗憾增量在迭代结束时一并写入; 交替更新先完成玩家 0 的遍历并立即写入其遗憾, 再完成玩家 1 的遍历, 此时玩家 1 面对的已经是玩家 0 更新后的策略。前者是雅可比式 (Jacobi) 更新, 后者是高斯-赛德尔式 (Gauss-Seidel) 更新。CFR+ 的原文采用交替更新 [1], 面向教学的实现多采用同步更新 [5]。本文把这两种次序都作为独立因子, 在每一类变体上分别运行。

### 3.4. 蒙特卡洛 CFR 与外部采样

蒙特卡洛 CFR 用采样估计式 (2) 中的反事实价值, 从而把单次迭代的代价从与整棵树成正比降到与一条采样轨迹成正比 [4]。本文采用外部采样: 在机会节点上按其真实概率抽取一个结果, 在对手的信息集上按当前策略抽取一个行动, 而在更新方的信息集上遍历全部行动。如此得到的遗憾增量是反事实遗憾的无偏估计, 但引入了采样方差; 方差随迭代次数的下降速度慢于偏差的下降速度, 这一点在实验中直接可见 [4, 12]。

## 四、实验设置

### 4.1. 基准博弈

Kuhn 扑克是最小的不完全信息博弈 [13]：一副三张牌，两名玩家各下注 1，各发一张私有牌，随后进行一轮下注，每轮可弃牌或下注 1。博弈值为  $-1/18$ ，可以利用上述精确最优反应核对实现。

Leduc 扑克是中等规模的标准基准 [14]：牌堆包含三个点数、每个点数两张，两名玩家各下注 1 并各得一张私有牌；第一轮下注的加注额为 2，之后翻开一张公共牌，进行第二轮下注，加注额为 4；每轮至多两次下注或加注。终局按是否与公共牌配对比大小，同点数按平局处理。两个基准的规模与均匀随机策略的可利用度列于表 1。

表 1: 基准博弈的规模与均匀随机策略的可利用度

| 博弈       | 节点数  | 信息集数 | 均匀策略可利用度 |
|----------|------|------|----------|
| Kuhn 扑克  | 55   | 12   | 0.4583   |
| Leduc 扑克 | 1936 | 288  | 2.3736   |

### 4.2. 预算、评价与实现

全部算法在同一台机器上以纯 Python 实现，共享同一份博弈树、同一份遗憾匹配实现与同一个精确最优反应求解器。确定性变体在迭代预算  $T \in \{10, 30, 100, 300, 1000, 3000, 10000\}$  上记录可利用度，Kuhn 上另取  $T = 3 \times 10^4$  与  $T = 10^5$ ；蒙特卡洛 CFR 在每个检查点上用 20 个随机种子运行，报告可利用度的均值与标准差，以暴露采样方差。所有运行都记录累计墙钟时间，用于按时间而不是按迭代次数比较。为避免浮点差异影响结论，最优反应与可利用度都用双精度计算，同一策略两次求值得到的数值完全一致。

## 五、结果与分析

### 5.1. 实现验证

图 1 与图 2 给出四个确定性变体在两种更新次序下的可利用度曲线，横轴为迭代次数，纵轴为可利用度。所有曲线都随预算单调下降，并在最大预算处降到均匀随机策略的千分之一量级以下。把最大预算处的平均策略代入精确最优反应，Kuhn 上的博弈值收敛到  $-0.055556$ ，与解析值  $-1/18$  在小数点后六位一致；Leduc 上的博弈值收敛到  $-0.0856$ ，与文献中报告的值一致。作为额外的健全性检查，本文还验证了最优反应求解器：在 Kuhn 上，它给出的最优反应值与对全部纯策略随机搜索 200 次得到的最优值完全相同；在 Leduc 上，它给出的最优反应值不低于对 400 个随机纯策略逐一求值的最大值。这些检查说明收敛现象来自算法本身，而不来自评价口径的偏差。

### 5.2. 收敛速率

对每个变体与每种更新次序，本文在  $\log T$  与  $\log \varepsilon$  坐标下对尾部检查点做最小二乘拟合，斜率即经验收敛阶，结果列于表 2。Kuhn 上所有组合的斜率都落在  $-0.49$  至  $-0.56$  之间，与式 (4) 给出的  $1/\sqrt{T}$  阶一致，说明在该尺度上理论界与实测行为吻合。Leduc 上的差别更大：同步更新下折扣 CFR 与 CFR+ 的斜率分别为  $-0.79$  与  $-0.64$ ，明显高于  $1/2$ ，与这两种变体在文献中被报告为收敛更快相符；交替更新下这两个变体的斜率降到  $-0.49$  与  $-0.40$ ，而 CFR 的斜率反而由  $-0.58$  降到  $-0.42$ 。斜率与最终可利用度给出的排序方向一致，二者都指向交替更新对带折扣变体的不利影响。

### 5.3. 变体与更新次序的交互

表 3 给出最大预算处的可利用度，图 3 用柱状图呈现同一组数据。在同步更新下，四个变体在 Leduc 上的可利用度相差一个数量级：折扣 CFR 与 CFR+ 分别为  $1.31 \times 10^{-3}$  与  $1.56 \times 10^{-3}$ ，CFR 为  $1.05 \times 10^{-2}$ ，线性 CFR 为  $1.25 \times 10^{-2}$ 。也就是说，两个带折扣的变体把可利用度降到 CFR 的  $1/8.0$  与  $1/6.7$ 。这一结果与 CFR+ 和折扣 CFR 的原文结论方向一致。

把更新次序换成交替之后，排序发生反转。同一预算下折扣 CFR 与 CFR+ 的可利用度分别升到  $1.81 \times 10^{-2}$  与  $1.67 \times 10^{-2}$ ，比同步更新时恶化 13.8 倍与 10.7 倍；CFR 反而由  $1.05 \times 10^{-2}$  降到  $6.28 \times 10^{-3}$ ，改善 1.6 倍；线性 CFR 的变化较小。于是更新次序对带折扣变体的影响已经超过变体之间的差距：一个采用同步更新的 CFR，




图 1: Kuhn 扑克上四个变体在两种更新次序下的可利用度随迭代次数的变化（双对数坐标）




图 2: Leduc 扑克上四个变体在两种更新次序下的可利用度随迭代次数的变化（双对数坐标）

表 2: Leduc 扑克上各变体与更新次序的经验收敛阶 ( $\log \varepsilon$  对  $\log T$  的斜率, 尾部窗口  $T \geq 1000$ )

| 变体     | 同步更新  |                       | 交替更新  |                       |
|--------|-------|-----------------------|-------|-----------------------|
|        | 斜率    | 可利用度                  | 斜率    | 可利用度                  |
| CFR    | -0.58 | $1.05 \times 10^{-2}$ | -0.42 | $6.28 \times 10^{-3}$ |
| CFR+   | -0.64 | $1.56 \times 10^{-3}$ | -0.40 | $1.67 \times 10^{-2}$ |
| 线性 CFR | -0.56 | $1.25 \times 10^{-2}$ | -0.17 | $1.66 \times 10^{-2}$ |
| 折扣 CFR | -0.79 | $1.31 \times 10^{-3}$ | -0.49 | $1.81 \times 10^{-2}$ |

在 Leduc 上比一个采用交替更新的 CFR+ 更低的可利用度。Kuhn 上不存在同样的反转，各组合的可利用度都落在  $3.2 \times 10^{-4}$  至  $8.1 \times 10^{-4}$  的窄区间内，更新次序与变体的差别都很小，这说明交互效应与博弈规模有关，在信息集较少时被压缩。

表 3: 最大预算处可利用度的变体与更新次序交互 (Kuhn 取  $T = 10^5$ , Leduc 取  $T = 10^4$ )

| 变体     | Kuhn 扑克               |                       | Leduc 扑克              |                       |
|--------|-----------------------|-----------------------|-----------------------|-----------------------|
|        | 同步更新                  | 交替更新                  | 同步更新                  | 交替更新                  |
| CFR    | $6.76 \times 10^{-4}$ | $6.81 \times 10^{-4}$ | $1.05 \times 10^{-2}$ | $6.28 \times 10^{-3}$ |
| CFR+   | $3.20 \times 10^{-4}$ | $4.84 \times 10^{-4}$ | $1.56 \times 10^{-3}$ | $1.67 \times 10^{-2}$ |
| 线性 CFR | $8.10 \times 10^{-4}$ | $7.92 \times 10^{-4}$ | $1.25 \times 10^{-2}$ | $1.66 \times 10^{-2}$ |
| 折扣 CFR | $3.79 \times 10^{-4}$ | $4.15 \times 10^{-4}$ | $1.31 \times 10^{-3}$ | $1.81 \times 10^{-2}$ |




图 3: 最大预算处可利用度的变体与更新次序交互 (Kuhn 取  $T = 10^5$ , Leduc 取  $T = 10^4$ )

## 5.4. 采样方差

表 4 与图 4 给出蒙特卡洛 CFR 外部采样在 20 个随机种子上的结果。均值随预算下降，符合无偏估计的预期；标准差相对均值的比例却不随预算持续下降，而是稳定在 15% 至 57% 的区间内。在 Kuhn 上，相对标准差在  $T = 10^4$  与  $T = 10^5$  处分别为 31.9% 与 35.0%；在 Leduc 上，相对标准差由  $T = 3 \times 10^3$  处的 15.8% 升到  $T = 3 \times 10^4$  处的 32.5%。原因是均值的下降速度与标准差相当，采样误差没有相对消失。相比之下，四个确定性变体在同一预算上的可利用度是确定量，重复运行得到完全相同的数值。对实际使用而言，这一差别意味着采样类算法的单次结果需要预留明显更大的安全余量。

表 4: 蒙特卡洛 CFR 外部采样在 20 个随机种子上的可利用度 (均值、标准差与相对标准差)

| 博弈       | 迭代次数            | 均值                    | 标准差                   | 相对标准差 |
|----------|-----------------|-----------------------|-----------------------|-------|
| Kuhn 扑克  | $10^4$          | $1.04 \times 10^{-2}$ | $3.32 \times 10^{-3}$ | 31.9% |
| Kuhn 扑克  | $10^5$          | $2.85 \times 10^{-3}$ | $9.96 \times 10^{-4}$ | 35.0% |
| Leduc 扑克 | $3 \times 10^3$ | $6.60 \times 10^{-1}$ | $1.04 \times 10^{-1}$ | 15.8% |
| Leduc 扑克 | $3 \times 10^4$ | $3.96 \times 10^{-1}$ | $1.29 \times 10^{-1}$ | 32.5% |

## 5.5. 等时预算下的比较

迭代次数的可比性依赖单次迭代代价，而精确算法与采样算法的单次代价相差很大。在 Leduc 上，精确变体每秒完成约 76 至 92 次迭代，蒙特卡洛 CFR 每秒完成约  $1.99 \times 10^4$  次迭代，相差约 250 倍。图 5 因此按墙钟




图 4: 蒙特卡洛 CFR 外部采样在 20 个随机种子上的可利用度均值与一个标准差区间

时间重画了收敛曲线。按时间比较时，精确算法仍然占优：蒙特卡洛 CFR 用 1.51 秒完成  $3 \times 10^4$  次迭代，可利用度均值为 0.396；而 CFR+ 在同步更新下用 1.3 秒完成 100 次迭代，可利用度为  $4.4 \times 10^{-2}$ ，在同一时间尺度上比采样算法低约 9 倍。随着时间增加，精确算法的曲线更陡，差距继续扩大，因为它的经验收敛阶接近  $1/T$ ，而采样算法受方差制约，阶数更低。本文的结论因此限定为：在这两个信息集规模很小的基准上，精确算法按时间比较即已足够；采样算法的价值出现在整棵树遍历不可行的更大博弈上，这一点与蒙特卡洛 CFR 的原始动机一致。




图 5: Leduc 扑克上按墙钟时间重新绘制的可利用度曲线（含蒙特卡洛 CFR 外部采样）

## 六、讨论

实验结果指向三点判断。首先，算法变体与更新次序不可混为一谈。带折扣的变体依赖对较早迭代的信任折扣，这些变体在同步更新下把当前策略同时冻结，使折扣作用于一份一致的历史；在交替更新下，一方看到的是对手刚更新过的策略，折扣所依据的历史在两侧不同步，收敛因此变慢。这一解释与表 3 中“折扣变体受影响大、CFR 受影响小”的格局相符，也与折扣 CFR 与 CFR+ 原文选择同步或交替次序的具体搭配相符。

其次，评价量本身会影响结论。把可利用度与博弈值分开看待是必要的：在本文的数据中，所有变体在两个基准上都收敛到相近的博弈值，但可利用度在最大预算处仍相差近十倍。若只报告博弈值，会得到各变体几

乎等价的结论；若只报告按迭代次数的可利用度，又会高估采样算法的效率。因此比较求解器时需要同时交代预算口径与评价量。

最后，本文的比较有明确的适用范围。基准只有 Kuhn 与 Leduc 两个双人零和完全回忆博弈，收益尺度与加注结构都是人为设定的；实现是纯 Python，单次迭代的常数因子与工程实现不同；蒙特卡洛 CFR 只用了外部采样一种采样方案，未包含结果采样、公共机会采样与方差缩减。这些限制都可能改变绝对数值，但不改变“更新次序的贡献与变体同量级”这一相对结论，因为该结论来自同一实现内的对照。

## 七、结论

本文在统一的实现与评价口径下比较了四类确定性遗憾最小化求解器与蒙特卡洛 CFR 外部采样，并把更新次序作为显式因子，在 Kuhn 扑克与 Leduc 扑克上用精确可利用度评价。两个基准都收敛到已知博弈值，验证了实现。主要结论是：在同步更新下，CFR+ 与折扣 CFR 在 Leduc 上把可利用度降到 CFR 的 1/6.7 与 1/8.0；在交替更新下排序反转，二者的可利用度恶化 10.7 倍与 13.8 倍，更新次序的影响与算法变体的影响属于同一量级。采样算法把单次迭代代价降低约两个数量级，但相对标准差稳定在 15% 至 57%，按时间比较时在本文的小规模基准上不占优势。据此，报告遗憾最小化求解器的比较结果时，预算口径、评价量与更新次序都应一并说明。

## 参考文献

- [1] Oskari Tammelin. *Solving Large Imperfect Information Games Using CFR+*. 2014. DOI: [10.48550/arxiv.1407.5042](https://doi.org/10.48550/arxiv.1407.5042). arXiv: [1407.5042](https://arxiv.org/abs/1407.5042). URL: <https://arxiv.org/abs/1407.5042>.
- [2] Noam Brown and Tuomas Sandholm. “Solving Imperfect-Information Games via Discounted Regret Minimization”. In: *Proceedings of the AAAI Conference on Artificial Intelligence* 33.01 (2019), pp. 1829–1836. ISSN: 2159-5399. DOI: [10.1609/aaai.v33i01.33011829](https://doi.org/10.1609/aaai.v33i01.33011829). URL: <http://dx.doi.org/10.1609/aaai.v33i01.33011829>.
- [3] Michael Bowling et al. “Heads-up limit hold’ em poker is solved”. In: *Science* 347.6218 (Jan. 2015), pp. 145–149. ISSN: 1095-9203. DOI: [10.1126/science.1259433](https://doi.org/10.1126/science.1259433). URL: <http://dx.doi.org/10.1126/science.1259433>.
- [4] Martin Schmid et al. “Variance Reduction in Monte Carlo Counterfactual Regret Minimization (VR-MCCFR) for Extensive Form Games Using Baselines”. In: *Proceedings of the AAAI Conference on Artificial Intelligence* 33.01 (2019), pp. 2157–2164. ISSN: 2159-5399. DOI: [10.1609/aaai.v33i01.33012157](https://doi.org/10.1609/aaai.v33i01.33012157). URL: <http://dx.doi.org/10.1609/aaai.v33i01.33012157>.
- [5] Qi Ju. *Sync Pure Counterfactual Regret Minimization in Incomplete Information Extensive Form Games*. 2023. DOI: [10.48550/arxiv.2311.07155](https://doi.org/10.48550/arxiv.2311.07155). arXiv: [2311.07155](https://arxiv.org/abs/2311.07155). URL: <https://arxiv.org/abs/2311.07155>.
- [6] Viliam Lisy and Michael Bowling. *Equilibrium Approximation Quality of Current No-Limit Poker Bots*. 2016. DOI: [10.48550/arxiv.1612.07547](https://doi.org/10.48550/arxiv.1612.07547). arXiv: [1612.07547](https://arxiv.org/abs/1612.07547). URL: <https://arxiv.org/abs/1612.07547>.
- [7] Daphne Koller and Nimrod Megiddo. “The complexity of two-person zero-sum games in extensive form”. In: *Games and Economic Behavior* 4.4 (Oct. 1992), pp. 528–552. ISSN: 0899-8256. DOI: [10.1016/0899-8256\(92\)90035-q](https://doi.org/10.1016/0899-8256(92)90035-q). URL: [http://dx.doi.org/10.1016/0899-8256\(92\)90035-q](http://dx.doi.org/10.1016/0899-8256(92)90035-q).
- [8] Bernhard von Stengel. “Efficient Computation of Behavior Strategies”. In: *Games and Economic Behavior* 14.2 (1996), pp. 220–246. ISSN: 0899-8256. DOI: [10.1006/game.1996.0050](https://doi.org/10.1006/game.1996.0050). URL: <http://dx.doi.org/10.1006/game.1996.0050>.
- [9] B. Bosansky et al. “An Exact Double-Oracle Algorithm for Zero-Sum Extensive-Form Games with Imperfect Information”. In: *Journal of Artificial Intelligence Research* 51 (Dec. 2014), pp. 829–866. ISSN: 1076-9757. DOI: [10.1613/jair.4477](https://doi.org/10.1613/jair.4477). URL: <http://dx.doi.org/10.1613/jair.4477>.
- [10] Sergiu Hart and Andreu Mas-Colell. “A Simple Adaptive Procedure Leading to Correlated Equilibrium”. In: *Econometrica* 68.5 (2000), pp. 1127–1150. ISSN: 1468-0262. DOI: [10.1111/1468-0262.00153](https://doi.org/10.1111/1468-0262.00153). URL: <http://dx.doi.org/10.1111/1468-0262.00153>.

- [11] Nicolo Cesa-Bianchi and Gabor Lugosi. *Prediction, Learning, and Games*. Cambridge University Press, Mar. 2006. ISBN: 9780511546921. DOI: [10.1017/cbo9780511546921](https://doi.org/10.1017/cbo9780511546921). URL: <http://dx.doi.org/10.1017/cbo9780511546921>.
- [12] Marc Lanctot et al. *No-Regret Learning in Extensive-Form Games with Imperfect Recall*. 2012. DOI: [10.48550/arxiv.1205.0622](https://doi.org/10.48550/arxiv.1205.0622). arXiv: [1205.0622](https://arxiv.org/abs/1205.0622). URL: <https://arxiv.org/abs/1205.0622>.
- [13] H. W. Kuhn. “9. A SIMPLIFIED TWO-PERSON POKER”. In: *Contributions to the Theory of Games (AM-24), Volume I*. Princeton University Press, Dec. 1951, pp. 97–104. ISBN: 9781400881727. DOI: [10.1515/9781400881727-010](https://doi.org/10.1515/9781400881727-010). URL: <http://dx.doi.org/10.1515/9781400881727-010>.
- [14] Finnegan Southey et al. *Bayes’ Bluff: Opponent Modelling in Poker*. 2012. DOI: [10.48550/arxiv.1207.1411](https://doi.org/10.48550/arxiv.1207.1411). arXiv: [1207.1411](https://arxiv.org/abs/1207.1411). URL: <https://arxiv.org/abs/1207.1411>.