

从“云”到“边缘”—— 电子游戏分布式计算架构的技术发展综述

*From Cloud to Edge:
A Review of Technical Evolution in Distributed Computing Architectures for Electronic Gaming*

copycat666^{1,2†}, doro^{1,2}, mysteriousK^{1,2}, Chengjie Liu³, Yizheng Gu⁴, Yumei Liu⁵

1. 《电子游戏科学与技术》编辑委员会
2. EigenLife 机器学习实验室，东北电力大学，吉林；3. 网络空间安全学院，成都信息工程大学，成都
4. 电子科技大学成都学院，成都；5. 计算机学院，东北电力大学，吉林

†: Corresponding Author. dev.projectamadeus@outlook.com

摘要：随着电子游戏在画质、交互复杂度与并发规模上的持续攀升，传统集中式云计算架构在网络延迟、带宽压力与服务可扩展性方面逐渐暴露出结构性局限。边缘计算与雾计算作为云计算的延伸范式，通过将计算与存储资源下沉至网络边缘，为云游戏、VR/AR 及大型多人在线游戏等低延迟敏感场景提供了新的技术路径。本文系统综述了电子游戏分布式计算架构从云到边缘的技术演进历程。首先，梳理了云计算基础架构及其在游戏领域的应用现状，分析其在调度策略、安全机制与能效管理方面的核心成果与不足；其次，聚焦云游戏技术，从流量检测、QoS/QoE 优化、渲染架构及延迟构成等维度总结了当前研究进展；再次，深入探讨边缘计算与雾计算在游戏场景中的介入方式，涵盖边缘节点架构、资源分配算法、5G 融合部署及绿色计算等关键技术；在此基础上，进一步分析了分布式游戏服务器架构的演进，包括集群设计、分片策略、微服务化、Serverless 计算及跨地域容灾等工程实践；最后，展望了云-边-端协同、6G 通信、元宇宙集成等未来发展方向。本综述旨在为游戏开发者与分布式系统研究人员提供技术选型的系统性参考。

关键词：云计算；边缘计算；雾计算；云游戏；分布式架构；低延迟

Abstract. With the continuous increase in graphical fidelity, interaction complexity, and concurrent scale of electronic games, traditional centralized cloud computing architectures are progressively exposing structural limitations in terms of network latency, bandwidth pressure, and service scalability. Edge computing and fog computing, as extended paradigms of cloud computing, offload computing and storage resources to the network edge, providing new technical pathways for latency-sensitive scenarios such as cloud gaming, VR/AR, and massively multiplayer online games. This paper systematically reviews the technical evolution of distributed computing architectures for electronic gaming from cloud to edge. First, we summarize the foundational cloud computing architectures and their application status in gaming, analyzing core achievements and limitations in scheduling strategies, security mechanisms, and energy efficiency management. Second, we focus on cloud gaming technologies, synthesizing current research progress from the perspectives of traffic detection, QoS/QoE optimization, rendering architectures, and latency composition. Third, we deeply investigate the integration approaches of edge computing and fog computing in gaming scenarios, covering key technologies including edge node architecture, resource allocation algorithms, 5G convergence deployment, and green computing. Furthermore, we analyze the evolution of distributed game server architectures, including engineering practices such as cluster design, sharding strategies, microservices, serverless computing, and cross-region disaster recovery. Finally, we discuss future directions including cloud-edge-device collaboration, 6G communications, and metaverse integration. This review aims to provide a systematic reference for technology selection for game developers and distributed systems researchers.

Keywords: Cloud Computing; Edge Computing; Fog Computing; Cloud Gaming; Distributed Architecture; Low Latency

目录

一 引言	4
二 云计算基础架构及其在游戏领域的应用	4
2.1. 云计算的核心架构与服务模型	5
2.2. 虚拟化技术与多租户隔离	5
2.3. 资源调度与负载均衡	5
2.3.1 传统调度算法及其局限	5
2.3.2 深度强化学习驱动的智能调度	5
2.3.3 虚拟机放置与资源竞争管理	6
2.4. 云安全机制与游戏场景的特殊挑战	6
2.4.1 基础设施安全与 DDoS 防护	6
2.4.2 游戏作弊检测与公平性保障	6
2.4.3 数据安全与隐私保护	6
2.5. 能效管理与绿色计算	7
2.5.1 游戏工作负载的能效特征	7
2.5.2 边缘计算的能效优势	7
2.5.3 任务调度层面的节能策略	7
2.6. 云计算中的 AI 融合与游戏智能	7
2.6.1 云端深度学习训练与推理	8
2.6.2 游戏数据分析与玩家行为挖掘	8
2.7. 游戏领域的云计算实践：成就与局限	8
三 云游戏技术现状与挑战	8
3.1. 云游戏系统架构与工作流程	8
3.2. 云游戏流量检测与识别	9
3.2.1 基于可编程数据平面的检测方法	9
3.2.2 云游戏流量的网络层特征分析	9
3.3. 云游戏服务质量与用户体验质量	9
3.3.1 QoS 指标体系与测量方法	10
3.3.2 QoE 建模与评估	10
3.3.3 异常检测与根因诊断	10
3.4. 云游戏渲染架构优化	10
3.4.1 边缘渲染与计算卸载	10
3.4.2 远程渲染的协议与框架优化	11
3.4.3 VR/AR 云渲染的特殊挑战	11
3.5. 云游戏延迟分析	11
3.5.1 延迟构成分解	11
3.5.2 延迟消减策略	11
3.5.3 延迟感知与用户行为响应	12
3.6. 云游戏面临的核心挑战	12
3.6.1 计算复杂度与成本压力	12
3.6.2 网络依赖与覆盖瓶颈	12
3.6.3 内容授权与商业模式	12
3.7. 本章小结	12
四 边缘计算与雾计算在游戏场景中的介入	13
4.1. 边缘计算：概念界定与核心架构	13
4.1.1 边缘计算的定义与本质特征	13
4.1.2 边缘计算的参考架构	13
4.1.3 边缘节点的形态谱系	13
4.1.4 边缘计算在游戏场景的适配性分析	14
4.2. 雾计算：概念、架构与定位	14
4.2.1 雾计算的定义与核心理念	14

4.2.2	雾计算参考架构	14
4.2.3	雾计算与边缘计算的对比分析	15
4.2.4	雾计算在游戏场景的独特价值	15
4.3.	边缘/雾计算的关键技术组件	15
4.3.1	资源调度与服务放置	15
4.3.2	服务迁移与状态同步	16
4.3.3	5G/6G 与边缘计算的融合	16
4.3.4	绿色边缘计算与能效优化	16
4.4.	边缘/雾计算在游戏场景中的典型应用场景	17
4.4.1	云游戏渲染的边缘卸载	17
4.4.2	多人游戏的状态同步与一致性保障	17
4.4.3	游戏 AI 的边缘推理	17
4.4.4	AR/VR 的边缘渲染与协作	18
4.5.	边缘/雾计算面临的挑战与局限	18
4.5.1	资源异构性与管理复杂度	18
4.5.2	服务迁移的连续性保障	18
4.5.3	安全与隐私风险	19
4.5.4	成本效益与商业可行性	19
4.6.	本章小结	19
五	分布式游戏服务器架构的演进	19
5.1.	游戏服务器架构的历史演进脉络	19
5.1.1	第一代：单服务器架构	19
5.1.2	第二代：分布式集群架构	20
5.1.3	第三代：面向服务的架构与微服务化	20
5.1.4	第四代：Serverless 与事件驱动架构	20
5.2.	分布式架构的关键设计维度	21
5.2.1	有状态与无状态服务的分离	21
5.2.2	分片策略与数据分布	21
5.2.3	负载均衡与流量分发	21
5.2.4	数据一致性与分布式事务	22
5.3.	高可用与容灾设计	22
5.3.1	主备切换与故障转移	22
5.3.2	无状态设计的可用性优势	22
5.4.	网络协议优化与实时通信	22
5.4.1	从 TCP 到 UDP 再到 QUIC	22
5.4.2	P2P 与混合架构	23
5.5.	性能优化与容量规划	23
5.5.1	性能瓶颈识别与优化	23
5.5.2	弹性伸缩与容量规划	23
5.6.	本章小结	23
六	未来展望与挑战	23
6.1.	云-边-端三级协同架构	23
6.1.1	从两级到三级的范式跃迁	23
6.1.2	任务的自适应切分与调度	24
6.2.	6G 通信与空天地一体化网络	24
6.2.1	6G 的性能目标与游戏应用	24
6.2.2	空天地一体化网络	24
6.3.	生成式 AI 与程序化内容生成	24
6.3.1	AI 辅助的游戏开发与运营	24
6.3.2	AI 生成内容的质量与一致性保障	24
6.4.	元宇宙与大规模虚拟世界的架构挑战	25
6.4.1	元宇宙的计算需求	25
6.4.2	大规模虚拟世界的分片与协调	25
6.5.	安全、隐私与伦理挑战	25

6.5.1	分布式架构下的安全风险	25
6.5.2	玩家隐私保护	25
6.6.	可持续计算与绿色游戏	26
6.6.1	游戏计算的能耗困境	26
6.6.2	碳感知的调度算法	26
6.7.	技术挑战的长期展望	26
6.7.1	延迟的物理极限	26
6.7.2	通用人工智能与游戏	26
6.8.	本章小结	26
七	结语与总结	26
7.1.	核心发现与技术脉络	27
7.1.1	从集中式到分布式：架构演进的必然性	27
7.1.2	关键技术的突破与局限	27
7.1.3	云-边-端协同：未来架构的核心特征	27
7.2.	对实践者的建议	27
7.2.1	对游戏开发者的技术选型建议	27
7.2.2	对分布式系统研究者的方向建议	28
7.3.	本综述的局限性与未来研究方向	28
7.3.1	综述范围的边界	28
7.3.2	研究方法的局限	28
7.3.3	未来研究方向	28
7.4.	结语	29

一、引言

随着电子游戏产业在画质表现、交互复杂度与并发用户规模上的持续攀升，传统集中式计算架构正面临前所未有的挑战。现代 AAA 级游戏已普遍采用 4K 乃至 8K 分辨率、实时光线追踪及复杂的物理仿真技术，而云游戏、VR/AR 及大型多人在线游戏等新兴业态进一步加剧了对计算资源与网络带宽的需求 [1]。在这一背景下，如何构建高效、可扩展且低延迟的游戏计算架构，已成为学术界与工业界共同关注的核心问题。

传统游戏部署模式主要依赖客户端-服务器架构，其中游戏逻辑与渲染计算均在玩家终端设备上完成。然而，随着游戏画质的不断提升，终端设备的硬件门槛也随之水涨船高，限制了用户群体的覆盖面。云游戏模式的兴起试图解决这一问题：将游戏渲染与计算任务迁移至云端服务器，玩家终端仅需接收视频流并回传控制指令 [2]。这一架构虽然在理论上降低了终端门槛，却引入了新的技术挑战——网络延迟成为影响用户体验的关键瓶颈 [3]。

研究表明，云游戏的端到端延迟主要由网络传输延迟、服务器处理延迟与客户端解码延迟三部分构成 [4]。其中，网络传输延迟受限于物理距离与骨干网拥塞状况，传统集中式云数据中心往往部署在远离用户的区域，导致往返时间（RTT）难以满足实时交互游戏（如第一人称射击游戏）对延迟的严苛要求（通常需低于 50ms）[5]。Lyu 等人对 NVIDIA GeForce NOW 云游戏平台的实测表明，即使在理想网络条件下，跨区域用户的感知延迟仍可能超过 100ms [6]。

为应对上述挑战，学术界与产业界开始探索将计算资源从集中式云数据中心向网络边缘下沉的技术路径。边缘计算（Edge Computing）与雾计算（Fog Computing）作为云计算的延伸范式，通过将计算、存储与网络资源部署于更接近用户的位置，显著缩短了数据传输的物理距离 [7][8]。在游戏应用场景中，边缘节点可以承担渲染任务卸载 [9]、游戏会话迁移 [10] 以及实时流量检测 [11] 等关键职能，从而有效降低端到端延迟并提升服务质量（QoS）与用户体验质量（QoE）[12][13]。

与此同时，分布式游戏服务器架构本身也在经历深刻变革。从早期的单服务器架构到基于集群的分布式部署，再到近年兴起的微服务化与 Serverless 计算范式，游戏后端架构的演进始终围绕着可扩展性、高可用性与资源利用率三大核心目标 [14][15]。分片（Sharding）策略、分布式事务处理与跨地域容灾等技术的成熟，使得大规模多人在线游戏能够支撑百万级并发用户 [16][17]。

本文旨在系统综述电子游戏分布式计算架构从云计算到边缘计算的技术演进历程。与既有综述不同，本文的贡献在于：（1）构建了从云计算基础 → 云游戏困境 → 边缘/雾介入 → 分布式架构演进的完整逻辑链条；（2）将网络协议优化、资源调度算法与系统架构设计三个维度纳入统一分析框架；（3）基于近年（2022-2026 年）的最新研究成果，为游戏开发者与分布式系统研究人员提供技术选型的系统性参考。

本文的组织结构如下：第二节介绍云计算基础架构及其在游戏领域的应用；第三节聚焦云游戏技术现状与挑战；第四节探讨边缘计算与雾计算在游戏场景中的介入方式；第五节分析分布式游戏服务器架构的演进；第六节展望未来发展方向；第七节总结全文。

二、云计算基础架构及其在游戏领域的应用

云计算作为一种按需提供计算资源的服务范式，在过去十五年间深刻改变了信息技术基础设施的部署与运营模式。对于电子游戏产业而言，云计算不仅为游戏后端提供了弹性可扩展的服务器资源，更为云游戏、游戏数据分析、AI 训练等新兴应用场景奠定了技术基础。本节将从云计算的核心架构模型出发，系统梳理其服务模式、虚拟化技术、资源调度策略、安全机制、能效管理及 AI 融合等关键维度，并分析各项技术在游戏领域的适用性与局限性。

2.1. 云计算的核心架构与服务模型

云计算架构通常划分为五个核心逻辑层：应用层、平台层、基础设施层、虚拟化层与硬件层 [18]。其中，基础设施层负责管理物理服务器、存储设备与网络资源；虚拟化层通过抽象物理资源实现多租户隔离；平台层提供应用开发与部署环境；应用层则承载面向最终用户的服务。这种分层架构的核心优势在于解耦——上层应用无需关心底层物理资源的实现细节，从而显著降低了运维复杂度。

在服务模型维度，云计算遵循 NIST 定义的三层分类体系：基础设施即服务（IaaS）、平台即服务（PaaS）与软件即服务（SaaS）[18]。IaaS 提供虚拟化的计算、存储与网络资源，用户可在其上部署任意操作系统与应用软件，典型代表包括 Amazon EC2 与阿里云 ECS。对于游戏开发者而言，IaaS 常用于部署游戏服务器集群、数据库与文件存储系统。PaaS 则进一步抽象了操作系统与运行时环境，开发者只需关注应用代码本身，适用于游戏后端的快速迭代与持续部署。SaaS 以完整应用的形式交付给终端用户，云游戏平台（如 NVIDIA GeForce NOW、Xbox Cloud Gaming）可视为 SaaS 在游戏领域的典型呈现 [2]。

值得注意的是，近年来 Serverless 计算作为一种新兴的服务模型逐渐兴起，它进一步抽象了服务器管理的概念，开发者仅需编写函数粒度的代码，由云平台自动处理弹性伸缩与计费 [14]。在游戏场景中，Serverless 架构已被探索用于匹配系统、排行榜更新与游戏内事件处理等突发性、间歇性负载场景，有效避免了传统常驻服务器带来的资源闲置成本 [14]。

2.2. 虚拟化技术与多租户隔离

虚拟化技术是云计算的基石，它允许多个虚拟机（VM）或容器共享同一套物理硬件资源，同时提供彼此隔离的执行环境。在游戏应用场景中，虚拟化技术面临独特的性能挑战：游戏服务器通常对 CPU 缓存命中率、内存访问延迟与网络 I/O 抖动高度敏感，过度虚拟化可能导致不可预测的性能波动。

传统虚拟机监控器（Hypervisor）采用完全虚拟化或半虚拟化方案，通过二进制翻译或内核辅助实现指令集的拦截与模拟。虽然这种方案提供了强大的隔离性，但其性能开销在游戏场景中往往不可接受。容器化技术（如 Docker）通过共享宿主机内核、利用命名空间（Namespace）与控制组（Cgroup）实现轻量级隔离，在保持接近裸机性能的同时降低了资源开销 [19]。Zhang 等人对基于移动 SoC 的边缘服务器集群研究表明，容器化部署可将游戏实例密度提升至虚拟机的 3-5 倍，同时将启动时间从秒级缩短至毫秒级 [20][21]。

然而，容器化方案在多租户隔离的完备性上仍存在争议。共享内核意味着容器间存在侧信道攻击的风险，而游戏服务器中频繁的系统调用与共享内存访问可能加剧这一问题。针对移动云游戏的安全威胁研究指出，恶意租户可通过 CPU 缓存时序攻击推断邻近容器的游戏状态信息，这对竞技类游戏的公平性构成潜在威胁 [22]。

2.3. 资源调度与负载均衡

资源调度是云计算系统的核心控制平面，其目标是在满足服务质量约束的前提下，最大化资源利用率与能效。对于游戏工作负载而言，调度算法面临三重挑战：负载的动态突发性（如新游戏发布、周末高峰）、任务的异构性（渲染、AI、物理模拟等不同类型计算），以及严格的实时性要求。

2.3.1 传统调度算法及其局限

早期云计算调度主要依赖启发式算法，包括先来先服务（FCFS）、最短作业优先（SJF）、轮询（Round Robin）及基于优先级的调度策略。这些算法实现简单、开销小，但在面对游戏负载的高度动态性时表现欠佳。多准则决策方法（MCDM）如层次分析法（AHP）与优劣解距离法（TOPSIS）被引入以在多个优化目标（延迟、吞吐量、能耗、成本）之间进行权衡 [23]。然而，MCDM 方法依赖专家先验知识对准则权重进行标定，难以适应游戏负载模式的动态变化。

针对游戏服务器集群的负载均衡问题，研究者提出了多种改进方案。Kim 等人提出的边缘负载均衡算法根据玩家地理位置与实时网络延迟，动态将游戏会话迁移至最近的边缘节点，在仿真实验中实现了平均延迟低于 30ms 的目标 [10]。该算法的核心创新在于引入了预测性迁移机制：基于玩家移动轨迹的短时预测，提前触发会话迁移，从而避免迁移过程中的服务中断。

2.3.2 深度强化学习驱动的智能调度

深度强化学习（DRL）近年来在资源调度领域展现出显著优势。与传统启发式算法不同，DRL 智能体通过与环境交互学习最优调度策略，能够自适应地响应负载模式的变化。Deng 等人提出了一种基于 DRL 的边缘云游戏资源分配框架，该框架将虚拟机放置问题建模为马尔可夫决策过程（MDP），状态空间包括当前资源占用率、待处理任务队列长度与用户 QoE 反馈，动作空间为虚拟机的放置决策与资源配额调整，奖励函数则综合了延迟、丢包率与能耗三个维度 [24]。实验结果表明，该框架在保证 QoE 的前提下，将资源消耗降低了约 22%。

Gao 等人进一步将 DRL 应用于移动边缘计算中的渲染服务动态放置问题，提出了一个双时间尺度调度架构：在大时间尺度上，使用 DRL 决定渲染服务的副本数量与放置位置；在小时间尺度上，使用启发式算法处理瞬时负载波动 [25]。这种分层调度策略在多人云游戏场景中展现出良好的扩展性，能够支持超过 1000 名并发用户的同时渲染服务。

Gao 等人提出的 GameDRL 框架则将深度强化学习直接应用于游戏服务器集群的自动扩缩容 [26]。该框架采用 LSTM 网络对玩家流量进行时序预测，并将预测结果输入 DRL 调度器以提前调整集群规模。在《英雄联盟》类 MOBA 游戏负载数据上的测试表明，GameDRL 相比传统的基于阈值的自动扩缩容策略，将资源浪费降低了 35%，同时将服务等级协议（SLA）违约率控制在 0.1% 以下。

2.3.3 虚拟机放置与资源竞争管理

虚拟机放置（Virtual Machine Placement, VMP）问题是云计算资源调度的核心子问题之一，其本质是一个 NP-hard 的组合优化问题。在游戏场景中，VMP 问题的复杂度进一步增加：多个游戏实例运行在同一物理节点上时，会产生 CPU 缓存、内存带宽与网络 I/O 的资源竞争，这种竞争可能导致延迟抖动，进而影响玩家体验。

Zhang 等人针对移动云游戏场景提出了一个 QoE 导向的虚拟机竞争模型 [27]。该研究通过实测揭示了不同游戏类型对资源竞争的敏感度差异：第一人称射击游戏对 CPU 缓存竞争最为敏感，缓存未命中率每增加 10%，玩家命中率下降约 3.2%；而策略类游戏对内存带宽竞争更为敏感。基于这一发现，作者提出了一种资源竞争感知的 VMP 算法，将敏感度相异的游戏实例放置在不同物理核心上，以降低资源争用的概率。

Imbien 的研究则将遗传算法与禁忌搜索相结合，提出了一种混合优化策略用于边缘云环境中的任务分配 [28]。该算法的创新之处在于引入了“温度”参数来控制搜索过程中的探索-利用平衡，有效避免陷入局部最优解。在包含 500 个边缘节点与 10000 个游戏会话的仿真实验中，该算法相比标准遗传算法将收敛速度提升了约 40%，同时将任务平均完成时间缩短了 18%。

2.4. 云安全机制与游戏场景的特殊挑战

云计算的安全问题贯穿基础设施、平台与应用三个层面，涉及数据机密性、完整性、可用性与隐私保护等多个维度 [29]。在游戏应用场景中，安全挑战呈现出独特的形态：除了传统的数据泄露与 DDoS 攻击风险外，游戏作弊、账号盗取与经济系统操纵等问题对云安全机制提出了额外要求。

2.4.1 基础设施安全与 DDoS 防护

分布式拒绝服务（DDoS）攻击是游戏服务器面临的最常见安全威胁之一。攻击者通过控制大量僵尸主机向目标服务器发送海量请求，耗尽带宽或计算资源，导致正常玩家无法连接。Wang 等人探讨了利用人工智能算法增强云网络安全的方法，提出了一个基于图神经网络（GNN）的异常流量检测框架 [30]。该框架通过构建网络流的异构图结构，将源 IP、目的 IP、端口号与协议类型建模为图中的节点与边，利用图卷积网络（GCN）学习正常流量的模式特征，从而实现 DDoS 攻击的早期检测。

针对云游戏场景的特殊性，Ky 等人提出了一种基于 P4 可编程交换机的混合架构用于云游戏流量检测 [5]。与传统的基于软件的检测方案不同，该架构将部分检测逻辑卸载至数据平面，利用 P4 语言的协议无关性实现线速处理。实验结果表明，该架构能够在 100Gbps 线速下完成云游戏流量的实时分类，检测延迟低于 10 微秒。Singh 等人则进一步探讨了在硬件层面使用机器学习模型检测云游戏流量的可行性，提出了 MATADOR 框架，该框架在 FPGA 上实现了轻量级随机森林分类器，在保持检测精度的同时将功耗控制在 5W 以内 [11]。

2.4.2 游戏作弊检测与公平性保障

云游戏架构为反作弊提供了新的技术路径。在传统客户端-服务器架构中，游戏逻辑运行于玩家终端，作弊程序可以通过内存修改、代码注入或封包篡改等方式干扰游戏运行。而在云游戏架构下，游戏渲染与逻辑均在云端执行，玩家终端仅接收视频流，这从根本上杜绝了内存修改类作弊手段。然而，新的作弊形式也随之出现：基于计算机视觉的瞄准辅助（Aimbot）通过分析视频流中的敌人位置自动移动准星，这种作弊方式不侵入游戏进程，仅依赖视频输出，对传统反作弊机制构成了挑战。

Kumar 等人对移动云游戏的安全威胁进行了深入分析，指出了视觉作弊检测的难点：合法玩家与作弊玩家的输入模式在统计特征上存在差异，但单一帧级别的检测往往无法区分二者 [22]。该研究提出了一种基于行为序列分析的检测方法，将鼠标移动轨迹建模为时序数据，利用 LSTM 网络区分人类玩家的自然抖动与机器生成

的平滑轨迹。在《使命召唤》移动版数据集上的测试表明，该方法对基于计算机视觉的瞄准辅助检测准确率达到 94.2%。

2.4.3 数据安全与隐私保护

SaaS 模式下的云游戏平台存储了大量玩家个人信息与游戏数据，包括账号凭证、支付信息、游戏进度与行为日志等 [31]。这些数据的安全保护面临多重挑战：数据在传输过程中可能被窃听或篡改；在云端存储时可能因配置错误或内部攻击而泄露；在多租户环境中可能因隔离失效而被其他租户访问。

Wang 等人提出了一种基于人工智能算法的云网络安全增强方案，该方案集成了联邦学习与差分隐私技术，允许多个云游戏平台在不共享原始数据的情况下协同训练入侵检测模型 [30]。联邦学习的核心思想是“数据不动模型动”——各参与方在本地训练模型，仅上传模型梯度更新至中央服务器聚合。差分隐私则通过在梯度中注入校准噪声来防止对手从模型中反推用户数据。这种组合方案在保护用户隐私的同时，显著提升了跨平台威胁检测的能力。

2.5. 能效管理与绿色计算

数据中心的能耗问题是云计算可持续发展面临的核心挑战之一。据估计，全球数据中心的年耗电量已超过 200 太瓦时，约占全球总用电量的 1%。对于游戏云服务而言，能效问题尤为突出：游戏工作负载的计算强度显著高于普通 Web 服务，且负载波动更为剧烈，导致能源浪费严重。

2.5.1 游戏工作负载的能效特征

与传统数据中心工作负载相比，游戏负载具有以下能效特征：（1）计算密集型——游戏渲染与物理模拟高度依赖 GPU，功耗远高于 CPU 密集型任务；（2）延迟敏感型——游戏负载对响应时间有严格约束，限制了深度节能状态的进入；（3）负载波动型——游戏在线人数呈现明显的昼夜周期与周周期波动，峰值与谷值负载可相差数倍 [32]。

Shanmugam 等人提出了一种基于猫群优化（CSO）算法的可持续云资源管理方法 [33]。CSO 算法模拟家猫在环境中的搜索行为，将资源调度建模为多目标优化问题，优化目标包括能耗、SLA 违约率与资源利用率三个维度。在模拟游戏负载上的实验表明，CSO 算法相比传统粒子群优化（PSO）算法将能耗降低了约 15%，同时保持了相近的 SLA 履约水平。

2.5.2 边缘计算的能效优势

边缘计算通过在靠近用户的位置部署计算资源，不仅降低了网络延迟，还带来了能效优势。Spinelli 等人从绿色计算的视角分析了边缘游戏的能效潜力 [34][35]。该研究指出，传统云数据中心的高能耗主要源于两方面的浪费：一是长距离传输带来的网络设备能耗；二是集中式冷却系统的大规模能量开销。边缘节点通常部署在基站或接入网设备附近，可以利用现有机房与散热基础设施，从而规避数据中心冷却系统的巨大能耗。

Zhang 等人对基于移动 SoC 的边缘服务器（称为 SFG）进行了深入分析，发现在移动云游戏场景中，SFG 的能效比（每瓦特每秒处理的帧数）是传统 x86 服务器的 3.7 倍 [36][21]。这一能效优势主要来源于移动 SoC 的异构计算架构——大核心（P-core）负责游戏渲染的主线程，小核心（E-core）处理网络 I/O 与输入采集，而神经网络加速单元（NPU）则承担视频编码中的超分辨率任务。这种“大小核 + 专用加速器”的异构设计，使得 SFG 在处理游戏负载时能够精准匹配计算需求与硬件资源，避免了大材小用式的能源浪费。

2.5.3 任务调度层面的节能策略

在任务调度层面，多种节能策略被提出用于降低游戏云平台的能耗。Monika 综述了云环境下的能效任务调度方法，将其归纳为三类：基于 DVFS（动态电压频率调整）的方法、基于虚拟机整合的方法与基于可再生能源调度的方法 [32]。

DVFS 方法通过动态调整 CPU/GPU 的工作频率与电压来匹配当前负载强度。在游戏负载中，DVFS 面临的主要挑战是频率切换的延迟——当负载突然增加时，频率上调需要数十微秒到数毫秒的时间，可能导致帧率下降。为应对这一问题，研究者提出了基于预测的 DVFS 策略：利用游戏负载的周期性特征（如对局开始/结束、团战爆发等事件）提前调整频率，从而规避切换延迟的影响。

虚拟机整合（VM Consolidation）方法通过将低负载节点上的虚拟机迁移到其他节点，从而关闭空闲节点以节省能耗。然而，游戏负载的延迟敏感性对虚拟机整合提出了挑战：迁移过程中的服务中断可能被玩家感知。为解决这一问题，研究者提出了“实时迁移”（Live Migration）技术，通过迭代复制内存页并在最后阶段短暂暂停虚拟机来完成迁移，将服务中断时间控制在毫秒级。对于游戏会话而言，这一中断窗口仍然可能被玩家感知，因此需要结合游戏状态同步机制来平滑迁移过程。

2.6. 云计算中的 AI 融合与游戏智能

人工智能与云计算的融合正在重塑游戏开发与运营的多个环节。从 AI 驱动的资源调度到云端深度学习训练，从智能 NPC 行为生成到玩家行为分析，云计算为游戏 AI 提供了算力支撑，而 AI 则为云计算带来了智能化能力。

2.6.1 云端深度学习训练与推理

现代游戏中的 AI 系统（如 NPC 行为树、对战机器人、玩家匹配算法）越来越依赖于深度学习模型。这些模型的训练需要大规模计算资源，而云计算恰好提供了弹性可扩展的 GPU 集群。Awan 对云环境中的深度神经网络应用进行了系统综述，分析了主流深度学习框架（TensorFlow、PyTorch、MXNet）在云平台上的部署模式与性能特征 [37]。

Wang 等人针对深度学习任务的 GPU 内存需求预测问题，提出了一个基于双向门控循环单元优化 Transformer 的预测模型 [30]。该模型通过分析计算图的静态结构与动态运行轨迹，预测模型训练过程中的峰值内存占用，为云平台的资源调度提供决策依据。在包含 Transformer、ResNet 与 BERT 等主流模型的测试集上，该模型的预测误差中位数仅为 4.7%，显著优于传统的基于经验的估算方法。

Li 等人则从理论层面探讨了混合专家模型（MoE）在移动边缘计算中的应用，提出了在资源受限的边缘设备上高效部署 MoE 模型的方法 [38]。该方法核心理念是“专家路由”——根据输入样本的特征动态选择部分专家网络进行推理，而非激活全部专家。在游戏 AI 推理场景中，这意味着边缘节点可以根据当前游戏状态（如对局阶段、地图区域、敌方阵容）选择性地加载 NPC 行为模型，从而在保持推理精度的同时降低内存占用与计算开销。

2.6.2 游戏数据分析与玩家行为挖掘

云平台汇聚了来自海量玩家的游戏行为数据，为数据驱动的游戏运营与设计优化提供了丰富素材。Hanefi 等人讨论了数据分析在实时游戏中的应用，指出云计算使得大规模实时数据处理成为可能 [39]。典型的应用场景包括：玩家流失预测、对局匹配优化、经济系统监控与作弊行为检测。

Harris 的分析进一步指出，云游戏行业的数据分析需求正在快速增长，年复合增长率达到 28% [40]。这一增长主要受两个因素驱动：一是游戏即服务（GaaS）模式的普及，要求开发者持续监控并优化玩家体验；二是电竞产业的成熟，使得对局数据的深度分析成为战队训练与战术制定的标准环节。

Bai 探讨了云计算在 B2C 电子商务价值链优化中的应用，虽然该研究聚焦于电商场景，但其提出的基于云的数据分析框架可迁移至游戏内购与虚拟商品交易分析 [41]。该研究指出，云原生数据仓库（如 Amazon Redshift、Google BigQuery）使得对 PB 级交易数据的实时分析成为可能，为游戏运营方提供了精准的用户画像与个性化推荐能力。

2.7. 游戏领域的云计算实践：成就与局限

综上所述，云计算为电子游戏产业带来了显著的技术红利：弹性计算资源使游戏开发者无需预先采购物理服务器即可应对千万级并发玩家；全球化的数据中心布局降低了跨国玩家的访问延迟；云原生技术栈（容器、服务网格、Serverless）则加速了游戏后端的迭代与运维自动化。

然而，云计算在游戏领域的应用也暴露出结构性局限。最为突出的是延迟问题：即使是最优化的网络路径，从玩家终端到云端数据中心的物理距离仍然导致数十毫秒的基础延迟。对于快节奏的竞技游戏而言，这一延迟足以影响游戏的公平性与沉浸感 [3]。此外，云游戏模式下视频流的带宽消耗（4K/60fps H.264 编码约需 25-40Mbps）对移动网络构成了巨大压力 [42]。

这些局限性的根源在于：传统云计算的架构设计假设计算资源可以远离用户，而游戏交互的实时性要求恰恰相反。这一矛盾催生了将计算资源向网络边缘下沉的技术趋势，我们将在下一节详细讨论云游戏技术的现状与挑战，为后续的边缘计算介入奠定分析基础。

三、云游戏技术现状与挑战

云游戏作为一种将游戏渲染与计算任务从终端设备迁移至云端服务器的交互范式，在过去十年间经历了从概念验证到商业落地的跨越式发展。与传统的游戏下载与本地运行模式不同，云游戏采用“远程渲染 + 视频流传输”的架构：游戏在云端服务器上运行，渲染完成的画面经过实时编码压缩后以视频流的形式推送到玩家终端，玩家的控制指令则通过反向信道回传至云端 [2]。这种架构从根本上降低了玩家终端的硬件门槛，使得在手机、平板甚至智能电视上畅玩 3A 级大作成为可能。然而，云游戏也面临着严峻的技术挑战——延迟、带宽、画质与成本之间的多重权衡构成了云游戏系统设计的核心难题。本节将从云游戏系统架构出发，系统梳理流量检测与识别、服务质量（QoS）与用户体验质量（QoE）评估、渲染架构优化、延迟分析与消减等关键技术维度的

研究进展，并深入剖析当前面临的核心挑战。

3.1. 云游戏系统架构与工作流程

典型的云游戏系统采用客户端-服务器架构，其中服务器端承担了游戏逻辑执行、画面渲染、视频编码与网络传输四大核心职能，客户端则负责视频解码、输入采集与指令回传。根据渲染任务与编码任务的部署位置差异，云游戏架构可进一步细分为三种变体：完全云端渲染架构、边缘辅助渲染架构与客户端辅助渲染架构。

完全云端渲染架构是最传统的实现方式，游戏的全部计算任务均在远端数据中心完成，客户端仅作为“瘦终端”存在。NVIDIA GeForce NOW、Xbox Cloud Gaming 与 PlayStation Now 等主流商业平台均采用此架构 [6]。该架构的优势在于实现简单、客户端兼容性高，但对网络条件的要求也最为严苛——任何网络抖动都可能直接表现为画面卡顿或输入延迟。

边缘辅助渲染架构试图通过将部分渲染任务下沉至边缘节点来缓解延迟问题。Kang 等人提出的 E-Render 架构是该方向的代表性工作 [9]。在该架构中，云端负责游戏逻辑与全局状态管理，边缘节点则承担超高清（UHD）画面的渲染与编码任务。通过将渲染节点部署在靠近用户的基站侧，E-Render 将端到端渲染延迟从传统云游戏的 80-120ms 降低至 30-50ms。Zhang 等人的研究进一步提出了利用高密度移动 SoC 集群构建边缘渲染节点的方案，通过数百个手机芯片的并行处理实现了单节点支持 64 路并发云游戏流的能力 [20][21]。

客户端辅助渲染架构则是一种混合方案，将部分渲染任务保留在客户端完成，云端仅处理计算密集型的特效或全局光照。这种架构在 5G 边缘计算场景下受到关注，但其对客户端硬件仍有较高要求，与云游戏“降低终端门槛”的核心初衷存在一定张力。

云游戏的工作流程涉及多个串行环节，任一环节的延迟都会累加到端到端总延迟中。以 GeForce NOW 平台为例，一次完整的玩家交互到画面响应包含以下步骤：（1）客户端采集输入指令；（2）指令经网络传输至云端；（3）云端服务器接收指令并更新游戏状态；（4）GPU 执行渲染命令生成新帧；（5）编码器将渲染完成的帧压缩为视频流；（6）压缩后的视频流经网络回传至客户端；（7）客户端解码视频帧；（8）客户端渲染显示 [6]。这一流程中的每一个步骤都在毫秒尺度上贡献延迟，而其中网络传输与视频编码是最大的两个延迟源。

3.2. 云游戏流量检测与识别

云游戏流量的准确检测与识别是网络服务质量保障、流量工程与异常检测的基础。与传统视频流（如 Netflix、YouTube）相比，云游戏流量具有独特的特征：对丢包极度敏感（一个丢包可能导致整个 GOP 无法解码）、呈现周期性突发模式（由帧率决定）、且上行与下行流量不对称（下行远大于上行）。这些特征使得云游戏流量在聚合流量中具有可区分性，为基于机器学习的方法提供了判别依据。

3.2.1 基于可编程数据平面的检测方法

Ky 等人提出了一种基于 P4 可编程交换机的混合架构用于云游戏流量的实时检测 [5]。该架构的核心创新在于将检测任务分解为两个层次：数据平面负责提取流量的轻量级特征（如包大小分布、到达间隔、流持续时间），控制平面则运行复杂的机器学习模型进行最终分类。通过在 P4 交换机上实现哈希表、计数器与状态机等原语，该架构能够在 100Gbps 线速下实时提取超过 20 个流特征，检测延迟低于 10 微秒。实验结果表明，该架构对云游戏流量的识别准确率达到 96.7%，同时引入的额外延迟仅为 2.3 微秒。

Singh 等人提出的 MATADOR 框架则更进一步，尝试将机器学习模型本身部署在可编程硬件上 [11]。该框架使用 FPGA 实现了轻量级随机森林分类器，通过将决策树量化为查找表与比较器网络，使得分类操作可以在单时钟周期内完成。MATADOR 在保持与软件方案相当的检测精度（94.2%）的同时，将功耗控制在 5W 以内，能效比达到 GPU 方案的 40 倍。这一成果为在边缘交换设备上大规模部署云游戏流量检测提供了可行路径。

3.2.2 云游戏流量的网络层特征分析

Graff 在其博士论文中对低延迟云游戏流量的网络层特性进行了系统分析 [4]。通过采集超过 1000 小时的 GeForce NOW 与 Stadia 真实流量数据，该研究揭示了云游戏流量的若干关键特征：（1）流量呈现明显的 ON-OFF 模式，ON 期间的数据率可达 40-60Mbps，OFF 期间则降至接近零；（2）包大小分布呈现双峰特征，小包（约 100-200 字节）承载控制信令与 ACK，大包（约 1400 字节）承载视频数据；（3）到达间隔在帧率对应的时间尺度上呈现周期性，60fps 游戏的平均帧间隔约为 16.7ms。这些特征为基于深度包检测（DPI）和基于行为分析的分类方法提供了判别依据。

Lu 对不同云游戏平台网络性能进行了对比研究 [43]，发现各平台在传输协议选择上存在显著差异：GeForce NOW 主要使用 UDP 传输视频流，辅以 TCP 传输控制信令；Stadia 则完全基于 QUIC 协议；而 Xbox Cloud Gaming 采用 WebRTC 协议栈。这种差异导致了不同平台在网络抗丢包能力与拥塞控制行为上的显著分化，也为跨平台的统一流量检测带来了挑战。

3.3. 云游戏服务质量与用户体验质量

服务质量（QoS）与用户体验质量（QoE）是评估云游戏系统性能的两个核心维度。QoS 侧重于网络与系统的客观性能指标，包括延迟、抖动、丢包率、带宽与吞吐量等；QoE 则关注用户主观感知的质量，通常通过平均意见分（MOS）或更细粒度的量表进行量化。在云游戏场景下，QoS 与 QoE 之间存在复杂的非线性映射关系，理解这一关系是进行有效的系统优化的前提。

3.3.1 QoS 指标体系与测量方法

云游戏的 QoS 指标可划分为三个层次：网络层 QoS、系统层 QoS 与应用层 QoS。网络层 QoS 包括往返时间（RTT）、单向延迟（OWD）、抖动（Jitter）、丢包率（PLR）与可用带宽等传统指标。系统层 QoS 则关注云端渲染与编码的性能，包括帧渲染时间、编码延迟、编码比特率与关键帧间隔等。应用层 QoS 最终体现为用户可感知的指标，如操作到画面的延迟（也称“玻璃到玻璃”延迟）、视频帧率、画质分辨率与卡顿频率等。

Lyu 等人对 GeForce NOW 平台的网络解剖研究是云游戏 QoS 测量领域的重要工作 [6]。该研究在全球部署了超过 50 个测量节点，对 GeForce NOW 的接入点分布、路由路径、延迟构成与丢包模式进行了大规模测量。研究发现，GeForce NOW 的端到端延迟中位数约为 68ms，其中网络传输贡献约 28ms，云端渲染与编码贡献约 30ms，客户端解码与显示贡献约 10ms。研究还发现，跨洲际连接的延迟显著高于洲内连接（相差约 80-100ms），且丢包率超过 0.5% 时用户可感知的画质下降开始出现。

3.3.2 QoE 建模与评估

Rossi 等人针对移动网络环境下的云端 VR 第一人称射击游戏建立了 QoE 评估模型 [13][44]。该研究通过受控实验（N=48 名受试者）系统考察了网络延迟、丢包率与帧率三个变量对用户沉浸感、操作精度与眩晕感的影响。研究发现，在 VR-FPS 场景下，端到端延迟超过 50ms 时用户的射击命中率开始显著下降（ $p < 0.01$ ），延迟超过 80ms 时超过 60% 的受试者报告中度到重度的眩晕症状。基于这些发现，作者提出了一个包含延迟、丢包与帧率的三维 QoE 预测模型，模型的预测与实测 MOS 值的相关系数达到 0.91。

Kumbhar 等人则探讨了在 5G 网络中结合无服务器计算与机器学习提升云游戏 QoE 的方法 [45]。该研究的核心思想是：利用无服务器计算的事件驱动特性，在检测到网络质量下降时动态触发 QoE 增强函数（如超分辨率重建、丢包隐藏、帧率上采样）。这些函数以轻量级云函数的形式部署在网络边缘，由 API 网关按需调用，避免了常驻服务器带来的资源浪费。实验表明，该方案在网络丢包率达到 3% 时仍能保持用户 MOS 维持在 3.5 以上（5 分制），而传统方案在同样丢包率下 MOS 已降至 2.8 以下。

Graff 等人对云游戏 QoS 保障中的排队策略进行了比较研究 [12]，重点对比了基于类的加权公平排队（CB-WFQ）与低延迟低损耗可扩展服务（L4S）架构在云游戏场景下的表现。L4S 是 IETF 提出的新型拥塞控制架构，其核心创新在于通过精确的往返时间测量与及时的拥塞标记，将排队延迟控制在亚毫秒级别。实验结果表明，在网络拥塞条件下，L4S 架构将云游戏流的 99 分位排队延迟从 CBWFQ 的 18ms 降低至 2.3ms，同时将丢包率从 0.8% 降低至 0.03%。这一结果为云游戏流量的网络层 QoS 保障提供了新的技术路径。

3.3.3 异常检测与根因诊断

云游戏服务的稳定性依赖于对异常事件的快速检测与根因诊断。Ky 等人提出了一个针对低延迟应用的异常检测框架，该框架集成了变分自编码器（VAE）与可解释性模块，能够在不依赖标注数据的情况下检测异常并定位根因 [46]。该框架的核心创新在于：VAE 的隐空间被设计为与物理变量（延迟、丢包、帧率）对齐，使得异常的隐变量偏移可以直接映射到具体的 QoS 指标异常。在云游戏场景的案例研究中，该框架成功识别了由路由震荡引发的周期性延迟尖峰，并将根因定位至特定自治域（AS）的 BGP 更新事件。

3.4. 云游戏渲染架构优化

渲染是云游戏中最计算密集的环节，其性能直接影响端到端延迟与视频质量。传统云游戏架构采用“全帧渲染 + 全帧编码”的模式，这种模式虽然实现简单，但存在计算冗余与延迟冗余——每一帧都被完整渲染，即使画面中仅有小区域发生变化。为突破这一局限，研究者从多个角度探索了渲染架构的优化方案。

3.4.1 边缘渲染与计算卸载

边缘渲染的核心思想是将渲染任务从集中式云端下沉至靠近用户的边缘节点，从而缩短渲染结果到达用户的物理距离。Kang 等人提出的 E-Render 架构是该方向的代表性工作 [9]。在该架构中，云端维护游戏全局状态的权威副本，边缘节点则负责根据本地玩家的视角进行差异化渲染。当一个边缘节点过载时，其承载的渲染任务可以动态迁移到邻近节点，迁移过程通过增量状态同步来减少中断时间。仿真实验表明，E-Render 在边缘节点密度为每百平方公里 10 个的条件下，将 95 分位渲染延迟从 102ms 降低至 47ms。

Zhang 等人对基于移动 SoC 的边缘渲染服务器进行了系统性的性能分析 [20][21][36]。该研究构建了一个包含 256 个手机 SoC 芯片的边缘服务器原型（称为 SFG），并评估了其在移动云游戏场景下的性能表现。结果显

示, SFG 在功耗控制上具有显著优势: 渲染《原神》移动版时, 单路流的功耗仅为 3.2W, 而传统 x86 服务器的功耗为 28W。这一能效优势主要来源于移动 SoC 的异构计算架构与精细化的功耗管理。研究还发现, SFG 在处理多路并发流时的扩展性接近线性, 256 个 SoC 可同时支持超过 200 路云游戏流。

3.4.2 远程渲染的协议与框架优化

Mejías 等人对远程 VR 渲染中的多媒体框架与传输协议进行了系统的性能对比 [47]。该研究对比了 Unity 渲染流、Unreal Engine 像素流、NVIDIA GameStream 与开源框架 Moonlight 四种方案在 VR 场景下的表现。评估指标包括端到端延迟、帧率稳定性、画质损失与 CPU/GPU 开销。结果显示, Unreal Engine 像素流在画质方面表现最佳 (PSNR 达到 38.2dB), 但其编码延迟较高 (平均 12ms); NVIDIA GameStream 在延迟方面最优 (端到端延迟约 28ms), 但画质在高速运动场景下出现明显的块效应。该研究还发现, WebRTC 协议在 VR 远程渲染场景下具有天然优势, 其内置的拥塞控制与自适应编码能够较好地应对移动网络的信道波动。

Choudhury 在其博士论文中描绘了通过移动网络在边缘云上实现 VR 远程渲染的系统架构 [48]。该架构将 VR 渲染拆分为三个层次: 云端负责全局光照与复杂物理模拟, 边缘云负责视角相关的渲染与预测生成, 终端负责异步时间扭曲 (ATW) 与空间扭曲等帧外推操作。这种三层分解使得系统能够在网络带宽波动时保持稳定的帧率: 当带宽充足时, 边缘云传输全分辨率帧; 当带宽不足时, 终端利用运动矢量与深度信息对低分辨率帧进行超分辨率重建。实验表明, 该架构在带宽从 50Mbps 骤降至 10Mbps 时, 仍能将感知帧率维持在 72fps 以上。

3.4.3 VR/AR 云渲染的特殊挑战

VR/AR 云渲染对延迟的要求比传统云游戏更为严苛。根据 IAFI 的工作文件, 沉浸式 VR 应用对运动到光子 (Motion-to-Photon) 延迟的要求为 5-10 毫秒, 远低于传统云游戏的 50-80 毫秒 [42]。这一差距主要源于 VR 的视觉生理特性: 当头显转动时, 渲染画面的更新延迟超过 10ms 会导致用户产生明显的晕动症 (Simulator Sickness)。此外, VR 云渲染的带宽需求也显著更高——双目渲染需要同时传输两个视角的画面, 且每只眼睛的分辨率通常不低于 2K×2K, 合计带宽需求可达 0.1-1 Gbit/s。

IEEE 802.11 标准工作组在其最新修订中明确指出, AR/VR 与无线游戏是其高通量低延迟场景的重要应用 [49]。802.11be (Wi-Fi 7) 引入的多链路操作 (MLO) 与 320MHz 带宽, 理论上可支持低至 1ms 的 MAC 层延迟与高达 30Gbps 的峰值速率。然而, 实际部署中的干扰、遮挡与用户移动等因素, 使得这些理论性能难以完全兑现。

3.5. 云游戏延迟分析

延迟是云游戏用户体验的核心制约因素。深入理解延迟的构成、来源与传播机制, 是进行系统优化的前提。本节将从延迟的构成分解、延迟消减策略以及延迟感知的用户行为响应三个维度展开分析。

3.5.1 延迟构成分解

Dharmapurikar 对云游戏延迟的构成因素进行了系统性的技术分析 [3]。该研究将端到端延迟分解为六个贡献项: (1) 输入采集延迟 (1-3ms); (2) 上行传输延迟 (依赖于网络距离, 通常为 10-40ms); (3) 云端处理延迟 (包括网络栈处理、游戏逻辑更新与渲染命令提交, 合计 5-15ms); (4) 渲染与编码延迟 (GPU 渲染时间取决于场景复杂度, 通常为 8-25ms; 编码时间取决于编码器与预设, 通常为 5-15ms); (5) 下行传输延迟 (10-40ms); (6) 客户端解码与显示延迟 (解码时间取决于硬件解码器性能, 通常为 2-8ms; 显示延迟包括屏幕刷新与像素响应, 通常为 5-15ms)。

这一分解揭示了云游戏延迟优化的两个关键结论: 第一, 传输延迟与渲染编码延迟是最大的两个贡献项, 各占总延迟的 30-40%; 第二, 即使传输延迟被完全消除, 渲染、编码与解码环节的固有延迟 (约 25-50ms) 仍然存在, 这意味着云游戏的端到端延迟存在一个理论下限。Patil 对低延迟公共云系统的优化策略进行了分析, 指出通过边缘节点的就近部署可以将传输延迟压缩至物理极限 (约每 1000 公里 5ms) [50], 但渲染与编码环节的延迟消减需要从算法与硬件两个层面同时入手。

3.5.2 延迟消减策略

针对渲染与编码延迟, 研究者提出了多种消减策略。在渲染侧, 可变速率着色 (VRS) 与注视点渲染 (Foveated Rendering) 是两种主流方案。VRS 允许开发者指定画面不同区域的着色率, 外围区域的着色率可以降低至中央区域的 1/4 甚至 1/16, 从而在不明显影响感知画质的前提下减少 GPU 负载。注视点渲染则进一步利用眼动追踪技术, 仅在用户注视的中央凹区域进行全分辨率渲染, 外围区域使用低分辨率渲染后再进行超分辨率重建。这些技术可将 GPU 渲染时间缩短 40-60%。

在编码侧, 分区编码 (Tile-based Encoding) 与分层编码 (Layered Encoding) 是两种有效的优化手段。分区编码将画面划分为多个矩形区块 (Tile), 每个区块独立编码, 使得编码器可以仅对有变化的区块进行重编码, 从而降低编码负载。分层编码则生成基础层与增强层两个码流, 网络条件良好时传输两层以获得高画质, 网络拥

塞时仅传输基础层以保证流畅性。HEVC 与 VVC 编码标准均对这两种模式提供了原生支持。

Patil 的研究进一步指出，高性能服务器的引入可以在一定程度上抵消延迟影响：当服务器处理能力足够强大时，渲染与编码延迟的降低可以部分补偿网络传输延迟的增加 [50]。这一发现为云游戏系统的成本-延迟权衡提供了新的视角——在某些场景下，投资于更强的 GPU 可能比投资于更优的网络路径更具成本效益。

3.5.3 延迟感知与用户行为响应

玩家对延迟的感知不是线性的，而是呈现出门槛效应：在低延迟区间（<30ms），大多数玩家无法感知延迟变化；在中延迟区间（30-80ms），延迟敏感型玩家开始抱怨；在高延迟区间（>80ms），几乎所有玩家都能明显感知到操作不跟手。这种非线性感知模式为云游戏的 QoS 目标设定提供了依据：将延迟控制在 30ms 以下是理想目标，将延迟控制在 50ms 以下是实用目标，而超过 80ms 的延迟应被视为服务异常。

Khan 等人探讨了元宇宙环境下沉浸式游戏的 QoE 挑战，指出在多人社交 VR 场景中，延迟不仅影响个体体验，还会通过人际交互产生社会性放大效应——当某玩家的动作在同伴的视角中出现明显延迟时，双方都会产生负面体验 [51]。这一发现暗示，云游戏与云 VR 系统的延迟优化目标可能需要从“个体延迟最小化”转向“延迟差异最小化”，即确保同一虚拟空间内各玩家的延迟尽可能接近。

3.6. 云游戏面临的核心挑战

尽管云游戏在技术层面取得了长足进步，其在商业化推广中仍面临多重挑战。这些挑战既有技术层面的（计算复杂度、网络依赖），也有经济层面的（成本结构、商业模式），还有监管层面的（内容合规、数据主权）。

3.6.1 计算复杂度与成本压力

云游戏的计算成本是制约其规模化推广的首要因素。运行一款 3A 级游戏需要高端 GPU（如 NVIDIA RTX 4080 级别）的持续投入，而一块这样的 GPU 在同一时刻仅能服务少数几个玩家（通常为 1-4 路并发）。以每路流每小时 0.5-1 美元的计算成本估算，云游戏平台在用户日均游玩 2 小时的条件下，仅计算成本就达到每月 30-60 美元，这已经超过了大多数用户的付费意愿阈值。

为降低计算成本，研究者从硬件与软件两个层面进行了探索。在硬件层面，Zhang 等人提出的移动 SoC 集群方案提供了一种低成本替代路径：移动 SoC 的采购成本仅为同性能 x86 方案的 1/3-1/2，功耗则仅为 1/4-1/3 [20]。在软件层面，通过帧间预测与增量编码技术降低编码负载，以及通过 AI 超分辨率技术以较低分辨率渲染后上采样至目标分辨率，都可以在不明显影响画质的前提下减少计算开销。

3.6.2 网络依赖与覆盖瓶颈

云游戏的可行性高度依赖于用户的网络条件。根据 Lu 的对比研究，在宽带速率低于 50Mbps 或 RTT 高于 40ms 的网络环境下，主流云游戏平台均难以提供令人满意的体验 [43]。这意味着全球仍有大量潜在用户因网络基础设施的限制而无法使用云游戏服务。即便在宽带普及率较高的地区，家庭网络的拥塞时段（如晚间高峰）与无线网络的信号波动，仍然会导致不可预测的体验下降。

5G/6G 网络的部署为缓解这一问题带来了希望。Sharma 等人比较了 5G/6G 环境下边缘计算在游戏中的应用进展，指出 5G 的 URLLC（超可靠低延迟通信）切片可提供 1ms 的空口延迟与 99.999% 的可靠性保障 [52]。Iacopino 等人对中国 5G 边缘计算市场发展的分析显示，中国已建成全球最大的 5G 边缘节点网络，为云游戏的低延迟覆盖奠定了基础 [53]。然而，边缘节点的部署成本与运营复杂度仍然是不容忽视的挑战。

3.6.3 内容授权与商业模式

云游戏平台的商业模式面临内容授权的根本性约束。与视频流媒体平台不同，游戏发行商通常要求云游戏平台为每一款游戏单独谈判授权协议，且授权费用往往与游戏销量挂钩。这使得云游戏平台的内容库建设成本极高，且面临内容随时下架的风险。Ravichandran 与 Kababiito 分别从不同角度探讨了数字游戏的合规性与监管挑战，指出云游戏涉及的数据跨境流动与未成年人保护等问题进一步增加了合规成本 [54][55]。

从商业模式创新的角度看，部分云游戏平台尝试通过订阅制（如 Xbox Game Pass Ultimate）与时长制（如 GeForce NOW 的按小时计费）来分散用户成本。然而，目前尚无一种模式被证明能够实现可持续盈利。Bhide 等人的综述指出，云游戏产业的健康发展需要硬件成本下降、网络基础设施升级与内容授权模式创新三者的协同推进 [2]。

3.7. 本章小结

云游戏作为云计算在游戏领域的直接应用，在过去数年间取得了显著的技术进步。从流量检测到 QoS 保障，从渲染优化到延迟消减，研究者从多个维度对云游戏系统进行了持续的改进与优化。然而，云游戏面临的本质困境——计算资源集中化与交互实时性之间的张力——并未从根本上得到解决。将计算资源向网络边缘下沉，成为突破这一困境的必然选择。下一节将深入探讨边缘计算与雾计算如何作为云计算的补充范式，为游戏应用提

供低延迟、高带宽与位置感知的计算能力。

四、边缘计算与雾计算在游戏场景中的介入

随着云游戏技术的发展和实时交互应用对低延迟的极致追求,传统集中式云计算架构的局限性日益凸显。将计算资源从远端数据中心迁移至网络边缘,成为突破这一瓶颈的核心技术路径。边缘计算(Edge Computing)与雾计算(Fog Computing)作为云计算的延伸与补充范式,通过将存储、计算与网络资源部署在更接近数据源与用户的位置,为游戏应用提供了低延迟、高带宽、位置感知与上下文感知的全新能力。本节将从概念界定出发,系统阐述边缘计算与雾计算的核心定义、参考架构、关键技术,并深入分析其在游戏场景中的具体应用方式、技术路线与工程实践。

4.1. 边缘计算：概念界定与核心架构

4.1.1 边缘计算的定义与本质特征

边缘计算并非一个单一的技术,而是一种分布式的计算范式,其核心思想是将计算任务从集中式云数据中心推向网络的逻辑边缘——即靠近数据源或终端用户的位置。OpenEdge Computing 联盟将边缘计算定义为“在网络边缘执行计算任务的分布式计算架构”,其中“边缘”涵盖了从基站、网关、边缘服务器到智能终端设备的连续谱系。

与传统的云计算相比,边缘计算具有四个本质性特征:(1)低延迟——物理距离的缩短直接转化为信号传播时间的减少,使得端到端延迟可以压缩至毫秒甚至亚毫秒级别;(2)高带宽——边缘节点处理本地数据,仅将摘要或关键信息回传云端,显著降低了对骨干网带宽的占用;(3)位置感知——边缘节点天然知晓其所处的地理位置与网络拓扑,可以为位置敏感的应用提供上下文信息;(4)分布式弹性——边缘网络的去中心化架构使其在部分节点失效时仍能维持服务,具有天然的高可用性。

Madhumitha 等人对边缘计算的架构、算法与设备进行了全面综述[8],将边缘计算的演进划分为三个阶段:第一阶段(约2010-2015年)以内容分发网络(CDN)为代表,核心能力是静态内容的边缘缓存;第二阶段(约2015-2020年)以移动边缘计算(MEC)为代表,核心能力是计算任务的边缘卸载;第三阶段(2020年至今)以边缘智能(Edge Intelligence)为代表,核心能力是在边缘节点上部署与执行AI模型。游戏应用的需求与这一演进轨迹高度吻合:从游戏资源的边缘预加载,到游戏逻辑的边缘卸载,再到AI驱动的边缘游戏智能。

4.1.2 边缘计算的参考架构

边缘计算的参考架构通常采用分层模型,不同组织提出的架构在层次划分上略有差异,但核心逻辑是一致的:从中心到边缘再到终端,形成一个计算资源的连续谱系。

ETSI(欧洲电信标准化协会)提出的移动边缘计算(MEC)参考架构是业界最具影响力的标准之一。该架构将边缘计算系统划分为三个逻辑层次:(1)系统层——负责边缘节点的编排、应用的生命周期管理以及与云端的协同;(2)主机层——包含边缘平台与边缘应用,边缘平台提供服务注册、流量规则管理与DNS解析等基础能力,边缘应用则承载具体的业务逻辑;(3)网络层——负责边缘节点与终端、边缘节点与云端之间的连接管理。在这一架构中,游戏应用可以以边缘应用的形式部署在MEC主机上,利用平台层提供的无线网络信息API(如用户位置、无线信道质量)来优化渲染参数与编码策略。

OpenFog 联盟提出的雾计算参考架构(我们将在下一节详细讨论)与MEC架构在理念上高度一致,但在覆盖范围上更为广阔——雾计算将云到端之间的所有计算节点均纳入考量,而不仅限于移动网络的边缘。

Delicato 与 Desai 在EDGE 2023的程序主席报告中指出,边缘计算正在从“概念探索期”进入“工程落地期”[56]。报告统计了近年来边缘计算领域的论文发表趋势,发现关于边缘节点编排、边缘服务迁移与边缘-云协同的论文数量在2021-2023年间增长了超过200%。这一趋势表明,产业界对边缘计算的态度已经从“能不能做”转向了“怎么做更好”。EDGE 2023会议录收录的多篇论文涵盖了边缘计算在游戏、AR/VR、自动驾驶等低延迟场景中的最新研究成果,为边缘计算的工程化应用提供了丰富的案例参考[57][58]。

4.1.3 边缘节点的形态谱系

边缘节点并非单一形态,而是覆盖了从网络核心到终端设备的连续谱系。根据部署位置与计算能力的差异,边缘节点可以分为以下四种典型形态:

1. 基站边缘:将计算资源集成在5G gNB(基站)或4G eNB中,是最靠近无线接入网的边缘形态。基站边缘的优势在于可以访问无线网络的物理层信息(如信道状态、干扰水平),从而进行跨层优化。Kartsakli 等人提出的AI驱动边缘架构将轻量级推理引擎部署在基站侧,用于实时预测游戏流量的无线信道质量,并据此动态调整编码比特率与调制编码方案(MCS)[59]。实验表明,这种跨层优化将无线传输的丢包率降低了约35%。

2. 网关边缘:将计算资源部署在家庭网关、企业路由器或运营商边缘路由器上。网关边缘的优势在于部署

密度高——一个城市可能拥有数千个基站，但拥有数十万个宽带网关。Zhang 等人的移动 SoC 集群方案可视为网关边缘的一种实现形式：将数十个手机 SoC 集成在一个小型机箱内，部署在宽带网关附近，为周边用户提供云游戏渲染服务 [20][21]。

3. 边缘云：将小型数据中心部署在区域级别的网络汇聚点，覆盖范围约为一个区县或一个城市。边缘云的计算能力通常强于基站边缘与网关边缘，可承载更复杂的游戏逻辑与 AI 模型。Silva 等人针对 5G+ 网络中的游戏切片优化问题，提出了在边缘云中部署游戏服务实例的方案，通过端到端切片编排实现了游戏流量的服务质量保障 [60]。

4. 设备边缘：将部分计算任务卸载到终端设备本身，利用智能手机、智能眼镜或游戏手柄中的嵌入式处理器进行本地计算。设备边缘是距离用户最近的边缘形态，其优势在于零网络延迟，但计算能力受限。在云游戏场景中，设备边缘常用于执行帧外推、运动补偿等轻量级渲染后处理任务。

4.1.4 边缘计算在游戏场景的适配性分析

边缘计算的上述特征与游戏应用的需求高度匹配。从延迟敏感性的角度看，竞技类游戏（FPS、MOBA、RTS）对端到端延迟的要求通常在 30-50ms 以内，传统云计算难以满足，而边缘计算通过将游戏逻辑与渲染节点部署在距离用户 10-20 公里的范围内，可以将单向传输延迟控制在 5-10ms 以内。从带宽消耗的角度看，云游戏的下行视频流通常需要 25-50Mbps 的稳定带宽，若所有流量均汇聚至云端骨干网，将造成巨大的带宽压力；边缘节点的本地分流机制可以有效缓解这一压力。

从计算模式的角度看，游戏负载具有“计算密集 + 延迟敏感”的双重特征，这使其成为边缘计算的理想应用场景。与 IoT 场景中的轻量级数据处理不同，游戏边缘计算需要处理的是 GPU 密集型的渲染任务——这正是边缘节点面临的巨大挑战。Zhang 等人的研究证实，基于移动 SoC 的边缘服务器可以在可接受的功耗下完成这一任务 [20]，为游戏边缘计算的工程可行性提供了实证支撑。

4.2. 雾计算：概念、架构与定位

4.2.1 雾计算的定义与核心理念

雾计算（Fog Computing）的概念由思科公司于 2012 年首次提出，旨在描述一种将云计算能力延伸至网络边缘的分布式计算基础设施。“雾”这一命名的隐喻意义在于：雾比云更接近地面，正如雾计算比云计算更接近终端用户。与边缘计算相比，雾计算强调的是连续的计算连续体（Computing Continuum）——从云数据中心到边缘节点再到终端设备，计算资源呈现为一个连续的光谱，而非离散的层次。

OpenFog 联盟对雾计算给出了正式定义：“雾计算是一种系统级的水平架构，将计算、存储、控制和网络资源与服务分布在云到物连续体中的任何位置。”这一定义强调了雾计算的三个关键特征：（1）水平架构——雾计算节点可以部署在网络的不同层级，而非固定于某一特定位置；（2）系统级——雾计算涵盖从硬件到应用的全栈能力；（3）云到物连续体——雾计算将云端、边缘端与终端设备整合为统一的资源池。

Walia 等人的综述对 AI 赋能的雾/边缘资源管理进行了全面梳理，指出雾计算与边缘计算在学术文献中常被混用，但二者存在概念上的细微差异 [7][61]。边缘计算通常聚焦于网络边缘（如基站、网关），而雾计算的覆盖范围更广，可以延伸到终端设备本身。此外，雾计算更强调节点间的水平协作——雾节点之间可以直接通信与协调，而边缘节点通常需要经由云端进行协调。这一差异在多人在线游戏场景中具有重要意义：当同一虚拟世界中的玩家分布在不同边缘节点上时，雾节点之间的水平通信可以显著降低跨节点状态同步的延迟。

4.2.2 雾计算参考架构

OpenFog 联盟发布的雾计算参考架构是当前最具影响力的标准之一。该架构采用层次化设计，自下而上分为四个层级：

1. 物理与虚拟化层：位于架构最底层，涵盖各类物理设备（服务器、交换机、传感器、执行器）及其虚拟化抽象。在游戏场景中，这一层对应着边缘服务器、GPU 集群、网络交换机等硬件基础设施。虚拟化技术使得多个游戏实例可以安全地共享同一套物理资源。

2. 雾节点管理层：负责单个雾节点内部的资源管理，包括计算、存储与网络资源的调度与监控。该层还负责执行本地策略，如游戏会话的准入控制、渲染任务的优先级调度等。

3. 雾节点协作层：负责多个雾节点之间的协调通信，包括服务发现、状态同步、任务迁移与负载均衡。这一层是雾计算区别于纯边缘计算的核心所在。在多人在线游戏场景中，当玩家在不同地理区域间移动时，协作层负责将其游戏会话从源雾节点平滑迁移至目标雾节点，迁移过程中的状态同步与延迟补偿由该层协议保证。

4. 应用与服务层：承载具体的游戏业务逻辑，包括渲染服务、匹配服务、语音服务与数据统计服务等。应用层通过北向接口与云端交互，通过南向接口调用下层提供的资源与服务。

这一分层架构为游戏开发者提供了清晰的部署模型：游戏的核心逻辑可以运行在雾节点上，利用低延迟优势服务本地玩家；同时，雾节点之间通过水平接口实现跨域协同，支撑大规模分布式游戏世界；而云端则负责全局状态聚合、数据分析与长周期任务。

4.2.3 雾计算与边缘计算的对比分析

雾计算与边缘计算的区分在学术界和产业界均存在一定模糊性，部分文献将二者视为同义词。然而，从严谨的概念界定出发，二者在以下维度存在显著差异：

覆盖范围：边缘计算主要聚焦于网络边缘——即从基站到网关的区域；雾计算的覆盖范围更广，涵盖了从云端到终端设备的整个连续谱系。在游戏场景中，这意味着雾计算可以更好地支持端-边-云三级协同。

节点间协作：边缘计算架构中，边缘节点通常仅与云端通信，节点间的直接通信较少；雾计算则强调节点间的水平协作，雾节点可以形成对等网络，直接交换信息与协调动作。这一特性对于需要全局状态一致性的多人在线游戏至关重要。

抽象层次：边缘计算通常以“节点”为抽象单位，关注单个边缘节点的能力与限制；雾计算则提供更高的抽象层次，将“雾网络”视为一个整体资源池，屏蔽了底层节点的异构性。

协议栈：边缘计算多采用与云计算相同的协议栈（TCP/IP、HTTP/REST），以保持与云端的兼容性；雾计算则支持更丰富的协议选项，包括 MQTT、CoAP、AMQP 等物联网协议，以适应终端设备的多样性。

Sangaraju 等人的综述对雾计算的应用场景、安全挑战与解决方案进行了系统梳理，明确指出互动游戏是雾计算的重要应用领域之一 [62]。该综述指出，雾计算在游戏场景中的核心价值在于：（1）将游戏状态管理分布至多个雾节点，避免单点瓶颈；（2）利用雾节点的位置感知能力为玩家提供低延迟匹配服务；（3）在雾层聚合游戏数据，减轻云端存储与分析压力。

4.2.4 雾计算在游戏场景的独特价值

尽管边缘计算已经能够解决云游戏的延迟问题，雾计算在以下四个方面提供了独特的附加值：

1. 状态一致性的分布式保障：大型多人在线游戏（MMO）需要维护一个全局一致的游戏世界状态。在纯边缘架构中，不同边缘节点上的玩家实例各自维护本地状态副本，节点间的状态不一致可能导致游戏逻辑错误。雾计算的节点间协作机制通过分布式共识协议（如 RAFT、PBFT）维护状态一致性，为 MMO 游戏的边缘化部署提供了理论支撑。

2. 玩家移动时的会话连续性：当玩家在物理空间中移动时（如从家中通勤至办公室），其游戏会话需要从当前边缘节点迁移至更优的目标节点。雾计算的水平通信能力使得这种迁移可以在毫秒级完成，迁移过程中的状态打包、传输与恢复由雾节点协作层透明处理。Kim 等人的边缘负载均衡研究虽未明确使用“雾计算”这一术语，但其提出的动态会话迁移机制本质上属于雾计算的节点协作范畴 [10]。

3. 游戏数据的多层次聚合：游戏遥测数据（对局结果、玩家行为、经济流动）具有多尺度特征——秒级的数据用于实时反作弊检测，分钟级的数据用于动态难度调整，小时级的数据用于匹配算法优化，天级的数据用于游戏平衡性分析。雾计算的分层架构天然适配这种多尺度数据处理需求：雾节点在本地处理实时数据，仅将聚合后的统计量上报云端，大幅降低了对骨干网带宽的需求。

4. 异构边缘资源的统一调度：在雾计算框架下，基站边缘、网关边缘、边缘云与终端设备被视为统一的资源池，调度器可以根据任务特征将游戏组件动态放置到最优位置——延迟敏感的渲染任务放置于基站边缘，计算密集的 AI 推理任务放置于边缘云，轻量级的输入处理则保留在终端设备。Ghafari 等人综述了群体智能技术在雾/边缘计算中的应用，指出群体智能算法特别适合这种大规模、异构、动态的调度问题 [63]。

4.3. 边缘/雾计算的关键技术组件

4.3.1 资源调度与服务放置

边缘/雾计算环境下的资源调度面临的核心挑战是资源的异构性与任务的动态性。与同构的云数据中心不同，边缘节点的计算能力、存储容量、网络带宽与能耗约束差异悬殊——一个基站边缘节点可能仅有一颗 ARM CPU 与有限内存，而一个边缘云节点可能配备多颗 GPU 与 TB 级存储。调度算法需要在如此异构的资源池中，为游戏任务找到最优的放置位置。

Zhou 等人对边缘计算资源调度的历史演进、架构模型与方法论进行了系统性分析 [64]。该综述将边缘调度算法划分为四代：第一代基于简单启发式（轮询、随机、最不繁忙）；第二代基于经典运筹学方法（整数规划、动态规划）；第三代基于元启发式算法（遗传算法、粒子群优化、蚁群算法）；第四代基于机器学习（深度强化学习、图神经网络）。研究表明，第四代方法在动态性强的边缘环境中表现最优，但其训练开销与可解释性问题仍需进一步解决。

Imbien 提出的混合遗传算法与禁忌搜索（HGATS）是第三代方法的代表性工作，专门针对边缘云环境中的任务分配问题 [28]。该算法将遗传算法的全局搜索能力与禁忌搜索的局部爬山能力相结合：在遗传算法的每一代进化后，对最优个体执行禁忌搜索以进一步优化。在游戏任务分配场景的仿真中，HGATS 相比标准遗传算法将任务平均完成时间缩短了 18%，同时将资源利用率提升了 12%。该研究还发现，禁忌表长度的自适应调整对算法性能有显著影响，过短的禁忌表会导致循环搜索，过长的禁忌表则会限制搜索空间。

Deng 等人提出的 DRL 资源分配框架代表了第四代方法的典型范式 [24][65]。该框架将边缘云游戏系统中的虚拟机放置问题建模为 MDP，状态空间包括各边缘节点的资源使用率、待处理任务队列长度、当前用户数量以

及网络链路质量；动作空间为将新任务分配至特定边缘节点或决定在云端执行；奖励函数则综合了延迟满足率、资源利用效率与能耗三个目标。在包含 50 个边缘节点、1000 个并发游戏会话的仿真环境中，该 DRL 框架的平均奖励值比最优启发式算法高出 34%，且在不同负载模式下的表现方差更小。

4.3.2 服务迁移与状态同步

服务迁移是边缘/雾计算支持玩家移动性的关键技术。当玩家在不同地理区域间移动时，其游戏会话需要从源边缘节点迁移至更靠近新位置的目标节点。迁移过程的核心挑战在于：如何在保证服务不中断（或中断时间极短）的前提下，将游戏状态从源节点完整传输至目标节点。

游戏会话的迁移与虚拟机迁移在技术上有相似之处，但存在重要差异：游戏会话的状态量远小于虚拟机内存（通常为 MB 级而非 GB 级），但对迁移延迟的容忍度也远低于企业应用（毫秒级而非秒级）。这一特性使得游戏会话迁移可以采用“冻结-复制-恢复”的简单模型：源节点冻结游戏进程，将内存状态打包传输至目标节点，目标节点恢复游戏进程并接管网络连接。

Kim 等人的边缘负载均衡算法中的会话迁移模块采用了一种预测性迁移策略 [10]。该策略基于玩家的移动轨迹历史数据训练一个短时预测模型（采用 LSTM 架构），在玩家即将离开当前边缘节点覆盖范围时提前触发迁移。预测性迁移的关键优势在于：迁移可以在游戏空闲时刻（如对局结束、加载界面）进行，避免了对正在进行的对局造成干扰。实验表明，该策略将迁移过程中的感知中断时间从平均 380ms 降低至 45ms。

Chandola 的综述指出，游戏状态同步是分布式游戏系统的经典难题，在边缘/雾架构下这一挑战变得更加复杂 [1][66]。在传统客户端-服务器架构中，所有玩家连接至同一权威服务器，状态一致性由服务器串行处理保证。在边缘/雾架构中，不同玩家可能连接至不同边缘节点，跨节点的状态同步需要分布式共识协议的支持。该综述认为，采用“分片+局部权威”的混合模型是解决这一问题的可行路径：游戏世界被划分为多个分片，每个分片由一个边缘节点作为权威，分片间的状态交互通过边缘节点的水平通信完成。

4.3.3 5G/6G 与边缘计算的融合

第五代移动通信系统(5G)与边缘计算在架构设计上存在天然的互补关系。5G 核心网的用户平面功能 (UPF) 可以灵活下沉至网络边缘，使得基站能够将用户流量直接转发至本地边缘节点，无需绕经核心网。这种“本地分流”机制是 5G 边缘计算的基石。

Kartsakli 等人提出的 AI 驱动边缘架构充分利用了 5G 的这一特性 [59]。在该架构中，5G 基站内置了轻量级推理引擎，可实时分析无线信道的质量指标 (RSRP、SINR、CQI) 与游戏流量的 QoS 需求。基于分析结果，架构可以动态调整三个层面的参数：(1) 无线层面——调制编码方案 (MCS)、传输块大小、MIMO 层数；(2) 边缘层面——视频编码比特率、关键帧间隔、渲染分辨率；(3) 应用层面——游戏画质预设、特效开关。这种跨层联合优化将游戏体验的鲁棒性提升至新高度：当无线信道质量下降时，系统并非简单地降低画质，而是根据游戏场景的重要性（如团战时刻 vs. 跑图时刻）进行差异化处理。

Iacopino 等人对中国 5G 边缘计算市场的发展进行了深入分析 [53]。报告指出，截至 2023 年底，中国已建成超过 100 万个 5G 基站，运营商部署的边缘节点数量超过 5000 个，覆盖了所有地级市的核心城区。这一基础设施规模为云游戏的低延迟覆盖奠定了物理基础。报告还指出，中国移动、中国电信、中国联通均已推出基于边缘计算的云游戏服务，用户可以在 5G 网络下以低于 15ms 的端到端延迟体验 3A 级游戏。然而，报告也指出了当前面临的挑战：边缘节点的部署成本高昂（单节点投资约 50-100 万元），跨省漫游时的服务连续性仍有待改善。

Silva 等人的研究聚焦于 5G+ 网络中的游戏切片优化问题 [60]。5G 网络切片技术允许运营商在同一物理网络上创建多个逻辑隔离的虚拟网络，每个切片可以定制化的服务等级协议。该研究提出了一种端到端的游戏切片编排框架，将切片从终端设备经无线接入网、传输网、边缘云一直延伸至云端，确保游戏流量在全路径上享有优先调度权。在包含 1000 个 UE 的仿真实验中，采用游戏切片的用户在拥塞场景下的平均延迟仍能维持在 22ms，而未使用切片的用户延迟则飙升至 180ms 以上。

4.3.4 绿色边缘计算与能效优化

边缘计算在能效方面的优势是学术界与产业界的共识。这一优势源于三个因素的叠加：(1) 边缘节点通常采用低功耗处理器（如 ARM 架构），其每瓦特性能远高于 x86 架构；(2) 边缘节点可以利用现有机房与散热设施，避免了数据中心集中冷却的巨大能耗；(3) 边缘计算通过本地数据处理减少了长距离传输的网络设备能耗。

Spinelli 等人从绿色计算的视角深入分析了边缘游戏的能效潜力 [34][35]。该研究构建了一个包含传输能耗、计算能耗与冷却能耗的全生命周期能耗模型，并基于该模型对比了云游戏与边缘游戏在不同用户密度下的总能耗。研究发现，当用户密度高于每平方公里 10 人时，边缘游戏的总能耗低于云游戏；当用户密度高于每平方公里 100 人时，边缘游戏的能效优势可达 60% 以上。这一发现具有重要的政策含义：在人口密集的城市地区，边缘游戏不仅提供更好的用户体验，还具有显著的环保效益。

Zhang 等人对基于移动 SoC 的边缘服务器 (SFG) 的能效进行了实测分析 [36][21]。测试结果表明，SFG 在运行移动云游戏时的能效比（每瓦特每秒处理的帧数）达到 3.7 FPS/W，而传统 x86 服务器的能效比仅为 1.0

FPS/W。SFG 的能效优势主要来自三个方面：移动 SoC 的先进制程（4nm vs. 数据中心的 7nm），异构计算架构（大小核+NPU 的精细化调度），以及无散热风扇的被动冷却设计（消除风扇能耗）。该研究还发现，SFG 在低负载时可以将空闲核心完全关闭，待机功耗仅为 0.5W，而 x86 服务器的待机功耗通常超过 30W。

Kumbhar 提出了在移动边缘计算中降低成本的资源管理策略，其核心思想是将能效作为调度决策的首要考量 [67]。该研究提出的 ECOS（Energy-Cost Optimized Scheduler）算法将任务的计算强度、延迟约束与边缘节点的实时电价、碳排放因子作为输入，通过求解一个多目标优化问题决定任务的放置位置。在游戏渲染任务场景的仿真中，ECOS 相比传统的延迟优先调度，将总成本降低了 28%，碳排放降低了 35%，同时将延迟违约率控制在可接受范围内（<5%）。

4.4. 边缘/雾计算在游戏中的典型应用场景

4.4.1 云游戏渲染的边缘卸载

边缘渲染是边缘计算在游戏领域最直接的应用形态。其核心逻辑是：将游戏渲染任务从远程云数据中心迁移至靠近用户的边缘节点，从而显著降低端到端延迟。Kang 等人提出的 E-Render 架构是这一方向的代表性工作 [9]。在该架构中，云端维护游戏全局状态的权威副本，负责处理玩家间交互、经济系统等跨会话逻辑；边缘节点则根据本地玩家的视角进行差异化渲染。当玩家的视角发生变化时（如转动镜头），边缘节点仅需重新渲染当前帧，无需与云端交互，从而大幅降低了对骨干网带宽的依赖。

Zhang 等人对基于移动 SoC 的边缘渲染服务器进行了全面的性能评估 [20][21]。该研究构建了一个包含 256 个手机 SoC 芯片的边缘服务器原型（SFG），并测试了其在多路并发云游戏场景下的性能表现。结果显示，SFG 在同时服务 64 路云游戏流时，平均帧率稳定在 60fps，帧渲染时间的标准差仅为 2.3ms，表现出优异的性能一致性。该研究还发现，SFG 的性能瓶颈不在于 GPU 算力，而在于内存带宽——当并发流数超过 64 时，多路流对 DRAM 的竞争导致帧渲染时间的抖动显著增大。

Proenca 在其研究中讨论了虚拟化技术在云游戏多服务部署中的应用 [19]。该研究指出，在边缘节点上同时部署多个游戏服务（如渲染、编码、匹配、语音）时，需要精细化的资源隔离机制来避免服务间的相互干扰。传统的基于虚拟机的隔离方案虽然隔离性好，但开销较大；基于容器的隔离方案开销小，但共享内核可能导致“吵闹邻居”问题。该研究提出的混合方案将关键服务（渲染）部署在专用核心上并绑定 CPU 亲和性，将非关键服务（匹配、语音）部署在共享核心上，在隔离性与资源利用率之间取得了平衡。

4.4.2 多人游戏的状态同步与一致性保障

多人在线游戏的状态同步是分布式系统领域的经典难题。在传统架构中，所有玩家连接至同一权威服务器，服务器以固定频率（通常为 20-60Hz）向所有客户端广播状态更新。这种架构简单可靠，但存在单点瓶颈与延迟放大问题——离服务器地理距离越远的玩家，其状态更新的延迟越大。

边缘/雾架构为多人游戏的状态同步提供了新的解决方案。其核心思想是：将游戏世界划分为多个区域（分片），每个区域由一个边缘节点作为权威；玩家的状态更新仅需与所在区域的权威节点交互；跨区域的交互（如不同区域玩家间的战斗）则通过边缘节点的水平通信协调。这种分片架构将状态同步的范围从“全局”缩小为“区域”，显著降低了权威节点的负载与跨玩家的通信延迟。

Li 等人的研究对分片策略在 MMO 游戏服务器中的应用进行了系统分析 [16]。该研究对比了三种分片策略：水平分片（将游戏世界划分为网格状区域，每个区域独立运行）、垂直分片（按游戏系统拆分，如战斗系统、经济系统、社交系统分别部署在不同服务器）与功能分片（按玩家类型拆分，如 PVE 玩家与 PVP 玩家使用不同服务器）。仿真结果表明，对于典型的 MMO 游戏负载，功能分片在延迟与吞吐量的综合表现上最优，但其分片边界的动态调整最为复杂。

Das 在其学位论文中讨论了游戏服务器的可扩展性测试自动化框架 [68]。该框架可以模拟数万名虚拟玩家的行为，对分布式游戏服务器集群进行压力测试，评估其在极端负载下的状态同步延迟与一致性表现。该研究发现，在边缘/雾架构下，状态同步的主要瓶颈不再是服务器的处理能力，而是边缘节点间的网络延迟与共识协议的开销。当跨边缘节点的状态交互频率超过一定阈值时，共识协议本身就可能成为新的瓶颈。

4.4.3 游戏 AI 的边缘推理

游戏 AI 的实时推理是边缘计算的另一重要应用场景。传统上，游戏 AI（如 NPC 行为决策、动态难度调整、对战机器人）运行在云端或客户端，前者延迟高，后者受限于终端算力。边缘计算提供了第三种路径：在靠近玩家的边缘节点上部署 AI 推理引擎，既保证低延迟，又可利用边缘节点的加速硬件（如 NPU、TPU）。

Alsalemi 等人以数据分类为案例，探讨了在边缘设备上部署深度学习的可行性与优化策略 [69]。虽然该研究的原始场景是 IoT 数据分类，但其提出的模型压缩方法（量化、剪枝、知识蒸馏）同样适用于游戏 AI 的边缘部署。该研究发现，经过 8 比特量化后的神经网络模型，其推理精度损失通常小于 1%，但模型体积可压缩至原来的 1/4，推理速度可提升 3-5 倍。这一发现对游戏 AI 的边缘部署具有重要意义：在资源受限的边缘节点上，量化模型可能是唯一可行的选择。

Li 等人从理论层面探讨了混合专家模型（MoE）在移动边缘计算中的应用 [38]。MoE 模型由多个专家网络和一个门控网络组成，门控网络根据输入样本的特征动态选择部分专家进行推理。在游戏 AI 场景中，这意味着边缘节点可以根据当前游戏状态（如对局阶段、地图区域、敌方阵容）选择性地加载 NPC 行为模型，而非加载所有模型。该研究证明，在专家数量为 N 、每次激活 k 个专家的条件下，MoE 模型的计算复杂度为 $O(k \cdot C)$ ，而传统模型的复杂度为 $O(N \cdot C)$ ，其中 C 为单个专家的计算量。当 N 较大时，MoE 可以带来数量级的计算节省。

Gao 等人提出的 GameDRL 框架不仅用于资源调度，也可用于游戏 AI 模型的边缘部署 [26]。该框架通过分析游戏负载的模式（如高峰时段、周末效应），预测 AI 推理请求的到达模式，并据此动态调整边缘节点上 AI 模型的副本数量与放置位置。在《王者荣耀》类 MOBA 游戏的 AI 对战场景中，GameDRL 将 AI 推理的平均延迟从云端的 65ms 降低至边缘的 22ms，同时将 AI 服务的可用性提升至 99.95%。

4.4.4 AR/VR 的边缘渲染与协作

增强现实（AR）与虚拟现实（VR）对延迟的要求比传统云游戏更为严苛。根据 IAFI 的工作文件，沉浸式 VR 应用的运动到光子延迟需要控制在 5-10 毫秒以内，否则用户将产生明显的晕动症状 [42]。这一要求使得 VR 渲染几乎不可能完全依赖集中式云端——即使是光速，从用户到 1000 公里外的数据中心也需要约 7ms 的单向传播时间，这还没有计入处理与编码延迟。

边缘计算为 VR 云渲染提供了技术可行性。Choudhury 在其博士论文中描绘了通过移动网络在边缘云上实现 VR 远程渲染的系统架构 [48]。该架构将 VR 渲染任务分解为三个层次：云端负责全局光照与复杂物理模拟（这些任务对延迟不敏感，但对算力要求高）；边缘云负责视角相关的渲染与预测生成（需要低延迟响应，但计算量适中）；终端负责异步时间扭曲（ATW）与空间扭曲等帧外推操作（零延迟，但能力有限）。这种三层分解使得系统能够在网络波动时保持稳定的感知帧率。

Rossi 等人针对移动网络环境下的云端 VR 第一人称射击游戏建立了 QoE 评估模型 [13][44]。通过受控实验，该研究确定了 VR 云游戏的关键 QoE 阈值：端到端延迟低于 20ms 时，用户报告“完全沉浸”；延迟在 20-35ms 时，用户报告“轻微不适”；延迟在 35-50ms 时，用户报告“明显不适”；延迟超过 50ms 时，超过 70% 的用户报告“无法继续游戏”。这一发现表明，VR 云游戏的延迟要求比传统云游戏严格一个数量级，这进一步强化了边缘计算在 VR 场景中的必要性。

Mejías 等人对远程 VR 渲染中的多媒体框架与协议进行了性能对比 [47]。该研究特别关注了边缘部署场景，比较了在边缘节点与终端距离 50km 的条件下各方案的表现。结果显示，使用边缘节点的方案相比使用云端数据中心（距离 500km）的方案，端到端延迟从 82ms 降低至 28ms，用户的晕动症状评分从 3.8（中度）降低至 1.6（轻度）。该研究还发现，WebRTC 协议在边缘 VR 场景下表现优异，其内置的自适应比特率算法能够较好地应对移动网络的信道波动。

4.5. 边缘/雾计算面临的挑战与局限

尽管边缘/雾计算在游戏场景中展现出显著优势，其大规模部署仍面临多重挑战。这些挑战涉及技术、经济、安全与监管等多个维度。

4.5.1 资源异构性与管理复杂度

边缘/雾计算环境由大量异构节点组成——从微型物联网设备到配备 GPU 的边缘服务器，节点间的计算能力、存储容量、网络带宽与能耗特征差异悬殊。这种异构性使得统一的资源管理与任务调度极为复杂。Zhou 等人的综述指出，传统的云调度算法假设资源池是同构的，这一假设在边缘环境中不再成立 [64]。

更棘手的是，边缘节点的可用资源具有时空动态性——不仅受限于节点的物理容量，还受到网络连接质量、供电稳定性与散热条件等因素的影响。Kumbhar 的研究发现，在夏季高温时段，部分室外部署的边缘节点因散热限制而被迫降频，可用算力下降可达 40% [67]。调度算法需要实时感知这种动态性并做出相应调整，这对系统的监控与反馈能力提出了极高要求。

4.5.2 服务迁移的连续性保障

当玩家在物理空间中移动时，其游戏会话需要在边缘节点间迁移。尽管 Kim 等人的预测性迁移策略已经将感知中断时间压缩至 45ms [10]，但对于快节奏的竞技游戏而言，45ms 的中断仍然可能被玩家感知。更重要的是，迁移过程中的状态一致性保障是一个尚未完全解决的问题——如果迁移过程中源节点与目标节点间出现状态分歧，可能导致游戏逻辑错误（如玩家位置跳变、血量不一致）。

Patel 等人的研究探讨了分布式事务在云游戏平台中的实现，提出了两阶段提交的优化协议（2PC+）来确保玩家资产和游戏状态的一致性 [70]。该协议通过引入超时机制与补偿事务，将传统两阶段提交的阻塞时间从秒级缩短至毫秒级。然而，该协议在网络分区场景下仍面临可用性与一致性的经典权衡——在边缘网络这种高度动态的环境中，网络分区是常态而非异常。

4.5.3 安全与隐私风险

边缘/雾计算将计算资源部署在靠近用户的位置，这既带来了低延迟的优势，也引入了新的安全风险。与高度受控的云数据中心相比，边缘节点通常部署在物理上可访问的位置（如基站、路边机柜），面临更高的物理篡改风险。一个被攻破的边缘节点可能导致其服务范围内的所有玩家的数据泄露。

Ravichandran 与 Kababiito 分别从不同角度探讨了数字游戏的合规性与监管挑战 [54][55]。在边缘计算架构下，玩家数据可能存储在处理地所在的国家或地区，这引发了数据主权与跨境数据流动的合规问题。例如，一个在欧洲的玩家连接到位于本地的边缘节点，但其游戏会话的状态可能通过节点协作机制同步至位于其他国家的节点，这一过程需要符合 GDPR 等数据保护法规的要求。

Kumar 等人对移动云游戏的安全威胁进行了深入分析，指出边缘计算环境下的侧信道攻击风险不容忽视 [22]。在共享物理主机的多租户环境中，恶意租户可能通过 CPU 缓存时序攻击推断邻近租户的游戏状态。该研究提出的防御方案是将同一游戏会话的不同组件（渲染、编码、网络）部署在隔离的物理核心上，避免它们与不可信租户共享缓存。

4.5.4 成本效益与商业可行性

边缘/雾计算的部署成本是制约其大规模推广的核心经济因素。Iacopino 等人的报告指出，单边缘节点的部署投资约为 50-100 万元人民币，包括硬件采购、机房改造、网络接入与运维系统 [53]。以一个中等城市部署 100 个边缘节点估算，初始投资即达到 5000 万至 1 亿元。考虑到游戏行业的季节性波动（新游戏发布时的峰值负载远高于日常），边缘节点的利用率可能长期处于低位，导致投资回报周期过长。

Kumbhar 提出的成本优化调度算法试图通过将非游戏负载（如视频转码、数据分析）引入边缘节点来提高资源利用率 [67]。该算法根据各任务的延迟敏感度与计算特征，将游戏渲染任务优先调度至低延迟边缘节点，将批处理任务调度至利用率较低的节点。仿真表明，这种混合负载调度可以将边缘节点的平均利用率从 35% 提升至 62%，显著改善了成本效益。

4.6. 本章小结

边缘计算与雾计算作为云计算的延伸范式，为游戏应用提供了低延迟、高带宽、位置感知与分布式弹性的技术能力。本章从概念界定出发，系统阐述了边缘计算与雾计算的核心定义、参考架构与关键特征，分析了二者在覆盖范围、节点协作与抽象层次上的差异与联系。在关键技术层面，本章详细讨论了资源调度与服务放置、服务迁移与状态同步、5G/6G 融合以及绿色边缘计算等核心组件的研究进展。在应用场景层面，本章从云游戏渲染卸载、多人游戏状态同步、游戏 AI 边缘推理与 AR/VR 边缘渲染四个维度，展示了边缘/雾计算在游戏领域的工程实践。最后，本章分析了资源异构性、服务连续性、安全隐私与成本效益等当前面临的挑战。边缘/雾计算与游戏的深度融合，正在将分布式游戏系统的技术边界从“云-端”两极扩展为“云-边-端”三级连续体，为下一代沉浸式游戏体验奠定计算基础设施。

五、分布式游戏服务器架构的演进

边缘计算与雾计算将计算资源推向网络边缘，为云游戏和实时交互应用提供了低延迟的基础设施。然而，一个完整的游戏系统不仅需要渲染层的边缘化，还需要后端服务器架构的分布式重构。从早期的单服务器架构到现代的多层分布式集群，从无状态 Web 服务到有状态游戏会话管理，从单体应用到微服务与 Serverless 范式，游戏服务器架构的演进始终围绕着可扩展性、高可用性、低延迟与成本效益四个核心目标展开。本节将从架构演进的视角，系统梳理分布式游戏服务器架构的设计理念、关键技术、工程实践与未来趋势。

5.1. 游戏服务器架构的历史演进脉络

5.1.1 第一代：单服务器架构

在互联网游戏发展的早期阶段（约 1995-2005 年），游戏服务器架构呈现出极为简单的形态：一台物理服务器同时承担游戏逻辑运算、玩家连接管理、数据持久化与网络通信等全部职能。玩家客户端通过 TCP/UDP 直连至服务器 IP 地址，服务器维护所有玩家的状态并在每个逻辑帧进行更新。

Zhang 等人对分布式实时游戏服务器集群架构的研究指出，单服务器架构的核心瓶颈在于三个方面 [71]：（1）计算瓶颈——单个 CPU 的处理能力有限，当同时在线玩家数超过一定阈值（通常为 1000-2000 人）时，服务器的逻辑帧率将无法维持；（2）网络瓶颈——单块网卡的带宽与连接数有限，数千个并发连接的报文处理会耗尽系统资源；（3）可用性瓶颈——单服务器无冗余设计，任何硬件故障或软件崩溃都将导致整个游戏服务不可用。

Fu 等人详细介绍了基于集群技术的分布式多层大型网络游戏平台架构，其中对早期单服务器架构的局限性进行了量化分析 [72]。该研究发现，在单服务器架构下，当同时在线玩家数达到 1500 人时，服务器的 CPU 占用

率已接近 100%，网络中断（掉线）的发生概率随玩家数增长呈超线性增长，在 2000 人时达到每小时约 15 次。这一发现揭示了单服务器架构的根本性不可扩展问题。

尽管存在诸多局限，单服务器架构在特定场景下仍有其价值：对于小型独立游戏、内部测试环境或低并发应用，单服务器的简单性使其成为快速原型验证的首选。Vogels 在其关于实时多用户互联网游戏服务器可扩展性的研究中指出，单服务器架构的简单性本身就是一种优势——没有分布式一致性问题、没有跨节点通信开销、调试与运维极为简便 [73]。

5.1.2 第二代：分布式集群架构

为了突破单服务器的性能瓶颈，游戏开发者开始引入分布式集群架构（约 2005-2015 年）。其核心思想是：将单一服务器拆解为多个协同工作的服务器节点，每个节点承担特定的职能，节点间通过网络通信协调工作。

Fu 等人的工作是这一时期的代表性成果 [72]。该研究提出并实现了一种基于集群技术的分布式多层网络游戏平台架构，包含三个逻辑层次：（1）接入层——由多台网关服务器组成，负责玩家连接的接入、负载均衡与报文转发；（2）逻辑层——由多台游戏逻辑服务器组成，每个服务器承载一个独立的游戏世界实例（或称“游戏房间”、“游戏分线”）；（3）数据层——由数据库服务器集群组成，负责玩家数据、游戏状态与日志的持久化存储。这一三层架构在 2008 年的实际部署中成功支持了超过 20000 人同时在线，将单服务器的容量提升了十倍以上。

White 在其技术博客中对网络游戏服务器的三种结构类型进行了系统总结 [74]：（1）单服务器结构——最简单，适用于小型应用；（2）多服务器结构——通过功能拆分将不同模块部署在不同服务器上，如登录服务器、游戏服务器、聊天服务器各自独立；（3）分布式结构——进一步将单一游戏服务器拆分为多个进程，每个进程负责游戏世界的一个子区域。White 的研究还深入探讨了关键技术实现，包括自定义通信协议、IOCP（完成端口）机制与多线程并发模型。

Zelkovitz 在《Advances in Computers》的综述章节中介绍了使用服务器集群维护游戏状态和管理玩家交互的通用模式 [75]。该综述指出，分布式集群架构的核心挑战在于状态共享：在单服务器架构中，所有玩家状态存储在本地内存中，访问速度极快；在集群架构中，玩家状态可能分布在不同服务器上，跨节点的状态访问需要通过网络通信完成，其延迟比本地内存访问高出数个数量级。为应对这一挑战，研究者提出了“数据本地化”原则——将相互频繁交互的玩家（如同公会成员、同地图玩家）分配到同一服务器节点，以最小化跨节点通信。

5.1.3 第三代：面向服务的架构与微服务化

随着云计算技术的成熟和游戏复杂度的持续提升，面向服务的架构（SOA）和微服务架构开始进入游戏服务器设计领域（约 2015-2020 年）。与传统的多层集群架构不同，微服务架构将游戏后端拆解为一系列小型、独立部署的服务，每个服务聚焦于单一业务能力，服务间通过轻量级通信协议（HTTP/REST、gRPC、消息队列）进行交互。

Liu 等人的研究将微服务架构引入实时多人游戏系统，提出了一个基于 Service Mesh 的服务治理框架 [15]。该研究将传统单体游戏后端拆分为七个独立的微服务：（1）匹配服务（Matchmaking）——负责根据玩家段位、延迟与偏好进行对局匹配；（2）聊天服务（Chat）——处理玩家间的文字与语音消息；（3）物理服务（Physics）——负责游戏世界中的碰撞检测与物理模拟；（4）AI 服务——控制 NPC 的行为决策；（5）经济服务（Economy）——管理虚拟货币、道具交易与商城系统；（6）社交服务（Social）——处理好友关系、公会系统与成就系统；（7）数据服务（Data）——负责游戏遥测数据的采集与分析。这些服务使用 Kubernetes 进行编排，通过 Istio 实现服务发现、负载均衡与熔断保护。在 100 万并发用户的压力测试中，微服务架构相比单体架构将故障影响范围缩小了 90%——当一个服务崩溃时，仅影响该服务对应的功能，其他服务仍可正常运行。

微服务架构在游戏领域的推广并非一帆风顺。Wei 在其研究中深入探讨了分布式事务在游戏服务器集群中的应用，指出微服务架构下的事务一致性问题是最大的技术障碍 [76]。在单体架构中，多个数据库操作可以封装在一个 ACID 事务中，保证原子性；在微服务架构中，一个业务流程（如玩家购买道具）可能涉及经济服务、库存服务与成就服务，需要分布式事务来保证一致性。该研究提出的解决方案是采用 SAGA 模式：将长事务拆解为一系列本地事务，每个本地事务提交后触发下一个事务，若中间步骤失败则执行补偿操作。在游戏道具购买场景中，SAGA 模式将事务完成时间从分布式两阶段提交的 850ms 缩短至 120ms，显著改善了用户体验。

5.1.4 第四代：Serverless 与事件驱动架构

Serverless 计算（也称函数即服务，FaaS）是云计算的最新范式，其核心理念是让开发者完全无需关心服务器管理，仅需编写函数粒度的代码，由云平台自动处理弹性伸缩、负载均衡与计费。Huang 等人的研究首次将 Serverless 架构引入大型多人在线游戏，提出了一套基于云函数的 MMO 架构方案 [14]。

该方案将游戏后端的各个功能模块拆解为独立的云函数：（1）玩家登录时触发认证函数；（2）匹配请求触发匹配函数；（3）对局结束时触发结算函数；（4）玩家升级触发成就函数。这些云函数由 API 网关按需触发，执行完毕后自动销毁，不占用任何常驻资源。在负载高峰时段（如新版本发布、周末晚间），云平台自动增加函数实例数量以应对流量冲击；在负载低谷时段，实例数量自动缩减至零，实现真正的“零闲置成本”。该研究在 AWS Lambda 上的实测表明，Serverless 架构相比传统的常驻服务器架构，将月均计算成本降低了约 65%，同时

将峰值负载的扩容时间从分钟级缩短至秒级。

然而，Serverless 架构在游戏场景中也有其局限性。云函数的执行时间通常被限制在 15 分钟以内（AWS Lambda 的限制），且冷启动延迟（从调用请求到函数实例就绪的时间）可能达到数百毫秒。对于延迟敏感的实时游戏逻辑（如战斗计算、物理模拟），云函数并不是合适的执行环境。Huang 等人的研究提出了一种混合方案：将延迟敏感的核心游戏逻辑保留在常驻容器中，将延迟不敏感的外围功能（匹配、结算、排行榜）迁移至云函数，在成本与性能之间取得平衡。

5.2. 分布式架构的关键设计维度

5.2.1 有状态与无状态服务的分离

在游戏服务器架构中，一个根本性的设计选择是：哪些服务需要维护状态，哪些服务可以设计为无状态。无状态服务不保存任何客户端相关的数据，每个请求可以路由到任意服务实例处理，因此具有完美的水平可扩展性。有状态服务则需要维护会话状态、游戏世界状态或玩家数据，请求必须路由到持有相应状态的特定实例，扩展性受限于状态迁移的复杂度。

Li 等人对分布式服务器架构的分析指出，游戏系统中的大多数服务可以设计为无状态 [77]。匹配服务、排行榜服务、商城服务、聊天服务（不考虑消息历史）均为天然的无状态服务——每个请求独立处理，无需记住之前的交互。而游戏逻辑服务（维护游戏世界状态）和会话管理服务（维护玩家连接状态）则必须是有状态的。

该研究提出了一种“状态-逻辑分离”的架构模式：将有状态的核心游戏逻辑与无状态的外围服务分离部署，核心逻辑使用少量高性能实例运行，外围服务则可任意扩展。在《英雄联盟》类 MOBA 游戏的架构设计中，每一局游戏的战斗逻辑运行在专用的游戏服务器实例上，实例的生命周期与对局生命周期绑定；而匹配、结算、好友、商城等功能则由无状态服务集群处理。这种设计既保证了核心战斗的低延迟与状态一致性，又实现了外围功能的无缝扩展。

5.2.2 分片策略与数据分布

分片（Sharding）是分布式系统中实现水平扩展的核心技术。其基本思想是：将数据集合划分为多个子集（分片），每个分片独立存储和处理，由不同的服务器节点负责。在游戏场景中，分片策略的选择直接影响系统的负载均衡效果与跨分片通信的开销。

Li 等人的研究系统性地分析了不同的分片策略在 MMO 游戏服务器中的应用 [16]，将分片策略归纳为三种典型模式：

水平分片（Horizontal Sharding）：将游戏世界按地理区域划分为网格状的分片，每个分片对应地图上的一个连续区域。玩家在其所在区域内的所有交互由该分片的服务器负责；当玩家跨越区域边界时，其会话状态从源分片迁移至目标分片。水平分片的优势在于数据本地性好——同一区域的玩家间交互无需跨分片通信。其劣势在于分片边界的负载可能不均匀（主城区域的人口密度远高于野外），以及跨边界移动时的状态迁移开销。

垂直分片（Vertical Sharding）：按游戏系统进行拆分，将不同系统（战斗系统、经济系统、社交系统）的玩家数据存储在不同服务器上。垂直分片的优势在于系统间的隔离性好——经济系统的负载峰值不会影响战斗系统的性能。其劣势在于单个玩家的一次操作可能涉及多个系统（如战斗胜利后获得金币），需要跨分片的事务来保证一致性。

功能分片（Functional Sharding）：按玩家类型或游戏模式进行拆分，将 PVE 玩家与 PVP 玩家、休闲玩家与竞技玩家分配到不同的分片。功能分片的优势在于可以根据不同玩家群体的行为特征进行针对性优化——竞技玩家对延迟更敏感，应分配至高性能节点；休闲玩家对成本更敏感，可分配至低配节点。其劣势在于分片边界的动态调整最为复杂——当玩家切换游戏模式时，需要在分片间迁移状态。

该研究的仿真结果表明，对于典型的 MMO 游戏负载，功能分片在延迟与吞吐量的综合表现上最优，但其实现复杂度也最高。水平分片在开放世界 MMO 中表现良好，但在主题公园式 MMO（玩家集中在少数区域）中表现不佳。垂直分片在系统间耦合度低的设计中可行，但在战斗与经济高度耦合的游戏中面临严峻的一致性挑战。

5.2.3 负载均衡与流量分发

负载均衡是分布式系统的核心控制平面，其目标是将请求均匀分发至后端服务实例，避免部分实例过载而其他实例空闲。在游戏场景中，负载均衡面临两个独特挑战：（1）有状态服务的请求必须路由至持有相应状态的特定实例，不能随意分发；（2）游戏流量的突发性远高于传统 Web 服务，负载均衡器需要快速响应负载变化。

Kim 等人提出的边缘负载均衡算法专门针对实时多人游戏场景设计 [10]。该算法综合考量三个维度的因素：玩家的地理位置（选择最近的边缘节点以最小化延迟）、节点的当前负载（避免将玩家分配至过载节点）以及节点间的会话迁移成本（尽量避免频繁迁移）。算法的核心是一个在线决策模型，在玩家发起连接请求时实时计算最优分配方案。在包含 200 个边缘节点、10000 名模拟玩家的仿真中，该算法将平均端到端延迟控制在 28ms 以内，同时将节点间的负载差异控制在 15% 以下。

Kumar 等人提出的混合云-边缘集群管理框架（HCCM）进一步将负载均衡的视角从单层扩展至多层 [78]。该框架使用统一的调度层管理云端数据中心、边缘云节点与基站边缘节点的三层资源，根据任务的延迟敏感度与计算强度进行分层调度：延迟敏感的任务（渲染、输入处理）优先分配至基站边缘；计算密集但对延迟有一定容忍度的任务（AI 推理、数据分析）分配至边缘云；批处理任务（日志聚合、离线训练）则分配至云端。这种分层调度将云端与边缘的资源利用率分别提升了 22% 与 18%。

5.2.4 数据一致性与分布式事务

在分布式游戏系统中，数据一致性是最具挑战性的问题之一。当玩家状态、游戏世界状态或经济数据分布在多个节点上时，任何节点间的状态不一致都可能导致游戏逻辑错误或经济系统漏洞。

Patel 等人的研究深入探讨了分布式事务在云游戏平台中的实现，提出了基于两阶段提交的优化协议（2PC+）来确保玩家资产和游戏状态的一致性 [70]。传统两阶段提交协议（2PC）的核心问题是协调者单点故障时的阻塞——如果协调者在第二阶段开始前崩溃，所有参与者将一直等待直到协调者恢复。2PC+ 通过引入超时机制与补偿事务解决了这一问题：当参与者等待协调者超过设定阈值时，主动查询协调者状态或向备份协调者请求决策，从而将阻塞时间从分钟级缩短至毫秒级。

Wei 的研究从另一个角度探讨了分布式事务问题，提出了“最终一致性 + 业务补偿”的设计哲学 [76]。该研究指出，游戏场景中的许多操作并不需要强一致性——例如，排行榜更新延迟几秒钟、好友状态显示不实时，对玩家体验的影响微乎其微。对于这类场景，采用最终一致性模型可以大幅简化系统设计。对于确实需要强一致性的场景（如道具交易、货币转账），则使用 2PC+ 或 SAGA 模式保证事务原子性。这种“混合一致性”策略在保证核心业务正确性的前提下，将系统复杂度控制在了可接受范围内。

5.3. 高可用与容灾设计

5.3.1 主备切换与故障转移

高可用性是游戏服务器架构的核心设计要求。对于商业游戏而言，服务不可用直接意味着收入损失与用户流失。传统的高可用方案采用主备模式：主服务器处理所有请求，备服务器处于热备状态，实时同步主服务器的状态；当主服务器故障时，备服务器接管服务。

Nakamura 等人提出了一套跨地域容灾方案（Geo-DR），利用全局分布式事务日志实现了无缝的玩家会话切换 [17]。该方案的核心创新在于“日志先行”原则：所有状态变更首先写入分布式的预写日志（WAL），日志在多个可用区的节点间同步复制后，才实际应用至状态存储。当主节点故障时，任一备节点可以通过重放日志恢复最新状态，从而实现 RTO（恢复时间目标）小于 30 秒、RPO（恢复点目标）为 0。该方案在《最终幻想 XIV》类 MMO 游戏架构中的模拟测试表明，即使整个可用区完全损毁，系统也能在 60 秒内恢复服务，数据零丢失。

5.3.2 无状态设计的可用性优势

无状态服务在可用性方面具有天然优势：由于服务实例不保存任何状态，当某个实例故障时，负载均衡器只需将后续请求转发至其他健康实例即可，无需任何状态恢复过程。这种“故障即剔除”的模型使得无状态服务可以实现极高的可用性（理论上可达 99.999% 以上）。

Li 等人的研究指出，在游戏架构设计中，应尽可能将有状态服务的范围缩小至最小必要集合 [77]。在理想情况下，只有正在进行的对局实例是有状态的，其他所有服务（匹配、社交、商城、数据）均可设计为无状态。这意味着即使整个匹配服务集群完全崩溃，正在进行的对局不会受到影响；当匹配服务恢复后，新玩家可以继续匹配。这种设计将故障的爆炸半径限制在最小范围。

5.4. 网络协议优化与实时通信

5.4.1 从 TCP 到 UDP 再到 QUIC

游戏实时通信对网络协议的选择极为敏感。TCP 提供了可靠的、有序的字节流传输，但其拥塞控制与重传机制在面对丢包时可能导致显著的延迟增加——一个丢包可能阻塞后续所有数据的传输，直到重传完成。UDP 则提供了不可靠的、无序的数据报传输，不保证交付也不保证顺序，但也不会因丢包而阻塞。

Chen 等人针对 FPS 游戏中的高频交互，提出了基于 UDP 的可靠传输扩展（RUDP）[79]。RUDP 在 UDP 之上实现了选择性的可靠性：对于关键消息（如玩家位置、射击事件），使用确认与重传机制保证可靠交付；对于非关键消息（如聊天文字、非战斗动画），允许丢失。RUDP 的另一个创新是“带外 ACK”机制——确认消息通过独立的 UDP 端口发送，避免与数据流竞争发送队列。在《守望先锋》类 FPS 游戏的网络仿真中，RUDP 将丢包恢复延迟从 TCP 的 150ms（等待重传超时）降低至 15ms（立即重传），显著改善了丢包场景下的游戏体验。

Jiang 等人将网络编码技术引入多人游戏消息传输 [80]。网络编码的核心思想是：中间节点不仅转发原始数据包，还可以对多个数据包进行线性组合后转发，接收方收到足够多的组合包后即可解码出原始数据。在游戏广播场景（如一个玩家向周围所有玩家广播位置更新）中，网络编码可以将冗余传输减少 50% 以上。该研究在

《绝地求生》类游戏的网络模型上的仿真表明，网络编码将广播型消息的带宽消耗降低了 58%，同时在网络拥塞期间将感知延迟降低了 32%。

5.4.2 P2P 与混合架构

中心化服务器架构虽然简单可靠，但在带宽成本上面临压力——所有玩家流量的汇聚意味着服务器需要处理海量数据。Zhang 等人提出了一种混合 P2P 与中心化服务器的流媒体传输模型 [81]。在该模型中，中心服务器仍然负责游戏状态的权威维护与关键消息的转发；但对于非关键的流媒体数据（如观战视频流、游戏回放），则通过 P2P 网络在玩家之间分发。这种混合架构将中心服务器的带宽消耗降低了约 70%，同时利用 P2P 网络的天然抗拥塞特性提升了流媒体的服务质量。

5.5. 性能优化与容量规划

5.5.1 性能瓶颈识别与优化

分布式游戏服务器的性能优化需要从多个层次入手：硬件层（CPU/GPU/内存/网络）、系统层（操作系统、网络协议栈）、中间件层（数据库、消息队列）与应用层（游戏逻辑）。

Zhang 等人的研究在分布式实时游戏服务器集群架构设计中，通过简化通信协议和数据包过滤机制，将处理性能提升了约 1.8 倍 [71]。该研究发现，传统游戏服务器在报文处理上的主要开销来自协议解析的冗余操作——每个数据包都需要经过多层协议栈的解封装。通过设计专用的轻量级游戏协议，跳过不必要的协议层次，报文处理吞吐量从每秒 5 万包提升至 9 万包。

5.5.2 弹性伸缩与容量规划

游戏负载具有高度可预测的周期性——工作日晚间高峰、周末高峰、节假日高峰、新版本发布高峰。准确的容量规划需要在保证服务质量的前提下最小化资源成本。

Gao 等人提出的 GameDRL 框架使用深度强化学习进行自动容量规划 [26]。该框架首先使用 LSTM 网络对玩家流量进行时序预测，预测模型以过去 7 天的历史数据为输入，输出未来 24 小时的负载曲线。预测结果输入 DRL 调度器，调度器根据当前集群状态与成本约束，决定何时扩容、扩容多少实例、将新实例部署在何处。在真实游戏负载数据上的回测表明，GameDRL 相比基于固定阈值的自动扩缩容策略，将资源浪费降低了 35%，同时将 SLA 违约率控制在 0.1% 以下。

5.6. 本章小结

分布式游戏服务器架构经历了从单服务器到集群、从集群到微服务、从微服务到 Serverless 的持续演进。这一演进的驱动力是游戏开发者对可扩展性、高可用性、低延迟与成本效益的不懈追求。本章系统梳理了分布式游戏架构的关键设计维度，包括有状态与无状态服务的分离、分片策略、负载均衡、数据一致性、高可用设计、网络协议优化与性能调优。边缘计算与雾计算的兴起，正在将分布式游戏系统的技术边界从“云-端”两极扩展为“云-边-端”三级连续体，为下一代沉浸式游戏体验奠定架构基础。

六、未来展望与挑战

从云计算到边缘计算，从集中式架构到分布式微服务，电子游戏的分布式计算基础设施在过去二十年经历了深刻的变革。然而，这一演进远未到达终点。随着元宇宙概念的兴起、生成式 AI 的爆发、6G 通信技术的推进以及新型人机交互设备的涌现，游戏计算架构正站在新一轮范式变革的门槛上。本节将从技术趋势、新兴应用与长期挑战三个维度，展望电子游戏分布式计算架构的未来发展方向。

6.1. 云-边-端三级协同架构

6.1.1 从两级到三级的范式跃迁

当前主流的游戏计算架构采用“云-端”两级模型：云端负责计算密集型任务，终端负责渲染与交互。边缘计算的引入将这一模型扩展为“云-边-端”三级架构。然而，现有的大多数实现仍将边缘视为云端的简单延伸，未能充分发挥三级协同的全部潜力。

Graff 等人作为 Horizon Europe CLOUDSTARS 项目的一部分，探讨了在异构计算环境（云-边缘-端）中部署在线游戏和可修改虚拟环境的挑战与解决方案 [82]。该研究提出的核心概念是“计算连续体”——将云、边、端的计算资源视为一个统一的、连续的资源池，任务可以根据其计算特征与延迟约束在连续体中的任意位置执行。在这一范式下，一个游戏应用的组件可以动态地在三级之间迁移：当玩家网络条件良好时，渲染任务下沉至终端以降低延迟；当终端电量不足时，渲染任务上浮至边缘以节省能耗；当边缘节点过载时，任务进一步上浮至

云端。

这一三级协同架构的实现面临两大技术挑战：一是跨层任务切分的粒度控制——切分过细会导致通信开销激增，切分过粗则无法充分利用三级资源；二是跨层迁移的透明性——迁移过程不应被玩家感知，这要求迁移延迟控制在单个帧间隔（16.7ms for 60fps）以内。

6.1.2 任务的自适应切分与调度

三级协同的核心是任务切分算法——决定游戏的哪些组件运行在云端、哪些运行在边缘、哪些保留在终端。这一决策需要综合考量多个因素：各层节点的当前负载、网络链路的可用带宽与延迟、终端的电量与散热状态、以及任务本身的计算特征与延迟敏感度。

Choudhury 在其博士论文中描绘的 VR 远程渲染三层分解提供了一个具体的切分范例 [48]：云端负责全局光照与复杂物理模拟（毫秒级延迟容忍度，算力需求高），边缘云负责视角相关的渲染与预测生成（亚毫秒级延迟容忍度，算力需求中），终端负责异步时间扭曲与帧外推（零延迟容忍度，算力需求低）。这种切分方式使得每一层的计算负载与其延迟约束相匹配，实现了资源的优化配置。

未来的研究方向包括：（1）基于在线学习的自适应切分算法，能够根据实时变化的网络与负载条件动态调整切分方案；（2）跨层任务迁移的标准化协议，使得不同厂商的边缘节点可以互操作；（3）面向游戏特征的专用切分模型，针对 FPS、RTS、MMO 等不同类型的游戏设计差异化的切分策略。

6.2. 6G 通信与空天地一体化网络

6.2.1 6G 的性能目标与游戏应用

第六代移动通信系统（6G）的标准化工作预计于 2025-2028 年间启动，2030 年前后开始商用部署。IMT-2030（6G）愿景草案提出了六大性能指标：峰值速率 1Tbps（是 5G 的 50 倍）、用户体验速率 10Gbps、空口延迟 0.1ms（是 5G 的 1/10）、连接密度 $10^7 \text{ devices/km}^2$ 、定位精度厘米级、以及新的“感知精度”指标。

这些性能指标对游戏应用具有深远意义。0.1ms 的空口延迟意味着无线接入环节的延迟可以忽略不计，端到端延迟的主要贡献将只剩下光传播延迟与处理延迟。厘米级的定位精度使得室内 AR 游戏可以实现虚拟物体与真实环境的精确对齐。Tbps 级的峰值速率使得多路 8K 120fps VR 流的无线传输成为可能。

Sharma 等人比较了 5G/6G 环境下边缘计算在游戏中的应用进展，指出 6G 将推动边缘计算从“可选优化”升级为“必需组件” [52]。在 6G 时代，边缘节点不再是云端的有益补充，而是网络架构的内生部分——每个 6G 基站都将内置计算能力，形成分布式的边缘计算网格。这种“计算原生”的网络架构将使游戏边缘渲染的部署密度达到前所未有的水平。

6.2.2 空天地一体化网络

6G 的另一重要特征是空天地一体化网络的构建，将地面蜂窝网络、低轨卫星网络（LEO）、高空平台（HAPS）与无人机网络整合为统一的通信基础设施。这一架构对于游戏应用的价值在于全球覆盖——即使在海洋、沙漠、极地等地面网络无法覆盖的区域，玩家仍可通过卫星链路接入游戏服务。

然而，卫星链路的延迟特性（LEO 卫星的往返延迟约为 25-50ms，GEO 卫星则高达 500ms 以上）对游戏应用的适配提出了挑战。未来的研究方向包括：（1）游戏协议的卫星链路优化，如针对长延迟高带宽产品设计新的拥塞控制算法；（2）地面-卫星链路的无缝切换技术，确保玩家在移动过程中服务不中断；（3）边缘节点在卫星上的部署可行性研究。

6.3. 生成式 AI 与程序化内容生成

6.3.1 AI 辅助的游戏开发与运营

生成式 AI 正在深刻改变游戏内容的生产方式。从 AI 生成游戏场景、角色模型、对话文本到动态任务系统，程序化内容生成（PCG）的技术边界正在被大语言模型（LLM）和扩散模型持续拓展。在分布式计算架构的视角下，生成式 AI 的引入提出了新的资源需求：模型推理需要大量 GPU 算力，而模型训练更是需要超大规模的计算集群。

未来的游戏架构可能呈现“云训练-边推理-端应用”的分层模式：大模型的训练在云端完成（利用数千张 GPU 的大规模集群），推理任务根据延迟要求分配至边缘节点或云端，生成的内容通过 CDN 分发至终端。对于实时生成的内容（如 AI 驱动的 NPC 对话），推理延迟需要控制在 100ms 以内，这要求推理节点尽可能靠近用户——边缘节点再次成为关键基础设施。

6.3.2 AI 生成内容的质量与一致性保障

尽管生成式 AI 在内容创作上展现出巨大潜力，其在游戏应用中的可靠性仍是悬而未决的问题。AI 生成的游戏场景可能存在几何不一致、纹理撕裂或碰撞检测错误；AI 生成的对话可能产生事实错误或角色性格不一致；

AI 生成的任务可能破坏游戏平衡性或产生逻辑矛盾。

这些问题的解决需要将 AI 生成与确定性规则验证相结合：AI 负责内容的“创意”部分（生成候选内容），传统的确定性算法负责内容的“验证”部分（检查几何一致性、逻辑正确性与平衡性）。这种混合架构对计算资源提出了新的要求——不仅是 AI 推理的算力需求，还包括验证算法的计算开销。如何在分布式环境中高效协调这两种计算模式，是未来的研究方向之一。

6.4. 元宇宙与大规模虚拟世界的架构挑战

6.4.1 元宇宙的计算需求

元宇宙被广泛认为是下一代互联网的演进方向，其核心特征包括：持久性（世界状态永久存在，不会因玩家离线而重置）、互操作性（不同虚拟世界间的资产与身份互通）、大规模并发（同一虚拟空间内支持数万名玩家同时在线）以及现实与虚拟的融合（AR/VR/MR 的无缝切换）。

这些特征对分布式计算架构提出了远超当前游戏系统的要求。Li 等人探讨了物联网与元宇宙的融合，指出元宇宙将产生前所未有的数据量——一个拥有百万用户的虚拟世界，每秒产生的状态更新消息可达数亿条 [83]。处理这一量级的数据需要全新的架构设计。

Khan 等人探讨了元宇宙环境下沉浸式游戏的 QoE 挑战，指出在多人社交 VR 场景中，延迟的影响会通过人际交互产生社会性放大效应 [51]。这意味着元宇宙的延迟优化目标可能需要从“个体延迟最小化”转向“延迟差异最小化”——确保同一虚拟空间内各玩家的延迟尽可能接近，以避免社交互动中的不协调感。

6.4.2 大规模虚拟世界的分片与协调

当前的 MMO 游戏通常采用分片架构来支撑大规模并发：将虚拟世界划分为多个独立的实例（分片），每个分片最多容纳数千名玩家。然而，元宇宙的愿景是建立一个统一的、无分片的虚拟世界，所有玩家共享同一个世界状态。

这一愿景的实现需要突破现有的技术瓶颈：（1）状态同步的规模瓶颈——当单分片的玩家数超过 1 万人时，状态更新的广播开销将耗尽网络带宽；（2）状态存储的容量瓶颈——一个持久化虚拟世界的历史状态数据可达 PB 级别；（3）状态查询的延迟瓶颈——跨区域的状态查询（如“距离我 100 公里范围内的所有玩家”）需要高效的分布式索引。

Li 等人的分片研究指出，“无分片元宇宙”在可预见的未来可能无法实现，更现实的路径是“分片 + 透明迁移”——玩家感知不到分片的存在，系统在后台自动将玩家分配到合适的分片，并在必要时透明地迁移 [16]。这一路径要求分片间状态同步的延迟足够低（低于玩家感知阈值），以及迁移过程足够平滑（不中断游戏体验）。

6.5. 安全、隐私与伦理挑战

6.5.1 分布式架构下的安全风险

边缘/雾计算的分布式架构在提升性能的同时，也扩大了攻击面。与高度受控的云数据中心相比，边缘节点通常部署在物理可访问的位置，面临更高的物理篡改风险。一个被攻破的边缘节点可能导致其服务范围内的所有玩家的数据泄露、游戏状态被篡改，甚至被用于发起对其他节点的攻击。

Ravichandran 与 Kababiito 分别探讨了数字游戏在合规性和监管方面的挑战，指出边缘计算环境下的数据主权问题亟待解决 [54][55]。当玩家数据存储于边缘节点时，存储位置可能跨越国界，引发数据保护法规的适用性问题。例如，一个在欧洲的玩家连接到位于本地的边缘节点，但其游戏会话的状态可能通过节点协作机制同步至位于其他国家的节点，这一过程是否符合 GDPR 的跨境数据传输规定，目前尚无明确答案。

未来的研究方向包括：（1）边缘节点的可信执行环境（TEE）技术，确保即使节点被物理攻破，其中的敏感数据仍受保护；（2）分布式身份认证与访问控制机制，防止恶意节点冒充合法节点；（3）数据主权感知的任务调度算法，确保玩家数据始终存储在合规的司法管辖区内。

6.5.2 玩家隐私保护

游戏系统收集的玩家数据极为丰富——不仅包括账号信息、支付数据等传统个人数据，还包括行为数据（操作序列、决策模式）、生物特征数据（语音聊天、摄像头画面在 VR 场景中）以及社交关系数据。这些数据的高度敏感性对隐私保护技术提出了更高要求。

联邦学习作为一种“数据不动模型动”的分布式机器学习范式，在保护玩家隐私的同时实现跨玩家数据的模型训练。Wang 等人的研究将联邦学习与差分隐私相结合，允许多个云游戏平台在不共享原始数据的情况下协同训练入侵检测模型 [30]。这一技术路径可推广至其他游戏 AI 场景，如基于玩家行为数据的个性化难度调整、基于对战数据的大规模策略学习等。

然而，联邦学习在游戏场景中的应用仍面临挑战：游戏行为数据的分布是非独立同分布的（不同玩家的操作风格差异巨大），传统联邦学习算法在这种场景下的收敛速度较慢。针对游戏场景设计的联邦学习优化算法，

是未来的研究方向之一。

6.6. 可持续计算与绿色游戏

6.6.1 游戏计算的能耗困境

游戏计算的能耗问题正日益受到关注。从个人电脑到游戏主机，从云游戏数据中心到边缘渲染节点，游戏的全生命周期碳足迹不容忽视。根据保守估计，全球游戏设备的年耗电量已超过 75 太瓦时，相当于一个中等国家的全年用电量。

Spinelli 等人从绿色计算的视角分析了边缘游戏的能效潜力，指出边缘游戏相比云游戏在人口密集地区具有显著的能耗优势 [34]。然而，这一优势依赖于边缘节点的利用率——如果边缘节点在非高峰时段闲置，其闲置能耗可能抵消能效优势。

6.6.2 碳感知的调度算法

未来的调度算法需要将碳排放作为一阶优化目标，而非能耗的附属考量。Kumbhar 提出的 ECOS 算法在这一方向上迈出了重要一步，将实时电价与碳排放因子纳入调度决策 [67]。ECOS 的核心思想是“延迟容忍-碳转移”：对于可以容忍一定延迟的任务（如游戏更新下载、非实时数据分析），将其调度至碳排放因子较低的时段或区域执行；对于延迟敏感的任务（如实时游戏渲染），则仍需就近执行。

这一思路的进一步延伸是“碳感知的游戏设计”——游戏本身可以根据当前的碳排放强度动态调整计算负载。例如，在电网碳排放强度高的时段，游戏可以降低画质预设、减少粒子特效、限制帧率，以降低能耗；在碳排放强度低的时段，恢复最高画质。这种设计不仅有助于降低碳足迹，还可以延长移动设备的电池续航。

6.7. 技术挑战的长期展望

6.7.1 延迟的物理极限

光速是延迟的终极物理极限。即使网络设备、协议栈和处理环节的延迟被完全消除，信号在光纤中的传播速度（约 2×10^8 m/s）仍然存在。这意味着，从上海到纽约（直线距离约 12000 公里）的单向传播延迟约为 60ms，往返延迟约为 120ms——这已经超过了大多数竞技游戏的延迟容忍阈值。

这一物理极限意味着，对于全球化的游戏服务，单纯依靠技术优化无法解决跨洲际玩家的延迟问题。解决方案可能来自两个方向：（1）区域性部署——将游戏服务按地理区域划分，不同区域的玩家无法跨区对战，或仅允许特定模式的跨区对战；（2）预测性补偿——利用 AI 预测对手在延迟期间的行为，在本地进行补偿渲染，待真实状态到达后再进行修正。后者已在格斗游戏和 FPS 游戏的网络代码中得到初步应用，但其效果仍受限于预测准确率。

6.7.2 通用人工智能与游戏

通用人工智能（AGI）的发展将对游戏产业产生深远影响。一方面，AGI 可以作为游戏中的 NPC，展现出接近人类的智能行为，大幅提升游戏的沉浸感与可重玩性；另一方面，AGI 也可能颠覆游戏的挑战性——如果 AI 可以轻松击败人类玩家，竞技游戏的吸引力将大打折扣。

从计算架构的角度看，AGI 的部署将需要远超当前深度学习模型的算力。一个 AGI 模型的推理可能需要在数千个加速器上并行执行，这将对边缘节点的算力密度和云-边协同提出全新要求。与此同时，AGI 的训练更是一个天文数字——据估计，训练一个人类水平的 AGI 可能需要 10^{25} 次浮点运算，是当前最大模型的百万倍以上。这一量级的计算需求，可能需要全新的计算范式（如量子计算、光计算、模拟计算）的出现。

6.8. 本章小结

从云-边-端三级协同到 6G 空天地一体化网络，从生成式 AI 到元宇宙，从安全隐私到绿色计算，电子游戏分布式计算架构的未来充满了机遇与挑战。技术的演进从未停止，而游戏作为最复杂、最苛刻的实时交互应用之一，始终站在分布式系统技术的前沿。未来的游戏架构将不再是“云”或“边”的二元选择，而是一个连续的计算光谱——任务在云、边、端之间动态流动，每一层贡献其独特的计算能力与延迟特性，共同为玩家创造无缝、沉浸、智能的游戏体验。

七、结语与总结

本文系统综述了电子游戏分布式计算架构从云计算到边缘计算的技术演进历程。通过梳理近五年（2022-2026 年）的最新研究成果，我们构建了一个从基础设施层到应用层的完整分析框架，涵盖了云计算基础、云游戏技术、边缘/雾计算介入、分布式服务器架构演进以及未来发展趋势五个核心维度。本节将总结全文的核心发

现，提炼对游戏开发者与分布式系统研究者的实践启示，并指出本综述的局限性与未来研究方向。

7.1. 核心发现与技术脉络

7.1.1 从集中式到分布式：架构演进的必然性

本文的分析表明，电子游戏计算架构的演进遵循一条清晰的逻辑主线：从客户端-服务器的集中式架构，到云计算的集中式数据中心架构，再到边缘/雾计算的分布式架构，最终走向云-边-端三级协同的连续计算范式。这一演进并非技术追逐潮流的结果，而是由游戏应用的本质需求——低延迟、高并发、强交互——所驱动的必然选择。

云计算为游戏产业带来了弹性资源供给与全球化部署能力，解决了游戏后端服务器的可扩展性问题。然而，云游戏模式的实践表明，将渲染与计算完全集中于远端数据中心，会引入难以克服的网络延迟（通常 50-100ms），这一延迟对于竞技类游戏而言是不可接受的 [3]。边缘计算与雾计算通过将计算资源下沉至网络边缘（距离用户 10-20 公里），将传输延迟压缩至 5-10ms 量级，为实时交互游戏提供了技术可行性 [9][20]。

分布式游戏服务器架构的演进则解决了另一维度的挑战：大规模并发下的状态管理与一致性保障。从单服务器到集群架构，从单体应用到微服务与 Serverless，游戏后端架构的分层解耦与功能拆分，使得现代游戏能够支撑百万级并发用户 [16][14]。

7.1.2 关键技术的突破与局限

在资源调度层面，深度强化学习（DRL）已成为边缘/雾计算资源管理的主流方法 [24][26]。与传统启发式算法相比，DRL 能够自适应地响应游戏负载的动态变化，在保证 QoE 的前提下将资源利用率提升 20-35%。然而，DRL 模型的训练开销、可解释性不足以及在极端场景下的泛化能力，仍是制约其实际部署的瓶颈。

在渲染架构层面，基于移动 SoC 的边缘服务器（SFG）为云游戏提供了一种高能效的替代方案 [36]。实测数据表明，SFG 的能效比（FPS/W）达到传统 x86 服务器的 3.7 倍，单节点可支持 64 路并发云游戏流。这一技术路径的成熟，使得在基站、网关等边缘位置部署高密度渲染节点成为可能，为云游戏的规模化推广奠定了硬件基础。

在网络协议层面，5G 网络切片、QUIC 协议与 L4S 拥塞控制架构为云游戏流量的 QoS 保障提供了新的技术选项 [60][12]。实验表明，L4S 架构将排队延迟从传统 CBWFQ 的 18ms 降低至 2.3ms，同时将丢包率从 0.8% 降低至 0.03%。然而，这些先进协议的实际部署仍受限于运营商网络设备的升级周期与跨厂商的互操作性挑战。

7.1.3 云-边-端协同：未来架构的核心特征

本文的分析表明，未来的游戏计算架构将不再是“云”与“边”的二元选择，而是一个计算连续体（Computing Continuum）[82]。在这一范式下，游戏应用的组件可以根据实时网络条件、设备状态与任务特征，在云数据中心、边缘节点与终端设备之间动态迁移。

这一三级协同架构的核心价值在于延迟-成本-能效的三维优化：延迟敏感的任务（实时渲染、输入处理）就近执行于边缘或终端；计算密集但延迟容忍的任务（全局光照、AI 训练）上浮至云端；突发性、间歇性的任务（匹配、结算、排行榜更新）采用 Serverless 架构按需执行，避免常驻成本 [14]。

7.2. 对实践者的建议

7.2.1 对游戏开发者的技术选型建议

基于本文的综述分析，我们为不同规模与类型的游戏开发者提供以下技术选型建议：

对于独立游戏开发者与小型工作室，建议优先采用成熟的云游戏 SaaS 平台（如 NVIDIA GeForce NOW、Xbox Cloud Gaming）或边缘渲染服务，避免自建基础设施的高昂成本与运维复杂度。在游戏设计上，应充分考虑网络延迟的约束，优先开发回合制、策略类或合作 PVE 等对延迟容忍度较高的游戏类型，规避实时竞技类游戏的延迟敏感风险。

对于中型游戏开发商，建议采用混合架构：核心游戏逻辑与状态管理部署于云端，利用云计算的弹性伸缩应对负载波动；渲染与流媒体服务部署于边缘节点，通过与电信运营商或边缘云服务提供商合作，降低延迟敏感型玩家的体验门槛。在服务器架构上，建议采用微服务模式，将匹配、聊天、经济、社交等功能拆分为独立服务，实现故障隔离与独立扩展 [15]。

对于大型游戏发行商与平台运营商，建议投资建设私有边缘节点网络或与运营商共建 MEC 基础设施，以支撑大规模、低延迟的竞技类游戏运营。在架构设计上，应积极探索 Serverless 与容器化的混合部署模式，将延迟不敏感的外围功能迁移至云函数，降低常驻服务器成本 [14]。同时，应投入研发资源开发自适应的 QoE 优化算法，根据实时网络条件动态调整渲染参数与编码策略 [59]。

7.2.2 对分布式系统研究者的方向建议

本文的综述揭示了若干值得深入研究的技术方向：

跨层联合优化：当前的研究多聚焦于单一层面（无线、网络、应用）的优化，缺乏跨层协同的系统性框架。未来的研究应探索无线信道状态、网络拥塞状况与游戏 QoE 需求之间的联合优化模型，实现从物理层到应用层的端到端 QoS 保障 [59]。

边缘智能与联邦学习：在保护玩家隐私的前提下，利用边缘节点的本地数据训练个性化 AI 模型（如难度调整、对手匹配、内容推荐），是提升游戏体验的重要路径。联邦学习作为一种“数据不动模型动”的分布式机器学习范式，在游戏场景中的应用仍处于初级阶段，其非独立同分布（Non-IID）数据下的收敛优化是亟待解决的技术难题 [30]。

元宇宙级分布式系统：面向未来元宇宙应用的大规模、持久化、互操作性虚拟世界，需要突破现有 MMO 架构的容量瓶颈。研究应聚焦于：（1）支持百万级并发玩家的分片与一致性协议；（2）跨区域、跨平台的无缝状态同步机制；（3）持久化虚拟世界的存储与索引优化 [51][16]。

绿色游戏计算：在“双碳”目标与 ESG 合规的背景下，游戏计算的能效优化将从“成本优化”升级为“社会责任”。研究应探索碳感知的任务调度算法、游戏设计的动态能耗调节机制，以及边缘计算与可再生能源的协同部署策略 [34][67]。

7.3. 本综述的局限性与未来研究方向

7.3.1 综述范围的边界

本综述聚焦于电子游戏领域的分布式计算架构，重点分析了云计算、边缘计算与雾计算的技术演进。然而，以下相关领域未能深入覆盖，构成了本综述的局限性：

区块链与去中心化游戏：基于区块链技术的去中心化游戏（如 GameFi、Play-to-Earn 模式）提出了全新的分布式架构范式——游戏状态由分布式账本维护，而非中心化服务器。这一范式在数据一致性、延迟性能与可扩展性方面面临独特挑战，值得独立综述。

专用游戏硬件与定制芯片：针对云游戏与边缘渲染场景，业界正在研发专用 ASIC（如 Google 的 Stadia 专用芯片、NVIDIA 的 Cloud Gaming GPU）。这些硬件层面的创新对系统架构设计具有深远影响，但本文主要聚焦于软件与系统层面的技术，硬件细节涉及有限。

游戏流媒体与内容分发：云游戏的视频流分发涉及复杂的 CDN 架构、自适应码率算法与 DRM 加密机制。这些内容虽与本文主题相关，但更多属于多媒体系统与网络安全领域，未能深入展开。

7.3.2 研究方法的局限

本综述主要依赖学术文献与公开技术报告，对工业界的实际部署细节与商业数据掌握有限。游戏行业的高度竞争性与技术保密性，使得许多关键性能数据（如真实云游戏平台的延迟分布、边缘节点的部署成本、Serverless 架构的实际节省比例）难以获取。这导致本文的部分结论基于仿真数据或小规模实验，可能与大规模生产环境存在偏差。

此外，本文的文献检索截止于 2026 年初，未能涵盖 2026 年及之后的最新进展。考虑到该领域的技术迭代速度（如 6G 标准化、生成式 AI、量子计算的潜在突破），本文的时效性将在未来 2-3 年内逐渐衰减，需要后续综述予以更新。

7.3.3 未来研究方向

基于本文的分析，我们认为以下方向将成为未来 2-5 年的研究热点：

6G 与空天地一体化网络的游戏适配：随着 6G 标准化工作的推进，0.1ms 级空口延迟与 Tbps 级峰值速率将为游戏应用开辟新的可能性。研究应聚焦于卫星链路的游戏协议优化、地面-卫星无缝切换技术，以及高空平台（HAPS）在游戏覆盖扩展中的应用 [52]。

生成式 AI 驱动的动态内容生成：大语言模型（LLM）与扩散模型在游戏内容生成中的应用，将对分布式计算架构提出新的需求。研究应探索“云训练-边推理-端应用”的分层部署模式，以及 AI 生成内容的实时验证与一致性保障机制。

触觉互联网与多感官交互：云游戏目前主要关注视觉与听觉的传输，未来的沉浸式体验将扩展至触觉（力反馈）、嗅觉与味觉。触觉互联网对延迟的要求更为严苛（1ms 级），需要边缘计算与新型网络协议的协同创新。

数字孪生与虚实融合：游戏引擎技术正在向数字孪生、工业仿真、智慧城市等领域渗透。这些应用对分布式系统的实时性、可靠性与安全性提出了更高要求，游戏架构的技术积累将为这些新兴领域提供重要借鉴。

7.4. 结语

电子游戏分布式计算架构的演进，是一部追求更低延迟、更高并发、更强沉浸的技术史。从云计算的弹性资源供给，到边缘计算的毫秒级响应，再到未来云-边-端协同的连续计算范式，每一次架构变革都深刻重塑了游戏体验的边界。

本文的综述表明，这一演进远未到达终点。6G 通信、生成式 AI、元宇宙与可持续计算等新兴趋势，正在为游戏分布式系统注入新的技术变量。对于研究者而言，这是一个充满挑战与机遇的时代——需要在跨学科的背景下（网络、系统、AI、硬件、能源）探索创新的架构设计与优化算法。对于开发者而言，这是一个技术选型日益丰富的时代——从成熟的云游戏 SaaS 到可定制的边缘节点部署，从单体架构到微服务与 Serverless，可以根据产品特性与成本约束灵活组合。

最终，所有技术演进的指向是一致的：让玩家无论身处何地、使用何种设备，都能获得无缝、沉浸、智能的游戏体验。这是分布式计算技术服务于人类娱乐需求的终极目标，也是本文综述希望传递的核心价值。

参考文献

- [1] Y. Chandola, V. Uniyal, R. Rawat, and A. Dhaundiyal, "Transformative impact of cloud computing on the gaming industry," *International Journal of Recent Technology and Engineering*, 2024.
- [2] M. M. Bhide, P. A. Bhiram, and K. Wani, "Impact of cloud in gaming and streaming," *International Journal of Gaming Technologies*, vol. 15, no. 3, pp. 123–134, 2025.
- [3] M. Dharmapurikar, "Latency in cloud gaming: A technical analysis," *CiiNOW Technical Report*, 2026.
- [4] P. Graff, *Caractérisation, identification dans le réseau et optimisation du transport de trafic à faible latence - le cas du Cloud-Gaming*. PhD thesis, Université de Lorraine, 2023.
- [5] J. R. Ky, B. Mathieu, P. Graff, and T. Cholez, "A hybrid p4/nfv architecture for cloud gaming traffic detection with unsupervised ml," in *2023 IEEE Symposium on Computers and Communications (ISCC)*, pp. 733–738, 2023.
- [6] M. Lyu, S. Madanapalli, A. Vishwanath, and V. Sivaraman, "Network anatomy and real-time measurement of nvidia geforce now cloud gaming," in *Proceedings of the 2022 IEEE International Conference on Cloud Computing (CLOUD)*, 2022.
- [7] G. K. Walia, M. Kumar, and S. S. Gill, "Ai-empowered fog/edge resource management for iot applications: A comprehensive review, research challenges, and future perspectives," *IEEE Communications Surveys & Tutorials*, 2024.
- [8] A. Madhumitha, A. G P, B. P. Swathi, B. Vanaja, and G. M. Raju, "A comprehensive review on edge computing - architecture, algorithm, and devices," *International Journal of Recent Technology and Engineering (IJIRT)*, 2025.
- [9] S. Kang, "E-render: Enabling uhd-quality cloud gaming through edge rendering," in *Proceedings of the 28th IEEE Symposium on Computers and Communications (ISCC)*, pp. 1234–1240, 2022.
- [10] S. Kim, J. Lee, and K. Park, "Edge-based load balancing for real-time multiplayer games," in *Proceedings of the 2024 ACM SIGCOMM*, 2024.
- [11] S. K. Singh, C. E. Rothenberg, A. Shirmarz, F. L. Verdi, I. Haque, G. Patra, and G. Pongrácz, "Matador: Ml-based cloud gaming traffic detection entirely in programmable hardware," in *Proceedings of the 2023 IEEE International Conference on Network and Service Management (CNSM)*, 2023.
- [12] P. Graff, X. Marchal, T. Cholez, B. Mathieu, S. Tuffin, and O. Festor, "Improving cloud gaming traffic qos: a comparison between class-based queuing policy and l4s," *IEEE Transactions on Network and Service Management*, 2024.
- [13] H. S. Rossi, K. Mitra, C. Åhlund, and I. Cotanis, "Qoe models for virtual reality cloud-based first person shooter game over mobile networks," *IEEE Access*, 2024.
- [14] Y. Huang, H. Liu, and Y. Zhang, "Serverless architecture for massive multiplayer online games," *IEEE Transactions on Games*, vol. 15, no. 2, pp. 105–117, 2023.

- [15] Y. Liu, H. Wang, and M. Zhou, "Microservice architecture for real-time multiplayer games," in *Proceedings of the 2025 ACM Symposium on Cloud Computing (SoCC)*, 2025.
- [16] J. Li, X. Zhou, and Y. Wang, "Sharding strategies for scalable mmo game servers," *ACM Transactions on Internet Technology*, vol. 25, no. 1, pp. 1–22, 2025.
- [17] T. Nakamura and K. Sato, "Cross-region disaster recovery for real-time game services," *Journal of Network and Computer Applications*, vol. 213, p. 103745, 2024.
- [18] S. Mangalampalli, S. S. Hashmi, A. Gupta, G. R. Karr, K. V. Rajkumar, T. Chakrabarti, P. Chakrabarti, and M. Margala, "Multi objective prioritized workflow scheduling using deep reinforcement based learning in cloud computing," *IEEE Access*, 2024.
- [19] J. D. G. Proença, "Applications of network and system virtualization in multiservice context," *International Journal of Network Management*, 2024.
- [20] L. Zhang, S. Wang, and M. Xu, "High-density mobile cloud gaming on edge soc clusters," in *Proceedings of the 2024 USENIX Annual Technical Conference (ATC)*, 2024.
- [21] L. Zhang, Z. Fu, B. Shi, X. Li, R. Lai, C. Yang, A. Zhou, X. Ma, S. Wang, and M. Xu, "More is different: Prototyping and analyzing a new form of edge server with massive mobile socs," in *Proceedings of the 2024 USENIX Annual Technical Conference (ATC)*, 2024.
- [22] G. Singh, "Research and implement solutions to tackle security threats in mobile cloud gaming," in *Proceedings of the 34th International Conference on Software Engineering and Knowledge Engineering (SEKE)*, 2022.
- [23] S. K. Sahoo and S. S. Goswami, "A comprehensive review of multiple criteria decision-making (mcdm) methods: Advancements, applications, and future directions," *Applied Sciences*, vol. 13, no. 6, p. 3433, 2023.
- [24] X. Deng, J. Zhang, H. Zhang, and P. Jiang, "Deep-reinforcement-learning-based resource allocation for cloud gaming via edge computing," *IEEE Internet of Things Journal*, vol. 10, no. 6, pp. 5364–5377, 2023.
- [25] Y. Gao and Z. Li, "Deep reinforcement learning based rendering service placement for cloud gaming in mobile edge computing systems," *Proceedings of the 2023 IEEE 47th Annual Computers, Software, and Applications Conference (COMPSAC)*, pp. 502–511, 2023.
- [26] L. Gao, F. Liu, and H. Chen, "Ai-driven orchestration of distributed game servers," in *Proceedings of the 2023 IEEE International Conference on Cloud Engineering (IC2E)*, 2023.
- [27] Y. Zhang, Y. Cao, X. Ren, C. Qiu, and X. Wang, "Virtual machine placement optimization in mobile cloud gaming through qoe-oriented resource competition," *IEEE Transactions on Cloud Computing*, vol. 10, no. 3, pp. 2204–2218, 2022.
- [28] J. R. Imbien, *Optimizing Collaborative Edge-Cloud Computing: A Task Allocation Strategy Using Hybrid Genetic Algorithm and Tabu Search*. PhD thesis, Oslo Metropolitan University, 2025.
- [29] J. J. Ang'udi, "Security challenges in cloud computing: A comprehensive analysis," *Journal of Wireless Applications and Emerging Technologies*, 2023.
- [30] Y. Wang and X. Yang, "Research on enhancing cloud computing network security using artificial intelligence algorithms," *IEEE Transactions on Cloud Computing*, 2025.
- [31] S. S. R and K. R, "Securing saas: Key challenges and effective mitigation strategies," *International Journal of Management and Remote Engineering (IJMRE)*, 2024.
- [32] R. C. Monika, "Optimization of energy efficient task scheduling in cloud environment," *International Journal for Research in Applied Science & Engineering Technology (IJRASET)*, 2024.
- [33] K. Shanmugam, S. K, and T. Rajasekhar, "Cso-based efficient resource management for sustainable cloud computing," *Computer Modeling*, 2024.

- [34] F. Spinelli, A. Bazco-Nogueras, and V. Mancuso, "Edge gaming: a greening perspective," in *2022 IEEE 23rd International Symposium on a World of Wireless, Mobile and Multimedia Networks (WoWMoM)*, 2022.
- [35] F. Spinelli, A. Bazco-Nogueras, and V. Mancuso, "Edge gaming: a greening perspective," *IEEE Transactions on Green Communications and Networking*, 2022.
- [36] L. Zhang, Z. Fu, B. Shi, X. Li, R. Lai, C. Yang, A. Zhou, X. Ma, S. Wang, and M. Xu, "More is different: Prototyping and analyzing a new form of edge server with massive mobile socs," in *Proceedings of the 2024 USENIX Annual Technical Conference (ATC)*, 2024.
- [37] B. H. Awan, "Deep learning neural networks in the cloud," *IEEE Access*, 2023.
- [38] H. Li and L. Duan, "Theory of mixture-of-experts for mobile edge computing," *arXiv preprint*, 2025.
- [39] M. Hanefi and R. Bütün, "Current studies in data science and analytics," *Data Science Journal*, 2024.
- [40] R. Harris, "Data analytics trends shared by oxylabs," *App Developer Magazine*, 2024.
- [41] X. Bai, "Optimization of b2c e-commerce enterprise value chain based on cloud computing," *International Journal of Information Systems and e-Business (IJISEB)*, 2024.
- [42] IAFI, "Further updates to the working document towards preliminary draft revision of report itu-r m.2527-0," tech. rep., International Association of Radio, Telecommunications and Information Technology (IAFI), 2024.
- [43] J. Lu, "Cloud gaming analysis: A comparative study," *Journal of Computer Networks and Communications*, 2023.
- [44] H. S. Rossi, K. Mitra, C. Åhlund, and I. Cotanis, "Qoe models for virtual reality cloud-based first person shooter game over mobile networks," *IEEE Access*, 2024.
- [45] S. Kumbhar, "Enhancing qoe in cloud gaming: A comprehensive study on 5g networks integrating serverless computing and machine learning," *International Journal of Network Management*, 2024.
- [46] J. R. Ky, "Anomaly detection and root cause diagnosis for low-latency applications in time-varying capacity networks," *arXiv preprint arXiv:2507.17843*, 2025.
- [47] D. Mejías, I. Yeregui, R. Viola, M. Fernández, and M. Montagud, "Remote rendering for virtual reality: performance comparison of multimedia frameworks and protocols," *arXiv preprint arXiv:2507.00623*, 2025.
- [48] S. Choudhury, *ARCHITECTURE AND DESIGN CONSIDERATIONS FOR NEXT-GENERATION MOBILE NETWORKS WITH INTEGRATED EDGE COMPUTING*. PhD thesis, Rutgers, The State University of New Jersey, 2024.
- [49] IEEE, "Ieee 802.11 overview and completed amendments," *IEEE 802.11 Standard*, 2024.
- [50] P. Patil, "Optimizing low latency public cloud systems: Strategies for network, compute and storage efficiency," *Journal of Web Engineering and Application Research*, 2025.
- [51] A. A. Khan, J. Yang, A. A. Laghari, F. Hajjej, Y.-L. Chen, C. S. Ku, and L. Y. Por, "Metaverse in multimedia gaming: Quality of experience (qoe) challenges and standards requirements for immersive media consumption," *International Journal of Multimedia and Ubiquitous Engineering*, 2023.
- [52] D. Sharma, A. Patel, and R. Singh, "A comparative study on the development of edge computing using 5g/6g technology," *International Journal of Computer Applications*, 2023.
- [53] P. Iacopino, D. George, Y. Zhong, K. Pang, J. Guan, and S. Lyu, "Edge computing in the 5g era: Technology and market developments in china," *GSMA Intelligence Report*, 2023.
- [54] L. Ravichandran, "Regulatory risk audits in esports and online casinos: Addressing compliance challenges in digital gaming," in *Proceedings of the 2024 International Conference on Digital Gaming Law*, 2024.

- [55] L. Kababiito, "Regulatory risk audits in esports and online casinos: Addressing compliance challenges in digital gaming," *International Review of Journal of Management and Economics*, 2025.
- [56] F. Delicato and N. Desai, "Edge 2023 program chairs message." IEEE International Conference on Edge Computing and Communications, 2023.
- [57] *Proceedings of the 7th International Conference on Edge Computing (EDGE 2023)*, 2023.
- [58] "Proceedings of the 7th international conference on edge computing (edge 2023)," in *EDGE 2023*, 2023.
- [59] E. Kartsakli, O. Sallent, J. P. Roig, J. Pérez-Romero, *et al.*, "Advanced edge computing architecture for ai-driven automation and slicing in beyond 5g," in *Proceedings of the 2024 International Conference on Advanced Edge Computing*, 2024.
- [60] B. M. d. Silva, L. F. Rodrigues, F. S. de Oliveira, and R. Moreira, "Optimizing edge gaming slices through an enhanced user plane function and analytics in beyond-5g networks," in *Proceedings of the 2025 IEEE International Conference on Edge Computing (EDGE)*, 2025.
- [61] G. K. Walia, M. Kumar, and S. S. Gill, "Ai-empowered fog/edge resource management for iot applications," *IEEE Communications Surveys & Tutorials*, 2024.
- [62] V. V. Sangaraju, S. A. Rao, A. Shaik, V. Prasuna, and P. Nagaraju, "Review on fog computing -applications, security, and solutions," *Journal of Computer Networks and Communications*, 2024.
- [63] R. Ghafari and N. Mansouri, "Swarm intelligence techniques and their applications in fog/edge computing: An in-depth review," *Artificial Intelligence Review*, 2025.
- [64] X. Zhou, H. Miao, J. Yang, W. Jiang, X. Liao, Y. Li, S. Luo, and J. Lu, "Edge computing resource scheduling: History, architecture, modeling, and method analysis," *IEEE Transactions on Parallel and Distributed Systems*, 2023.
- [65] X. Deng, J. Zhang, H. Zhang, and P. Jiang, "Deep-reinforcement-learning-based resource allocation for cloud gaming via edge computing," *IEEE Internet of Things Journal*, vol. 10, no. 6, pp. 5364–5377, 2023.
- [66] Y. Chandola, V. Uniyal, R. Rawat, and A. Dhaundiya, "Transformative impact of cloud computing on the gaming industry," *International Journal of Recent Technology and Engineering*, 2024.
- [67] G. Kumbhar, "Cost-effective resource management in mobile edge computing," in *Proceedings of the 2024 IEEE International Conference on Mobile Computing and Networking (MobiCom)*, 2024.
- [68] S. Das, *Ensuring Scalability and Robustness of an Actor-Network Based Server for a Game Using Test Automation*. PhD thesis, Oulu University of Applied Sciences, 2025.
- [69] A. Alsalemi, A. Amira, H. Malekmohamadi, and K. Diao, "Facilitating deep learning for edge computing: A case study on data classification," in *2022 IEEE Conference on Dependable and Secure Computing (DSC)*, 2022.
- [70] A. Patel and R. Singh, "Distributed transaction management in cloud gaming platforms," *Future Generation Computer Systems*, vol. 139, pp. 65–78, 2024.
- [71] W. Zhang, "Architecture design of distributed real-time game server clusters," *Computer Engineering*, 2014. In Chinese.
- [72] D. Fu and H. Kuang, "Design and implementation of a large-scale network game platform architecture," *Computer and Digital Engineering*, vol. 36, no. 3, pp. 7–12, 2008. In Chinese.
- [73] W. H. Vogels, "Scalable cluster technologies for mission-critical enterprise computing," *VRIJE UNIVERSITEIT*, 2003.
- [74] Y. Bai, "Research and implementation of network engine for online game servers," *Technical Blog*, 2008. In Chinese.

- [75] M. V. Zelkovitz, “Advances in computers volume 76,” *Advances in Computers*, 2009.
- [76] Q. Wei, “Application of distributed transactions in game server clusters,” *Journal of Software*, 2024. In Chinese.
- [77] Q. Li, “Distributed server architecture,” *Frontiers of Network Technology*, 2025. In Chinese.
- [78] P. Kumar and A. Singh, “Hybrid cloud-edge cluster management for large-scale game deployments,” in *Proceedings of the 2024 IEEE International Conference on Distributed Computing Systems (ICDCS)*, 2024.
- [79] J. Chen and X. Liu, “Real-time network protocol optimization for high-frequency game interactions,” *Computer Networks*, vol. 224, p. 108964, 2023.
- [80] Z. Jiang and Q. Wu, “Network coding techniques for reducing latency in multiplayer games,” *IEEE Transactions on Communications*, vol. 73, no. 4, pp. 2101–2114, 2025.
- [81] Q. Zhang and Y. Sun, “Hybrid p2p-server architecture for low-latency game streaming,” *IEEE Access*, vol. 12, pp. 112233–112245, 2024.
- [82] P. Graff, X. Marchal, T. Cholez, and B. Mathieu, “Deploying online games and modifiable virtual environments across the compute continuum,” *Proceedings of the CLOUDSTARS Project*, 2024.
- [83] K. Li, Y. Cui, W. Li, T. Lv, X. Yuan, S. Li, W. Ni, M. Simsek, and F. Dressler, “When internet of things meets metaverse: Convergence of physical and cyber worlds,” *IEEE Wireless Communications*, vol. 26, no. 4, pp. 178–183, 2022.