

游戏平衡参数的仿真优化：评估噪声与随机数共用对随机搜索、SPSA、CMA-ES 与贝叶斯优化的影响

Simulation-Based Optimization of Game Balance Parameters: Effects of Evaluation Noise and Common Random Numbers on Random Search, SPSA, CMA-ES, and Bayesian Optimization

copycat666^{1,2*}, doro^{1,2}, mysteriousK^{1,2}

1. EigenLife 机器学习实验室，东北电力大学，吉林；2. 《电子游戏科学与技术》编辑委员会，吉林，
submission.joest.cn@outlook.com

*: Corresponding Author

摘要：游戏平衡参数的调优通常只能依靠大量对局仿真来评估，评估结果带有统计噪声，调参过程因此同时受到仿真预算与噪声的约束。本文以一个波次防守对局的随机仿真模型作为实验平台，把平衡调参写成六维设计参数到目标胜率曲线的黑箱优化问题，并在相同的评估预算下比较随机搜索、同时扰动随机逼近（SPSA）、协方差矩阵自适应进化策略（CMA-ES）、高斯过程贝叶斯优化与逐轮淘汰五类算法。实验在三种重复次数（4、16、64）与是否共用随机数两种设定下各运行三十个随机种子，并用大样本复核最终解的真实目标值。结果表明：SPSA在各档重复次数下都取得最低的真实目标值，随机搜索在重复次数较高时与之接近；共用随机数使优化器报告的估计值更接近真实值，却系统性地降低了最终解的真实质量，平均相对恶化约10%至36%；把共用随机数的刷新间隔由整轮固定缩短为每次重抽，可以恢复其中大部分损失。本文据此给出在评估预算与噪声约束下进行游戏平衡调参时的算法选择与随机数使用建议。

关键词：仿真优化；黑箱优化；随机数共用；CMA-ES；贝叶斯优化；游戏平衡

Abstract. Tuning game balance parameters typically relies on evaluating many simulated matches, and each evaluation carries statistical noise, so the tuning process is constrained by both the simulation budget and the noise level. This paper uses a stochastic simulation of wave-based defensive matches as an experimental platform and formulates balance tuning as a six-dimensional black-box optimization problem that minimizes the mismatch between the achieved win-rate curve and a designer-specified target. Under an identical evaluation budget, five algorithms are compared: random search, simultaneous perturbation stochastic approximation (SPSA), the covariance matrix adaptation evolution strategy (CMA-ES), Gaussian-process Bayesian optimization, and racing with sequential resampling. Experiments cover three replication levels (4, 16 and 64) and two common-random-number settings, each with thirty random seeds, and every final solution is re-evaluated with a large validation budget. SPSA attains the lowest true objective at all replication levels, while random search becomes competitive when replications are plentiful. Common random numbers make the optimizer's reported estimates more faithful to the true values but systematically degrade the true quality of the returned solution, by roughly 10 to 36 percent on average, and shortening the refresh interval of the shared random stream recovers most of this loss. The results provide guidance on algorithm choice and random-number usage for game balance tuning under budget and noise constraints.

Keywords: Simulation Optimization; Black-Box Optimization; Common Random Numbers; CMA-ES; Bayesian Optimization; Game Balancing

一、引言

电子游戏的平衡性依赖大量数值参数，例如敌人生命与攻击的缩放倍率、波次增长系数、精英单位的强度、玩家资源获取速率以及初始容错空间。这些参数共同决定不同熟练度玩家的胜率曲线，开发者通常通过反复调整参数并观察对局结果来完成设定。当对局过程包含随机事件与多波次累积时，解析地预测胜率并不可行，只能通过仿真得到目标函数值，调参工作因此落在仿真优化的范畴之内 [1, 2, 3]。

仿真优化的困难来自预算与噪声两方面。每次评估需要仿真若干场对局，可供使用的总对局数有限 [4]；用有限场对局估计的胜率只是真实胜率的抽样估计，目标函数值因此含有统计误差 [5]。噪声带来两个后果。优化器在比较两个候选参数时会受到估计误差干扰，被选中的“当前最优”的真实质量往往低于其报告值，这一现象通常称为乐观偏差；不同算法对噪声的敏感程度也不相同，在低噪声条件下表现良好的算法未必能在高噪声条件下保持优势。这两个后果在工程上的意义是，算法选型不能只依据低噪声实验，随机数使用策略也需要在实际搜索过程中加以检验。

面向无导数的黑箱优化, 已有大量算法可供选择。随机搜索实现简单, 对问题维度不敏感, 在超参数调优中被证明是难以击败的基线 [6]。同时扰动随机逼近 (simultaneous perturbation stochastic approximation, SPSA) 用两次评估构造随机梯度方向, 其每次迭代的评估次数与维度无关, 专门面向带噪声的目标 [7, 8]。协方差矩阵自适应进化策略 (covariance matrix adaptation evolution strategy, CMA-ES) 通过自适应协方差矩阵刻画搜索分布, 在中等维度的连续问题上表现稳定 [9, 10, 11]。高斯过程贝叶斯优化用代理模型与采集函数决定下一个评估点, 适合单次评估代价高昂的场景 [12, 13, 14, 15]。逐轮淘汰类方法把预算集中到更有希望的候选上, 是仿真优化中处理噪声的经典手段 [16, 17]。

在仿真实验中, 共用随机数 (common random numbers, CRN) 被广泛用于降低候选方案之间的比较方差 [18, 4]。CRN 的经典结论建立在比较一组固定方案的场景上: 让不同方案面对同一批随机数, 可以抵消公共的环境波动, 从而更可靠地判断方案之间的优劣。当优化器在连续参数空间中反复搜索时, 同一批随机数会被所有候选共享。此时 CRN 一方面降低比较方差, 另一方面把某一次抽样的偏差固定下来并贯穿整个搜索过程。考察这种固定偏差对搜索的作用, 是本文关注的一个具体问题。

游戏研究领域已有大量关于难度调整与内容生成的工作 [19, 20, 21, 22, 23, 24]。这些工作主要关注玩家建模、难度自适应规则设计或者内容的搜索式生成, 较少在统一的仿真预算与噪声设定下比较优化算法本身。本文的关注点落在优化过程一侧。

本文以一个波次防守对局的随机仿真模型作为可复现的实验平台, 把平衡调参写成六维设计参数到目标胜率曲线的黑箱优化问题, 并在相同评估预算下比较随机搜索、SPSA、CMA-ES、高斯过程贝叶斯优化与逐轮淘汰五类算法。实验把每次评估的重复场次取三档, 把是否共用随机数取两种设定, 各运行三十个随机种子, 全部最终解用大样本复核真实目标值。本文的主要发现可以概括为三点: 在本文的实验设定下, SPSA 在各档噪声水平上都取得最低的真实目标值, 随机搜索在重复场次较多时与之接近; 共用随机数让优化器报告的估计值更接近真实值, 却系统性地降低了最终解的真实质量, 平均相对恶化约 10% 至 36%; 把共用随机数的刷新间隔由整轮固定缩短为每次重抽, 可以恢复其中大部分损失。

本文其余部分安排如下。第二节回顾相关工作并说明本文的差异, 第三节给出问题描述与仿真模型, 第四节介绍所比较的算法与预算记账方式, 第五节说明实验设置, 第六节报告并分析结果, 第七节讨论实践含义与局限, 第八节总结全文。

二、相关工作

2.1. 仿真优化

仿真优化研究如何在目标函数只能通过仿真估计、且估计带有噪声的条件下寻找最优的设计参数。已有综述把该领域的方法分为随机逼近、响应面与代理模型、随机搜索与元启发式以及基于排序与选择的统计方法等若干类 [1, 2, 3]。这些工作在方法论层面已经相当完整, 但算法之间的相对优劣依赖具体问题的维度、噪声强度与预算规模, 定量的横向比较仍然有价值 [2]。

2.2. 无导数与随机逼近算法

随机搜索在给定的参数空间中独立均匀采样, 其收敛速度与维度呈多项式关系而不依赖梯度信息, 在超参数优化实验中与更复杂的模型搜索方法相当乃至更优 [6]。SPSA 通过同时扰动全部维度并用两次评估构造梯度的估计, 把每次迭代的评估代价固定为两次 [7, 8], 这一性质使其在评估昂贵的高维问题中具有吸引力。CMA-ES 属于进化策略, 通过沿着成功步方向更新协方差矩阵来自适应搜索分布的形状与尺度 [9, 11, 10]。贝叶斯优化用高斯过程等代理模型拟合已有评估点, 并以期望改进等采集函数平衡探索与利用 [12, 15, 13, 14]。

2.3. 噪声处理与序贯重采样

在含噪目标上, 一种有效手段是让重采样次数随候选的潜力变化。Hoeffding 淘汰法在一批候选中逐步加大重采样次数并淘汰明显劣于当前最优的候选 [16]; 最优计算预算分配把有限的仿真次数在候选之间显式地优化分配, 使正确选择的概率最大化 [17]。这类方法的目标是在给定总仿真次数下提高选对候选的概率。

2.4. 随机数共用

共用随机数要求不同方案在同一批随机数下仿真, 其收益与方案之间的单调性关系密切。已有研究给出了使用 CRN 的适用条件与保证, 指出当随机性与方案的关系不满足适当条件时, CRN 可能使比较方差反而增大 [18]。仿真教材通常把 CRN 作为方差缩减技术介绍, 并强调它作用于方案比较而非单个方案的估计 [4, 25, 5]。本文考察的情形略有不同: 随机数在一整轮搜索中保持固定, 优化器据此反复比较大量候选。

2.5. 游戏平衡与自动调参

游戏人工智能领域的研究把游戏中的设计、生成与测试问题转写为搜索与优化问题 [19]。搜索式内容生成把关卡、地图或者规则表示为可搜索的解空间，并用可计算的适应度函数评价候选 [23]。难度调整方面，已有工作提出基于玩家模型的自适应难度规则 [21, 22, 20]，也有工作用进化算法生成能够代表不同玩家风格的代理，用于在无人参与的情况下评估内容 [24]。这些工作的适应度函数同样来自仿真，因而面对相同的噪声与预算问题，但把优化算法本身作为比较对象的工作并不多见。

2.6. 本文的差异

本文与上述工作在三个层面有所不同。在问题层面，本文把平衡调参明确写成固定预算下的含噪黑箱优化问题，并把“估计是否可靠”与“解是否真的好”分开度量。在方法层面，本文在完全相同的预算记账下比较五类代表性算法，而非只报告单一算法在单一噪声设定下的结果。在结论层面，本文给出共用随机数在搜索场景下的定量影响，并通过刷新间隔的消融实验解释其来源。本文不提出新的优化算法，所考察的五类算法均为已有方法，贡献在于可复现的定量比较与结论。

三、问题描述与仿真模型

3.1. 设计参数与目标曲线

考虑一个波次防守类对局。敌方强度与经济投放由六个设计参数控制，记为 $\theta = (h, a, g, e, r, p)$ ，其含义与取值范围见表 1。玩家的熟练度用标量 q 表示，取值范围为 $[0, 1]$ ，反映玩家把获得的资源转化为战力的效率。设计者给出四个熟练度档位上的目标胜率，本文取 $q \in \{0.30, 0.50, 0.70, 0.90\}$ ，对应目标胜率 $t = (0.35, 0.55, 0.75, 0.90)$ ，即熟练度越高目标胜率越高。这一目标曲线的含义是，游戏应当对四个档位的玩家都保持可玩且有挑战的难度。

表 1: 仿真模型中的设计参数与取值范围

符号	含义	下界	上界
h	敌人生命倍率	0.50	2.00
a	敌人攻击倍率	0.50	2.00
g	波次增长系数	0.00	0.20
e	精英波强度	0.00	0.60
r	资源经济倍率	0.50	2.00
p	初始生命加成	0	80

3.2. 对局仿真

一场对局包含 $W = 10$ 个波次。防守方的初始生命值与攻击力分别取 100 与 10，并在此基础上增加由 p 给定的初始生命加成。记第 w 个波次的增长因子为

$$s_w = (1 + g)^w, \quad w = 0, 1, \dots, W - 1. \quad (1)$$

每场对局开始时抽取一个对数正态强度因子 $z = \exp(\sigma\zeta)$ ，其中 $\zeta \sim \mathcal{N}(0, 1)$ ， $\sigma = 0.35$ ，用于刻画同一组参数下对局之间的整体强弱波动。第 w 波敌人的生命值与攻击力为

$$H_{e,w} = 40 h s_w z, \quad A_{e,w} = 4 a s_w z (1 + e b_w), \quad (2)$$

其中 $b_w \sim \text{Bernoulli}(0.2)$ 表示该波是否为精英波。

在两个波次之间，防守方获得资源并转化为战力。按熟练度折算后的资源量为 $r(10 + 2w)q$ ，其中六成用于提升生命值，四成用于提升攻击力：

$$H_d \leftarrow H_d + 0.6 r (10 + 2w) q, \quad A_d \leftarrow A_d + 0.4 r (10 + 2w) q. \quad (3)$$

每个波次的作战按伤害竞赛处理。双方的有效攻击力各乘一个区间 $[0.8, 1.2]$ 内的均匀扰动，即 $\tilde{A}_d = A_d u_d$

与 $\tilde{A}_e = A_{e,w}u_e$ ，其中 $u_d, u_e \sim \mathcal{U}(0.8, 1.2)$ 。记击杀对方所需回合数为

$$\tau_e = \frac{H_{e,w}}{\tilde{A}_d}, \quad \tau_d = \frac{H_d}{\tilde{A}_e}. \quad (4)$$

当 $\tau_e \leq \tau_d$ 时防守方守住该波，否则该场对局在第 w 波结束。防守方在守住的波次中承受的伤害为

$$\Delta = \tilde{A}_e \min(\tau_e, \tau_d), \quad (5)$$

并从生命值中扣除。整个对局的胜负定义为是否守住全部 W 个波次。

3.3. 目标函数与估计噪声

给定设计参数 θ ，第 k 个熟练度档位的胜率记为 $p_k(\theta)$ ，目标函数为四个档位胜率与目标曲线的均方误差：

$$J(\theta) = \frac{1}{K} \sum_{k=1}^K (p_k(\theta) - t_k)^2, \quad K = 4. \quad (6)$$

J 没有解析表达式，只能用仿真估计。用每个档位 N 场对局估计胜率得到 $\hat{p}_k$ ，估计目标值为

$$\hat{J}_N(\theta) = \frac{1}{K} \sum_{k=1}^K (\hat{p}_k(\theta) - t_k)^2. \quad (7)$$

重复场次 N 决定估计噪声的强弱。本文把一次这样的估计称为一个评估单元，它消耗 $N \times K$ 场对局仿真。

共用随机数的作用方式如下。设 ξ 表示一场对局用到的全部随机量，即强度因子、精英波指示与每波的两个扰动。独立评估时每个候选参数使用独立抽取的随机量；共用随机数时所有候选参数使用同一批随机量，估计量只依赖重复下标而与候选参数无关。由于估计量对每个固定的 θ 仍然无偏，CRN 改变的是不同 θ 之间估计误差的相关性。

为了把“报告值是否可信”与“解是否真的好”分开度量，本文对每个算法返回的最终解同时记录两个量：优化器自身报告的最优估计值 $\hat{J}$ ，以及用大样本重新估计得到的真实目标值 J 。二者之差 $J - \hat{J}$ 的相反数记为乐观偏差，即 $\hat{J} - J$ ，取负值时表示优化器报告的估计值偏低，也就是估计偏乐观。

四、优化算法

所有算法都在归一化坐标 $\mathbf{u} \in [0, 1]^6$ 上运行，通过线性映射 $\theta = \mathbf{l} + \mathbf{u} \odot (\mathbf{h} - \mathbf{l})$ 得到实际参数，其中 $\mathbf{l}$ 与 $\mathbf{h}$ 为表 1 给出的下界与上界。这样处理可以避免不同参数之间的量纲差异影响步长设置。所有算法共享同一套预算记账：每次调用产生一个评估单元并消耗 $N \times K$ 场对局仿真，预算耗尽时算法停止。

4.1. 随机搜索

随机搜索在每个评估单元中从单位立方体内独立均匀采样一个候选并评估，全程保存已评估点中的最优者。该方法不使用历史信息，因此对目标函数的平滑性与维度不敏感，常被用作基线 [6]。

4.2. 同时扰动随机逼近

SPSA 在每一步抽取一个取值为 ± 1 的随机扰动向量 Δ ，并在 $\mathbf{u} \pm c_k \Delta$ 两点评估，用两点之差构造梯度估计

$$\hat{\mathbf{g}}_k = \frac{\hat{J}(\mathbf{u}_k + c_k \Delta_k) - \hat{J}(\mathbf{u}_k - c_k \Delta_k)}{2c_k} \Delta_k^{-1}, \quad (8)$$

其中 Δ_k^{-1} 表示逐元素取倒数。参数按 $\mathbf{u}_{k+1} = \mathbf{u}_k - a_k \hat{\mathbf{g}}_k$ 更新，步长与扰动幅度按 $a_k = a/(k+1+A)^\alpha$ 与 $c_k = c/(k+1)^\gamma$ 递减 [7, 8]。每步消耗两个评估单元。

4.3. 协方差矩阵自适应进化策略

CMA-ES 每代采样 λ 个候选，记第 t 代的搜索分布为 $\mathcal{N}(\mathbf{m}_t, \sigma_t^2 \mathbf{C}_t)$ 。按目标值排序后取前 μ 个候选，用其加权均值更新分布的均值，并用成功步方向更新累积路径 $\mathbf{p}_c$ 与 $\mathbf{p}_\sigma$ ，随后以秩一与秩 μ 更新协方差矩阵 $\mathbf{C}_t$ ，同

时按路径长度比自适应步长 σ_t [9, 10]。候选在评估前被裁剪到单位立方体内。种群规模取 $\lambda = 4 + \lfloor 3 \ln n \rfloor$ ，在 $n = 6$ 时 $\lambda = 9$ ，初始步长取 0.25。每代消耗 λ 个评估单元。

4.4. 高斯过程贝叶斯优化

贝叶斯优化先用拉丁超立方采样选择 12 个初始点，随后每一步用高斯过程拟合已有评估点，协方差函数取各向同性平方指数核，长度尺度取 0.25，并叠加方差为 10^{-6} 的观测噪声项 [15]。目标值在拟合前做标准化。在 2000 个随机候选点上计算期望改进并选取最大值点作为下一个评估点 [12, 13, 14]。每个新评估点消耗一个评估单元。

4.5. 逐轮淘汰

逐轮淘汰把评估预算分配到一批候选中，逐轮加大重采样次数并淘汰排名靠后的候选 [16]。每一轮取 32 个候选，按当前累计均值排序后保留前 8 个并进入下一轮，保留者的重采样次数翻倍；三轮之后用存活候选的累计均值更新全局最优。该算法在一次评估单元上返回候选的累计均值，因此预算记账与其它算法一致。算法 1 给出了其流程。

Algorithm 1 逐轮淘汰

Require: 评估预算 B ，批大小 $m = 32$ ，晋级数 $s = 8$ ，轮数 $R = 3$

Ensure: 已用预算内的最优候选

```

1: while 剩余预算不少于  $m$  do
2:   在单位立方体内均匀采样  $m$  个候选，重采样次数均置为 1
3:   for  $r = 1$  to  $R$  do
4:     对存活候选按当前重采样次数评估并累加估计值
5:     按累计均值排序，保留前  $\lceil m/(m/s)^r \rceil$  个
6:     将存活候选的重采样次数翻倍
7:   end for
8:   用存活候选的累计均值更新全局最优
9: end while
10:
11: return 全局最优

```

五、实验设置

实验考察三个因子：优化算法、评估单元的重复场次 N 与随机数使用方式。算法取上节介绍的五种。重复场次取 $N \in \{4, 16, 64\}$ 三档，对应每次评估 16、64 与 256 场对局仿真。随机数使用方式取独立抽取与整轮共用两档。每个组合运行 30 个随机种子，共 $5 \times 3 \times 2 \times 30 = 900$ 次优化运行。

所有算法在每个组合下获得相同的预算，即 120 个评估单元，等价于 $120 \times 4N$ 场对局仿真。为了在相同口径下评价最终解，每次运行结束后用 16384 场对局的独立大样本重新估计其真实目标值，四个熟练度档位各仿真 16384 场。为了分离“共用随机数”与“随机种子”的作用，共用随机数在每次运行中使用不同的随机数实现，而不是让全部运行共享同一批随机数。

作为参照，本文用大预算的 CMA-ES（2000 个评估单元，重复场次 64，六次重启）在大样本下搜索到一个参考最优解，其真实目标值约为 8×10^{-4} 。该数值可以视为本文问题在给定参数范围内的可达水平，目标函数值低于该量级的差异不再具有实际意义。

六、结果与分析

6.1. 五种算法的比较

表 2 给出五种算法在三档重复场次下的平均真实目标值，数值单位为 10^{-3} ，括号内为 30 个种子上的标准误，两档随机数设定合并统计。图 1 以对数坐标给出同样的结果。

SPSA 在三档重复场次下都取得最低的平均真实目标值，在 $N = 4$ 时比随机搜索低约 43%，在 $N = 64$ 时低约 33%。这一结果与 SPSA 的设计目标一致：它在含噪目标上通过两点差分抑制噪声对梯度方向的影响，且在六个维度上的每步成本固定为两次评估。

表 2: 平均真实目标值 (10^{-3}), 两档随机数设定合并, 括号内为标准误

算法	$N = 4$	$N = 16$	$N = 64$
随机搜索	17.18 ± 3.34	5.95 ± 0.92	2.21 ± 0.23
SPSA	9.87 ± 1.66	4.70 ± 0.94	1.47 ± 0.15
CMA-ES	20.95 ± 3.25	4.98 ± 0.68	2.25 ± 0.18
贝叶斯优化	14.57 ± 2.24	5.19 ± 0.94	2.28 ± 0.22
逐轮淘汰	15.64 ± 2.83	5.14 ± 0.94	2.38 ± 0.22

其余四种算法的排序随重复场次变化。在 $N = 4$ 时, CMA-ES 的平均真实目标值最高, 接近参考最优值的 26 倍; 在 $N = 16$ 与 $N = 64$ 时, 四种算法的差别缩小到一倍以内, 且都接近参考最优值。随机搜索的相对表现提升最为明显, 从 $N = 4$ 时最差的一档变为 $N = 64$ 时与 CMA-ES、贝叶斯优化、逐轮淘汰处于同一水平。其原因在于当重复场次充足时目标估计已经足够准确, 基于历史信息的搜索策略所能带来的额外收益有限, 而随机搜索的每个评估单元都用一个新候选, 单位预算下的探索范围最大。这一现象与随机搜索在超参数优化中被反复观察到的表现相符 [6]。




图 1: 不同重复场次下五种算法的平均真实目标值, 误差线为标准误

图 2 给出真实目标值随评估单元的下降过程, 两条曲线分别对应 $N = 4$ 与 $N = 16$ 且不使用共用随机数。曲线取各检查点上历史最优解的真实目标值, 因此单调不增。在 $N = 4$ 时, SPSA 与逐轮淘汰下降最快, 贝叶斯优化与 CMA-ES 在预算后期仍高于前两者; 在 $N = 16$ 时各算法的差距明显缩小, SPSA 与随机搜索在预算结束时处于最低位置。

按“真实目标值不高于 5×10^{-3} ”作为达标口径, 各算法的达标率随重复场次上升。 $N = 4$ 时, 随机搜索、SPSA、CMA-ES、贝叶斯优化与逐轮淘汰的达标率分别为 0.35、0.50、0.27、0.32 与 0.38; $N = 64$ 时分别上升到 0.95、0.97、0.95、0.93 与 0.95。也就是说, 当重复场次过少时, 即使使用较为精细的搜索策略, 也仍有近一半的运行无法得到可用解; 把重复场次提高到 64 之后, 五种算法在达标率上的差别已不明显。

6.2. 共用随机数的效果

表 3 给出引入共用随机数后平均真实目标值的相对变化, 以及乐观偏差的均值, 数值单位为 10^{-3} 。图 3 给出对应的图示。

在本文的设定下, 共用随机数在十五个算法与重复场次的组合中有十二个使真实目标值变大, 合并后的恶化幅度为 10% 至 36%。全部五个算法在 $N = 16$ 档都出现恶化, 幅度为 6% 至 78%。这一结果与 CRN 的经典预期方向相反, 需要结合乐观偏差一起理解。

表 3 的下半部分显示, 不使用共用随机数时乐观偏差为负, 且随重复场次增加由 -6.94×10^{-3} 缩小到 -1.31×10^{-3} ; 使用共用随机数后乐观偏差接近零甚至变正。也就是说, 独立评估下优化器报告的估计值系统性偏低, 而共用随机数下报告的估计值更接近真实值。这一现象的直接解释是, 独立评估时最优估计来自大量带独立误差的估计值中的极小值, 极小值统计量天然偏低; 共用随机数把误差固定, 被选中的估计值不再享受这种选择效




图 2: 真实目标值随评估单元的下降过程, 左为 $N = 4$, 右为 $N = 16$ (不使用共用随机数)

表 3: 共用随机数引起的相对变化 (%) 与乐观偏差 (10^{-3})

	$N = 4$	$N = 16$	$N = 64$
随机搜索	+47.6	+27.5	+15.8
SPSA	+80.1	+50.9	+17.7
CMA-ES	-13.5	+6.4	-8.3
贝叶斯优化	+6.0	+77.9	+5.0
逐轮淘汰	+134.6	+30.4	+25.7
五算法合并	+33.9	+36.0	+10.1
乐观偏差 (独立)	-6.94	-2.87	-1.31
乐观偏差 (共用)	+2.60	+0.57	-0.32

应，报告值因此更诚实。

报告值更诚实并不等于解更好。共用随机数把所有候选放在同一批随机数上比较，优化器实际优化的对象是这个固定随机实现所定义的目标函数，其最优点与真实目标函数的最优点之间存在系统性偏离。独立评估时，优化器每步面对不同的随机扰动，选中的点需要在一个不断变化的噪声环境中反复胜出，最终落点往往位于真实目标函数较优的平坦区域；共用随机数时，优化器可以沿着固定的偏差场精确下降，从而把这个偏差场的极小值完全兑现。这一机制意味着共用随机数在搜索场景中把抽样误差转换成了系统性偏差，而偏差不会随评估次数增加而消失。恶化幅度随重复场次增加而减小，在 $N = 64$ 时降到 10.1%，这与“重复场次越多、固定偏差场越接近真实目标函数”的预期一致。




图 3: 左: 两档随机数设定下的平均真实目标值; 右: 对应的乐观偏差

6.3. 刷新闻隔的消融

为了检验上述解释，本文把共用随机数从整轮固定逐步放松到每次重抽。记刷新闻隔为 R ，表示每隔 R 个评估单元重新抽取一次随机数， $R = 1$ 等价于独立评估， $R = \infty$ 等价于整轮固定。实验取 $R \in \{1, 4, 16, \infty\}$ ，算法取 SPSSA 与 CMA-ES，重复场次取 4 与 16。结果见表 4 与图 4。

表 4: 刷新闻隔对平均真实目标值的影响 (10^{-3})

算法	重复场次	$R = 1$	$R = 4$	$R = 16$	$R = \infty$
SPSSA	4	8.25	8.29	12.09	12.70
SPSSA	16	3.55	4.31	4.07	5.66
CMA-ES	4	14.23	15.20	19.72	19.44
CMA-ES	16	5.75	4.58	6.14	5.13

在 $N = 4$ 的两行上，平均真实目标值随刷新闻隔增大而单调上升：SPSSA 由 8.25×10^{-3} 升到 12.70×10^{-3} ，CMA-ES 由 14.23×10^{-3} 升到 19.44×10^{-3} ，整轮固定相对每次重抽分别恶化约 54% 与 37%。与此同时，乐观偏差从明显负值抬升到接近零。在 $N = 16$ 的两行上，刷新闻隔的影响明显减弱，四条曲线之间的差别大多落在一个标准误以内，其中 CMA-ES 在 $N = 16$ 时不呈现单调趋势。这一档次的弱化与重复场次增多时固定偏差场本身更接近真实目标函数的判断一致。

消融实验支持了固定偏差场被过度利用的解释：缩短刷新闻隔相当于周期性地更换随机数，优化器无法再沿着同一个偏差场持续下降，损失随之减小。在工程上，这一结论给出了一个实用的折中：若希望保留共用随机数在比较上的方差优势，可以每隔若干次评估重新抽取随机数，而不必整轮固定。

6.4. 达标解的胜率曲线

图 5 给出一个收敛较好的解与一个中等质量的解所对应的实测胜率曲线，参考曲线为设计目标。收敛较好的解在四个档位上的胜率与目标值的偏差都在 0.035 以内，中等质量的解在低熟练度档位上明显偏低，说明预算不足时失败主要发生在低熟练度一端，也就是玩家战力最弱、对参数最敏感的那一端。




图 4: 刷新间隔对真实目标值 (左) 与乐观偏差 (右) 的影响




图 5: 设计目标曲线与两个代表性解的实测胜率曲线

七、讨论

本文的结果对游戏平衡调参有几条直接含义。当可用对局预算很低、每次评估只能仿真少量对局时，算法之间的差别很大，此时使用SPSA这类专门为含噪目标设计的算法收益最明显，而把评估精度放在次要位置、追求更大探索范围的随机搜索会明显落后。当每次评估可以承担较多对局仿真时，算法之间的差别迅速缩小，选择实现最简单的随机搜索也不会带来实质损失，把同样的预算用于提高每次评估的重复场次往往比更换算法更有效。这一结论与随机搜索在超参数优化领域得到的经验一致[6]。

关于共用随机数，本文的结果提示在搜索场景下需要谨慎。共用随机数确实让报告的估计值更可信，但它同时把偏差固定下来，使优化器更容易收敛到偏差场的极小值而不是真实目标函数的最优点。当优化器需要反复搜索而不是比较少量固定方案时，可以考虑周期性更换随机数，以保留比较方差上的收益并避免把偏差当成信号。已有研究对CRN的适用条件给出了理论边界[18]，本文的结果可以看作该结论在搜索场景中的一个具体体现。

本文的实验存在若干局限。实验只使用一个仿真模型与一个六维问题，目标函数光滑且约束为简单箱式约束，结论是否推广到更高维度、强约束或者多峰问题需要进一步验证，轨迹平滑性、可行域处理以及代理模型的质量都会影响算法排序。实验只使用120个评估单元的预算，预算进一步增大或者进一步缩小可能改变排序。共用随机数的实现方式只有一种，即让所有候选共享同一批随机数，其它实现方式，例如只对相邻候选共享，可能表现出不同的性质。本文也不涉及并行评估，在可以并行仿真的场景下，每步评估次数固定的算法与每次只评估一个候选的算法之间的相对成本会发生变化。最后，本文使用解析定义的对局模型而不是真实游戏的日志数据，模型中的简化会影响结论的适用范围。

八、结论

本文以一个波次防守对局的随机仿真模型为平台，把游戏平衡调参写成六维设计参数到目标胜率曲线的黑箱优化问题，并在相同评估预算下比较随机搜索、SPSA、CMA-ES、高斯过程贝叶斯优化与逐轮淘汰五类算法，同时考察重复场次与随机数共用两个因子。实验包含九百次优化运行，全部最终解用大样本复核真实目标值。结果表明，SPSA在三档重复场次下都取得最低的真实目标值，随机搜索在重复场次较多时与之接近，而重复场次过少时近一半的运行无法得到合格解。共用随机数让优化器报告的估计值更接近真实值，却使最终解的真实质量平均恶化约10%至36%，恶化幅度随重复场次增加而减小；把共用随机数的刷新间隔由整轮固定缩短为每次重抽，可以恢复其中大部分损失。这些结果为在仿真预算与噪声约束下进行游戏平衡调参提供了算法选择与随机数使用方面的定量参考。

参考文献

- [1] Satyajith Amaran et al. "Simulation optimization: a review of algorithms and applications". In: *Annals of Operations Research* 240.1 (2016), pp. 351–380.
- [2] Michael C. Fu. "Optimization for simulation: Theory vs. practice". In: *INFORMS Journal on Computing* 14.3 (2002), pp. 192–215.
- [3] Sigrún Andradóttir. "Simulation optimization". In: *Handbook of Simulation*. Ed. by Jerry Banks. John Wiley and Sons, 1998, pp. 307–333.
- [4] Averill M. Law and W. David Kelton. *Simulation Modeling and Analysis*. 3rd ed. New York: McGraw-Hill, 2000.
- [5] Jack P. C. Kleijnen. *Design and Analysis of Simulation Experiments*. 2nd ed. Cham: Springer, 2015.
- [6] James Bergstra and Yoshua Bengio. "Random search for hyper-parameter optimization". In: *Journal of Machine Learning Research* 13 (2012), pp. 281–305.
- [7] James C. Spall. "Multivariate stochastic approximation using a simultaneous perturbation gradient approximation". In: *IEEE Transactions on Automatic Control* 37.3 (1992), pp. 332–341.
- [8] James C. Spall. "An overview of the simultaneous perturbation method for efficient optimization". In: *Johns Hopkins APL Technical Digest* 19.4 (1998), pp. 482–492.
- [9] Nikolaus Hansen and Andreas Ostermeier. "Completely derandomized self-adaptation in evolution strategies". In: *Evolutionary Computation* 9.2 (2001), pp. 159–195.
- [10] Nikolaus Hansen. *The CMA evolution strategy: A tutorial*. arXiv:1604.00772. 2016.

- [11] Hans-Georg Beyer and Hans-Paul Schwefel. “Evolution strategies – A comprehensive introduction”. In: *Natural Computing* 1.1 (2002), pp. 3–52.
- [12] Donald R. Jones, Matthias Schonlau, and William J. Welch. “Efficient global optimization of expensive black-box functions”. In: *Journal of Global Optimization* 13.4 (1998), pp. 455–492.
- [13] Eric Brochu, Vlad M. Cora, and Nando de Freitas. *A tutorial on Bayesian optimization of expensive cost functions*. arXiv:1012.2599. 2010.
- [14] Bobak Shahriari et al. “Taking the human out of the loop: A review of Bayesian optimization”. In: *Proceedings of the IEEE* 104.1 (2016), pp. 148–175.
- [15] Carl Edward Rasmussen and Christopher K. I. Williams. *Gaussian Processes for Machine Learning*. Cambridge, MA: MIT Press, 2006.
- [16] Oded Maron and Andrew W. Moore. “Hoeffding races: Accelerating model selection search for classification and function approximation”. In: *Advances in Neural Information Processing Systems* 6. 1994, pp. 59–66.
- [17] Chun-Hung Chen and Loo Hay Lee. *Stochastic Simulation Optimization: An Optimal Computing Budget Allocation*. Singapore: World Scientific, 2011.
- [18] Paul Glasserman and David D. Yao. “Some guidelines and guarantees for common random numbers”. In: *Management Science* 38.6 (1992), pp. 884–908.
- [19] Georgios N. Yannakakis and Julian Togelius. *Artificial Intelligence and Games*. Cham: Springer, 2018.
- [20] Mohammad Zohaib. “Dynamic difficulty adjustment (DDA) in computer games: A review”. In: *Advances in Human-Computer Interaction* 2018 (2018), p. 5681652.
- [21] Robin Hunicke. “The case for dynamic difficulty adjustment in games”. In: *Proceedings of the 2005 ACM SIGCHI International Conference on Advances in Computer Entertainment Technology*. 2005, pp. 429–433.
- [22] Olana Missura and Thomas Gärtner. “Player modeling for intelligent difficulty adjustment”. In: *Discovery Science (DS 2009)*. 2009, pp. 197–211.
- [23] Julian Togelius et al. “Search-based procedural content generation”. In: *Applications of Evolutionary Computation (EvoApplications 2010)*. 2010, pp. 141–150.
- [24] Christoffer Holmgård et al. “Evolving personas for player decision modeling”. In: *2014 IEEE Conference on Computational Intelligence and Games (CIG)*. 2014, pp. 1–8.
- [25] Jerry Banks et al. *Discrete-Event System Simulation*. 4th ed. Upper Saddle River, NJ: Prentice Hall, 2005.